


AX & Agent Infrastructure

Практическое руководство по архитектуре
и эксплуатации AI-агентов



LLM • Agent Harness • MCP • Agent Substrate • Google AX
Local Inference • Security • Observability

INDEPENDENT TECHNICAL GUIDE

Содержание

Книга построена от фундаментальных mental models к AX/Substrate и затем к эксплуатации. Ссылки кликабельны в PDF.

0. Как читать эту книгу и что именно зафиксировано

1. Карта современной агентной системы: от модели до кластера

2. LLM как вычислительный компонент агентной системы

3. Что такое агент: цикл, границы и критерии остановки

4. Agent harness: система вокруг LLM

5. Context, state, memory и snapshot: не смешивать

6. Tools, MCP и Skills

7. Multi-agent архитектуры без лишней магии

8. От Linux process к gVisor и microVM

9. Kubernetes: необходимый минимум для понимания AX/Substrate

10. Control plane и distributed systems: база без академической перегрузки

11. Actor model применительно к агентным workload

12. Agent Substrate: назначение и operational architecture

13. Substrate resources: Atespace, WorkerPool, ActorTemplate, Actor, Tag

14. Suspend, snapshot, resume и golden snapshot

15. Substrate networking: routing, wake-up и egress

16. AX: архитектура control plane и реальная граница с Substrate

17. AX primitives: Task, Workspace, Gateway и Model

18. Runner: PID 1 как платформенный контракт

19. Полный lifecycle Task: от YAML до suspend/resume

20. Local inference: CPU, GPU, vLLM и llama.cpp

21. Производительность inference: что измерять для 10-15+ агентов

22. Multi-agent на AX: как делегировать без task explosion

23. Security architecture: threat model agent platform

24. Identity, authorization и Human-in-the-loop

25. Observability: четыре слоя и единая correlation identity

26. Лабораторный стенд на Proxmox/KVM: Kind, k3s или kubeadm

27. Production engineering: HA, persistence, upgrades и DR

28. Performance и scaling: что реально ограничивает систему

29. Failure modes и troubleshooting handbook

30. Когда AX нужен, а когда проще другой инструмент

31. Антипаттерны

32. Практикум: 14 последовательных лабораторных работ

33. Две референсные multi-agent архитектуры

34. Mental models, glossary и cheatsheets

35. Context engineering: управление контекстом и durable state

36. MCP 2026: протокол, discovery, transport и trust boundaries

37. Безопасное выполнение tools: idempotency, approvals и attenuation полномочий

38. AX control plane: state, event flow и operational truth

39. Substrate snapshots: ownership, storage и совместимость

40. Gateway и egress: DNS, TLS и проверка реальной доступности

41. Local inference sizing: память GPU, parallelism и эксплуатационные SLO

42. Production security, secrets и disaster recovery

43. Operations runbook: диагностика по слоям и release acceptance

Приложения: аудит, checklist, источники

Как читать эту книгу и что именно зафиксировано

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

Эта книга построена не как пересказ README, а как инженерный учебник: сначала даётся mental model, затем ровно та фундаментальная база, без которой конкретный механизм AX или Agent Substrate превращается в «магический чёрный ящик», после чего идут эксплуатационные выводы и практика. Целевая аудитория - системные и сетевые инженеры, архитекторы инфраструктуры и разработчики платформ, которым важнее **развернуть, наблюдать, ограничивать и диагностировать агентные workload'ы**, чем изменять внутренний Go-код проекта.

Версионная база

Для воспроизводимости основной слой книги фиксируется на релизах:

Компонент	Базовая версия	Зафиксированный commit	Дата релиза	Как используем
Google AX	v0.3.1	e70162a	25.09.2026	основной release baseline
Agent Substrate	v0.3.0	csecc78	30.09.2026	основной release baseline
MCP	2026-07-28	версия спецификации	28.07.2026	протокольная база
vLLM	v0.30.0	release	22.09.2026	пример GPU inference
llama.cpp	v0.4.1 + rolling builds	release	14.09.2026	CPU/hybrid fallback

При этом `main` AX/Substrate исследован отдельно. Это необходимо, потому что оба проекта меняются быстрее обычной инфраструктурной документации. Например, current AX README уже описывает Gateway и отдельный ax-controller, в то время как часть DESIGN.md всё ещё показывает reconciliation внутри ax-server. Такие расхождения не надо «усреднять»: их надо отмечать.

В книге используются четыре метки:

- **IMPLEMENTED** - подтверждено базовой или текущей реализацией и официальной документацией.
- **MAIN DELTA** - уже есть в `main`, но могло появиться после выбранного релиза.
- **ROADMAP** - объявлено разработчиками как направление, но не должно приниматься за доступную production-функцию.

- **BACKGROUND** - общая инженерная база или рекомендуемый pattern, а не обещание AX.

Главная оговорка

AX и Substrate - pre-stable системы. AX использует `ax.io/v1alpha1`, а Substrate прямо предупреждает о быстрых breaking changes. Поэтому любые production-планы должны начинаться с pinning версий, проверки совместимости и отдельного test environment. В этой книге команды лабораторных работ являются **шаблонами воспроизводимого стенда**, но перед применением в реальной инфраструктуре необходимо сверять release notes выбранных версий.

Что книга намеренно не делает


Она не заменяет полноценный курс Kubernetes, не погружается в математику Transformer'ов и не проводит строчный аудит Go-кода. Если механизм можно понять и эксплуатировать, не разбирая конкретную реализацию до функции и struct, мы остаёмся на архитектурном уровне. И наоборот: runner, lifecycle, snapshots, Gateway и trust boundaries разбираются глубоко, потому что ошибки именно здесь дают эксплуатационные и security-инциденты.

Источники и дальнейшее чтение

- [AX repository](#)
- [AX README](#)
- [AX roadmap](#)
- [Substrate repository](#)
- [Substrate architecture](#)

Карта современной агентной системы: от модели до кластера

Карта стека: где заканчивается LLM и начинается инфраструктура



Самая полезная отправная точка - перестать использовать слово «агент» для всего стека сразу. LLM генерирует продолжение последовательности токенов и может структурированно предложить вызов инструмента. Агент появляется тогда, когда вокруг модели есть цикл исполнения: получить состояние, сформировать контекст, запросить модель, разобрать действие, выполнить его, вернуть observation, решить, продолжать ли работу. Но даже это ещё не платформенная система.

Надёжный agent workload требует как минимум: lifecycle, изоляции, долговременного состояния, секретов, сетевой политики, бюджетов, наблюдаемости и механизма восстановления. Multi-agent система добавляет делегирование, координацию, ограничения дерева задач и агрегацию результатов. Поэтому удобнее мыслить слоями.

LLM отвечает за вероятностное решение внутри шага. **Harness** превращает модель в выполняющий цикл. **Agent framework** может задавать граф состояний, supervisor/worker или другой pattern. **AX** предоставляет декларативные ресурсы и lifecycle для agent workloads. **Agent Substrate** даёт logical Actor, физические WorkerPool, sandbox, suspend/resume и routing. **Kubernetes/Linux** управляют узлами, контейнерными workload'ами и базовыми ресурсами. Inference при этом вообще может жить как рядом с AX, так и снаружи кластера.

Ключевой практический вывод: проблемы разных слоёв выглядят одинаково на поверхности. «Агент завис» может означать GPU saturation, таймаут MCP, запрет egress, остановившийся child process при живом runner, застрявший Actor resume или логическую петлю planner'a. Диагностика начинается не с prompt'a, а с определения слоя отказа.

Что AX добавляет поверх обычного Kubernetes

Kubernetes превосходно управляет Pods, Services и декларативными объектами инфраструктуры. Но population agent workloads может быть намного больше числа реально активных процессов. Агент способен простаивать минуты и часы, а затем быстро просыпаться с сохранённым состоянием. Хранить миллионы короткоживущих объектов в Kubernetes API также не всегда разумно. AX потому отделяет своё control-plane состояние и использует Substrate как специализированный runtime.


Это не означает, что AX «лучше Kubernetes». Он занимает другой уровень. Аналогично LangGraph или собственный Python harness не конкурирует с Kubernetes: один описывает логику агента, другой - физическое выполнение и изоляцию.

Источники и дальнейшее чтение

- [AX design](#)
- [Substrate README](#)
- [Kubernetes concepts](#)

LLM как вычислительный компонент агентной системы

Local inference: путь запроса через batching, prefill, KV cache и decode



Для эксплуатации agent infrastructure не требуется выводить формулы attention, но нужно понимать, какие свойства модели определяют latency, стоимость и надёжность системы.

Tokens, context и generation

Текст перед запросом разбивается tokenizer'ом на токены. Модель получает последовательность токенов контекста и предсказывает следующие. **Context window** - ограниченный бюджет для system instructions, пользовательской цели, истории, результатов tools, retrieved documents и промежуточного состояния. Когда агент «забывает», проблема часто не в memory module, а в том, что нужная информация не попала в текущий context или была выдвлена/сжата.

Generation условно состоит из двух существенно разных стадий. **Prefill** обрабатывает входной контекст и строит KV-cache. **Decode** последовательно генерирует новые токены, многократно обращаясь к KV-cache. Большой context сильнее нагружает prefill и память, а большой объём output - decode. Это важно для планирования concurrency локального inference.

Tool calling и structured output

Современные API позволяют модели не только вернуть текст, но и выбрать tool и сформировать аргументы по схеме. Это не означает, что tool был выполнен. Ответ модели - лишь **proposal**. Harness должен валидировать имя инструмента, аргументы, полномочия, бюджеты и только затем вызвать внешнюю систему. Поэтому нельзя строить security boundary на фразе «модель обещала вызвать только read-only tool».

Structured output уменьшает синтаксическую неопределённость, но не гарантирует семантическую корректность. Значение `router_id=17` может пройти JSON Schema и всё равно

оказаться неправильной целью. Для destructive action нужна проверка объекта, scope и preconditions вне LLM.

Sampling и детерминизм

Температура и другие sampling parameters влияют на разнообразие генерации, но «temperature=0» не превращает сложную LLM систему в детерминированный автомат: остаются различия серверных реализаций, batching, model revisions, floating-point effects и неоднозначность самого запроса. Поэтому production pipeline должен быть устойчив к тому, что один и тот же logical step иногда даёт разные решения.

Stateless request против stateful agent

LLM endpoint обычно не является долговременной памятью приложения. Даже если API предлагает conversation/thread abstraction, архитектурно разумно считать модель заменяемым вычислительным сервисом, а authoritative state хранить в собственной системе. Это особенно важно при suspend/resume, смене модели или переходе между cloud и local inference.

Практическая формула


При проектировании каждого шага разделяйте четыре вещи: **входные данные, контекст для модели, authoritative state, side effect**. Модель может помочь решить, что делать; authoritative state и подтверждение результата должны жить вне неё.

Источники и дальнейшее чтение

- [vLLM docs](#)
- [llama.cpp](#)

Что такое агент: цикл, границы и критерии остановки

Agent harness: минимальная операционная анатомия



Агент полезно определять как процесс, который многократно выбирает следующий шаг на основе цели и наблюдаемого состояния среды. Минимальный цикл выглядит так: `observe` → `assemble context` → `decide` → `act` → `observe`. Если действие само создаёт новую задачу, цикл превращается в дерево или граф.

Agent loop

1. Получить входное событие/goal.
2. Загрузить релевантное состояние и policy.
3. Сформировать context.
4. Запросить LLM или deterministic router.
5. Разобрать результат.
6. Проверить budget/policy/approval.
7. Выполнить tool/action.
8. Зафиксировать observation и side effects.
9. Проверить stop condition.
10. Повторить или завершить.

Ошибки чаще всего возникают в пунктах 6-9. Без жёстких stop conditions агент может бесконечно повторять ошибочную операцию. Без idempotency повторный tool call после network timeout способен выполнить действие дважды. Без budget controller безобидная логическая петля превращается в расход GPU/API quota.

Паттерны

ReAct чередует reasoning и действия и хорош там, где следующий шаг зависит от результата предыдущего. **Planner/executor** отделяет построение плана от выполнения, что удобно для контроля и перепланирования. **Router** выбирает специализированный путь. **Supervisor/worker** позволяет одному компоненту держать общую цель, а отдельным агентам - ограниченный контекст и полномочия. **Fan-out/fan-in** эффективен для независимых параллельных проверок. **Evaluator/critic** полезен, когда результат можно формально или полуформально оценить; бесконечная «самокритика» без критерия сходимости - анти-паттерн.


State machine + LLM обычно надёжнее «полностью автономного» агента в production: deterministic state machine определяет разрешённые переходы, а LLM помогает внутри ограниченного состояния. Это особенно подходит инфраструктурным операциям, где последовательность `collect → diagnose → propose → approve → execute → verify` важнее свободы агента.

Делегирование не равно масштабирование

Разделять задачу на множество agents стоит только при реальной независимости контекста, tools или ответственности. Если пять агентов вынуждены постоянно обмениваться всей историей, вы получили более дорогую и менее наблюдаемую версию одного агента. АХ делает Task дешёвой единицей изоляции, но не отменяет необходимость разумной декомпозиции.

Agent harness: система вокруг LLM

Agent harness: минимальная операционная анатомия



Harness - удобный термин для слоя, который превращает модель в управляемый исполняемый процесс. В разных frameworks границы отличаются, но эксплуатационно полезно выделять одинаковые обязанности.

Обязательные функции harness

Context assembly выбирает инструкции, goal, историю, memory и результаты tools. **Model adapter** нормализует различия OpenAI/Anthropic/Gemini/local endpoints. **Tool executor** преобразует tool proposal в настоящий вызов. **State manager** хранит progression. **Policy layer** решает, допустима ли операция. **Budget controller** ограничивает число шагов, tokens, wall time и деньги. **Retry policy** различает временный сбой и логическую ошибку. **Tracing** связывает LLM request, tool call и task/actor identity.

Хороший harness не должен полагаться на prompt как на единственную защиту. Правило «никогда не выполняй shutdown» внутри system prompt слабее технического deny policy, потому что prompt injection воздействует на тот же канал принятия решения. Правильный подход: model proposes, policy decides, tool enforces.

Harness и orchestrator - разные роли

Harness управляет шагами **внутри** agent execution. Orchestrator управляет множеством executions: создать Task, выбрать Workspace, приостановить idle workload, выделить ресурсы, повторить при инфраструктурном сбое, уничтожить sandbox. Если смешать уровни, возникает путаница: retry HTTP 503 модели должен быть обязанностью harness/model gateway, а восстановление Actor после падения Worker - обязанностью runtime/control plane.


Minimal production contract

Для каждого агента стоит явно определить: входной schema, maximum wall time, maximum steps, token budget, разрешённые tools, outbound destinations, persistent state location, checkpoint strategy, termination semantics и expected artifacts. Это превращает «автономного агента» в управляемую workload единицу.

АХ не навязывает конкретный harness. Это важная архитектурная граница: можно запускать собственный Python/Go/Node agent, framework или CLI-agent, если container/runner contract соблюлён.

Context, state, memory и snapshot: не смешивать

Состояние агента: шесть разных сущностей, которые часто ошибочно называют «памятью»



В agent systems слово «memory» часто скрывает несколько совершенно разных механизмов. Для правильной эксплуатации их нужно разделять.

LLM context существует только в рамках конкретного inference request и ограничен context window. **Working state** - текущий plan, cursor, промежуточные результаты и state machine. **Persistent memory** - записи, которые переживают перезапуск и могут быть retrieved. **Workspace** - файлы проекта, artifacts и tool configuration. **Process RAM** - heap/stack конкретного процесса. **Snapshot** - технический checkpoint части runtime state. **External system state** - Git, ticket, router config, DB - authoritative data, которые нельзя «откатить» восстановлением локального snapshot.

Почему это важно при resume

Если runtime восстанавливает RAM image, TCP connection к внешнему API всё равно может оказаться недействительным: peer закрыл сессию, DNS/IP изменились, token протух. Если AX восстанавливает только durable /workspace и запускает новое process tree, агент должен самостоятельно восстановить in-memory progression из файлов/DB. Оба поведения могут называться «resume», но требования к приложению принципиально различаются.

Рекомендуемая модель состояния


- Authoritative business state - во внешнем durable store или системе назначения.
- Agent progression - в journal/event log или компактном state object.

- Workspace/artifacts - в durable filesystem/object store.
- Prompt/context - производное представление, которое можно пересобрать.
- Snapshot - optimisation для быстрого продолжения, но не единственная копия критического state.

Для инфраструктурного агента особенно опасно считать snapshot транзакцией: после `configure terminal` на роутере и до локального checkpoint внешнее устройство уже изменено. Resume не отменит изменение. Поэтому write actions должны быть журналированы и верифицированы независимо.

Tools, MCP и Skills

MCP trust boundary: протокол не заменяет авторизацию



Tool - это формализованная операция, доступная agent loop. Он может быть локальной функцией, HTTP API, shell command или MCP tool. Главное свойство production tool - не «модель умеет его вызвать», а наличие чёткой схемы, проверяемых полномочий, predictable side effects и наблюдаемого результата.

MCP в версии 2026-07-28

Текущая спецификация MCP существенно отличается от ранних туториалов. Ядро стало stateless: убраны protocol-level sessions и старый `initialize/initialized` handshake. Каждый запрос несёт protocol version и client capabilities в `_meta`. Сервер должен поддерживать `server/discover`, позволяющий узнать версии, capabilities и identity. Для совместимости со старыми STUDIO servers discovery может использоваться как probe.

Практически это улучшает работу через gateways, WAF и rate limiters: routing и metering меньше зависят от долгоживущей сессии. Но security всё равно остаётся задачей deployment'a. Self-reported `serverInfo` нельзя использовать как security proof.

В MCP полезно помнить ownership semantics: **Prompts** обычно user-controlled, **Resources** application-controlled, **Tools** model-controlled с точки зрения выбора вызова. «Model-controlled» не означает «безусловно разрешённый»; policy enforcement находится снаружи.

Skills

Skill - не transport protocol. Это переиспользуемый пакет инструкций, процедур и вспомогательных материалов, который помогает agent harness выполнить класс задач. Tool даёт capability, Skill объясняет способ применения capability. MCP стандартизует взаимодействие между client/server; Skill может ссылаться на MCP tools, но не является их сетевым эквивалентом.

Что делает AX Workspace


Workspace может описывать Git repositories, files, MCP servers/registries и skill registries/path. Тем самым Workspace становится декларативным описанием рабочей среды, а не просто volume. Но security implication очевиден: MCP server или skill registry - часть supply chain. Подключение неизвестного registry должно проходить не менее строгий review, чем новый package repository.

Источники и дальнейшее чтение

- [MCP 2026-07-28 release](#)
- [MCP discovery](#)
- [AX Workspace concepts](#)

Multi-agent архитектуры без лишней магии

Практика: software-engineering multi-agent workflow



Multi-agent architecture оправдана, когда разделение даёт хотя бы одно из трёх: меньший context, разные полномочия/tools или параллельное выполнение. Если этих преимуществ нет, один хорошо ограниченный agent часто проще и дешевле.

Основные топологии

Supervisor/worker. Supervisor хранит high-level цель и делегирует ограниченные subtasks. Worker не должен получать больше authority, чем нужно его роли. **Hierarchical delegation** продолжает этот pattern на несколько уровней, но требует budget propagation и ограничения глубины. **Fan-out/fan-in** запускает несколько независимых проверок и агрегирует вывод. **Specialist routing** выбирает агента по типу инцидента или ресурса. **Evaluator gate** проверяет результат перед следующей стадией.

Coordination state

Не стоит передавать всё через естественный язык. Надёжнее иметь structured task state: ID, parent ID, input artifact refs, expected output schema, deadline, allowed tools, budget, status. Текстовая summary может быть частью context, но не должна заменять machine-readable contract.

Failure propagation

Если child Task упал, parent должен знать: retryable ли ошибка, был ли side effect, можно ли повторить с тем же idempotency key, стоит ли отменять siblings. В infrastructure workflow осо-


бенно важно отличать «не смог прочитать telemetry» от «изменил конфигурацию, но потерял ответ».

АХ и дерево задач

АХ концептуально допускает, что один Task создаёт другие и таким образом формирует большое дерево. При этом сама платформа не обязана моделировать бизнес-семантику дерева за вас. Это сознательное решение: Task остаётся дешёвой изолированной единицей, а relation/budget/authority должны проектироваться на уровне agentic application до тех пор, пока соответствующие primitives не появятся в стабильной спецификации.

От Linux process к gVisor и microVM

Лестница изоляции: усиление boundary обычно увеличивает стоимость и сложность



Изоляция agent workload важнее, чем у обычного внутреннего микросервиса: агент способен генерировать и запускать код, клонировать внешние repository, подключать инструменты и реагировать на потенциально hostile content. Поэтому «он же в контейнере» - недостаточный threat model.

Linux process и container

Namespaces разделяют представления PID, mount, network, user и других ресурсов. cgroups ограничивают/учитывают CPU, memory, I/O и число процессов. Linux capabilities дробят привилегии root на отдельные права. seccomp фильтрует системные вызовы. no_new_privileges запрещает процессу получать новые privileges через exec. Вместе эти механизмы значительно уменьшают blast radius, но обычный container всё ещё разделяет kernel host'a.

gVisor

gVisor вставляет userspace application kernel (Sentry) между приложением и host kernel. OCI runtime runsc позволяет использовать эту модель через Docker/Kubernetes. Большая часть Linux interface переимплементируется в userspace, поэтому hostile process имеет существенно меньшую прямую поверхность host syscalls. Цена - compatibility/performance overhead, который зависит от workload.

microVM

microVM использует аппаратную виртуализацию и отдельный guest kernel. Boundary обычно сильнее, но появляются VMM, guest image, virtual devices, boot/snapshot complexity и требования к KVM. На Proxmox/KVM lab nested virtualization должна быть доступна VM, иначе microVM backend не будет рабочим практическим вариантом.

Выбор


Для первого стенда разумнее gVisor: меньше движущихся частей. microVM стоит изучать как второй backend для более сильной изоляции. Выбор должен опираться на threat model и benchmark именно вашего workload, а не на абстрактную таблицу «безопаснее/быстрее».

Источники и дальнейшее чтение

- [gVisor architecture](#)
- [gVisor runsc](#)

Kubernetes: необходимый минимум для понимания AX/Substrate

Kubernetes reconciliation loop - mental model, который нужен для AX/Substrate



Kubernetes здесь нужен не как отдельный предмет, а как substrate инфраструктуры. Достаточно уверенно понимать несколько mental models.

Pod - минимальная deployable unit Kubernetes, а не VM. **Deployment** поддерживает desired number stateless Pods. **DaemonSet** гарантирует Pod на подходящих nodes и поэтому естественен для node-level supervisor. **Service** даёт стабильную сетевую точку над changing Pods. **Namespace** разделяет имена и policy scope. **Secret/ConfigMap** поставляют configuration, хотя Secret сам по себе не является HSM. **RBAC** определяет права на Kubernetes API. **NetworkPolicy** ограничивает сетевые потоки при поддержке CNI.

Control plane

kube-apiserver принимает API operations. etcd хранит cluster state. kube-scheduler назначает unscheduled Pods nodes. Controllers постоянно сравнивают desired и actual state. На node kubelet обеспечивает запуск Pod через container runtime.

Главный transferable concept - **reconciliation**. Пользователь не просит «создай контейнер прямо сейчас», а объявляет desired state. Controller снова и снова стремится привести actual state к desired. AX внешне использует похожую declarative модель, но сохраняет высокочастотное task state вне Kubernetes API.

Почему не хранить миллионы Tasks в CRD

Kubernetes официально рекомендует не использовать Custom Resources как обычное application/end-user/monitoring data store и предупреждает, что большое количество CRs нагружает API storage. AX design идёт в ту же сторону: небольшие декларативные control-plane объекты Kubernetes остаются там, а population короткоживущих agent tasks хранится в специализированном store.

Что изучать отдельно

Если после этой главы непонятны Pod lifecycle, Services/DNS, RBAC или CNI, стоит пройти официальные Kubernetes Concepts и отдельный lab до AX. Для AX не требуется становиться Kubernetes developer, но попытка диагностировать Substrate без понимания `kubect1 get/describe/logs`, readiness и scheduling почти гарантированно приводит к путанице.

Источники и дальнейшее чтение

- [Kubernetes components](#)
- [Kubernetes custom resources](#)

Control plane и distributed systems: база без академической перегрузки

AX/Substrate - распределённые control planes, поэтому несколько идей необходимо понимать практически.

Desired/actual state и eventual consistency

После `apply` результат не обязан появиться мгновенно. API может успешно принять объект, а reconciler ещё будет создавать Actor, ждать Worker и readiness. Поэтому корректный клиент читает status/conditions или watch stream, а не считает HTTP/gRPC success равным готовности workload.

Idempotency

Control plane операции будут повторяться: из-за retry, restart controller'a или потери ответа. Поэтому шаги reconciliation должны быть идемпотентными либо иметь уникальные operation IDs. Для внешних tools это особенно важно: «повторить API call» может быть безопасно для GET и опасно для `create payment / change route`.

Distributed lock

Когда несколько controller replicas могут reconcile один ресурс, нужен механизм не выполнять конфликтующие операции одновременно. Lock не заменяет идемпотентность: holder может умереть после side effect, но до записи status. Правильная система выдерживает повтор после lock expiry.

Redis, PostgreSQL, streams

AX использует Redis как высокоскоростной store/event mechanism для своего task control plane. Current `ax-controller` читает Redis stream consumer group и вызывает reconciler. Substrate current architecture использует PostgreSQL для высокочастотного dynamic Actor/Worker state. Это два разных слоя с разными failure domains; Redis backup не восстанавливает Substrate actors, а PostgreSQL backup не восстанавливает AX desired specs.

gRPC/protobuf


Protobuf задаёт typed message schema, gRPC - RPC contract и streaming. Операционно важны deadlines, retries, message-size limits, TLS/mTLS, authority/server-name, load balancing и backpressure. «RPC висит» без deadline способен привязать controller worker надолго.

Consistency versus recovery

Для orchestration важнее не абсолютная синхронность каждого поля, а возможность восстановить истинное состояние. Status должен быть наблюдаемым и переоцениваться. Если runtime сообщает Actor RUNNING, но Worker умер, reconciler обязан обнаружить расхождение и перевести ресурс в корректное состояние.

Actor model применительно к агентным workload

Actor $\neq$ Worker: logical population can be larger than active capacity



Actor в Substrate полезно понимать как **логически долгоживущую identity + state**, которая не обязана постоянно занимать физический process/Pod. Worker - физическая capacity, готовая выполнить Actor. Это главное отличие от интуитивной модели «один agent = один Pod навсегда».

Почему это подходит agents

Типичный агент много времени ждёт: человека, external tool, webhook, следующую задачу. Если каждый idle agent удерживает 1-4 GiB RAM, плотность системы быстро упирается в hardware. Если runtime умеет checkpoint state, освободить Worker и позже восстановить Actor, logical population может быть существенно больше active capacity.

ActorTemplate

`ActorTemplate` - immutable blueprint: image, sandbox class/config, resources, volumes, snapshot policy и другие runtime параметры. Из него создаётся golden snapshot. Изменение workload должно приводить к новой версии template, а не к мутации state root под существующими actors.

WorkerPool

WorkerPool описывает физическую warm capacity и в Substrate связан с Kubernetes objects. Matching sandbox class и selectors определяют, на какие workers может попасть Actor. Именно здесь появляются capacity planning, oversubscription и queueing.

Dormant Actor

Suspended Actor продолжает существовать в control plane и object storage, но не занимает active Worker. Его можно разбудить explicit API call или сетевым запросом через routing layer. Это не serverless function в классическом смысле: Actor имеет durable identity и state lineage.


Agent Substrate: назначение и operational architecture

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

Agent Substrate: operational data path



Agent Substrate позиционируется как runtime для большого количества sandboxed stateful actors поверх Kubernetes. Он намеренно не является agent SDK: внутренняя reasoning logic остаётся приложению. Его задача - lifecycle, placement, isolation, snapshot/restore и routing.

Основные компоненты current architecture

- `ateapi` - control API.
- `atecontroller` - reconciliation Kubernetes-side WorkerPool resources.
- `atelet` - supervisor на node/worker side, координирующий lifecycle и snapshot transfer.
- `ateom` - runtime management внутри worker path; варианты gVisor и microVM.
- `atenet` - networking/routing, включая wake-on-request path.
- PostgreSQL - dynamic Actor/Worker state в текущей архитектуре.
- Object storage - snapshot blobs. В local Kind quickstart проект разворачивает RustFS; cloud deployments могут использовать GCS/S3-compatible path.

Важная оговорка о документации

Architecture document Substrate прямо предупреждает, что значительная часть описания aspirational и может ещё не быть реализована. Поэтому книгу нельзя использовать как «contract по каждой стрелке». Для production baseline проверяются release notes, API guide и реальное поведение на pinned версии.

Project claims и sizing


README заявляет очень высокую density, sub-500ms resume и высокую suspend/resume throughput. Эти цифры полезны как направление design goals, но не как sizing input. Реальная latency зависит от snapshot size, object-store bandwidth, sandbox backend, node locality, CPU pressure и workload readiness. Мы будем benchmark'ить собственный path.

Источники и дальнейшее чтение

- [Substrate README](#)
- [Substrate architecture](#)
- [Substrate API guide](#)

Substrate resources: Atespace, WorkerPool, ActorTemplate, Actor, Tag

Golden snapshot и жизненный цикл stateful Actor



Atespace

Atespace задаёт logical tenancy/scope для Substrate resources. Имена и права удобно рассматривать вместе с tenant boundary, а не просто как «namespace под другим названием».

WorkerPool

WorkerPool - физическая capacity. Он определяет replicas, worker image, sandbox class и pod template properties. Labels WorkerPool могут участвовать в выборе через `workerSelector`; не следует считать namespace или RBAC автоматическим scheduler selector'ом.

ActorTemplate

ActorTemplate immutable. Он содержит контейнеры, required `sandboxConfig`, ресурсы, snapshot config, volumes и selectors. При создании Substrate подготавливает golden actor, ждёт readiness/warmup, suspend'ит его и публикует golden snapshot через Tag. Так дорогая initialization может быть оплачена один раз.

Actor

Actor - конкретный instance template. В status хранится lifecycle state, assignment и snapshot metadata. Один Actor в каждый момент привязан максимум к одному Worker, но между resume может оказаться на другом Worker.

Tag


Tag даёт отдельное ownership snapshot'a и позволяет клонировать состояние. Snapshot lifetime важен: actor snapshot заменяется следующим successful suspend, тогда как Tag живёт до удаления. Actor, созданный из Tag, может некоторое время **заимствовать** tag-owned snapshot; преждевременное удаление Tag способно сломать последующий resume.

SandboxConfig

SandboxConfig определяет runtime assets/configuration и связывается с `sandboxClass` (`gvisor` или `microVM`). Для воспроизводимости runtime binaries и guest assets должны быть pinned так же жёстко, как container image.

Suspend, snapshot, resume и golden snapshot

Resume on demand: запрос может разбудить suspended actor



Checkpointing - центральный механизм density, но его семантику нужно понимать точнее, чем «поставили VM на паузу».

Golden snapshot

При создании ActorTemplate временный golden actor проходит boot и initialization. Затем его suspend создаёт baseline state, опубликованный через golden Tag. Новый Actor может стартовать из этого состояния и избегать повторной expensive initialization. Полезный pattern: загрузить runtime, библиотеки и тяжёлые read-only assets **до** golden snapshot; per-actor secrets и identity, наоборот, должны появляться после cloning безопасным способом.

Actor snapshot

`SuspendActor` фиксирует runtime state и durable data в external snapshot и освобождает Worker. Следующий resume назначает свободный Worker и восстанавливает state. Snapshot связан с ActorTemplate UID: если template изменился, memory image старого sandbox не обязательно совместим. Current API guide описывает fallback, при котором durable data может быть восстановлена, а guest boot выполнен заново.

Network и external resources

Нельзя считать открытые TCP sessions частью надёжно переносимого business contract. Даже если file descriptor присутствует в memory image, remote endpoint не обязан считать соединение живым. Приложение должно уметь reconnect. Аналогично temporary credentials, DNS answers и leases могут протухнуть.

Eviction и data-loss window

Current Substrate guide указывает grace path для eviction: Actor получает `SIGTERM` и ограниченное время на suspend; если checkpoint не завершён, Actor может перейти в CRASHED, а изменения после последнего snapshot потеряются. Поэтому long-running active actor должен либо checkpoint'иться периодически, либо хранить critical progress вне snapshot.

AX nuance

В current AX runner semantics `/workspace` восстанавливается, но container/process tree создаётся заново. Это значит, что agent command должен уметь reconstruct progression. Не проектируйте AX Task так, будто Python heap гарантированно продолжится с той же instruction pointer только потому, что underlying Substrate вообще умеет RAM snapshots.

Источники и дальнейшее чтение

- [Substrate API guide](#)
- [AX runner](#)

Substrate networking: routing, wake-up и egress

Stateful Actor может менять физический Worker, поэтому адрес Pod/Worker нельзя использовать как долговременную identity. Routing layer должен разрешить logical Actor → current assignment и при необходимости инициировать resume.

Request parking

High-level flow: запрос приходит в `atenet`, router выясняет состояние Actor, если он `suspended` - удерживает запрос, control plane назначает Worker, `atelet/ateom` восстанавливают sandbox, после `readiness` открывается authenticated tunnel и исходный request продолжается. Это скрывает relocation от клиента, но добавляет resume latency в first request.

Egress

Agent workload имеет необычно высокий риск exfiltration и supply-chain calls. Хорошая default posture - deny egress и разрешать конкретные destinations. В Substrate v0.2.0+ egress policy стала заметной частью security model. AX Gateway переводит пользовательскую декларацию в runtime network policy.

L7 и TLS reality

Hostname allowlist сложнее CIDR: DNS меняется, TLS шифрует HTTP payload, SNI имеет свои ограничения, а transparent interception создаёт PKI risk. В AX v0.3.0 был публично задокументирован bug, где hostname allowlist ломал TLS egress, в то время как CIDR/wildcard работали. Это хороший operational lesson: condition `GatewayReady=True` означает, что policy применена, а не что реальный end-to-end запрос успешен.

Как тестировать

После policy deployment делайте positive и negative probes **из sandbox**: разрешённый DNS, разрешённый TCP/TLS, запрещённый destination, MCP endpoint и model endpoint. Логи egress проху должны входить в incident playbook.

Источники и дальнейшее чтение

- [AX Gateway issue #345](#)
- [Substrate release notes](#)


АХ: архитектура control plane и реальная граница с Substrate

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

АХ Task: путь от декларации до выполняемого агента



Фактическая схема current main уже разделяет ax-server и ax-controller; design-документ частично отстаёт.

АХ даёт Kubernetes-подобный declarative UX для agent workloads, но не является Kubernetes API extension. Это принципиальная деталь архитектуры.

Release baseline и current main

Design document описывает ax CLI, ax-server и ax-task-runner, причём ax-server валидирует manifests, сохраняет state в Redis и сам reconciles с Agent Substrate. Current source tree уже содержит отдельный ax-controller: он читает Redis stream consumer group, поднимает TaskReconciler и вызывает Substrate client. CONTRIBUTING также говорит о deployment Redis + controller + server. Следовательно, актуальная operational модель - разделённые API и reconciliation paths, а DESIGN.md частично отстаёт.

Это не мелочь для эксплуатации. API replicas и controller replicas имеют разные bottlenecks. Публичный issue current main указывает, что один controller worker способен reconcile tasks последовательно, то есть throughput конкретного pod ограничен одной цепочкой reconcile. Масштабировать API без controller capacity бессмысленно.

State path

Пользователь применяет ax.io/v1alpha1 manifest через CLI. API валидирует имя/спец и сохраняет resource state в Redis. Событие попадает в controller processing. Controller разрешает ссылки на Workspace/Gateway/Model, формирует необходимые Substrate resources/policies, создаёт или восстанавливает Actor, следит за readiness и записывает Task status/conditions. Клиент получает eventual status через get/watch.

Почему Redis, а не CRD per Task

AX design аргументирует это ожидаемой population миллионов короткоживущих tasks и ограничениями etcd/API server. Даже без веры в headline «billions of tasks» rationale разумен: Kubernetes declarative API хорошо подходит для относительно небольших, человекочитаемых configuration objects, а не для высокочастотного application state. Redis позволяет AX построить собственную более узкую consistency/reconciliation model.

Failure boundary

Redis потерян - AX может потерять desired/status layer даже если Substrate actors продолжают существовать. Substrate control plane/DB потерян - AX specs остаются, но runtime placement/snapshot state недоступен. Поэтому backup и DR этих слоёв рассматриваются раздельно.

Источники и дальнейшее чтение

- [AX DESIGN](#)
- [Current ax-controller](#)
- [AX CONTRIBUTING](#)

AX primitives: Task, Workspace, Gateway и Model

Current AX README описывает четыре маленьких пользовательских primitive. Они не являются эквивалентами Kubernetes Pod/PVC/NetworkPolicy; это agent-oriented abstraction layer.

Task

Task - минимальная единица isolated execution. Он задаёт image, command, compute requests/limits, environment, Workspace bindings, Gateway reference и debug behavior. Task intentionally small: один Task может быть всей работой или узлом дерева delegated tasks. Status содержит phase и conditions. Не следует считать Running равным «agent command жив»: current issue показывает случай, когда runner остаётся PID 1 после exit child command, а status продолжает выглядеть healthy. Значит, application-level liveness нужно измерять отдельно.

Workspace

Workspace описывает то, что агент должен получить в рабочей среде: Git sources, static files, MCP configuration, skills и optional goal для environment preparation. Один Task может bind несколько workspaces; первый становится working directory command. Подготовка должна быть idempotent и выполняться один раз на durable state.

Gateway

Gateway задаёт сетевую границу: listeners и outbound egress allowlist. Это не «удобная настройка сети», а ключевой security primitive. Правильный default - deny и явные destinations. Реальные версии требуют end-to-end validation: наличие status GatewayReady подтверждает reconciliation policy, но не доказательство работоспособности DNS/TLS/application protocol.

Model

Model описывает provider, model identifier, parameters и secret reference. Важно не приписывать Model больше, чем он делает в текущей версии. Публичный issue v0.3.0 указывает, что наличие Model не означало автоматического безопасного secret injection в произвольный Task: связь Task→Model и secret semantics менялись. Поэтому в production надо проверять actual API schema pinned release, а не рассчитывать на имя ресурса.

Manifest discipline


Все имена следует считать API identifiers: lowercase RFC1123-style, pinned image digests, explicit atespace, explicit resource requests/limits и ограниченный Gateway. Multi-document YAML удобно хранить как immutable deployment unit для лаборатории, но в production reusable Workspace/Gateway/Model могут иметь самостоятельный lifecycle.

Источники и дальнейшее чтение

- [AX README](#)
- [AX manifests](#)
- [AX concepts](#)
- [AX issue #348](#)

Runner: PID 1 как платформенный контракт

Runner contract: почему PID 1 здесь является частью платформенного API



Runner - одна из самых важных и при этом недооценённых частей AX. Control plane не запускает `spec.command` напрямую. Он запускает `/usr/local/bin/ax-task-runner` как PID 1; уже runner читает `AX_TASK_YAML`, `AX_WORKSPACES_YAML`, `env`, подготавливает `workspace`, запускает `child command` и обслуживает `control endpoints`.

Минимальный contract

Runner должен слушать port 80 и предоставлять `/healthz` и `/readyz`. Readiness остаётся 503, пока `workspace` не готов. Metadata endpoints могут отдавать Task/Workspaces. При `debug: true` runner включает guest services, через которые работает `ax ssh`; это фактически arbitrary process execution/file access внутри sandbox, поэтому `debug` нельзя оставлять включённым без причины.

Workspace initialization once

На первом boot runner клонирует Git, записывает files, подготавливает skill path/MCP config и выполняет goal-based bootstrap. Он должен сохранить marker, чтобы после resume не пере-клонировать repository поверх изменённого workspace. Current default runner использует служебный marker под `/ax`.

Child process semantics

Runner запускает agent command отдельной process group, но **остаётся жить после завершения child**. Это позволяет сохранить metadata/debug surface, однако создаёт monitoring nuance: container alive != agent alive. Current control plane не получает exit code child

command как authoritative Task status. Значит, ваш custom runner или harness должен экспортировать application state отдельно.

SIGTERM и suspend

Stop/suspend доставляют SIGTERM PID 1. Runner обязан forward signal process group, дать bounded grace period, затем завершить остаток. Всё, что должно пережить resume, нужно flush в durable state до выхода. Это нормальная Unix discipline, а не специфический «LLM механизм».

Custom runner


Есть три уровня customization: расширить default image; embedded Go runner package; полностью свой implementation на любом языке. Для большинства платформенных команд оптимален первый вариант - сохранить contract и изменить только toolchain image. Полный custom runner оправдан, когда agent framework уже имеет собственный supervisor или нужен иной workspace layout.

Источники и дальнейшее чтение

- [AX runner contract](#)
- [AX sandbox](#)

Полный lifecycle Task: от YAML до suspend/resume

AX Task: путь от декларации до выполняемого агента



Разберём Task как распределённую state machine, а не как «контейнер, который стартовал».

Create path

1. `ax apply` разбирает multi-document manifest.
2. `ax-server` валидирует resource schemas/refs и сохраняет desired state.
3. Controller получает event из store/stream.
4. Разрешаются Workspace/Gateway/Model и runtime requirements.
5. Формируется/выбирается Substrate ActorTemplate и Actor.
6. Runtime назначает Worker и поднимает sandbox.
7. Runner стартует PID 1.
8. Workspace bootstrap выполняется один раз.
9. `/readyz` становится 200.
10. Controller выставляет `WorkspaceReady / Ready`.
11. Agent command выполняет loop.

Каждый пункт - отдельный failure domain. Поэтому «Task Pending» и «Task Running but useless» требуют разных playbooks.

Suspend path

Пользователь или policy инициирует suspend. AX переводит lifecycle вниз в Substrate, runner получает termination signal и обязан flush state. Substrate/AX сохраняют durable workspace/runtime snapshot согласно текущей integration semantics, освобождают physical Worker и обновляют status. Suspended Task остаётся logical resource.

Resume path

Task снова получает Worker. Durable `/workspace` возвращается, runner запускается заново, видит markers и пропускает destructive re-bootstrap, затем запускает agent command. Harness должен определить, где остановилась работа, и продолжить по durable journal/state. Именно здесь хорошо спроектированный state machine превосходит prompt-only memory.

Delete


Delete должен освобождать AX resource, Substrate Actor/snapshot ownership и связанные runtime artifacts согласно lifecycle. External side effects - Git commits, tickets, конфигурации устройств - не исчезают. Поэтому delete Task никогда не является бизнес rollback.

Operational invariant

На каждом этапе задавайте три вопроса: **какой слой владеет desired state? какой слой владеет runtime state? какой сигнал доказывает readiness?** Если ответ нельзя сформулировать, система будет плохо диагностироваться.

Local inference: CPU, GPU, vLLM и llama.cpp

Local inference: путь запроса через batching, prefill, KV cache и decode



Локальный inference позволяет контролировать данные, latency profile, стоимость hardware и availability, но переносит на вас capacity planning, model serving и upgrades. Для АХ это просто model endpoint: orchestration не должно зависеть от того, облачный он или локальный.

Два практических server класса

vLLM ориентирован на throughput GPU serving, continuous batching и масштабирование крупных моделей. Current release line 2026-09 - `v0.30.0`. OpenAI-compatible server упрощает интеграцию с harnesses. **llama.cpp** удобен для CPU, hybrid CPU/GPU, GGUF quantization, homelab и fallback; server тоже предоставляет OpenAI-compatible интерфейс и умеет parallel decoding/continuous batching.

Prefill и decode

Prefill обрабатывает весь prompt и создаёт KV-cache. Decode генерирует токены последовательно. Поэтому TTFT зависит от prompt length, batching и prefill throughput, а inter-token latency - от decode path и contention. Large context может съесть VRAM даже если model weights помещаются комфортно.

KV cache

KV cache - динамическая память, растущая с числом активных sequences и длиной context. Поэтому вопрос «модель занимает 20 ГиБ, хватит ли 32 ГиБ GPU?» неполон. Нужны weights + KV + runtime buffers + fragmentation margin. У vLLM есть отдельные настройки memory utilization и KV cache size/dtype; менять их следует после измерения, а не по случайному tuning guide.

Quantization

Quantization снижает memory footprint и иногда повышает throughput, но может изменить quality и kernel path. Для agent workloads особенно важно тестировать tool calling/structured output, а не только perplexity. Модель, которая отвечает красиво, но чаще ломает JSON schema, эксплуатационно хуже.

Security server endpoint


OpenAI-compatible endpoint не должен автоматически становиться доступным всей сети. API key конкретного inference server может защищать не все administrative endpoints. Помещайте server за network policy/reverse proxy, ограничивайте paths и identity, а metrics/admin отделяйте от inference traffic.

Источники и дальнейшее чтение

- [vLLM docs](#)
- [vLLM releases](#)
- [llama.cpp](#)

Производительность inference: что измерять для 10-15+ агентов

Local inference: путь запроса через batching, prefill, KV cache и decode



Для agent platform количество агентов не равно числу одновременно декодирующих запросов. Агент проводит время в tool calls, waiting, planning, approvals и I/O. Поэтому capacity моделируется через **arrival rate и duty cycle**, а не «N agents × full model speed».

Основные метрики

- **TTFT (time to first token)** - задержка до начала ответа; чувствительна к prefill/queueing.
- **ITL (inter-token latency)** - задержка между токенами decode.
- **Output tokens/s** - скорость отдельной sequence.
- **Aggregate tokens/s** - throughput всего server.
- **Queue time** - время ожидания scheduler.
- **KV cache occupancy** - pressure на memory.
- **GPU utilization / memory bandwidth** - помогает отличить compute от memory bottleneck.
- **p50/p95/p99 latency** - среднее почти бесполезно при agent orchestration.

Пример capacity mental model

Допустим, 15 голосовых/чат agents активны одновременно, но каждый делает LLM inference 35% wall time, остальное - ASR/TTS/tools/wait. Тогда средняя inference concurrency ближе к 5-6, однако burst может дать все 15. Сервер нужно sizing'овать по приемлемому p95/p99 burst latency, а не только average utilization.

Continuous batching

Server объединяет sequences на каждом decode step, что увеличивает hardware utilization. Но слишком высокая concurrency увеличивает per-request latency и KV pressure. Production goal обычно не «максимум tokens/s любой ценой», а SLO на TTFT/ITL при заданной concurrency.

Agent-aware routing


Не все шаги требуют одной модели. Router может отправлять дешёвую классификацию/validation на меньшую модель, а сложный planning - на более крупную. Но routing logic должен быть измеримым: экономия tokens не нужна, если маленькая модель удваивает retries и tool errors.

Benchmark protocol

Сохраняйте модель/revision, quantization, hardware, driver/CUDA, server version, context distribution, output distribution, concurrency, sampling config и tool schema. Без этого benchmark нельзя сравнивать во времени.

Multi-agent на AX: как делегировать без task explosion

Практика: software-engineering multi-agent workflow



AX Task удобно использовать как unit isolation для специализированных workers. Но Task не должен создаваться на каждый микрошаг. Граница Task оправдана, когда нужны отдельные resources, security scope, Workspace, lifecycle или parallelism.

Coordinator pattern

Root Task получает goal и создаёт structured subtasks. Каждому child передаются ограниченный input, expected output schema, deadline, maximum steps/tokens и allowed capabilities. Результат сохраняется как artifact/state, а coordinator решает дальнейший переход.

Budget propagation

Если root budget 100 условных единиц, дети не должны суммарно получить 500. Budget распределяется сверху вниз. Это касается не только tokens, но и wall time, GPU quota, external API cost и количества spawned Tasks. Хороший invariant: `sum(child maximum) <= remaining parent budget + explicitly approved burst`.

Authority attenuation

Child Task не должен наследовать все credentials parent. Researcher получает read-only repo; implementer - write branch, но не merge; tester - execution tools без production credentials; reviewer - read. Для infrastructure workflow collector получает telemetry read-only, action agent - временный scope только после approval.

Idempotent delegation

Coordinator restart не должен создавать дубликаты children. Используйте deterministic subtask IDs/idempotency keys и durable task journal. Если AX API create не имеет нужной high-level semantic, это обеспечивает application layer.

Result aggregation

Не склеивайте все ответы агентов в огромный prompt. Сначала валидируйте structured outputs, извлекайте facts/artifacts и только затем создавайте компактный synthesis context. Это снижает token cost и prompt injection propagation.


Security architecture: threat model agent platform

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

Security: безопасный агент - это цепочка ограничений, а не один sandbox



Agent platform объединяет несколько высокорисковых свойств: untrusted natural-language input, executable tools, downloaded code, credentials и network access. Sandbox нужен, но он закрывает только часть угроз.

Основные классы угроз

Prompt injection заставляет модель изменить решение. **Tool injection** подсовывает вредоносные descriptions/results. **Malicious repository/Skill/MCP server** атакует supply chain. **Credential exfiltration** использует shell/network/tool. **Sandbox escape** атакует kernel/runtime boundary. **Lateral movement** использует cluster/service credentials. **Runaway execution** расходует tokens/CPU/API quota. **Confused deputy** заставляет привилегированный tool выполнить действие от имени менее привилегированного task.

Defense in depth

1. Минимальный system/container image.
2. gVisor или microVM в зависимости от threat model.
3. Без privileged/root capabilities без нужды.
4. Read-only base FS там, где возможно; durable mount только в нужное место.
5. Default-deny egress.
6. Short-lived scoped credentials.
7. Tool-level authorization по operation и arguments.
8. Approval для destructive/write actions.

9. Resource/token/time budgets.
10. Audit trail и immutable action journal.
11. Central secret manager/Kubernetes secret integration с минимальным exposure.
12. Continuous vulnerability/supply-chain scanning.

Debug как capability

ax ssh требует `spec.debug: true`, а runner guest services позволяют arbitrary process/file operations внутри sandbox. Следовательно, debug - привилегия, не cosmetic flag. В production его лучше делать временным break-glass mechanism с audit и отдельной identity, а не включать у всех Tasks.

Current maturity


Substrate threat-model document в июне 2026 прямо описывал раннюю стадию hardening; последующие релизы добавили identity/egress/authorization работу, но pre-1.0 status остаётся. AX current issues также поднимают auth/authz control plane. Поэтому production internet/multi-tenant deployment без собственного perimeter и review следует считать высоким риском.

Источники и дальнейшее чтение

- [Substrate threat model](#)
- [Substrate releases](#)
- [AX issues](#)

Identity, authorization и Human-in-the-loop

Controlled action pattern: observe → diagnose → propose → approve → execute → verify



Authorization для agents должна отвечать не «кто запустил Pod», а «какой logical Task сейчас просит какое действие над каким объектом». Это сложнее обычного service account, потому что один agent способен породить дерево child tasks.

Разделяем identities

- Human/operator identity - кто инициировал или approved.
- Platform/workload identity - какой Task/Actor выполняется.
- Tool identity - каким credential агент обращается к внешней системе.
- Resource authority - над каким subset objects допустимо действие.

Хорошая система связывает их в audit event, но не делает один вечный token универсальным ключом ко всему.

Approval gate

Approval нужен не для каждого tool call, иначе система становится ручным workflow. Его ставят на transition authority: переход из read-only диагностики к write, повышение scope, destructive operation, превышение budget или доступ к sensitive data.

Approval object должен содержать конкретный action plan, targets, expected changes, expiry и hash/ID параметров. Подтверждение «разрешить агенту работать дальше» слишком широкое.

Read / write / destructive

Практический policy taxonomy:


Класс	Пример	Default
Read	show route, logs, metrics	allow при scoped identity
Bounded write	создать branch/ticket, изменить один объект	policy + optional approval
High-impact	BGP policy, delete VM, firewall rollout	explicit approval + pre/post checks
Destructive/ irreversible	wipe data, revoke root PKI	отдельная процедура / возможно запрет агенту

Verification after action

Успешный tool response не равен успешному outcome. После write всегда отдельный verification step: прочитать новое состояние из authoritative system, проверить invariants и записать result. Желательно, чтобы verifier был логически отделён от executor и не доверял его natural-language summary.

Observability: четыре слоя и единая correlation identity

Четыре слоя observability нельзя смешивать в один «лог агента»



Наблюдаемость agent system должна позволять пройти путь от user goal до конкретного tool side effect и одновременно увидеть infrastructure bottleneck.

Infrastructure layer

Node/Pod CPU, RAM, disk latency, network drops, GPU memory/utilization, Redis/PostgreSQL/object-store metrics, Kubernetes events. Это отвечает на вопрос «платформа физически здорова?».

Runtime layer

Actor state, Worker assignment, resume/suspend duration, snapshot size/transfer, WorkerPool occupancy, scheduling wait. Substrate actor логически переживает разные Workers, поэтому logs должны иметь stable actor metadata, иначе история распадется по Pod names.

Agent layer

Step number, plan/route decision, tool name, sanitized arguments, result class, retry, child Task, approval state. Логи chain-of-thought не являются обязательным или желательным telemetry format; нужен структурированный event trail действий и решений без раскрытия скрытого reasoning.

LLM layer

Provider/model/revision, prompt/output token counts, TTFT, ITL, queue time, error class, cache hit, request ID и cost estimate. Prompt content следует логировать выборочно/редактированно: observability storage сама может стать источником утечки secrets/PII.

Correlation

Минимальные IDs: `trace_id`, user/job id, AX Task id, Substrate Actor UID, tool call id, model request id. Для multi-agent добавляется parent/root task. Один trace должен переживать suspend/resume и Worker relocation.

SLO


Примеры SLO: time-to-Task-ready, resume p95, tool success rate, model TTFT p95, successful agent outcome rate, percentage actions requiring manual recovery. «Tokens/s» сам по себе не является SLO бизнеса.

Источники и дальнейшее чтение

- [Substrate observability](#)

Лабораторный стенд на Proxmox/KVM: Kind, k3s или kubeadm

Базовый учебный стенд: один VM, воспроизводимый путь до работающего AX



Для первой воспроизводимой установки выбираем **Kind внутри одной Debian/Ubuntu VM на Proxmox/KVM**, потому что Substrate current quickstart имеет автоматизированный Kind path и локально поднимает зависимые PostgreSQL/RustFS. Это учебный выбор, не production recommendation.

Kind

Kind запускает Kubernetes nodes как Docker containers и сам использует kubeadm внутри node images. Плюсы: быстро удалить/создать cluster, повторяемость, удобно для CI/lab. Минусы: дополнительный слой container-in-VM, networking/storage отличаются от production, hardware/runtime integration сложнее.

k3s

K3s - лёгкий conformant distribution в одном binary с разумными defaults; удобно для homelab/edge и небольших VM. Он уменьшает операционную стоимость, но скрывает часть деталей, которые полезно увидеть при изучении обычного Kubernetes. Для второго стенда это хороший вариант, особенно если ресурсы ограничены.

kubeadm

Kubeadm даёт более «обычный» Kubernetes bootstrap и заставляет явно выбрать CNI, control-plane topology, storage и upgrades. Это лучше для обучения production mechanics и multi-node lab, но требует больше работы.

Практический выбор

Lab-1: Proxmox → VM → Docker → Kind → Substrate → AX.

Lab-2 optional: 3+ VM → kubeadm или k3s → Substrate → AX → separate inference node.

Если планируется microVM, Proxmox должен пробросить nested virtualization/KVM внутрь VM (/dev/kvm доступен guest). Для gVisor это требование мягче, хотя конкретный runsc platform тоже надо проверить.

Минимальный размер VM


Не задаём универсальные числа, потому что версии и demo images меняются. Практический старт для control-plane lab без большой LLM: несколько vCPU, 12-16 GiB RAM и десятки GiB SSD. Локальный LLM лучше вынести на отдельную GPU VM/host и подключить API, иначе resource pressure смешивает две задачи: изучение orchestration и benchmark inference.

Источники и дальнейшее чтение

- [Substrate README quickstart](#)
- [Kind](#)
- [K3s](#)
- [kubeadm](#)

Production engineering: HA, persistence, upgrades и DR

Production-like topology: failure domains должны быть явными



Production-like AX/Substrate нужно рассматривать как несколько независимых stateful planes, а не как один application Deployment.

Что сохранять

AX state: manifests/status/events в Redis - определить persistence/replication/backup strategy и RPO.

Substrate dynamic state: PostgreSQL - HA, PITR/backup, consistency с snapshot metadata.

Snapshot blobs: object storage - durability, lifecycle, versioning/retention, throughput.

Container images: registry - immutable digests и availability.

Secrets/identity: Kubernetes/external secret store, CA/JWT/SPIFFE material.

Observability: separate backend с retention.

HA не равно «реплик больше»

API replicas требуют load balancing и shared state. Controllers требуют правильных consumer groups/locks/idempotency. PostgreSQL/Redis HA добавляет собственные failure modes. Object store должен выдерживать одновременно restore burst и checkpoints. WorkerPool availability зависит от Kubernetes nodes и image locality.

Upgrade discipline

Для pre-1.0 компонентов:

1. Pin exact versions/images.
2. Read breaking release notes.
3. Test snapshot compatibility.

4. Upgrade lab/staging.
5. Create recovery point.
6. Upgrade control plane before/after workers согласно конкретной compatibility matrix.
7. Run create/suspend/resume/delete and egress tests.
8. Roll gradually.

DR questions

Восстановление должно отвечать: можно ли поднять AX desired resources из backup, сопоставятся ли они с Substrate Actors, доступны ли snapshot URIs, совместимы ли sandbox assets, какие external side effects уже произошли. Документированный DR drill важнее наличия файлов backup.

Capacity reserve

Нельзя держать WorkerPool и inference GPU на 100% average utilization. Resume burst, compaction, node drain и model load требуют headroom. Резерв задаётся через SLO/benchmark, а не фиксированными 20% для всех систем.

Performance и scaling: что реально ограничивает систему

Производительность AX/Substrate определяется цепочкой bottlenecks. Headline density бесполезна без понимания active ratio и snapshot profile.

Основные коэффициенты

logical actors / physical workers - oversubscription. Он полезен только если большая доля actors suspended/idle. Для постоянно активных agents oversubscription не создаёт бесплатный compute.

resume latency складывается из assignment, snapshot location/transfer, restore, readiness и routing. Большой workspace/snapshot или удалённый object store легко доминирует над собственно sandbox startup.

controller throughput определяет скорость массового create/update. Current AX issue про serial reconcile напоминает: bottleneck может быть в control-plane loop, даже когда Workers свободны.

state-store QPS и tail latency влияют на scheduling/status. Redis/PostgreSQL должны benchmark'иться с реальным object count и payload size.

object-store bandwidth/IOPS особенно критичны при suspend storm, node drain или массовом resume после события.

Benchmark matrix

Измеряйте отдельно:

- cold create → ready;
- golden start → ready;
- suspend latency vs snapshot size;
- resume latency warm/cold object cache;
- concurrent resumes 1/10/100/...;
- controller create/reconcile throughput;
- WorkerPool saturation behavior;
- egress proxy overhead;
- inference latency independently от AX.

Project claims

Substrate README публикует ориентиры высокой density и sub-second resume. В книге они отмечаются как **PROJECT CLAIM**, а не гарантия. Ваша target workload может иметь большие files, dirty memory, network dependencies и другую storage topology.

Practical performance budget

Полезно заранее разложить SLO: например, interactive agent wake $p95 \leq 2$ s, LLM TTFT $p95 \leq 1.5$ s, tool call $p95 \leq 2$ s. Тогда видно, где оптимизация действительно заметна пользователю, а где выигрыш 50 ms растворяется в model inference.

Failure modes и troubleshooting handbook

Диагностика идёт снизу вверх: infrastructure → runtime → AX control plane → runner/workspace → tools/model → agent logic. Ниже - рабочая матрица, которую стоит адаптировать под конкретный deployment.

Симптом	Слой	Что проверить первым	Типичные причины
Task не создаётся	AX API	ax apply , server logs, schema	invalid name/spec, missing ref
Task долго Pending	AX/Substrate	controller events, Actor status	no eligible Worker, reconcile backlog
Actor не resume	Substrate	WorkerPool, snapshot, atele	no capacity, incompatible/ broken snapshot
WorkspaceReady=False	Runner	runner logs, /readyz	Git/MCP/goal bootstrap failed
WorkspaceReady=True, файлов нет	Runner	filesystem + Git exit	silent bootstrap error/version bug
Task Running, агент умер	Runner/app	ps , custom app metric	child exited, PID1 runner жив
ax ssh не работает	debug/ network	spec.debug , routing	debug off, CLI bug, guest service unreachable
TLS egress ломается	Gateway/ atenet	DNS/TCP/TLS probes	policy translation/SNI/hostname issue
Model timeout	inference/ network	server queue, TTFT, GPU	saturation, oversized context, egress
GPU OOM	inference	KV/weights/batch	context/concurrency too high
Suspend медленный	Substrate/ storage	snapshot size/ bandwidth	dirty memory/files, object store
Resume cold	Substrate/ storage	cache/locality	remote snapshot/image pull
Child Tasks множатся	harness	spawn events/budget	retry without idempotency, no depth limit
Write action повторён	tool layer	action journal/ idempotency	timeout after side effect

Командный порядок

1. Зафиксировать exact versions и timestamps.
2. `kubectl get pods -A / events / node pressure`.
3. Проверить AX server/controller health/logs и Redis reachability.
4. Проверить Actor/WorkerPool status и Substrate components.
5. Проверить runner health/readiness и actual child process.
6. Positive/negative egress probes из sandbox.
7. Model endpoint latency independently.
8. MCP endpoint independently с той же identity/policy.
9. Только после этого анализировать agent prompt/loop.

Не доверять одному status


Current AX issues показывают полезный принцип: control-plane condition может отражать «шаг reconciliation завершён», а не end-to-end truth. `Ready=True` не доказывает живой child command; `GatewayReady=True` не доказывает успешный TLS к allowlisted host. Верификация должна соответствовать пользовательскому outcome.

Источники и дальнейшее чтение

- [AX issue #346](#)
- [AX issue #345](#)
- [AX issue #347](#)
- [AX issues](#)

Когда АХ нужен, а когда проще другой инструмент

Когда АХ является разумным кандидатом, а когда это избыточный слой



АХ разумно оценивать по workload properties, а не по моде на agents.

Сильные сигналы в пользу АХ/Substrate

- Много логических agents, значительная часть времени idle.
- Нужна изоляция untrusted/generated code.
- Workspace/state должны переживать паузы.
- Желательны suspend/resume и reclaim physical capacity.
- Нужен единый declarative lifecycle для heterogeneous agent images.
- Task population и churn выходят за удобную модель «один Pod/Job на всё».

Когда обычный Kubernetes Job лучше

Если workload stateless, запускается, делает deterministic batch и завершает работу, Job проще. Он интегрирован с Kubernetes auth/observability и не требует дополнительного control plane.

Когда worker queue лучше

Если code trusted, tasks короткие, state хранится в DB, а изоляция не нужна, Celery/RQ/ custom workers или message queue могут быть намного дешевле операционно.

Когда Temporal/workflow engine лучше

Если главная сложность - durable business workflow, timers, retries и exactly-tracked transitions, а execution code trusted, workflow engine часто естественнее. АХ можно комбинировать с ним: workflow engine решает business orchestration, АХ - sandboxed agent execution.

Когда LangGraph/AutoGen/CrewAI уместны

Они находятся ближе к agent logic/harness. Их можно запускать **внутри** АХ Task. Сравнивать «АХ vs LangGraph» как взаимоисключающие продукты некорректно.

Ray

Ray решает distributed compute/scheduling и actors в другом смысле. Он может быть хорош для parallel Python/ML workloads, но security/sandbox/suspend semantics и agent-specific primitives отличаются. Выбор зависит от dominant problem.

Главный принцип: сначала используйте самый простой runtime, который удовлетворяет threat model, state и scaling requirements. Дополнительный control plane должен окупать собственную сложность.

Антипаттерны

Один гигантский агент

Один process с доступом ко всем tools и credentials удобен для demo, но создаёт огромный blast radius, context pollution и плохую диагностику. Разделяйте роли там, где различаются authority или context.

Agent вместо deterministic logic

Не просите LLM считать CIDR, проверять обязательный формат или решать, выполнен ли health check, если это можно сделать кодом. LLM полезна для неоднозначного reasoning; deterministic constraints должны исполняться deterministically.

State только в prompt

После context compaction/restart состояние исчезнет или исказится. Critical progression фиксируется в durable structured state.

Unlimited retries

Retry без классификации error создаёт loops и дублирует side effects. Нужны limits, exponential backoff и idempotency.

Shared root credentials

Один token на всех agents уничтожает возможность least privilege/audit. Используйте scoped/short-lived identity.

`egress: *` навсегда

Wildcard удобен на первом smoke test и опасен как постоянная production policy. Сначала измерьте реальные destinations, затем сузьте allowlist и добавьте отрицательные probes.

Debug всегда включён

`spec.debug` расширяет control surface внутри sandbox. Включайте только там, где есть операционная необходимость.

Task per thought

Создание Task на каждый reasoning step превращает control plane в дорогую шину сообщений. Task boundary должна соответствовать isolation/resource/lifecycle boundary.

Snapshot как backup


Snapshot оптимизирует resume; он не заменяет backup authoritative state. Особенно это верно для внешних systems и Tag lifetime.

Benchmark на одном пустом actor

Результат не переносится на real workspace, dirty memory, large snapshots и concurrent bursts. Benchmark должен репрезентировать production distribution.

Практикум: 14 последовательных лабораторных работ

Базовый учебный стенд: один VM, воспроизводимый путь до работающего AX



Ниже - маршрут от чистой VM до двух multi-agent systems. Команды намеренно ориентированы на понимание процесса; exact flags текущего релиза необходимо сверить с pinned README/release notes перед запуском.

Lab 1. Подготовка VM

Создайте Debian 13 или Ubuntu LTS VM в Proxmox. Включите достаточные CPU/RAM/disk, NTP и nested virtualization, если хотите microVM. Проверьте `virt-host-validate//dev/kvm` по необходимости. Установите Docker, Git, Go версии, требуемой pinned AX/Substrate, `kubectl`, `ko`.

Результат: чистый snapshot VM `ax-lab-base`.

Lab 2. Kind и Kubernetes minimum

Создайте Kind cluster. Отработайте `kubectl get nodes`, `get pods -A`, `describe`, `logs`, `exec`, Service/DNS, Secret, readiness probe. Намеренно сломайте image и readiness, чтобы увидеть events.

Lab 3. Agent Substrate quickstart

Используйте pinned release scripts `hack/create-kind-cluster.sh` и `hack/install-ate-kind.sh --deploy-ate-system ...`. Убедитесь, что поднялись control components, PostgreSQL и RustFS. Установите `kubectl-ate` подходящей версии.

Lab 4. Actor lifecycle

Создайте WorkerPool, ActorTemplate, Actor. Наблюдайте transition `suspended/running`, `assignment` и `component logs`. Цель - руками увидеть, что Actor identity не равна Pod identity.

Lab 5. Snapshot/resume

Запишите state в durable directory и RAM/app state согласно demo; suspend; убедитесь, что Worker освобождён; resume на возможном другом Worker. Измерьте latency и размер snapshot. Повторите 10 раз.

Lab 6. gVisor и microVM

Сравните RuntimeClass/SandboxConfig path. Для microVM проверьте KVM/nested virtualization. Выполните одинаковую filesystem/network/process workload и зафиксируйте compatibility/performance differences. Если microVM невозможно поднять в nested lab, архитектурный эксперимент считается завершённым после проверки constraints - не маскируйте отсутствие KVM обходом security.

Lab 7. Установка AX

Checkout tag `v0.3.1`, настройте image registry, выполните deployment в `ax-system`. Проверьте Redis, server/controller components. Установите CLI той же версии, а не `@latest`.

Lab 8. Первый Task + Workspace

Создайте Workspace с небольшим Git repo и file; Task с `sleep`/простым agent command. Наблюдайте `ax watch`, `WorkspaceReady`, filesystem. Suspend/resume и убедитесь, что workspace changes сохранены, а process PID изменился.

Lab 9. Gateway

Начните с deny/явного allow. Проверьте DNS, HTTP, TLS для разрешённого и запрещённого destination из `ax ssh`. Сохраните egress проху logs. Не используйте успешный status как единственную проверку.

Lab 10. Cloud LLM

Подключите provider через безопасный secret path, доступный вашей pinned версии. Сделайте минимальный model adapter с timeout/retry и метриками tokens/TTFT. Не кладите API key literal в Task manifest.

Lab 11. CPU local inference

На отдельной VM или host поднимите pinned llama.cpp server с небольшой GGUF model. Проверьте OpenAI-compatible endpoint, concurrency 1/2/4, context 1k/4k/8k. Снимите CPU utilization, RAM и latency. Это fallback lab, который воспроизводится без GPU.

Lab 12. NVIDIA + vLLM + Qwen

На GPU host установите совместимые NVIDIA driver/CUDA/container toolkit. Запустите pinned `vLLM v0.30.0` image/server с выбранной Qwen model, начав с conservative context/concurrency. Измерьте TTFT/ITL/aggregate throughput и KV pressure. Затем увеличивайте concurrency до нарушения целевого SLO. Зафиксируйте точку saturation.

Примерный шаблон, не copy-paste для любой модели:

```
vllm serve <model-id> \
  --tensor-parallel-size 1 \
  --max-model-len <tested-context> \
  --gpu-memory-utilization <tested-value> \
  --api-key <service-key>
```

Lab 13. Software-engineering multi-agent


Coordinator создаёт Researcher/Implementer/Tester/Reviewer Tasks. Каждая роль получает отдельный policy/Workspace view. Implementer пишет только branch, Reviewer не имеет write, merge остаётся human-approved. Измерьте число Tasks, tokens и wall time против single-agent baseline.

Lab 14. Infrastructure multi-agent


Постройте pipeline Coordinator → Telemetry → Network Diagnostics → Logs/Config → Validator → Action Planner → Approval → Restricted MCP → Verification. Read-only agents работают без approval. Action tool выдаёт краткоживущую sarability только на заранее согласованный объект/операцию. Verification повторно читает устройство/систему и подтверждает intended outcome.

Критерий успеха: agent не может расширить scope собственным prompt'ом и не может выполнить write до approval.

Практика: software-engineering multi-agent workflow




Практика: инфраструктурная диагностика с контролируемым изменением



Две референсные multi-agent архитектуры

Практика: инфраструктурная диагностика с контролируемым изменением



Software engineering

Coordinator отвечает за decomposition, budgets и final synthesis. Researcher анализирует issue/repository, но не пишет. Implementer получает отдельный branch. Tester выполняет tests в sandbox и возвращает machine-readable результаты. Reviewer сверяет diff с goal и security rules. Human или отдельный policy gate выполняет merge/release.

Смысл разделения - не имитация команды людей, а разные capabilities. Если всем четырём ролям дать один token с admin-доступом к GitHub, архитектура теряет большую часть security value.

Infrastructure / network operations

Этот сценарий лучше показывает production constraints. Telemetry collector собирает metrics/flows/logs. Network diagnostic agent анализирует MTR/BGP/routing state. Config analyst читает running config и change history. Validator сопоставляет независимые evidence. Planner формирует **структурированный** change request: device, commands/API, expected effect, rollback/preconditions. Approval service подтверждает exact request. Restricted MCP server выполняет только разрешённую операцию. Verification agent читает пост-состояние.

Write tool должен проверять target и arguments сам. Если approval разрешил `set local-pref 150 for policy X`, agent не должен суметь подменить target на policy Y в последнем tool call. Capability должна быть cryptographically or server-side bound to approved parameters либо пересверяться policy engine.

Rollback

Rollback - отдельный plan, а не фраза «если плохо, верни назад». Нужны pre-change snapshot/config, measurable success condition, timeout observation и deterministic reverse action. Для BGP/network change это может быть staged route-map attach/detach и проверка traffic/route table, а не LLM improvisation.

Mental models, glossary и cheatsheets

Если запомнить только десять вещей

- 1. **LLM ≠ Agent.** Модель предлагает следующий output; agent появляется из loop + state + tools.
- 2. **Agent ≠ Harness.** Harness - управляющая система вокруг reasoning.
- 3. **Harness ≠ Orchestrator.** Первый управляет шагами одного execution, второй - population/lifecycle.
- 4. **AX ≠ Substrate.** AX даёт agent-oriented declarative control plane; Substrate - actor/sandbox runtime.
- 5. **Actor ≠ Worker.** Actor - logical identity/state; Worker - physical capacity.
- 6. **Task ≠ Pod.** Task - AX abstraction, которая через Substrate в итоге использует Kubernetes resources.
- 7. **Context ≠ Memory.** Context - текущие tokens; memory/state должны иметь durable representation.
- 8. **Snapshot ≠ Backup.** Snapshot оптимизирует resume и имеет lifecycle/compatibility ограничения.
- 9. **MCP ≠ Authorization.** MCP стандартизует capability exchange; policy всё равно надо enforce.
- 10. **Ready ≠ outcome.** Control-plane readiness не доказывает, что бизнес/agent action успешен.

Мини-гlossарий

Термин	Практическое значение
Agent	цикл принятия действий вокруг модели и среды
Harness	context/tool/state/policy/retry infrastructure агента
Tool	формализованная операция с schema и side effect semantics
MCP	протокол взаимодействия agent clients с tools/resources/prompts
Skill	переиспользуемая инструкция/процедура, а не transport
Task	AX unit isolated execution
Workspace	declarative Git/files/MCP/skills environment
Gateway	AX network ingress/egress policy abstraction
Model	AX model provider/config/credential reference

Термин	Практическое значение
Actor	Substrate logical stateful instance
ActorTemplate	immutable runtime blueprint + golden snapshot root
WorkerPool	physical warm execution capacity
Worker	physical assignment target for running Actor
Snapshot	checkpoint RAM/durable data according to runtime semantics
Golden snapshot	prepared baseline used to start new Actors
Reconciliation	повторное сведение actual state к desired state
TTFT	time to first generated token
ITL	inter-token latency during decode
KV cache	attention state для active sequence

AX operational cheatsheet

```
# Используйте CLI той же версии, что control plane
ax apply -f stack.yaml
ax get tasks
ax describe task <name>
ax watch task <name>
ax suspend task <name>
ax resume task <name>
ax delete task <name>
# только при debug=true
ax ssh <name> -- ps aux
```

Kubernetes first-response cheatsheet

```
kubectl get nodes -o wide
kubectl get pods -A -o wide
kubectl get events -A --sort-by=.lastTimestamp
kubectl describe pod -n <ns> <pod>
kubectl logs -n <ns> <pod> --all-containers --tail=200
kubectl top nodes
kubectl top pods -A
```

Incident questions

- Какая exact версия AX/Substrate?
- Какой Task/Actor UID?
- Desired state принят API?
- Controller обработал событие?


- Есть подходящий Worker?
- Snapshot доступен и совместим?
- Runner `/healthz` и `/readyz`?
- Child agent process реально жив?
- Gateway пропускает DNS/TCP/TLS до нужного endpoint?
- Model server не в queue/OOM?
- MCP tool доступен с той же identity?
- Есть ли записанный side effect до retry?

Что изучать глубже отдельно

Для Kubernetes - официальные Concepts, RBAC, NetworkPolicy и kubeadm docs. Для Linux isolation - namespaces/cgroups/seccomp и gVisor architecture. Для distributed systems - idempotency, leases, consensus и transactional outbox. Для inference - vLLM/llama.cpp performance docs и GPU architecture. Для MCP - всегда сверяйте **versioned** specification, потому что протокол в 2026 существенно изменился относительно ранних материалов.

Context engineering: управление контекстом и durable state

Context engineering: finite budget is assembled, not magically remembered



Context engineering - это управление ограниченным вычислительным ресурсом

У агента нет бесконечной «памяти». В каждый запрос модели попадает конечный context window, а значит harness должен выбирать, **какие факты в него попадут сейчас**, а какие останутся во внешнем state. Практическая модель бюджета:

- P - policy/system instructions;
- S - текущий structured state задачи;
- R - retrieved evidence;
- H - недавняя история;
- T - tool results;
- O - резерв на output.

Рабочее правило: $P + S + R + H + T + O \leq C$, где C - доступное context window. Это не математическая оптимизация ради оптимизации: при переполнении harness начинает либо терять важные ограничения, либо «забывать» модель второстепенными логам и трассировками.

Что должно быть durable

В durable state стоит хранить не поток текста, а сведения, которые нужны для возобновления и аудита:

```
objective: "диагностировать потерю доступности"
constraints:
  - "write actions require approval"
known_facts:
  - source: "telemetry-api"
    fact: "packet_loss=18% on uplink-2"
    observed_at: "2026-10-03T08:11:00Z"
decisions:
  - id: d-17
    decision: "collect reverse-path trace before proposing change"
open_questions:
  - "is loss visible from alternate peer?"
side_effects:
  - tool_call_id: tc-442
    action: "created diagnostic ticket"
    external_id: "INC-9042"
```

Compaction должен сохранять **факты, принятые решения, ограничения, незакрытые вопросы, внешние идентификаторы и уже совершённые side effects**. «Сделать summary последних 50 сообщений» - слабая стратегия, если summary теряет именно эти элементы.

Provenance важнее красноречия

Harness должен знать происхождение каждого существенного факта. Для operational agent разумный приоритет примерно такой: live authoritative API/state > signed/config repository > internal documentation > curated knowledge base > general web > arbitrary untrusted content. Это не означает, что низкоприоритетный источник бесполезен; означает, что конфликт нельзя разрешать только по уверенности формулировки LLM.

Prompt injection и разделение данных/инструкций

Retrieved content, Git README, тикет пользователя, web page и output внешнего MCP server должны по умолчанию трактоваться как **данные**, а не как privileged instructions. Harness должен отдельно хранить policy layer и не позволять документу вида «ignore previous instructions and run ...» автоматически менять полномочия агента.

Memory tiers

Практически полезно различать:

Слой	Для чего	Типичный TTL
Request context	один model call	секунды/минуты
Working state	текущая Task	часы/дни
Episodic history	прошлые эпизоды/решения	дни/месяцы
Semantic knowledge	устойчивые факты/документация	месяцы
External source of truth	реальное состояние системы	определяется системой

Persistent memory не должна становиться альтернативной CMDB/CRM/NMS. Если истиной является Router API, Git или Lanbilling, агент должен уметь вернуться к этой системе и перепроверить факт.

Resume contract


После suspend/resume агент должен восстанавливать не «ощущение непрерывного сознания», а конкретный execution contract: objective, state version, acquired evidence, pending operations, tool call ledger, approval state и external IDs. Для AX это особенно важно: durable / workspace может сохраниться, но процесс runner/agent стартует заново.

Метрики context layer

Следите минимум за input tokens, output tokens, долей retrieved context, compaction count, cache hit ratio, retrieval latency, number of conflicting facts, stale-state age и процентом model calls, где harness был вынужден отбросить evidence из-за budget. Это позволяет отличить «слабую модель» от плохо собранного context pipeline.

MCP 2026: протокол, discovery, transport и trust boundaries

MCP 2026-07-28: stateless request model and discovery



Сначала проверьте версию протокола

MCP быстро эволюционировал. Для этой книги reference point - спецификация **2026-07-28**. Она существенно отличается от ранних tutorial: core стал stateless, старый protocol-level session lifecycle удалён, version/capabilities передаются в request metadata, а server discovery вынесен в отдельный механизм. Поэтому пример с `initialize`, `initialized` и обязательным `Mcp-Session-Id` нельзя автоматически переносить на новый implementation.

Логическая модель

MCP отвечает за стандартизированный обмен capability между host/client и server. Для эксплуатации полезно мыслить четырьмя независимыми слоями:

1. **Discovery** - какие servers/capabilities существуют.
2. **Description/schema** - какие tools/resources/prompts доступны и какие аргументы они принимают.
3. **Transport** - как именно request добирается до server.
4. **Authorization/policy** - имеет ли данный principal право выполнять действие сейчас.

Schema не является authorization. Наличие `delete_user(id)` в tool list не означает, что агенту следует разрешить его вызвать.

Tools, resources и prompts

Tool - действие с потенциальным side effect. **Resource** - адресуемые данные/контент. **Prompt** - reusable prompt/template contract. Эти категории нужно различать при policy:

чтение inventory resource и выполнение `commit_config` требуют принципиально разной authority.

Discovery

В новой модели discovery должен позволять client определить server metadata/capabilities без старой stateful handshake. При этом self-reported metadata не следует использовать как доказательство доверия: имя server, description или advertised capability не удостоверяют identity.

Transport и routing

При HTTP transport эксплуатационная цепочка выглядит не как «LLM вызывает MCP», а как `agent harness -> MCP client -> resolver/proxy -> authenticated HTTP/TLS -> MCP server -> target system`. На каждом переходе возможны собственные таймауты, DNS ошибки, proxy policy и credential scope.

Authorization

Хороший policy layer проверяет одновременно principal, Task/tenant, tool, resource scope, arguments, time window, approval token и expected target state. Для write operation полезно связывать approval не с именем tool, а с **конкретным normalized action hash**: `tool + arguments + target + revision + expiry`.

Multi-round interactions

Протокол поддерживает сценарии, где server во время выполнения запрашивает дополнительный ввод/подтверждение. Harness обязан ограничивать такие цепочки: max rounds, timeout, cumulative budget и допустимые request types. Иначе «один tool call» становится скрытым бесконечным workflow.

Long-running work

Длительная операция должна иметь external operation/task identifier и наблюдаемый status. Не держите единственный HTTP request открытым часами, если target system предоставляет job model. Retry по timeout без idempotency key может создать дублирующий side effect.


MCP server как часть threat model

MCP server может быть ошибочным, скомпрометированным или просто возвращать untrusted content. Он не должен получать больше network/credential authority, чем требуется его назначению. Особенно опасен «универсальный admin MCP», внутри которого десятки несвязанных полномочий выдаются одному process identity.

MCP в AX Workspace

Workspace удобен как декларативная точка подключения MCP и skills, но это не отменяет network policy, secret scoping и runtime authorization. Нормальный acceptance test должен проверить: discovery, один read call, denied write without approval, allowed write with bounded approval, timeout, unavailable server, malformed output и audit correlation ID.

Безопасное выполнение tools: idempotency, approvals и attenuation полномочий



Tool call - это маленькая транзакция, а не функция модели

Для production agent полезно разделять каждый потенциально изменяющий вызов на последовательность:

proposal -> schema validation -> semantic validation -> authorization -> approval -> execution -> verification -> audit.

LLM может сформировать proposal, но не должна сама определять, что proposal авторизован.

Классы side effects

Класс	Пример	Retry policy
Pure/read	<code>show interface</code>	обычно безопасный retry
Idempotent write	<code>set desired_state=X</code>	retry с key/version
Create	создать ticket/VM	только с idempotency key
Destructive	delete/reset/reboot	explicit approval + precondition
Irreversible/external	отправка платежа/письма	strongest confirmation + ledger

Самая неприятная ситуация - **timeout after commit**: client не получил ответ и не знает, произошло действие или нет. Решение - idempotency key, external operation ID и read-after-timeout reconciliation, а не слепой повтор.

Preconditions

Write action следует привязывать к ожидаемому состоянию:

```
{
  "device": "edge-1",
  "operation": "replace_route_map",
  "expected_revision": "sha256:...",
  "desired_revision": "sha256:...",
  "approval_id": "apr-771",
  "idempotency_key": "task-91-step-8"
}
```

Если `expected_revision` уже не совпадает, агент должен вернуться в plan/approval, а не применять устаревшее решение.

Authority attenuation

Coordinator не должен передавать child agent полный собственный credential. При delegation выдаётся более узкий capability: меньший set tools, меньший target scope, меньший TTL, меньший budget. Каждый следующий слой может **сужать**, но не расширять authority без нового внешнего решения policy engine.

Approval должен быть связан с объектом действия

Плохой approval: «разрешаю агенту менять BGP в течение часа». Хороший: «разрешаю operation X на device Y с diff Z при current revision R, до 17:05, после чего обязательна verification V». Это превращает human-in-the-loop из психологической кнопки «ОК» в технический control.

Verification и compensation

После write читаем состояние из authoritative source и сравниваем с success condition. Rollback/compensating action готовятся **до** destructive step. У некоторых систем rollback не является inverse function, поэтому playbook должен учитывать реальные semantics target API.


Circuit breakers

Harness должен иметь per-tool rate limit, max consecutive failures, global task budget, concurrency cap и emergency deny switch. Это защищает и от hallucination loop, и от реального degraded dependency.

Audit record


Записывайте principal, Task/agent identity, normalized request, policy result, approval, idempotency key, start/end timestamps, external operation ID, result hash и verification result. Полный raw secret/token в audit попадать не должен.

Authority attenuation: child may narrow scope, never silently widen it



AX control plane: state, event flow и operational truth

Current AX control path: API and reconciliation are separable scaling domains



Почему одного API status недостаточно

В declarative control plane существует несколько разных истин: request принят API, desired state записан, event увиден controller, reconciliation выполнен, Substrate создал/возобновил Actor, runner жив, child process жив, Workspace готов, а конечная бизнес-задача действительно выполняется. Эти состояния нельзя сворачивать в один boolean Ready.

Current-main controller split

В current main AX присутствует отдельный ax-controller, использующий Redis stream consumer group и TaskReconciler с Substrate client. Это отличается от старого DESIGN.md, где reconciliation описан как обязанность ax-server. В книге release baseline и current-main delta поэтому разведены явно.

Redis как control state/event substrate

Если Redis используется для desired/status/event coordination, его persistence, eviction policy и memory pressure становятся control-plane safety issue. allkeys-lru для такого store - плохая идея: eviction control object может выглядеть как «случайная потеря Task». Production deployment должен знать, какие keys/streams durable, как устроены consumer groups и как выполняется recovery после restart.

Conditions как timeline

Pending, Running, Ready, WorkspaceReady, Suspended, Failed полезны только вместе с reason/message/transition time/generation. Operator должен видеть, **какое поколение specs** породило status, иначе старый Ready=True может быть принят за подтверждение нового изменения.

Liveness != progress

Runner может оставаться живым после выхода child command. Поэтому нужны две независимые группы сигналов:

- platform health: API/controller/Substrate/runner доступны;
- workload progress: child PID/state, heartbeat, last meaningful event, output/checkpoint age, task-specific success condition.

Progress watchdog особенно нужен автономным agent loops: process может не падать, но часами повторять одну ошибку.

Controller backlog

Наблюдайте stream lag, oldest unprocessed event age, reconcile latency p50/p95/p99, retries per object, dead-letter/error count и Substrate API latency. При росте population сначала может ломаться не sandbox capacity, а serialized reconciliation path.


Dependency updates

Workspace, Model, Gateway и Task должны иметь понятную propagation semantics. Если Task уже запущен, изменение shared object не обязано мгновенно и безопасно менять его runtime. В production лучше использовать versioned/immutable references и deliberate rollout, чем «магическое live mutation».


Operational truth hierarchy

При инциденте идём сверху вниз: client request -> API persisted desired state -> controller event/reconcile -> Substrate Actor/Worker -> runner -> child process -> MCP/model dependency -> final external effect. Это снижает риск диагностировать LLM, когда на самом деле controller не обработал spec.

State ownership: четыре хранилища отвечают за разные истины




Readiness hierarchy: each green light proves only its own layer



Substrate snapshots: ownership, storage и совместимость

Snapshot ownership: URI lifetime matters for clones and garbage collection



Snapshot - объект с владельцем и contract, а не просто файл

Substrate связывает snapshot с Actor/Tag и ActorTemplate identity. Для external storage полезно понимать логическую структуру пути: отдельные namespaces/atespaces, actor UID и snapshots, а также tag-owned copies. Storage layout - часть runtime contract, но приложение не должно напрямую модифицировать эти объекты.

Кто владеет snapshot

У Actor есть текущий snapshot, который заменяется после следующего успешного suspend. Tag может удерживать собственную копию дольше lifecycle исходного Actor. Clone, созданный из Tag, способен временно использовать borrowed snapshot до своего первого успешного suspend, после чего получает собственный state lineage.

Template compatibility

Snapshot содержит связь с ActorTemplate UID. При несовместимом template runtime может восстановить durable data, но выполнить fresh boot guest/process environment вместо полного memory resume. Это правильное поведение: восстановление RAM поверх другого runtime image может быть физически некорректным.

Dirty state и consistency

Прежде чем считать snapshot консистентным, нужно понимать, что происходило с filesystem buffers, database clients, sockets и внешними транзакциями. Memory checkpoint может зафиксировать process в момент, когда удалённая транзакция уже committed, а локальный

response ещё не обработан. Поэтому external side effects всё равно требуют idempotency ledger.

Storage performance

Resume latency складывается не только из orchestration. Важны metadata lookup, object-store RTT, snapshot size, available bandwidth, decompression/page-fault strategy, worker locality и concurrent restores. Headline «sub-second resume» нельзя превращать в universal SLO без собственного benchmark.

Integrity и encryption

Snapshot потенциально содержит secrets, plaintext tokens, retrieved data и process memory. Object storage должен обеспечивать encryption at rest, tenant isolation, integrity checking, scoped credentials и lifecycle deletion. Backup retention и snapshot retention - разные policies.

Golden snapshot


Golden snapshot должен быть максимально детерминированным: runtime packages, runner, base workspace preparation. Long-lived user secrets лучше inject после restore/start, а не bake в golden image/snapshot. Иначе rotation становится дорогой, а compromise snapshot затрагивает весь population.

Snapshot != backup

Snapshot оптимизирует runtime resume. Backup обеспечивает восстановление после потери control state/storage/cluster. Production DR должен отдельно сохранять declarative manifests, control-plane DB/Redis/PostgreSQL, object storage и внешние source-of-truth данные.

Gateway и egress: DNS, TLS и проверка реальной доступности

Gateway validation: test DNS, transport, TLS and application outcome separately



GatewayReady не означает, что приложение дошло до API

Network policy может быть syntactically valid и reconciled, но реальный connection ломается на DNS, route, TCP, TLS, SNI, proxy или application authorization. Поэтому readiness policy object - только один слой evidence.

Hostname allowlist сложнее CIDR

Hostname policy требует решить, кто резолвит имя, как долго кешируются IP, что делать с несколькими A/AAAA, CDN rotation и DNS rebinding. Если enforcement происходит на IP layer, результат DNS должен корректно и безопасно обновлять allowed destinations. Если на L7/TLS layer - нужен корректный SNI/hostname matching.

TLS chain

Минимальная диагностика из sandbox:

```
getent ahosts api.example.com
nc -vz api.example.com 443
openssl s_client -connect api.example.com:443 -servername api.example.com </dev/null
curl -sv https://api.example.com/health
```

Первые команды последовательно проверяют resolver, TCP reachability, TLS/SNI/certificate chain и HTTP/application. Это быстрее, чем сразу менять Gateway manifest.

Negative tests обязательны

После разрешения `model.internal:443` проверьте не только успешный call туда, но и отсутствие доступа к запрещённому control endpoint, metadata service, RFC1918 ranges и произвольному Internet host. Security acceptance test должен доказывать и allow, и deny.

Dependencies надо инвентаризировать

Agent image может обращаться не только к model API: Git, package mirrors, OAuth/OIDC, MCP servers, DNS, NTP, artifact registry, telemetry collector. Runtime package installation в production Task часто превращает tight egress policy в allow-all. Лучше собирать immutable images заранее.

MCP gateway


Для большого числа external MCP/API endpoints полезен controlled egress proxy/gateway: central auth, destination allowlist, rate limits, audit, DLP и credential brokering. Тогда sandbox знает только один restricted endpoint, а не получает десятки raw secrets.

Incident flow

Проверяйте: Gateway desired/status -> DNS result -> policy target -> route -> TCP -> TLS/SNI -> HTTP -> application auth -> MCP/model protocol. AX issue с hostname Gateway/TLS на ранней версии - хороший пример того, почему каждый слой нужно тестировать отдельно.

Local inference sizing: память GPU, parallelism и эксплуатационные SLO

Tensor parallelism: extra GPUs add communication, not just VRAM



VRAM - это не только веса модели

Приближённый бюджет GPU memory состоит из: weights + KV cache + activations/workspaces + CUDA/runtime allocations + fragmentation/reserve. Поэтому модель, чьи quantized weights «влезает в 24 GB», ещё не гарантирует нормальный serving при длинном context и concurrency.

KV cache зависит от workload

KV pressure растёт с количеством одновременно активных sequences и их фактической длиной context. Для sizing собирайте распределение input/output tokens, а не один `max_model_len`. Если 99% запросов имеют 4k tokens, резервировать поведение как при 128k для каждого slot может быть слишком дорого.

Tensor parallelism

Tensor parallel делит вычисления слоя между GPU и требует collective communication практически на каждом decode step. На NVLink/NVSwitch это одна экономика, на PCIe - другая. Добавление второй GPU может быть необходимо для capacity, но не обязательно удваивать tokens/s и иногда ухудшает latency для небольшой модели.

Pipeline и data parallel

Pipeline parallel полезен, когда модель не помещается на одном устройстве/TP domain, но вводит bubbles и complexity. Data parallel/replicas часто проще для независимых запросов, если модель целиком помещается на одной GPU. Выбор определяется model fit, topology и SLO.

CPU fallback

llama.cpp/ GGUF позволяет построить воспроизводимый CPU-only lab и аварийный low-throughput path. Но CPU fallback не следует считать равнозначным GPU production endpoint: TTFT и decode latency могут изменить поведение timeouts всего agent harness.

vLLM knobs

Memory utilization, max model length, max concurrent sequences, batching/scheduling и parallelism flags должны документироваться **по конкретной версии vLLM**. Не копируйте tuning command из старой статьи без сверки `--help` и release docs.

OpenAI-compatible != identical

Совместимость endpoint означает похожий API surface, но не гарантирует одинаковые параметры, tool-call semantics, structured output, token accounting или error codes. Model adapter должен иметь provider-specific capability tests.

SLO сначала, GPU потом


Для agent platform определите: допустимый TTFT, p95 end-to-end model latency, target concurrent active generations, peak prompt tokens/s, output tokens/s, max queue delay и availability. Только после этого выбираются model size, quantization и GPU topology.

Интеграция с АХ

Model endpoint лучше предоставлять через стабильный internal service URL. Agent Task не должен знать физический GPU host. Observability связывает Task/Actor ID с inference request ID, чтобы можно было отличить «агент завис» от «10 секунд стоял в model queue».

Production security, secrets и disaster recovery

Disaster recovery: backup sets are interdependent and external side effects remain



Классифицируйте secrets по назначению

Разделяйте control-plane credentials, model API keys, MCP/service credentials, registry pull secrets, user delegated tokens и infrastructure admin secrets. Один универсальный secret для всех Tasks уничтожает tenant isolation.

Injection time имеет значение

Статический secret в image - худший вариант. Лучше short-lived credential при start/resume или on-demand exchange через broker/проxy. Тогда suspend длительностью сутки не означает, что проснувшийся agent продолжит использовать credential, срок/полномочия которого уже изменились.

Rotation после resume

Harness должен предполагать, что credential после длительного сна истёк. Resume path включает refresh/re-auth, а не только повтор старого request. Ошибка 401 после resume должна маршрутизироваться в credential recovery, а не в бесконечный LLM retry.

Tenant boundary

Namespace сам по себе не является полной multi-tenant security boundary. Нужны RBAC, service accounts/workload identity, NetworkPolicy/egress, sandbox isolation, secret scope, storage isolation и audit. Для hostile code выбирается более сильный sandbox class.

Что резервировать

Минимальный backup set: pinned manifests/Helm values, AX control state, Substrate dynamic state database, snapshot/object storage, PKI/identity configuration, registry references и external system mappings. Git repositories и CRM/CMDB могут быть отдельными authoritative systems и не дублироваться без необходимости.

RPO/RTO по слоям

Не задавайте одно RPO «для AX». Desired manifests могут иметь RPO почти ноль в Git, Redis/PostgreSQL - минуты, snapshots - часы, transient logs - вообще не восстанавливаться. RTO control plane и RTO каждого dormant Actor также разные.

Recovery order

Типовой порядок: identity/PKI -> Kubernetes core -> durable DB/object storage -> Substrate control plane -> WorkerPools -> AX state/control plane -> model/MCP dependencies -> workload resume. Если начать поднимать Actors до восстановления policy/identity, можно получить функционально работающую, но небезопасную систему.

External side effects не откатываются из backup


Восстановление Task к старому checkpoint не отменит уже созданный тикет, отправленное письмо или применённую сетевую конфигурацию. Поэтому ledger external actions и idempotency keys должны переживать disaster recovery.

DR drills

Проверяйте как минимум: loss одного worker, loss Kubernetes node, restart Redis/PostgreSQL, temporary object-store outage, restore control plane в новый cluster, недоступный model endpoint и восстановление task state при уже совершённом external action.

Operations runbook: диагностика по слоям и release acceptance

Troubleshooting ladder: идите от физического слоя к agent logic



Не начинайте инцидент с restart всего кластера

Сначала сохраните evidence: Task manifest/status, generation/conditions, controller lag/logs, Actor/Worker assignment, runner health, child process state, Gateway/DNS test, model request ID, MCP call ID и последние внешние side effects. Restart может удалить самую полезную информацию.

Слой 1 - Kubernetes/infrastructure

```
kubectl get nodes -o wide
kubectl get pods -A -o wide
kubectl get events -A --sort-by=.lastTimestamp
kubectl top nodes
kubectl top pods -A
```

Проверяем pressure, scheduling, image pulls, storage/network и crash loops.

Слой 2 - Substrate

Проверяем WorkerPool capacity, Actor phase/assignment, snapshot URI/compatibility, resume errors, object-store reachability и atele/atecontroller logs. Если Actor не получил Worker, AX runner ещё вообще не участвует в проблеме.

Слой 3 - AX

Сверяем desired Task generation, controller reconcile/error/backlog, referenced Workspace/Model/Gateway, conditions и suspend/resume transition. Current-main split `ax-server/ax-controller` означает, что API может быть доступен при сломанном reconciliation.

Слой 4 - runner/workload

`/healthz` отвечает на вопрос о runner, `/readyz` - о readiness contract, но отдельно проверяется child process и task-specific progress heartbeat. Из debug Task полезны `ps`, `environment metadata`, `/workspace contents` и DNS/network probes.

Слой 5 - MCP/network/model

Проверяем DNS -> TCP -> TLS -> HTTP/protocol; затем auth, rate limit и server-side operation status. Для inference сравниваем queue time, TTFT, decode throughput, KV/VRAM pressure и OOM/eviction events.

Слой 6 - agent logic

Только после инфраструктурных проверок анализируем prompt/context, tool schema, retry loop, planning и memory. Это предотвращает типичную ошибку: «тюнинговать prompt», когда MCP endpoint просто не резолвится.

Failure taxonomy

Используйте категории: desired-state admission, reconciliation, placement/capacity, restore/snapshot, runner/bootstrap, dependency/network, inference, tool authorization, external side effect, agent reasoning. Incident tag по слою облегчает статистику повторяемости.

Release acceptance suite

Перед обновлением AX/Substrate прогоните pinned набор: create simple Task; Workspace Git bootstrap; MCP read; denied write; approved idempotent write + verification; suspend/resume with durable file; worker loss; forbidden egress; model call; child-process exit; snapshot restore; backup/restore control state. Результаты сохраняйте вместе с exact versions/commits.

Post-incident

Фиксируйте timeline, root layer, detection gap, unsafe retry/approval opportunities, lost observability и конкретный regression test. Для быстро меняющегося pre-1.0 stack regression suite важнее предположения «minor update ничего не ломает».

Приложение А. Аудит проектов и выявленные расхождения

A.1 AX

Release baseline: v0.3.1, commit e70162a, release 25.09.2026.

Current API family: ax.io/v1alpha1.

Stability: project explicitly warns about breaking changes before stable.

Ключевые факты current documentation/source audit:

- README описывает четыре user primitives: Task, Workspace, Gateway, Model.
- docs/manifests.md в current crawl говорит «all four kinds», но видимая часть документа подробно показывает Task/Workspace/Model; Gateway лучше проверять по README/examples/API, а не по одной странице.
- cmd/ax-controller существует и читает Redis stream consumer group, создавая TaskReconciler с Substrate client.
- DESIGN.md всё ещё описывает reconciliation внутри ax-server. Это documentation drift.
- Runner всегда PID 1 и restart после resume видит durable /workspace, но новое process tree.
- Current known issues показывают полезные ограничения: readiness может не отражать exit child command; workspace clone мог завершаться «успешно» при пустом repo; hostname Gateway/TLS имел bug; ssh/control-plane auth вопросы меняются.

Вывод: production runbook должен ссылаться на pinned release и regression tests, а не только на main docs.

A.2 Agent Substrate

Release baseline: v0.3.0, commit ccecc78, release 30.09.2026.

Status: pre-1.0; API compatibility не гарантирована.

Ключевые факты:

- Quickstart использует Kind и может разворачивать PostgreSQL/RustFS локально.
- WorkerPool - Kubernetes-side physical capacity; ActorTemplate/Actor/Worker dynamic state относится к Substrate API/state store.
- Current architecture использует PostgreSQL для dynamic control state и object storage для snapshots.
- gVisor и microVM - разные sandbox classes.
- Golden snapshot и Tag ownership - важная часть clone/resume semantics.
- Architecture document содержит прямое предупреждение, что часть design aspirational.

- v0.2.0/v0.3.0 быстро усиливали multi-actor networking, egress, identity, authorization/observability, поэтому старые статьи быстро устаревают.

A.3 MCP

Для книги принята specification 2026-07-28, потому что она меняет базовый mental model: stateless core, server/discover, request metadata versioning, новый subscription mechanism и изменения authorization/deprecations. Материалы 2024-2025 про обязательный initialize/session flow нужно читать как legacy compatibility, а не current normative behavior.

Приложение B. Production readiness checklist

Platform

- ☐ AX/Substrate/container images pinned по digest/tag.
- ☐ Compatibility matrix проверена в staging.
- ☐ Redis/PostgreSQL persistence и backup протестированы restore drill'ом.
- ☐ Object storage durability/throughput/retention проверены.
- ☐ WorkerPool headroom измерен burst benchmark'ом.
- ☐ Registry и DNS имеют понятные failure modes.

Security

- ☐ Default-deny egress; wildcard отсутствует вне исключений.
- ☐ Debug/SSH disabled by default.
- ☐ Scoped short-lived tool credentials.
- ☐ MCP servers/skills/repositories проходят allowlist/review.
- ☐ Write/destructive tools требуют policy/approval.
- ☐ Sandbox backend выбран по threat model.
- ☐ Control-plane API закрыт perimeter/authn/authz.
- ☐ Audit logs нельзя изменить workload'у.

Agent

- ☐ Max steps/tokens/wall time заданы.
- ☐ Retry limits и idempotency strategy заданы.
- ☐ Durable state не существует только в prompt/RAM.
- ☐ Child task depth/count budget задан.
- ☐ Tool calls имеют schema validation.
- ☐ Post-action verification есть для writes.

Observability

- ☐ Trace связывает user/job → Task → Actor → tool/model request.
- ☐ TTFT/ITL/queue/KV metrics собираются.
- ☐ Suspend/resume/snapshot metrics собираются.
- ☐ Central logs переживают Worker relocation.
- ☐ Alerts основаны на SLO, а не только CPU.

Приложение С. Карта источников

Основные первичные источники, использованные для аудита:

1. Google AX repository: <https://github.com/google/ax>
2. AX README: <https://github.com/google/ax/blob/main/README.md>
3. AX DESIGN: <https://github.com/google/ax/blob/main/DESIGN.md>
4. AX concepts: <https://github.com/google/ax/blob/main/docs/concepts.md>
5. AX manifests: <https://github.com/google/ax/blob/main/docs/manifests.md>
6. AX runner: <https://github.com/google/ax/blob/main/docs/runner.md>
7. AX roadmap: <https://github.com/google/ax/blob/main/docs/roadmap.md>
8. AX current controller source: <https://github.com/google/ax/blob/main/cmd/ax-controller/main.go>
9. AX issues: <https://github.com/google/ax/issues>
10. Agent Substrate repository: <https://github.com/agent-substrate/substrate>
11. Substrate architecture: <https://github.com/agent-substrate/substrate/blob/main/docs/architecture.md>
12. Substrate API guide: <https://github.com/agent-substrate/substrate/blob/main/docs/api-guide.md>

13. Substrate observability: <https://github.com/agent-substrate/substrate/blob/main/docs/observability.md>
14. Substrate threat model: <https://github.com/agent-substrate/substrate/blob/main/docs/threat-model.md>
15. Kubernetes Concepts: <https://kubernetes.io/docs/concepts/>
16. Kubernetes Custom Resources: <https://kubernetes.io/docs/concepts/extend-kubernetes/api-extension/custom-resources/>
17. gVisor: <https://gvisor.dev/docs/>
18. MCP specification 2026-07-28: <https://modelcontextprotocol.io/specification/2026-07-28>
19. MCP release notes: <https://blog.modelcontextprotocol.io/posts/2026-07-28/>
20. vLLM docs: <https://docs.vllm.ai/>
21. vLLM releases: <https://github.com/vllm-project/vllm/releases>
22. llama.cpp: <https://github.com/ggml-org/llama.cpp>
23. Kind: <https://kind.sigs.k8s.io/>
24. K3s: <https://docs.k3s.io/>
25. kubeadm: <https://kubernetes.io/docs/setup/production-environment/tools/kubeadm/>

Веб-документация была проверена 03.10.2026. Для быстро меняющихся `main` страниц это дата среза, а не гарантия неизменности.