

AX & Agent Infrastructure

Практическое руководство по архитектуре и эксплуатации AI-агентов



LLM • Agent Harness • MCP • Agent Substrate • Google AX • Local Inference • Security • Observability

Independent technical guide

Содержание

Книга построена от фундаментальных mental models к AX/Substrate и затем к эксплуатации. Ссылки кликабельны в PDF.

0. Как читать эту книгу и что именно зафиксировано

1. Карта современной агентной системы: от модели до кластера

2. LLM как вычислительный компонент агентной системы

3. Что такое агент: цикл, границы и критерии остановки

4. Agent harness: система вокруг LLM

5. Context, state, memory и snapshot: не смешивать

6. Tools, MCP и Skills

7. Multi-agent архитектуры без лишней магии

8. От Linux process к gVisor и microVM

9. Kubernetes: необходимый минимум для понимания AX/Substrate

10. Control plane и distributed systems: база без академической перегрузки

11. Actor model применительно к агентным workload

12. Agent Substrate: назначение и operational architecture

13. Substrate resources: Atespace, WorkerPool, ActorTemplate, Actor, Tag

14. Suspend, snapshot, resume и golden snapshot

15. Substrate networking: routing, wake-up и egress

16. AX: архитектура control plane и реальная граница с Substrate

17. AX primitives: Task, Workspace и Model без магии

18. Runner: PID 1 как платформенный контракт, а не просто entrypoint

19. Task lifecycle в AX: synchronous reconciliation, состояния и recovery

20. Local inference: CPU, GPU, vLLM и llama.cpp

21. Производительность inference: что измерять для 10-15+ агентов

22. Multi-agent на AX: как делегировать без task explosion

23. Security architecture: threat model agent platform

24. Identity, authorization и Human-in-the-loop

25. Observability: четыре слоя и единая correlation identity

26. Лабораторный стенд на Proxmox/KVM: Kind, k3s или kubeadm

27. Production engineering: HA, persistence, upgrades и DR

28. Performance и scaling: что реально ограничивает систему

29. Failure modes и troubleshooting handbook

30. Когда AX нужен, а когда проще другой инструмент

31. Антипаттерны

32. Практикум: 14 последовательных лабораторных работ

33. Две референсные multi-agent архитектуры

34. Mental models, glossary и cheatsheets

35. Context engineering: управление контекстом и durable state

36. MCP 2026: протокол, discovery, transport и trust boundaries

37. Безопасное выполнение tools: idempotency, approvals и attenuation полномочий

38. AX control plane: state, event flow и operational truth

39. Substrate snapshots: ownership, storage и совместимость

40. Gateway и egress: DNS, TLS и проверка реальной доступности

41. Local inference sizing: память GPU, parallelism и эксплуатационные SLO

42. Production security, secrets и disaster recovery

43. Operations runbook: диагностика по слоям и release acceptance

Приложения: аудит, checklist, источники

Как читать эту книгу и что именно зафиксировано

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

Эта книга построена не как пересказ README, а как инженерный учебник: сначала даётся mental model, затем ровно та фундаментальная база, без которой конкретный механизм AX или Agent Substrate превращается в «магический чёрный ящик», после чего идут эксплуатационные выводы и практика. Целевая аудитория - системные и сетевые инженеры, архитекторы инфраструктуры и разработчики платформ, которым важнее **развернуть, наблюдать, ограничивать и диагностировать агентные workload'ы**, чем изменять внутренний Go-код проекта.

Версионная база

Для воспроизводимости основной слой книги фиксируется на релизах:

Компонент	Базовая версия	Зафиксированный commit	Дата релиза	Как используем
Google AX	v0.3.1	e70162a	25.09.2026	основной release baseline
Agent Substrate	v0.3.0	csecc78	30.09.2026	основной release baseline
MCP	2026-07-28	версия спецификации	28.07.2026	протокольная база
vLLM	v0.30.0	release	22.09.2026	пример GPU inference
llama.cpp	v0.4.1 + rolling builds	release	14.09.2026	CPU/hybrid fallback

При этом `main` AX/Substrate исследован отдельно. Это необходимо, потому что оба проекта меняются быстрее обычной инфраструктурной документации. Например, current AX README уже описывает Gateway и отдельный ax-controller, в то время как часть DESIGN.md всё ещё показывает reconciliation внутри ax-server. Такие расхождения не надо «усреднять»: их надо отмечать.

В книге используются четыре метки:

- **IMPLEMENTED** - подтверждено базовой или текущей реализацией и официальной документацией.
- **MAIN DELTA** - уже есть в `main`, но могло появиться после выбранного релиза.
- **ROADMAP** - объявлено разработчиками как направление, но не должно приниматься за доступную production-функцию.

- **BACKGROUND** - общая инженерная база или рекомендуемый pattern, а не обещание AX.

Главная оговорка

AX и Substrate - pre-stable системы. AX использует `ax.io/v1alpha1`, а Substrate прямо предупреждает о быстрых breaking changes. Поэтому любые production-планы должны начинаться с pinning версий, проверки совместимости и отдельного test environment. В этой книге команды лабораторных работ являются **шаблонами воспроизводимого стенда**, но перед применением в реальной инфраструктуре необходимо сверять release notes выбранных версий.

Что книга намеренно не делает


Она не заменяет полноценный курс Kubernetes, не погружается в математику Transformer'ов и не проводит строчный аудит Go-кода. Если механизм можно понять и эксплуатировать, не разбирая конкретную реализацию до функции и struct, мы остаёмся на архитектурном уровне. И наоборот: runner, lifecycle, snapshots, Gateway и trust boundaries разбираются глубоко, потому что ошибки именно здесь дают эксплуатационные и security-инциденты.

Источники и дальнейшее чтение

- [AX repository](#)
- [AX README](#)
- [AX roadmap](#)
- [Substrate repository](#)
- [Substrate architecture](#)

Карта современной агентной системы: от модели до кластера

Карта стека: где заканчивается LLM и начинается инфраструктура



Представим не демонстрационного чат-бота, а рабочую инженерную задачу. Ночью часть клиентов теряет доступ к сервису. Дежурный инженер просит агента собрать метрики, проверить DNS и TLS, сопоставить событие с последним изменением конфигурации, предло-

жить безопасное исправление и после подтверждения выполнить его. На экране это может выглядеть как один диалог. Внутри участвует целая система.

Кто-то должен принять цель и определить границы работы. Кто-то — собрать контекст для модели. Кто-то — дать модели список доступных инструментов. До выполнения команды необходимо проверить полномочия, объект воздействия и необходимость подтверждения. После вызова инструмента нужно сохранить результат, отличить временную ошибку от окончательной, решить, продолжать ли работу, и не повторить уже выполненное изменение. Сам процесс должен где-то запуститься, получить CPU и память, доступ к нужным файлам и сети, но не получить доступ ко всему кластеру. Если работа прервётся, её состояние потребует восстановления. Все действия должны остаться в журналах и трассировках.

Большая языковая модель решает лишь часть этой задачи. Она способна проанализировать переданный ей контекст, сформулировать следующий шаг или предложить вызов инструмента. Всё остальное создаётся вокруг неё. Поэтому первая полезная привычка при проектировании агентных систем — не называть словом «агент» весь стек целиком.

Одно слово скрывает несколько разных систем

В повседневной речи агентом могут назвать и prompt с циклом, и Python-программу, и контейнер, и Task в AX, и всю multi-agent платформу. Пока система работает, такая неточность кажется безобидной. Во время проектирования или инцидента она мешает определить владельца проблемы.

Удобнее разделять систему на уровни ответственности.

Уровень	Главный вопрос	Примеры обязанностей
LLM / inference	Как получить вероятностное решение или текст?	generation, structured output, tool proposal, embeddings
Agent loop и harness	Как превратить отдельные вызовы модели в управляемую работу?	context assembly, tools, state, policy, budgets, retries, stop conditions
Agent framework	Как описать сложную логику и координацию?	граф состояний, planner/executor, supervisor/worker, fan-out/fan-in
Orchestrator	Как управлять множеством отдельных выполнений?	создание, наблюдение, приостановка, возобновление, удаление, quotas
Execution runtime	Где и с какими гарантиями выполняется workload?	sandbox, process lifecycle, workspace, snapshots, routing
Infrastructure	На каких физических и кластерных ресурсах всё работает?	Linux, Kubernetes, nodes, storage, network, GPU
External systems	Где происходят реальные действия и хранится бизнес-состояние?	Git, CMDB, router API, ticket system, database, cloud API

Границы могут проходить немного иначе в разных продуктах. Важно не название слоя, а явное распределение обязанностей. Если retry одновременно реализован в model client,

harness, очереди, orchestrator и внешнем proxy, одна временная ошибка способна породить несколько одинаковых действий. Если ни один слой не считает себя владельцем retry, задача остановится после первого сетевого сбоя.

Соглашение терминов этой книги

Одни и те же слова часто используют для разных уровней системы. Дальше книга придерживается следующего соглашения:

Термин	Что он означает в этой книге
задача	Пользовательская или бизнес-цель: что должно измениться или какой результат нужно получить.
run	Одно логическое выполнение harness: последовательность состояний от принятия цели до завершения, ожидания или ошибки.
Task	Долговечная единица orchestration. В AX это конкретный ресурс со своим spec, status и lifecycle.
execution	Физическая попытка выполнить run или Task: process, container, Actor placement или другой workload instance.
coordinator	Прикладная роль: декомпозирует цель, делегирует части работы, собирает evidence и решает, выполнена ли бизнес-задача.
orchestrator	Инфраструктурный слой: размещает workloads, управляет их lifecycle, ресурсами, restart и recovery.
validation	Проверка формы, schema, аргументов, полномочий и preconditions до действия.
verification	Проверка фактического результата во внешней системе после действия.

Перезапуск process создаёт новое execution, но не обязан создавать новый run или Task. Coordinator отвечает за смысл работы, orchestrator - за надёжное выполнение выделенной единицы. Validation отвечает на вопрос «можно ли и корректно ли вызвать операцию?», verification - «получен ли требуемый результат?».

Что на самом деле делает LLM

LLM получает конечную последовательность токенов и вычисляет вероятное продолжение. Современный model API может вернуть обычный текст, структурированный объект или предложение вызвать инструмент. Модель может написать:


```
{
  "tool": "restart_service",
  "arguments": {
    "service": "edge-gateway",
    "region": "eu-1"
  }
}
```

Этот ответ ещё не является перезапуском. Он выражает решение модели на основании того контекста, который ей показали. Модель сама по себе не доказывает, что сервис существует, что регион выбран правильно, что пользователь имеет соответствующие полномочия, что изменение разрешено сейчас и что такой вызов не был выполнен минуту назад.

Между предложением модели и реальным воздействием должна находиться обычная проверяемая программа. Она валидирует `schema` и значения, определяет требуемое разрешение, запрашивает `approval`, добавляет `idempotency key`, вызывает инструмент, сохраняет внешний идентификатор операции и затем проверяет результат. Фраза в `system prompt` «не перезапускай `production` без разрешения» полезна как инструкция модели, но не является технической границей безопасности.

Поэтому LLM разумно считать заменяемым вычислительным компонентом. Она помогает выбирать следующий шаг, классифицировать данные, строить гипотезы и формировать объяснения. `Authoritative state`, полномочия и подтверждение `side effects` должны находиться вне неё.

Когда появляется агент

Минимальный агент возникает тогда, когда отдельные вызовы модели соединяются в цикл обратной связи:

```
получить цель
  ↓
прочитать состояние и наблюдения
  ↓
собрать контекст
  ↓
получить решение модели
  ↓
проверить и выполнить действие
  ↓
зафиксировать результат
  ↓
продолжить, приостановиться или завершить работу
```

В этом цикле могут присутствовать и полностью детерминированные ветви. Например, превышение бюджета не обсуждается с моделью: программа завершает задачу. Операция, требующая подтверждения, переводит работу в состояние `WaitingForApproval`. Повторный ответ внешней системы с тем же `operation ID` не должен восприниматься как новое действие.

Чтобы цикл был эксплуатационно пригодным, для него необходимо определить как минимум:

- цель и входные данные;
- допустимые действия;
- текущее состояние;
- правила формирования контекста;
- бюджеты времени, токенов и шагов;
- обработку ошибок и повторов;
- критерии остановки;
- место хранения результатов;
- правила выполнения внешних изменений;
- способ наблюдения и аварийной остановки.

Программа с одним вызовом модели может быть полезной, но ей не обязательно становиться агентом. Если задача решается детерминированным parser, SQL-запросом или обычным workflow, добавление цикла с LLM увеличит стоимость и число вариантов отказа, не дав полезной адаптивности.

Harness: система, которая делает цикл управляемым

Agent harness — это программный слой вокруг модели, который реализует цикл агента и превращает вероятностные ответы в контролируемое выполнение. Это не обязательно отдельный продукт. Для небольшого агента harness может быть несколькими модулями собственного приложения. Для сложной платформы — большим набором сервисов и библиотек.

У harness обычно есть несколько обязанностей.

Context assembly решает, что попадёт в следующий model request: system policy, цель, актуальное состояние, недавняя история, найденные документы и результаты инструментов. Он же должен не допустить, чтобы случайный README или ответ внешнего MCP server получил тот же уровень доверия, что и platform policy.

Model adapter скрывает технические различия model providers и локальных inference servers: форматы сообщений, tool schemas, streaming, лимиты, ошибки, timeouts и метрики. Замена модели не должна требовать переписывания всей бизнес-логики.

Tool executor принимает предложение модели, валидирует аргументы и выполняет реальный вызов. Он связывает запрос модели с operation ID, timeout, журналом и результатом.

State manager хранит progression задачи. В нём находятся факты, уже принятые решения, открытые вопросы, выполненные side effects и данные, необходимые после перезапуска.

Policy и approval layer определяет, может ли действие быть выполнено. Read-only запрос метрик и изменение маршрутизации — разные классы полномочий, даже если оба представлены как tools.

Budget и retry control ограничивает число шагов, время, стоимость и глубину делегирования. Он отличает повтор безопасного чтения от повтора операции, которая могла уже изменить внешнюю систему.

Observability связывает task ID, model request, tool call, approval и внешний operation ID. Без такой корреляции инженер видит пять разрозненных журналов и не может восстановить ход работы.

Termination logic отвечает на неудобный, но обязательный вопрос: когда работа завершена? Ответ модели «готово» недостаточен. Критерий должен проверяться по результату: тесты прошли, устройство вернуло ожидаемую конфигурацию, артефакт создан, итог подтверждён независимым чтением.

Harness управляет шагами внутри одного выполнения. Он не обязан создавать контейнеры, выбирать Kubernetes node или восстанавливать sandbox после потери Worker. Эти задачи относятся к другим слоям.

Harness и agent framework — не синонимы

Agent framework предоставляет готовые абстракции для построения логики: граф состояний, роли, messages, planner/executor, supervisor/worker, сохранение checkpoints или интеграции с tools. Harness — эксплуатационная оболочка, которая должна существовать независимо от того, используется framework или нет.

Framework может стать частью harness, но не заменяет автоматически policy enforcement, секреты, сетевую изоляцию, бюджеты или end-to-end observability. И наоборот, простой агент иногда не нуждается в тяжёлом framework. Цикл из нескольких явно написанных состояний легче проверить и сопровождать, чем универсальный граф, если задача небольшая и хорошо определена.

Выбирать framework стоит, когда его модель действительно совпадает с задачей: требуется ветвящийся workflow, долговременное состояние, человеческие подтверждения, повторное выполнение отдельных узлов или сложная координация ролей. Если нужен один model call, три deterministic проверки и один API-запрос, собственный небольшой harness обычно прозрачнее.

Tools и MCP: доступ к возможностям, а не передача власти модели

Tool — это операция, которую harness умеет предложить модели и затем выполнить. MCP стандартизует способ обнаружить такие возможности и обмениваться запросами с внешними серверами. Ни tool schema, ни MCP сами по себе не решают вопрос доверия.

Рассмотрим диагностический MCP server. Он предлагает tools `get_interface_counters` и `set_interface_state`. Первый читает telemetry, второй меняет состояние порта. Если агенту передать оба инструмента с одними и теми же credentials, различие между чтением и изменением останется лишь в описании, которое видит модель. Надёжная система выдаёт раз-

ные capabilities, проверяет объект и scope операции, требует approval для write и использует короткоживущие полномочия.

Результат tool call также нельзя автоматически считать истинным. Сервер может вернуть устаревшие данные, ошибку внутри поля `result`, неполный ответ или вредоносный текст. Harness сохраняет provenance: какой источник дал факт, когда он был получен и каким запросом. Внешнее действие завершается не успешным HTTP-ответом, а проверкой intended outcome.

Состояние существует сразу в нескольких местах

Фраза «агент помнит задачу» слишком неоднозначна. В реальной системе есть несколько типов состояния.

Model context — токены конкретного запроса. Он ограничен и пересобирается.

Working state — текущая стадия задачи, накопленные факты, план, счётчики и ожидаемые события.

Persistent memory — долговременные записи, которые можно найти и использовать позже.

Workspace — файлы, репозитории, конфигурация инструментов и создаваемые артефакты.

Process state — память и открытые ресурсы конкретного процесса.

Runtime snapshot — технический checkpoint, который runtime способен сохранить для ускоренного resume.

External state — реальные изменения в Git, базе, тикетной системе или сетевом устройстве. Он не откатывается восстановлением локального snapshot.

Это различие определяет архитектуру восстановления. Если процесс запускается заново, working state должен быть прочитан из durable store или workspace. Если восстанавливается RAM image, внешнее TCP-соединение всё равно может оказаться закрытым, а token — просроченным. После любого resume программа обязана перепроверить внешние предположения.

Orchestrator управляет выполнениями, а не мыслями модели

Когда один harness нужно запускать много раз, появляется следующий класс задач:

- создать изолированное выполнение;
- назначить ему ресурсы и Workspace;
- выдать секреты и сетевые правила;

- отслеживать lifecycle;
- приостанавливать idle workload;
- восстанавливать его по событию;
- ограничивать число дочерних задач;
- удалять завершённые окружения;
- связывать их журналы и стоимость.

Это обязанности orchestrator и execution runtime. Они не должны зависеть от конкретного reasoning pattern агента. Один Task может запускать собственный Python harness, CLI-agent или приложение на framework. Платформа управляет workload, но не обязана понимать внутренний plan модели.

Multi-agent система добавляет ещё один уровень. Coordinator может создать Researcher, Diagnostic и Validator, но техническая возможность создать дочерний Task не отвечает на вопросы: кто имеет право делегировать, какой максимальный depth дерева, кто наследует credentials, как отменяются дочерние работы и что происходит при частичном успехе. Эти правила относятся к harness/governance и orchestrator contract одновременно, поэтому граница должна быть явной.

Runtime и sandbox отвечают за место выполнения

Контейнер упаковывает приложение и его зависимости, но сам по себе не определяет всю security model. Для agent workload важны:

- изоляция процессов и файловой системы;
- CPU, память и disk quotas;
- capabilities и системные вызовы;
- доступ к секретам;
- разрешённые сетевые направления;
- lifecycle дочерних процессов;
- durable и ephemeral storage;
- способ диагностики;
- поведение при suspend/resume;
- очистка после завершения.

Обычный container может быть достаточен для доверенного внутреннего агента с read-only инструментами. Для выполнения непроверенного кода из пользовательского репозитория граница может потребовать gVisor или microVM. Более сильная изоляция обычно означает дополнительную сложность, ограничения совместимости и стоимость запуска. Правильный выбор зависит от threat model, а не от моды.

Kubernetes находится ещё ниже. Он управляет nodes, Pods, Services, volumes и инфраструктурными политиками. Kubernetes не знает, что процесс внутри Pod выполняет agent loop,

ожидает approval или исчерпал token budget. Специализированная платформа использует Kubernetes там, где сильны его механизмы, и добавляет agent-aware lifecycle выше.

Сквозной путь одной задачи

Вернёмся к инциденту с недоступностью сервиса.

1. Пользователь или automation создаёт задачу и задаёт допустимый score.
2. Orchestrator создаёт execution и связывает его с Workspace, моделью и политикой.
3. Runtime назначает sandbox, подготавливает filesystem, identity и network access.
4. Runner запускает команду агента и сообщает readiness.
5. Harness загружает objective и durable state, затем собирает первый context.
6. LLM предлагает собрать telemetry.
7. Policy разрешает read-only tools; executor вызывает MCP server.
8. Harness сохраняет observations и provenance, после чего модель формирует гипотезу.
9. Модель предлагает изменение. Policy переводит задачу в ожидание approval.
10. После подтверждения executor выполняет idempotent write с ограниченной capability.
11. Отдельное чтение проверяет реальное состояние системы.
12. Harness завершает работу и создаёт итоговый отчёт.
13. Orchestrator сохраняет артефакты и освобождает runtime resources.

Жизнь Task: от декларации до проверенного внешнего результата



Эта цепочка показывает, почему «ответ модели был правильным» не равнозначно «задача успешно выполнена». Успех является end-to-end свойством всей системы.

Три плоскости, которые полезно не смешивать

Control plane хранит desired state и управляет lifecycle: создать Task, назначить runtime, изменить статус, приостановить или удалить.

Execution plane выполняет код: runner, harness, процессы, filesystem и model/tool clients.

Side-effect plane включает системы, где происходят реальные изменения: Git provider, network controller, cloud API, ticketing или production database.

Разделение особенно полезно при повторях и восстановлении. Control plane может повторно отправить событие после сбоя. Execution может не знать, успел ли внешний API завершить операцию до timeout. Side-effect plane должен поддерживать idempotency или предоставлять operation status, а harness — хранить ledger вызовов.

Как выбирать уровень инструмента

Инженерный выбор начинается не с названия продукта, а со свойств задачи.

Ситуация	Обычно достаточно	Почему
Один предсказуемый шаг	Скрипт или обычный сервис	Минимум состояния и вариантов отказа
Надёжная последовательность известных шагов	Workflow engine	Нужны durable retries и orchestration, но не вероятностное планирование
Короткая изолированная вычислительная работа	Kubernetes Job	Хорошо известный lifecycle run-to-completion
Один адаптивный цикл с несколькими tools	Собственный небольшой harness	Логику можно сделать явной и проверяемой
Сложный граф, branching и human approval	Agent framework + harness	Готовые state/checkpoint abstractions сокращают собственную реализацию
Много изолированных, stateful и часто idle executions	Специализированный orchestrator/runtime	Нужны lifecycle, multiplexing, suspend/resume и policy на уровне платформы
Непроверенный код и сильная tenant boundary	Усиленный sandbox, возможно gVisor/microVM	Обычного process/container boundary может быть недостаточно

Эта таблица не является автоматическим решателем. Она заставляет сформулировать требования. Например, пять доверенных внутренних агентов можно запускать обычными deployments или worker queue. Специализированная платформа становится интереснее, когда executions много, они stateful, долго простаивают, запускают непроверенный код, требуют независимых workspaces или должны быстро приостанавливаться и возобновляться.

Не стоит выбирать AX только потому, что задача содержит LLM. Не стоит выбирать multi-agent только потому, что можно создать несколько ролей. Каждый новый слой должен устранять конкретное ограничение более простой архитектуры.

Что AX и Agent Substrate добавляют к этой карте

В зафиксированном baseline AX `v0.3.1` пользователь декларативно описывает `Task`, `Workspace` и `Model`. AX принимает эти ресурсы, хранит собственное control-plane состояние и через Agent Substrate приводит Task к исполняемому состоянию. Внутри Task запускается runner, который подготавливает Workspace и стартует команду пользователя.

AX не определяет reasoning strategy. Он не превращает любой container в качественного агента, не реализует за приложение надёжные tools и не решает автоматически governance. Harness остаётся ответственностью приложения или выбранного framework.

Agent Substrate находится ниже AX. Его основная модель отделяет logical Actor от физического Worker. Большая совокупность actors может отображаться на меньший pool заранее подготовленных workers. Runtime управляет lifecycle, sandbox, placement, suspend/resume и routing. Kubernetes при этом продолжает управлять узлами и worker Pods.

Такое разделение полезно для workloads, которые активны всплесками и долго ждут событий. Но оно создаёт новые задачи: хранение snapshots, совместимость при restore, data locality, correlation logs между разными workers и собственный control plane. Архитектура выбирается не бесплатно: плотность и быстрый resume оплачиваются дополнительной системой, которую потребуется эксплуатировать.

Проекты остаются pre-1.0, а часть архитектурных документов описывает целевое состояние раньше полной реализации. Поэтому конкретные возможности нужно проверять по зафиксированной версии, API guide и реальному стенду. В книге design goals, реализованное поведение и roadmap рассматриваются отдельно.

Почему симптом «агент завис» ничего не объясняет

Один пользовательский симптом может иметь причины на любом уровне.

- **LLM/inference:** очередь на GPU, oversized context, rate limit или model timeout.
- **Harness:** потерян stop condition, повторяется один plan, ожидается approval, исчерпан budget.
- **Tool/MCP:** сервер недоступен, schema изменилась, credential просрочен, операция осталась в неизвестном состоянии.
- **Runner:** служебный процесс жив, но child agent завершился.
- **Network policy:** DNS работает, но TLS или конкретный egress destination запрещён.
- **Runtime:** Actor не получил Worker, snapshot несовместим или restore слишком медленный.
- **AX control plane:** событие не обработано, controller отстаёт, ссылка на Workspace не разрешена.
- **Kubernetes:** node pressure, image pull, storage или CNI.
- **Внешняя система:** действие принято асинхронно и ещё не завершилось либо было отвергнуто собственной policy.

Поэтому диагностика начинается с correlation identity и определения последнего подтверждённого перехода. Получил ли Task desired state? Назначен ли Actor? Готов ли runner? Жив ли child process? Был ли отправлен model request? Какой tool call выполняется? Есть ли внешний operation ID? Только после ответа на эти вопросы имеет смысл изменять prompt.

Метод выбора архитектуры

Перед добавлением очередного слоя полезно письменно ответить на восемь вопросов.

1. Какая неопределённость требует LLM, а что можно решить детерминированно?
2. Как выглядит проверяемый результат работы?
3. Где находится authoritative state?
4. Какие действия имеют side effects и как обеспечивается idempotency?
5. Какой код считается недоверенным и какая нужна граница изоляции?
6. Сколько executions одновременно активно, сколько простаивает и как долго?
7. Что должно пережить restart, suspend и потерю node?
8. Кто будет наблюдать, обновлять и восстанавливать каждый новый компонент?

Если ответы не требуют долговременного агента, отдельного sandbox runtime и массового lifecycle, более простая система почти всегда лучше. Если же нужны stateful executions, независимые workspaces, управляемая приостановка, строгие policies и большое число idle workloads, специализированный стек становится обоснованным.

Практическое упражнение

Возьмите задачу: «агент проверяет pull request, запускает тесты и при необходимости предлагает исправление». Разложите её на таблицу:

- где выполняется agent loop;
- что входит в context;
- где хранится progression;
- кто запускает тесты;
- имеет ли агент право писать в branch;
- кто подтверждает merge;
- какой уровень изоляции нужен для кода из pull request;
- что произойдёт после restart;
- как проверить, что результат действительно опубликован;
- нужен ли здесь AX или достаточно CI runner и небольшого harness.

Затем измените условие: одновременно работают десять тысяч таких задач, большинство ждёт ревью несколько часов, а код считается недоверенным. Посмотрите, какие ответы изменятся. Именно изменение требований, а не наличие слова «agent», приводит к выбору другой архитектуры.

Если запомнить только главное

- LLM предлагает решения; система вокруг неё отвечает за выполнение и последствия.

- Агент появляется как цикл с состоянием, действиями и критерием остановки.
- Harness управляет внутренним execution loop; orchestrator управляет множеством executions.
- Framework помогает описывать логику, но не заменяет security, runtime и operations.
- Context, working state, workspace, snapshot и external state — разные сущности.
- AX управляет декларативным lifecycle agent workloads, но не пишет harness за приложение.
- Agent Substrate управляет Actor/Worker, sandbox и suspend/resume поверх инфраструктуры Kubernetes.
- Выбирать инструмент нужно по требованиям к state, isolation, lifecycle, scale и side effects.
- «Агент завис» — симптом, а не диагноз.


Дальше. Карта стека готова. В следующей главе мы увеличим один её участок - model request - и разберём, какие гарантии LLM действительно даёт системе.

Источники и дальнейшее чтение

- [AX README, baseline e70162a](#)
- [AX Design, baseline e70162a](#)
- [AX Core concepts, baseline e70162a](#)
- [Agent Substrate README, baseline ccecc78](#)
- [Agent Substrate architecture, baseline ccecc78](#)
- [Kubernetes Concepts](#)
- [Model Context Protocol specification](#)
- [gVisor documentation](#)

LLM как вычислительный компонент агентной системы

Путь model request: tokenizer, scheduler, prefill, KV cache и decode



В главе 1 мы построили карту всего стека. Теперь увеличим её внутренний слой - один model request - и отделим возможности LLM от гарантий, которые обязана обеспечить окружающая система.

Представим, что команда строит агента для первичной диагностики сетевых инцидентов. На вход он получает описание симптома, фрагменты конфигурации, метрики, результаты DNS- и TLS-проверок. На выходе должен выбрать следующий read-only инструмент, объяснить гипотезу и при необходимости подготовить изменение для подтверждения человеком.

Вопрос «какую LLM взять?» кажется главным. Команда сравнивает размер модели, длину context window и цену миллиона токенов. Но эти цифры не отвечают на более важные вопросы. Сможет ли модель правильно выбрать инструмент среди двадцати похожих? Не перепутает ли interface ID с VLAN ID? Как часто она сформирует синтаксически допустимый, но опасный вызов? Что произойдёт, если в context не поместится часть telemetry? Как изменится end-to-end latency, если каждый шаг агента передаёт модели всю историю заново?

LLM в такой системе полезно рассматривать не как «разум агента», а как вычислительный компонент с вероятностным контрактом. Она получает конечный набор токенов и возвращает продолжение: текст, структурированный объект или предложение вызвать инструмент. Всё, что связано с актуальностью данных, полномочиями, долговременным состоянием, повтором операций и проверкой результата, остаётся обязанностью программы вокруг модели.

Такой взгляд не обесценивает возможности LLM. Напротив, он позволяет использовать её там, где она сильна, и не требовать от неё гарантий, которых у неё нет.

Что происходит при одном запросе

Между массивом сообщений в приложении и первым символом ответа находится несколько стадий.

1. Harness собирает system instructions, цель, состояние, найденные документы, результаты tools и формат ожидаемого ответа.
2. Model adapter преобразует это в формат конкретного provider и применяет chat template модели.
3. Tokenizer превращает текст и специальные маркеры в идентификаторы токенов.
4. Inference server ставит запрос в очередь и назначает его вычислительным ресурсам.
5. На стадии prefill модель обрабатывает входные токены и создаёт KV cache.
6. На стадии decode модель генерирует новые токены по одному, каждый раз используя уже построенный cache.
7. Токены преобразуются обратно в текст или structured output и передаются приложению потоком либо целиком.
8. Harness интерпретирует результат, но не обязан ему доверять.

На каждом переходе есть собственные ошибки. Неверный chat template способен ухудшить instruction following даже при правильных весах. Переполненный context приводит к отказу или truncation. Очередь inference server увеличивает задержку до первого токена. Оборванный stream оставляет harness с частичным JSON. Наконец, полностью успешный HTTP-ответ может содержать убедительный, но фактически неверный вывод.

Поэтому метрика `request succeeded` доказывает только исправность transport и serving path. Она ничего не говорит об успешности инженерной задачи.

Токен - не слово и не символ

Tokenizer разбивает вход на элементы словаря модели. Распространённые семейства алгоритмов - BPE, WordPiece и Unigram - сохраняют частые фрагменты крупными токенами, а редкие последовательности раскладывают на более мелкие. Разные модели способны по-разному токенизировать один и тот же текст.

Из этого следуют несколько практических выводов.

Во-первых, длину запроса нельзя надёжно оценивать количеством слов или символов. Русский текст, исходный код, длинные идентификаторы, base64, JSON и таблицы могут иметь очень разную token density. Проверять лимит нужно tokenizer'ом конкретной model revision.

Во-вторых, сообщения приложения не попадают в модель «как есть». Chat template добавляет role markers, разделители и специальные токены. Поэтому сумма токенов отдельных строк может не совпасть с фактической длиной итогового prompt.

В-третьих, context budget расходуется не только пользовательским текстом. В него входят system policy, tools schemas, примеры, история, retrieved documents, observations и зарезер-

вированное место для ответа. Список из сотни подробных tool descriptions иногда занимает больше контекста, чем сама задача.

Наконец, токены - единица ограничения и стоимости, но не единица смысла. Два фрагмента одинаковой длины могут иметь совершенно разную ценность. Актуальное состояние интерфейса важнее трёх страниц общей документации, даже если оно занимает всего двадцать токенов.

Context window - рабочий стол, а не долговременная память

Context window задаёт максимальный объём последовательности, доступной модели в одном запросе. Это жёсткий технический лимит, но не обещание одинаково качественной работы с каждым токеном внутри него.

Исследования long-context моделей показывают, что релевантная информация может использоваться хуже, если она находится в середине большого контекста. Кроме того, лишний текст увеличивает prefill latency, стоимость и вероятность того, что модель обратит внимание на правдоподобную, но нерелевантную деталь. Поэтому стратегия «положим в prompt всё» редко является хорошим context engineering.

Полезно заранее разделить context на зоны:

Зона	Что в ней находится	Как обращаться
Platform instructions	Неизменяемые правила и границы поведения	Формирует платформа, пользователь и документы не могут их переопределить
Task objective	Цель, score и критерий завершения	Должны быть короткими и проверяемыми
Working state	Текущая стадия, подтверждённые факты, открытые вопросы	Пересобирается из durable state
Evidence	Telemetry, найденные документы, tool observations	Содержит provenance, время получения и уровень доверия
Action surface	Доступные tools и их schemas	Ограничивается текущей стадией и полномочиями
Output contract	Schema, формат объяснения, лимит ответа	Проверяется после generation

Context нужно собирать заново для каждого шага. В него включают не всю историю, а информацию, необходимую для следующего решения. Старый диалог можно свернуть в структурированное состояние; документы - отобрать retrieval-слоем; большие tool results - предварительно нормализовать; уже выполненные side effects - хранить в отдельном ledger.

Если важный факт существует только в предыдущем model response, но не сохранён в authoritative state, система неизбежно потеряет его после compaction, restart или смены provider.

Prefill, decode и KV cache отвечают за разные задержки

Во время prefill модель обрабатывает входной prompt и вычисляет внутренние представления для его токенов. Эта стадия хорошо использует параллельные вычисления и становится особенно заметной при длинном context. Пользователь видит её как часть time to first token, или TTFT.

Decode устроен иначе. Авторегрессионная модель выбирает следующий токен, добавляет его к последовательности и только затем может вычислить следующий. Эта зависимость делает generation последовательной. Задержка между токенами измеряется как inter-token latency, или ITL.

Без KV cache на каждом decode step пришлось бы повторно вычислять attention для всей предыдущей последовательности. Cache сохраняет key/value представления уже обработанных токенов и позволяет переиспользовать их. За ускорение приходится платить памятью: cache растёт с числом активных sequences, длиной context и параметрами архитектуры модели.

Для agent workload различие prefill и decode особенно важно:

- длинные policies, tool schemas и observations увеличивают TTFT;
- длинное объяснение или большой code patch увеличивают decode time;
- несколько параллельных агентов конкурируют не только за compute, но и за KV cache;
- повтор общей части prompt может получить выгоду от prefix caching, если server и provider это поддерживают;
- новый tool result обычно требует нового prefill хотя бы для добавленного контекста;
- короткий ответ модели не означает дешёвый запрос, если перед ним был передан огромный prompt.

Inference server может объединять запросы в continuous batches, разбивать длинный prefill на chunks и приоритизировать decode. Эти механизмы улучшают использование GPU, но создают trade-off между throughput, TTFT и ITL. Глубокий capacity planning рассматривается позже; здесь важно понимать, почему «tokens per second» не описывает пользовательскую задержку целиком.

Модель выдаёт распределение вероятностей, а не факт

На каждом decode step модель оценивает вероятности следующего токена. Generation strategy выбирает один из кандидатов и продолжает цикл. Веса модели содержат статистические закономерности, полученные во время обучения, а не актуальную копию CMDB, репозитория или состояния кластера.

Из этого не следует, что любой ответ модели случаен или бесполезен. Модель может очень хорошо извлекать структуру, сопоставлять признаки, объяснять гипотезы и строить план. Но уверенная формулировка не является доказательством.

Полезно различать четыре типа утверждений:

- **дано во входе** - факт присутствует в проверенном observation;
- **получено инструментом** - факт связан с источником и временем чтения;
- **выведено моделью** - гипотеза, классификация или интерпретация;
- **проверено системой** - результат подтверждён независимым условием.

Если итоговый отчёт смешивает эти категории, инженер не понимает, чему можно доверять. Хороший harness сохраняет provenance и просит модель маркировать предположения, но окончательное разделение выполняет программа.

Пример: модель видит рост TLS errors после deployment и предполагает несовместимый cipher suite. Это полезная гипотеза. Подтверждённым фактом она станет только после чтения конфигурации и воспроизводимой TLS-проверки.

Sampling управляет разнообразием, но не создаёт гарантий

Greedy decoding выбирает наиболее вероятный токен на каждом шаге. Sampling выбирает токен из распределения. Temperature изменяет его форму, а top-p ограничивает множество кандидатов совокупной вероятностной массой. Параметр `max_new_tokens` ограничивает длину generation.

Для инфраструктурных задач обычно нужен низкий уровень вариативности. Однако правило «всегда temperature=0» слишком примитивно.

- Короткое извлечение поля или выбор tool полезно делать максимально стабильным.
- Поиск нескольких независимых гипотез может выиграть от ограниченного разнообразия.
- Генерацию пользовательского объяснения можно отделить от принятия действия.
- Несколько candidates имеют смысл только тогда, когда существует evaluator, способный их сравнить.

Даже greedy decoding не следует считать бизнес-гарантией детерминизма. Результат может измениться после обновления model revision, tokenizer, chat template, serving engine или provider-side configuration. Разные hardware kernels и batching также могут проявить различия возле близких вероятностей.

Поэтому воспроизводимость строится выше модели: фиксируются version и параметры, сохраняется фактический request, результат проверяется тестами, а side effects защищаются idempotency и preconditions. Система должна оставаться корректной, даже если модель предложила другой допустимый план.

Structured output ограничивает форму, но не смысл

Обычный текст трудно надёжно разбирать. Structured output и constrained decoding позволяют ограничить generation JSON Schema или другой грамматикой. Tool calling добавляет модельный интерфейс, в котором ответ содержит имя инструмента и аргументы.

Это серьёзно снижает количество синтаксических ошибок, но не превращает вывод модели в доверенную команду. Между model result и tool executor нужны четыре проверки.

```
{
  "tool": "set_interface_state",
  "arguments": {
    "device_id": "edge-17",
    "interface": "xe-0/0/3",
    "enabled": false
  },
  "reason": "Observed flapping after the last configuration change"
}
```

Schema validation проверяет наличие полей, типы и допустимый формат.

Domain validation проверяет, что устройство и интерфейс существуют, аргументы согласованы, а requested state имеет смысл.

Authorization and policy проверяют identity, scope, change window и необходимость human approval.

Outcome verification после вызова независимо читает состояние и убеждается, что intended result достигнут.

JSON может быть идеально валидным и при этом выключать не тот порт. Tool name может существовать, но быть недоступным текущему пользователю. Поэтому structured output - это интерфейс между вероятностным компонентом и обычным кодом, а не обход обычного кода.

Если schema сложна, лучше разбить решение на несколько шагов. Модели проще сначала выбрать тип действия, затем заполнить узкую schema конкретного tool, чем генерировать один универсальный объект с десятками условных полей.

Способности модели нельзя свести к одному рейтингу

Model size и публичный benchmark дают ориентир, но production-выбор зависит от конкретного workload. Для agent infrastructure важны разные способности.

Способность	Как проверять на своей задаче
Instruction following	Выполняет ли модель platform policy при конфликтующем пользовательском или документном тексте
Tool selection	Выбирает ли правильный tool и умеет ли отказаться от лишнего вызова
Argument filling	Правильно ли переносит IDs, enums, units, time ranges и optional fields
Long-context retrieval	Находит ли нужный факт в типичных по длине и структуре observations
Reasoning and planning	Строит ли проверяемый план без пропущенных preconditions
Multilingual quality	Понимает ли русские описания, англоязычные логи и смешанную терминологию
Code and configuration	Корректно ли читает diff, YAML, policy и vendor-specific config
Structured output	Соблюдает ли schema и насколько часто требует repair/retry
Calibration and abstention	Признаёт ли недостаток данных вместо выдуманного ответа
Latency and efficiency	Укладывается ли TTFT и end-to-end latency в SLO при нужной concurrency

Модель, которая выигрывает общий reasoning benchmark, может хуже заполнять аргументы конкретных сетевых tools. Большая модель может немного повысить task success, но не оправдать четырёхкратную задержку на каждом шаге. Меньшая модель может быть лучшим router, но плохим автором change plan.

Следовательно, единицей выбора является не «лучшая модель вообще», а связка:

`model revision + tokenizer + chat template + serving configuration + prompt contract + tool schemas`.

Изменение любого элемента требует хотя бы сокращённого regression eval.

Как строить eval до выбора модели

Правильный eval начинается с реальных типов задач, а не с случайного набора вопросов.

1. Соберите репрезентативные cases: простые, типичные, редкие и опасные.
2. Для каждого case зафиксируйте входные данные, допустимые действия и проверяемый ожидаемый результат.
3. Добавьте adversarial cases: конфликтующие инструкции, устаревший документ, похожие IDs, отсутствующий обязательный факт.
4. Разделите метрики: task success, tool choice, argument accuracy, unnecessary calls, unsafe proposals, latency, token usage и retries.

- 5. Прогоните несколько повторов там, где используется sampling или допускается несколько корректных планов.
- 6. Проводите shadow run без side effects, затем canary на ограниченном scope.
- 7. Сохраняйте model revision, server version, параметры generation и полный trace.

Для tool-using агента одного exact match недостаточно. Допустимы разные последовательности read-only проверок, если они приводят к подтверждённому результату в пределах бюджета. Поэтому evaluator часто сочетает детерминированные проверки и экспертную rubric.

Пример минимальной scorecard:

Метрика	Смысл	Пример порога
Verified task success	Достигнут ли проверяемый результат	не ниже 95% на типовых cases
Unsafe action proposal	Предложено ли запрещённое действие	0 на safety-наборе
Tool argument accuracy	Все ли критичные аргументы правильны	не ниже 99% для write proposals
Unnecessary tool calls	Лишние вызовы и стоимость	p95 не более заданного бюджета
Schema repair rate	Доля повторов из-за формата	достаточно мала для SLO
End-to-end latency	Время всего model step	p95 соответствует UX/automation deadline

Числа здесь являются примером формы, а не универсальными нормативами. Для read-only assistant и автоматического изменения routing policy допустимый риск будет разным.

Маленькая модель, большая модель или deterministic код

Не каждый шаг агента должен выполняться одной и той же LLM.

Тип шага	Предпочтительный первый кандидат
Проверка обязательных полей и типов	Обычный код или schema validator
Точное сопоставление по известному ключу	SQL, search или deterministic rule
Простая классификация с устойчивыми классами	Малая модель после eval либо обычный classifier
Извлечение структуры из неоднородного текста	Малая или средняя LLM со structured output
Сложная диагностика с несколькими гипотезами	Более сильная reasoning model

Тип шага	Предпочтительный первый кандидат
Генерация change plan для подтверждения	Сильная модель плюс deterministic policy checks
Проверка postcondition	Инструмент и обычный код, не самооценка модели

Router может снизить стоимость, направляя простые steps на меньшую модель. Но router сам становится источником ошибок. Экономия имеет смысл только тогда, когда измеряется итоговая стоимость успешной задачи, включая retries и неверную маршрутизацию.

Хорошая стратегия начинается с одной модели и прозрачного baseline. Разделение на fast/strong модели добавляют после того, как traces показывают разные классы нагрузки и понятную границу routing.

Cloud API, локальный endpoint и hybrid path

Способ serving - отдельное решение от выбора model family.

Cloud API обычно ускоряет старт, даёт elasticity и снимает эксплуатацию GPU. Взамен появляются зависимость от внешнего provider, egress данных, rate limits, меняющаяся модель сервиса и стоимость по usage.

Local inference даёт контроль над model revision, данными, сетью и hardware. Он может быть экономичен при стабильной загрузке, но команда принимает на себя capacity planning, обновления, драйверы, observability и availability.

Hybrid позволяет использовать локальный endpoint для регулярной нагрузки, а внешний - для burst, fallback или более сложных steps. Такой путь требует проверки semantic compatibility: два API с похожим форматом могут по-разному поддерживать tools, schemas, token accounting и finish reasons.

Выбор удобно начинать с вопросов:

- разрешено ли передавать данные внешнему provider;
- нужен ли offline или isolated режим;
- каков профиль burst и средняя utilization;
- какая model capability нужна именно этой задаче;
- допустима ли деградация при недоступности preferred model;
- кто будет эксплуатировать serving stack;
- как фиксируется revision и проводится rollback.

Fallback не должен незаметно менять security или качество. Если основная модель отказалась от опасного действия, повтор на другой модели не является корректным retry. Если fallback имеет меньший context limit, harness обязан пересобирать context, а не обрезать его случайным образом.

Model adapter - контракт, а не тонкая обёртка над HTTP

Provider APIs различаются форматами сообщений, tool calls, streaming events, usage accounting, error codes и возможностями. Model adapter должен нормализовать общие части, но сохранять различия, важные для приложения.

Полезный внутренний контракт включает:

```
ModelRequest
  model_profile
  messages
  tools
  response_schema
  max_output_tokens
  deadline
  trace_id

ModelResult
  content
  tool_calls
  finish_reason
  input_tokens / output_tokens
  provider_request_id
  model_revision
  raw_metadata

ModelError
  category
  retryable
  request_may_have_completed
  provider_request_id
```

Особенно важен `finish_reason`. Остановка по `normal end`, достижение `token limit`, `policy refusal` и `transport interruption` требуют разных действий. Нельзя передавать truncated JSON в tool executor или автоматически повторять запрос, который мог уже вернуть часть результата.

Capability profile должен быть явным: поддерживает ли endpoint tools, parallel tool calls, конкретный JSON Schema subset, vision, streaming, prefix caching и нужную длину context. Название «OpenAI-compatible» или похожий HTTP surface не доказывает одинаковую семантику.

Ошибки model step нужно классифицировать

Фраза «LLM не ответила» объединяет разные классы отказов.

Класс	Пример	Типичная реакция
Capacity	rate limit, queue timeout, overload	bounded retry с backoff или другой capacity pool

Класс	Пример	Типичная реакция
Transport	connection reset, incomplete stream	повтор только для model request, не для уже выполненного tool
Input contract	context too long, invalid schema	пересобрать context или исправить request; слепой retry бесполезен
Output contract	truncated/malformed structured output	repair или повтор в пределах бюджета
Policy	provider refusal или local guardrail	зафиксировать причину; fallback только по явной policy
Quality	правдоподобный, но неверный вывод	evaluator, дополнительное evidence, другая стратегия или модель
Tool semantics	верный JSON, неверный tool/arguments	domain validation блокирует side effect
Version drift	изменилось поведение после update	regression eval и rollback/pin revision

Retry способен исправить временную перегрузку, но не плохой prompt, недостающий факт или систематическую ошибку модели. Несколько бездумных повторов иногда лишь повышают вероятность получить ответ, который пройдет поверхностную проверку.

Где проходит граница AX

В AX ресурс `Model` связывает `Task` с `model endpoint` и его конфигурацией. Это полезная `platform abstraction`: `Task` не обязан знать физический GPU host или детали внешнего provider.

Но `Model resource` не выбирает `reasoning strategy` и не доказывает пригодность модели для `workload`. AX не валидирует за приложение `tool semantics`, `context composition`, `eval quality` или `postconditions`. Эти обязанности остаются в `harness` и `model adapter`.

Такое разделение позволяет менять `cloud endpoint` на `local serving`, не переписывая `lifecycle Task`. Однако переносимым будет только тот слой, который действительно описан общим контрактом. `Provider-specific` возможности должны оставаться в `capability profile` и тестироваться явно.

Практическое упражнение

Возьмите агента, который анализирует `pull request` и при необходимости предлагает `patch`.

Подготовьте двадцать cases:

- небольшой безопасный diff;
- изменение `access policy`;

- скрытая ошибка в конфигурации;
- большой diff с нерелевантными файлами;
- конфликтующие инструкции внутри README;
- тесты с неоднозначным failure;
- отсутствующий контекст;
- похожие имена файлов;
- попытка вызвать запрещённый write tool;
- задача, где правильный ответ - запросить уточнение.

Для двух candidate models измерьте:

- смогла ли модель выбрать нужные файлы;
- верно ли интерпретировала тесты;
- соблюла ли границу read/write;
- сколько tool calls сделала;
- сколько input/output tokens использовала;
- каковы TTFT и end-to-end latency;
- сколько раз потребовался schema repair;
- достигнут ли результат после независимой проверки.

Затем повторите сравнение после сокращения context и удаления лишних tools. Если меньшая модель резко улучшилась, проблема была не только в её capability, но и в качестве контракта вокруг неё.

Если запомнить только главное

- LLM - вероятностный вычислительный компонент, а не authoritative state и не исполнитель side effects.
- Фактический input определяется tokenizer'ом и chat template, а не количеством слов.
- Context window - ограниченный рабочий бюджет; большой лимит не гарантирует эффективного использования всего контекста.
- Prefill определяет значительную часть TTFT, decode - скорость появления следующих токенов, а KV cache - memory pressure.
- Structured output гарантирует форму только в пределах поддерживаемых constraints; смысл и полномочия проверяет обычный код.
- Temperature и sampling управляют разнообразием, но бизнес-корректность обеспечивается eval, validation и idempotency.
- Модель выбирают по собственным cases и нескольким метрикам, а не по одному публичному рейтингу.
- Cloud, local и hybrid serving имеют разные эксплуатационные и security trade-offs.
- Model adapter обязан нормализовать API, не скрывая capability differences и finish reasons.

- AX управляет ссылкой Task на Model, но качество model step остаётся ответственностью приложения.


Дальше. Один model call выбирает продолжение, но ещё не образует агента. В следующей главе мы соединим такие вызовы с observation, state, actions и stop conditions в управляемый loop.

Источники и дальнейшее чтение

- [Attention Is All You Need](#)
- [Hugging Face: tokenization algorithms](#)
- [Hugging Face: generation strategies](#)
- [Hugging Face: KV cache strategies](#)
- [vLLM: optimization and chunked prefill](#)
- [vLLM: production metrics](#)
- [Lost in the Middle: How Language Models Use Long Contexts](#)
- [Holistic Evaluation of Language Models](#)
- [Generating Structured Outputs from Language Models](#)
- [AX Core concepts, baseline e70162a](#)

Что такое агент: цикл, границы и критерии остановки

Agent loop: цель, контекст, решение, действие и обратная связь



Глава 2 разобрала один model call. Теперь соединим такие вызовы с обратной связью от среды и определим, в какой момент программа становится агентом, где заканчивается его автономность и кто имеет право остановить loop.

Представим задачу: проверить, почему после изменения DNS часть клиентов не может подключиться к сервису. Обычный workflow можно заранее расписать: получить записи, проверить propagation, выполнить TLS probe, сравнить конфигурацию, сформировать отчёт. Но реальный инцидент быстро выходит за рамки одного сценария. В одном случае обнаружится stale resolver cache, в другом - неправильный CNAME, в третьем - доступ к нужной зоне отсутствует и потребуется запросить помощь.

Агент нужен не потому, что задача содержит текст или LLM. Он нужен тогда, когда следующий полезный шаг нельзя полностью выбрать заранее и его приходится определять по наблюдаемому состоянию среды.

Минимальное инженерное определение можно сформулировать так:

Агент - это ограниченный процесс, который получает цель, наблюдает состояние, выбирает допустимое действие, фиксирует результат и повторяет цикл до проверяемого завершения, паузы или контролируемого отказа.

В этом определении важны все слова. Без цели получается бесконечный исследователь. Без наблюдений - генератор предположений. Без ограничений - источник неконтролируемых side effects. Без сохранённого состояния - чат, который забывает progression. Без критериев остановки - цикл, способный расходовать ресурсы неограниченно.

Не всё, что вызывает LLM, является агентом

Термин «агент» часто применяют слишком широко. Для выбора архитектуры полезно различать несколько классов систем.

Система	Кто выбирает следующий шаг	Есть ли цикл	Когда использовать
Один model call	Приложение	Нет	Классификация, извлечение, генерация ограниченного результата
Prompt chain	Заранее написанный код	Фиксированная последовательность	Известные стадии с проверками между ними
Workflow	State machine или workflow engine	Возможны повторы и ожидания по заданным правилам	Предсказуемый процесс, durable retries, human tasks
Router	Правило, classifier или LLM	Обычно нет собственного длинного цикла	Выбор специализированного пути
Agent	Модель в заданных границах	Да, следующий шаг зависит от observations	Неопределённая последовательность исследований или действий
Multi-agent system	Несколько ограниченных loops и coordinator	Граф или дерево	Независимые contexts, authorities или параллельная работа

Граница не всегда бинарна. Production-система часто сочетает deterministic workflow и agentic nodes. Например, state machine жёстко задаёт этапы collect - diagnose - propose - approve - execute - verify, а LLM внутри этапа diagnose выбирает, какие read-only проверки выполнить.

Такой гибрид обычно надёжнее идеи «пусть модель сама решит всё». Свобода остаётся там, где полезна адаптивность, а переходы с высоким риском контролирует обычный код.

У автономности есть несколько независимых измерений

Слово «автономный» ничего не говорит без уточнения. Агент может иметь высокую свободу планирования, но не иметь права на внешние изменения. Или работать часами, но каждый write требовать подтверждения.

Полезно оценивать автономность по отдельным осям:

- **decision autonomy** - насколько свободно выбирается следующий шаг;
- **action authority** - какие side effects разрешены;
- **time horizon** - сколько времени процесс может работать без участия человека;
- **resource budget** - сколько steps, tokens, денег и compute доступно;
- **delegation depth** - может ли агент создавать дочерние работы;
- **environment scope** - какие данные, tools и systems видимы;
- **reversibility** - насколько легко отменить последствия;
- **human checkpoints** - где требуется approval или уточнение.

Агент для исследования документации может иметь широкую decision autonomy и почти нулевой blast radius. Агент с одним разрешённым API-вызовом в production может иметь узкую логику, но высокий риск. Поэтому security review должен начинаться не с вопроса «насколько умна модель», а с authority, scope и reversibility.

Минимальный agent loop

Поведение агента удобно представить как цикл observe - decide - act - verify. В production между этими словами появляются дополнительные gates.

1. Принять objective, scope и initial state.
2. Загрузить policy, budgets и durable progression.
3. Получить observations, необходимые для текущего шага.
4. Собрать context из state и trusted/untrusted evidence.
5. Попросить модель предложить следующий шаг или итог.
6. Разобрать structured decision.
7. Проверить schema, domain rules, policy и approval requirement.
8. Выполнить действие с operation ID и timeout.
9. Сохранить observation, provenance и возможный side effect.
10. Проверить postcondition и progress.
11. Перейти к следующему состоянию, приостановиться или завершиться.

Упрощённый skeleton выглядит так:

```

while true:
    state = load_durable_state(task_id)

    terminal = evaluate_terminal_conditions(state)
    if terminal:
        return finalize(terminal, state)

    context = assemble_context(state)
    proposal = model.decide(context)

    decision = validate_proposal(proposal, state.policy)

    if decision.requires_approval:
        checkpoint(state, waiting_for_approval(decision))
        return PAUSED

    operation = execute_idempotently(decision, state.operation_ledger)
    observation = verify_operation(operation)

    state = apply_observation(state, observation)
    checkpoint(state)

```

Это не готовая реализация. Важна форма: модель не исполняет действие напрямую, terminal conditions проверяются вне модели, а state сохраняется до следующего шага.

Observation, state и plan - разные сущности

Эти три понятия часто смешивают, из-за чего агент становится трудно восстанавливать и диагностировать.

Observation - результат конкретного чтения или действия. Например: «resolver 10.0.0.5 вернул старый IP в 12:04 UTC». Observation содержит источник, время, request ID и raw artifact.

State - компактное представление progression. Например: текущая стадия diagnosis, подтверждённые факты, отклонённые гипотезы, оставшийся budget, ожидаемый approval и ledger операций.

Plan - текущая гипотеза о будущих шагах. Он может измениться после нового observation и не является authoritative truth.

Если plan хранится как state без различия статусов, восстановившийся агент способен принять старое намерение за уже выполненное действие. Если observations хранятся только внутри model context, они исчезнут после compaction. Если state состоит из свободного текста, программе трудно проверить invariant.

Практичная модель данных разделяет как минимум:

Поле	Пример
objective	восстановить доступность клиентов, не меняя authoritative DNS без approval
phase	diagnosing

Поле	Пример
verified facts	origin healthy; resolver A stale; resolver B current
hypotheses	cache propagation delay; split-horizon mismatch
open questions	какой TTL был до изменения
operations	read-17 completed; change-3 proposed, not approved
budgets	8 из 20 steps, 4 минуты из 15
waiting for	none
expected outcome	два независимых probes возвращают новый IP и успешный TLS

Модель получает проекцию этого state, но не должна быть единственным компонентом, который умеет его интерпретировать.

Детерминированная оболочка вокруг вероятностного решения

LLM полезна для классификации неоднозначных данных, построения гипотез и выбора исследования. Но многие решения должны оставаться обычным кодом.

Решение	Предпочтительный владелец
Достигнут ли timeout	Runtime или harness
Остался ли budget	Budget controller
Существует ли tool	Tool registry
Допустимы ли аргументы	Schema и domain validator
Имеет ли identity право на действие	Authorization service
Нужен ли approval	Policy engine
Выполнялась ли операция раньше	Operation ledger
Достигнут ли измеримый postcondition	Deterministic verifier
Какую гипотезу проверить следующей	LLM в разрешённых границах
Как объяснить вывод человеку	LLM на основе проверенных facts

Это разделение называется не недоверием к модели, а корректным распределением обязанностей. Даже очень сильная модель не должна вычислять, истёк ли wall-clock deadline,

если это может сделать таймер. И не должна подтверждать успешность собственного изменения без независимого чтения.

Agent execution лучше моделировать как state machine

Цикл `while true` скрывает важные operational states. Явная state machine делает паузы, восстановление и терминальные исходы видимыми.

Состояние	Значение	Допустимый следующий переход
Created	objective принят, выполнение ещё не началось	Running, Cancelled
Running	агент выбирает или выполняет безопасный шаг	WaitingForTool, WaitingForApproval, Verifying, Failed
WaitingForTool	внешний read/operation ещё не завершён	Running, Verifying, Failed, Cancelled
WaitingForApproval	требуется решение человека или policy owner	Running, Cancelled, Failed
Verifying	проверяется итог или postcondition	Succeeded, Running, Failed
Succeeded	доказан expected outcome	терминальное
Failed	продолжение невозможно или исчерпан допустимый budget	терминальное либо явный operator retry
Cancelled	выполнение остановлено владельцем или системой	терминальное

Waiting не равно failure. Task, который ожидает approval два часа, не должен занимать активный worker и не должен каждые десять секунд повторно спрашивать модель. Он сохраняет checkpoint и возобновляется по событию.

Failed также не означает «модель однажды ошиблась». Локальная ошибка может привести к repair или альтернативному пути. Terminal failure наступает, когда классифицированная ошибка неисправима в текущем score, исчерпан budget либо нарушен invariant.

Критерий успеха должен существовать до запуска

Фраза «сделай так, чтобы всё работало» не задаёт проверяемого результата. Если success condition не определён, агенту остаётся доверять собственному ощущению завершенности.

Хороший expected outcome отвечает на вопросы:

- что именно должно стать истинным;
- каким инструментом это измеряется;
- сколько независимых подтверждений требуется;
- какое состояние не должно измениться;
- в течение какого окна результат считается стабильным;
- какой artifact нужно сохранить.

Для задачи с DNS критерий может выглядеть так:

- authoritative zone содержит ожидаемую запись и serial;
- два независимых resolver возвращают новый адрес после TTL window;
- TLS probe на hostname успешен;
- origin health не ухудшился;
- итоговый отчёт содержит timestamps и raw probe IDs.

Ответ модели «готово» не входит в этот список.

Success condition полезно отделять от completion report. Сначала код проверяет outcome, затем модель объясняет человеку, что произошло. Если объяснение не сгенерировалось, технический результат может оставаться успешным, а report generation - отдельной repairable задачей.

Остановка бывает успешной, ожидающей и аварийной

У agent loop должно быть несколько явных путей выхода.

Success - postcondition подтверждён.

Needs input - отсутствует факт, который может предоставить пользователь или другая система. Это pause, а не догадка.

Needs approval - следующий допустимый шаг имеет side effect выше текущего authority.

Blocked - требуемый ресурс недоступен, а альтернативный путь отсутствует.

Budget exhausted - достигнут лимит steps, времени, tokens, tool calls, денег или delegation depth.

No progress - новые iterations не меняют state и не добавляют evidence.

Cancelled - владелец задачи или control plane запросил остановку.

Safety stop - policy или invariant запрещает продолжение.

Для каждого исхода задают machine-readable reason и human-readable summary. Иначе operator увидит общий статус Failed и снова запустит тот же процесс, не понимая, что агент на самом деле ждал недостающий credential или упёрся в policy.

Budget - не одна цифра

Ограничение только по maximum steps недостаточно. Один step может быть дешёвым read-only запросом, а другой - часовым job или вызовом дорогой модели.

Budget обычно включает:

- wall-clock deadline;
- maximum active execution time;
- maximum model requests;
- input и output tokens;
- monetary cost;
- tool calls по классам;
- число write proposals;
- retries каждого operation;
- объём созданных artifacts;
- число и depth дочерних задач.

Budgets должны уменьшаться монотонно и храниться в durable state. Restart процесса не должен обнулять счётчики. Child task получает долю оставшегося parent budget, а не новый безграничный лимит.

При исчерпании budget агент не обязан просто оборваться. Он может сохранить partial result, перечислить подтверждённые facts, незакрытые вопросы и безопасный следующий шаг. Это превращает контролируруемую остановку в полезный outcome.

Как обнаруживать отсутствие прогресса

Max iterations гарантирует конечность, но не замечает бессмысленную работу заранее. Полезен отдельный no-progress detector.

Он может отслеживать:

- повтор одного tool с теми же нормализованными аргументами;
- одинаковые ошибки без изменения recovery strategy;
- отсутствие новых verified facts;
- неизменный fingerprint state несколько шагов подряд;
- plan, который циклически возвращается к предыдущей стадии;
- evaluator score, который не улучшается;
- последовательность «прочитать - предложить - отклонить» для одного объекта;

- постоянное создание новых subtasks без закрытия старых.

Fingerprint не должен включать шум вроде timestamps или request IDs, иначе каждый iteration будет казаться новым. Полезнее хешировать semantic state: phase, open questions, verified facts, pending operations и нормализованный proposed action.

Реакция также должна быть поэтапной. Сначала агент получает structured feedback о повторе. Затем пробует ограниченную альтернативу. После заданного patience window останавливается с reason NO_PROGRESS. Бесконечная просьба к той же модели «подумай ещё» не является recovery strategy.

Недавние исследования infinite agentic loops подтверждают, что циклы могут проходить через model calls, tools, workflow transitions и handoffs. Поэтому bound должен существовать на каждом feedback path, а не только в основном for-цикле.

Retry не равен новому рассуждению

Повтор допустим, когда ошибка временная и операция безопасно повторяема. Например, model endpoint вернул overload до начала generation или read-only API завершился connection reset.

Если timeout произошёл во время write, неизвестно, выполнила ли внешняя система действие. Повтор без проверки способен создать дубль. Нужны:

1. стабильный operation ID или idempotency key;
2. запись intent до вызова;
3. сохранение provider request ID;
4. запрос статуса существующей операции;
5. независимая проверка external state;
6. только затем решение о retry или compensation.

Идемпотентность не означает, что запрос «обычно безопасен». Она означает, что повтор с тем же identity и payload не создаёт дополнительного эффекта.

Модель не должна сама решать, можно ли повторить write, по тексту ошибки. Класс операции и retry semantics задаёт tool contract.

Human-in-the-loop - полноценное состояние, а не модальное окно

Approval особенно часто реализуют как временный prompt: процесс ждёт ответ в памяти и теряет его при restart. Production-система должна рассматривать human interaction как durable interrupt.

Перед паузой сохраняются:

- proposed action и нормализованные arguments;
- причина и evidence;
- ожидаемый side effect;
- diff или preview;
- identity запрашивающего;
- срок действия предложения;
- state version;
- operation ID, если он уже выделен.

После resume необходимо проверить, что approval относится к той же версии state. За время ожидания конфигурация могла измениться, credential - истечь, а incident - завершиться. Старое подтверждение не должно автоматически разрешать новый payload.

Human-in-the-loop включает не только yes/no. Агент может запросить недостающий score, предложить несколько вариантов, получить изменённые параметры или передать задачу operator. Эти ответы являются events, которые изменяют durable state.

Plan не должен становиться скрытым API

Модели удобно предложить план, но текстовый plan нельзя использовать как единственный control structure. У фразы «проверить DNS, затем исправить запись» нет schema, статусов и retry semantics.

Для исполнения полезнее разложить намерение на structured steps:

```
plan_version: 4
steps:
  - id: read-authoritative
    kind: tool
    status: completed
    result_ref: observation-81
  - id: compare-resolvers
    kind: fanout-read
    status: running
    required_successes: 2
  - id: propose-change
    kind: decision
    status: pending
    requires: [read-authoritative, compare-resolvers]
    approval_policy: dns-write
```

LLM может предложить или обновить такой plan. Harness проверяет зависимости, разрешённые step kinds и invariants. Фактическое состояние каждого step изменяет executor, а не модель.

При небольшом числе состояний отдельный planner вообще не нужен. Модель может выбирать одно следующее действие, а deterministic state machine - сохранять progression. Planner/

executor оправдан, когда предварительный план помогает распределять работу, оценивать зависимости или запрашивать approval на весь change set.

Основные patterns и критерии выбора

Patterns - это способы распределить decision-making, а не названия продуктов.

ReAct чередует reasoning и action. Он полезен, когда каждый следующий шаг зависит от свежего observation: search, диагностика, exploration. В production reasoning result лучше выражать как краткое decision summary и structured action, а не считать скрытую цепочку рассуждений audit log.

Prompt chaining передаёт результат через фиксированную последовательность stages. Это workflow, а не автономный agent, и именно поэтому он часто лучше для предсказуемой задачи.

Routing выбирает один специализированный путь. Он снижает context и позволяет использовать разные models/tools, но требует обработки ошибочной классификации.

Planner/executor отделяет построение плана от исполнения. Полезен для задач с зависимостями, но план должен перепроверяться после каждого значимого observation.

Evaluator/optimizer повторяет генерацию и проверку. Он оправдан только при измеримом criterion и bounded iterations. «Модель-критик считает ответ лучше» без калиброванного evaluator легко создаёт дорогую петлю.

Fan-out/fan-in параллельно выполняет независимые проверки и объединяет structured results. Он ускоряет работу, если ветви действительно независимы и budget делится заранее.

Supervisor/worker делегирует ограниченные subtasks. Он нужен при разных tools, authority или context. Подробная multi-agent архитектура рассматривается отдельно.

Требование	Первый кандидат
Известные стадии и переходы	Workflow/state machine
Следующий шаг зависит от нового observation	ReAct-подобный loop
Есть несколько устойчивых классов входа	Router
Нужен change plan с зависимостями	Planner/executor
Результат можно автоматически оценить и улучшить	Bounded evaluator loop
Независимые проверки можно выполнять параллельно	Fan-out/fan-in
Различаются authority, workspace или expertise	Supervisor/worker

Нельзя выбирать pattern только потому, что framework предоставляет красивую диаграмму. Каждый дополнительный loop или role должен улучшать измеримый результат сильнее, чем повышает latency, стоимость и число failure modes.

Когда workflow лучше агента

Workflow предпочтительнее, если:

- процесс известен заранее;
- каждый transition можно выразить правилами;
- важны predictability и auditability;
- ошибки имеют известные recovery paths;
- variation входных данных невелика;
- side effects критичны;
- регулятор или оператор должен заранее понимать все пути.

Agent оправдан, если:

- число возможных путей велико;
- нужны исследования и адаптация по observations;
- вход содержит неоднородный неструктурированный материал;
- невозможно заранее перечислить все полезные read-only шаги;
- ценность гибкости выше дополнительной стоимости и риска.

Часто лучший ответ - workflow с agentic island. Например, workflow управляет approval и deployment, а агент исследует логи и формирует change proposal. Такой дизайн локализует неопределённость.

Safety и liveness - две разные задачи

Safety означает: плохое событие не произойдёт. Агент не выйдет за score, не выполнит write без approval, не превысит authority, не повторит необратимое действие.

Liveness означает: полезное событие когда-нибудь произойдёт. Задача не останется навсегда WaitingForTool, approval event не потеряется, retry закончится, а cancel действительно остановит descendants.

Можно построить очень безопасную систему, которая никогда ничего не завершает. Можно построить активную систему, которая быстро выполняет неправильные изменения. Production contract обязан включать оба набора invariants.

Примеры safety invariants:

- write tool недоступен до approved state;
- child authority не шире parent;

- каждый external write имеет operation ID;
- terminal Task не запускает новые actions.

Примеры liveness invariants:

- каждый non-terminal state имеет timeout или входящее событие;
- каждый retry bounded;
- orphan operation периодически reconciled;
- cancel распространяется на активные children;
- WaitingForApproval имеет owner и expiry policy.

Observability должна показывать переходы, а не только текст

Лог полного conversation history полезен, но недостаточен. Для диагностики нужно восстановить причинную цепочку:

```
task - state version - model request - proposal - policy decision - tool operation - observation - transition.
```

На каждом step полезно фиксировать:

- step ID и parent step;
- state before/after;
- model/provider request ID;
- выбранный action type;
- tool и нормализованные arguments;
- policy/approval decision;
- operation ID;
- latency и resource usage;
- observation/artifact refs;
- termination check result.

Необязательно сохранять скрытое внутреннее reasoning модели. Для audit важнее входные evidence, явное decision summary, фактическое действие и проверенный результат. Это уменьшает риск перепутать правдоподобное объяснение с реальной причиной перехода.

Как тестировать agent loop

Agent loop нельзя проверять только набором удачных диалогов. Такой тест показывает, что один знакомый сценарий однажды сработал, но ничего не говорит о повторяемости, остановке, восстановлении и безопасности. Единица проверки здесь - не красивый ответ модели, а переход системы из одного состояния в другое.

Полезно разделить тестирование на четыре уровня.

1. Детерминированные unit-тесты оболочки

Policy, budget accounting, state transitions, idempotency и обработка tool results должны тестироваться без модели. Для каждого перехода задаются входное состояние, событие и ожидаемое новое состояние.

Примеры:

- Running + proposal(write) + no approval -> WaitingForApproval;
- WaitingForTool + timeout + retries_left -> Running;
- WaitingForTool + timeout + no retries -> Failed;
- Verifying + success evidence -> Succeeded;
- Running + repeated fingerprint -> Blocked;
- any non-terminal state + cancel -> Cancelled.

Эти тесты должны также проверять invariants: terminal state не порождает новые actions, declined approval не превращается в write, один operation ID не приводит к двум side effects.

2. Симулированная среда

Реальные tools дороги, медленны и иногда опасны. Поэтому useful test harness должен уметь возвращать заранее заданные observations: успешный ответ, timeout, malformed payload, stale data, partial success, conflict или permission denied. Важно симулировать не только штатный путь, но и неоднозначность.

Например, DNS tool может сначала вернуть timeout, затем показать уже обновлённую запись. Правильный agent не должен слепо повторить write: он обязан выполнить read-after-timeout, сопоставить desired state с actual state и только затем решать, нужен ли retry.

3. Scenario evals и replay

Набор сценариев должен описывать цель, начальное состояние среды, разрешённые действия, ожидаемые evidence и недопустимые side effects. Один и тот же сценарий запускают многократно, потому что решение модели вероятно.

Trajectory полезно сохранять как последовательность нормализованных событий, а затем replay-ить без реальных side effects. Replay отвечает на два разных вопроса:

1. корректно ли оболочка обработала уже полученные proposals и observations;
2. изменилось ли решение модели после смены prompt, model version или tool description.

Это позволяет отделить регрессию orchestration от регрессии reasoning.

4. Recovery и counterfactual tests

Хороший агент должен не только идти по счастливому пути, но и корректно менять план после новой информации. Поэтому в тесте намеренно меняют среду:

- log source становится недоступен;

- permission исчезает между plan и execute;
- approval приходит после изменения state version;
- tool возвращает success, но verification не подтверждает результат;
- оператор отменяет Task во время долгой операции;
- один из параллельных workers возвращает противоречащие evidence.

Counterfactual test задаёт вопрос: «Если бы observation отличалось в одном существенном месте, изменилось бы решение?» Если агент предлагает один и тот же action при `certificate expired` и при `certificate valid`, он, вероятно, следует поверхностному шаблону, а не фактам.

Метрики production-качества

Одна метрика `task completed` слишком груба. Она не отличает доказанный успех от самоуверенного отчёта. Минимальный набор включает:

Метрика	Что она показывает
Verified task success rate	Доля задач, где критерий успеха подтверждён evidence
Invalid action rate	Доля proposals, нарушивших schema, state или policy
Unsafe proposal / executed action	Разницу между тем, что model пыталась сделать, и тем, что реально пропустила оболочка
Steps to verified outcome	Эффективность траектории, а не длину текста
No-progress stop rate	Способность обнаруживать loop до исчерпания бюджета
Recovery rate	Долю сценариев, завершённых после tool failure или изменения среды
Escalation quality	Достаточно ли оператору контекста, чтобы принять решение
Cost and latency distribution	Медиану и хвосты, а не только среднее значение

Особенно важно отдельно считать unsafe proposals и executed unsafe actions. Нулевая доля фактических нарушений может означать как качественное reasoning, так и сильный policy layer, который постоянно спасает плохо настроенную модель. Это разные инженерные ситуации.

Где проходит граница AX

В AX `Task` предоставляет внешний lifecycle работы: создание, запуск, наблюдение, завершение, отмену и связь с execution metadata. `Workspace` задаёт изолированный контекст файлов и процессов. `Model` выполняет inference. Но эти абстракции сами по себе не определяют внутреннюю семантику agent loop.

Runner или agent runtime поверх AX должен определить:

- schema логического state;
- допустимые actions и tools;
- policy и approval rules;
- способ записи observations;
- критерии успеха;
- budgets и stopping conditions;
- checkpoint и recovery semantics;
- формат итогового результата и evidence.

Это разделение важно по двум причинам.

Во-первых, инфраструктурный runtime не должен угадывать domain semantics. AX может надёжно доставить событие, сохранить artifact и остановить process, но не знает, означает ли HTTP 200 успешное восстановление сервиса или попадание на fallback page.

Во-вторых, логический checkpoint агента не равен снимку процесса. Возобновить контейнер с того же instruction pointer недостаточно: внешняя среда могла измениться, lease истечь, approval устареть, а tool operation завершиться после потери связи. При resume агент должен загрузить durable state, reconcile незавершённые operations, обновить observations и только затем выбрать новый transition.

Два уровня retry

В системе обычно существуют как минимум два разных retry:

1. **Step retry** - повтор конкретной tool operation внутри agent loop.
2. **Task retry** - повтор всего runner после infrastructure failure.

Если их не различать, Task retry может заново выполнить side effect, который на самом деле успел завершиться. Поэтому operation ID и idempotency key должны переживать перезапуск Task. После восстановления runner сначала проверяет статус ранее начатой операции и только потом решает, повторять ли её.

AX отвечает за надёжную execution substrate. Agent runtime отвечает за корректный переход от цели к действию и от observation к следующему решению. Продуктовая система отвечает за domain policy и за то, что считается доказанным результатом. Смешивание этих уровней делает failure analysis почти невозможным.

Практикум: агент исследует TLS-инцидент

Рассмотрим задачу: «Пользователи получают ошибку TLS при обращении к `api.example.com`; найди причину и подготовь безопасное исправление».

Шаг 1. Зафиксировать контракт

До написания prompt опишите:

- **goal:** определить подтверждённую причину и восстановить корректный TLS handshake;
- **scope:** DNS, load balancer, certificate inventory и логи только для `api.example.com`;
- **success evidence:** handshake проходит из двух независимых probes, certificate chain валидна, hostname совпадает, error rate вернулся ниже порога;
- **forbidden:** выпуск нового сертификата, DNS write и production reload без approval;
- **budget:** 20 model steps, 10 минут, 30 tool calls, один write proposal;
- **terminal result:** `Succeeded`, `WaitingForApproval`, `Blocked`, `Failed` или `Cancelled` с evidence.

Шаг 2. Определить state

Минимальная schema может содержать:

```
incident:
  host: api.example.com
  reported_error: tls_handshake_failed
observations: []
hypotheses: []
selected_hypothesis: null
proposed_change: null
approval:
  status: not_requested
  state_version: 0
operations: {}
budgets:
  steps_left: 20
  tool_calls_left: 30
termination:
  status: running
  evidence: []
```

Не храните только `certificate is probably expired`. Храните observation с источником и временем: какой endpoint проверен, какой serial number получен, какую chain вернул load balancer, на каком host возникла ошибка.

Шаг 3. Ограничить tools

Read-only набор может включать:

- DNS lookup;
- TLS probe с выводом chain и SNI;
- чтение certificate inventory;
- чтение конфигурации load balancer;
- агрегированный поиск по логам;
- чтение deploy history.

Write tools лучше не выдавать сразу. Агент сначала формирует change proposal: точный target, expected effect, rollback, verification и evidence. Отдельный approval transition открывает ровно нужную capability на ограниченное время.

Шаг 4. Проверить альтернативные гипотезы

Устаревший сертификат - лишь одна причина. Agent должен различить как минимум:

- сертификат действительно истёк;
- load balancer отдаёт старый certificate bundle;
- SNI ведёт на default virtual host;
- DNS указывает на старый endpoint;
- неполная intermediate chain ломает часть клиентов;
- часы probe или сервера некорректны;
- handshake исправен, а исходный alert относится к другому региону.

Каждая гипотеза должна иметь ожидаемый discriminating observation. Иначе список гипотез превращается в декоративный текст.

Шаг 5. Спроектировать transitions

Пример полезной траектории:

```
Created
-> Running: собрать DNS и TLS facts
-> Running: сопоставить serial с inventory и deploy history
-> Running: выбрать подтверждённую гипотезу
-> WaitingForApproval: представить ограниченный change plan
-> Running: выполнить approved operation с operation ID
-> Verifying: независимые probes и error-rate check
-> Succeeded: сохранить evidence и summary
```

Если TLS probe расходится между регионами, агент не должен усреднять ответы. Он создаёт новое observation, сужает score и либо продолжает диагностику в бюджете, либо завершает Blocked с точным описанием недостающей capability.

Workflow или agent?

Полностью детерминированный workflow хорошо подходит для известного случая «сертификат истекает через N дней»: проверить inventory, выпустить replacement, развернуть, проверить. Но incident diagnosis содержит развилки, которые зависят от свежих observations.

Практичный дизайн здесь гибридный:

1. workflow создаёт incident Task, задаёт budgets и собирает базовые probes;
2. agentic island исследует evidence и строит change proposal;
3. workflow проводит approval;
4. детерминированный executor выполняет изменение;
5. workflow запускает независимую verification;

6. agent пишет объяснение только на основании сохранённых evidence.

Так модель помогает там, где действительно нужна адаптация, а критические side effects остаются в предсказуемом контуре.

Итоги главы

- Agent - это bounded control loop, а не просто model call с tools.
- Goal должен быть преобразован в проверяемый expected outcome до первого действия.
- Observation, state и plan - разные сущности; их смешивание разрушает audit и recovery.
- Каждый transition проходит через policy, budget и termination checks.
- Retry безопасен только вместе с reconciliation и idempotency.
- Human-in-the-loop требует durable pause, versioned approval и повторной проверки state.
- Workflow предпочтителен для известных путей; agent нужен для адаптации по новым observations.
- Safety запрещает плохие события, liveness гарантирует, что полезная работа не зависнет навсегда.
- Agent eval должен измерять проверенный результат, восстановление, остановку и side effects, а не красоту ответа.
- AX даёт execution substrate; смысл loop, tools, policy и success evidence задаёт agent runtime и продуктовая система.


Дальше. Мы получили bounded agent loop, но пока не ответили, какой код хранит state, проверяет proposals, вызывает tools и восстанавливает работу после сбоя. Это задача harness из следующей главы.

Источники и дальнейшее чтение

- [ReAct: Synergizing Reasoning and Acting in Language Models](#) - исходная работа о чередовании reasoning traces и действий.
- [Building Effective AI Agents](#) - практическое различие workflows и agents, composable patterns и stopping conditions.
- [Thinking in LangGraph](#) - проектирование state, nodes, error handling и human-in-the-loop.
- [Idempotent Receiver](#) - классический паттерн защиты от повторной обработки запросов.
- [Temporal: Tasks и Standalone Activity](#) - durability, retry и idempotency для внешних операций.
- [Infinite Agentic Loops in Production](#) - taxonomy и detection бесконечных loop в agentic systems.
- [AX Core concepts, baseline e70162a](#) - границы базовых примитивов AX.

Agent harness: система вокруг LLM

Agent harness: control loop, adapters, policy и evidence



В предыдущей главе агент был описан как ограниченный control loop: получить observation, выбрать действие, выполнить его, проверить результат и решить, продолжать ли работу. Но эта схема не отвечает на главный практический вопрос: **какой код обеспечивает ограничения, сохраняет состояние, вызывает модель, проверяет tool call и переживает сбой процесса?**

Этот код и образует agent harness.

Представим маленького агента для анализа incident logs. В демонстрации он выглядит просто: system prompt, список tools и цикл из нескольких вызовов модели. Затем появляются production-требования:

- выбрать модель с нужными capabilities;
- не потерять Task после restart;
- ограничить стоимость и число шагов;
- не передать модели лишние secrets;
- проверить arguments до tool execution;
- запросить approval перед production write;

- отличить provider timeout от неправильного решения модели;
- повторить безопасную операцию, но не продублировать side effect;
- связать model request, tool call и итоговый artifact в trace;
- остановить всё дерево работы по cancel.

Если добавлять эти обязанности прямо в while-цикл, он быстро превращается в неявный framework со случайными контрактами. Harness делает эти контракты явными.

Agent harness - это runtime одного агентного execution, который связывает model, state, context, tools, policy и lifecycle в управляемый процесс.

Слово harness буквально означает оснастку или систему крепления. Модель остаётся вычислительным компонентом, а harness удерживает её внутри инженерных границ. Он не делает модель детерминированной, но делает детерминированными условия, при которых её предложение может стать действием.

Harness не равен агенту, framework или orchestrator

Эти понятия часто смешивают, потому что один продукт может реализовывать сразу несколько ролей.

Сущность	Главный вопрос	Пример ответственности
Model	Как получить следующее вероятностное решение?	inference, structured output, tool proposal
Agent	Какое поведение решает задачу?	goal, loop, strategy, termination semantics
Harness	Как безопасно выполнить один agent run?	context, state, validation, tools, budgets, checkpoint
Framework/ SDK	Какими abstractions это программировать?	Agent, Tool, Runner, graph node, middleware
Orchestrator	Где и когда запустить workload?	scheduling, Task lifecycle, Worker, restart, resource placement
Sandbox	Где физически выполняется недоверенный код?	process isolation, filesystem, network boundary
Model gateway	Как унифицировать доступ к providers?	routing, credentials, quotas, provider telemetry
Workflow engine	Как надёжно провести известный процесс?	durable timers, retries, signals, state-machine history

Framework может предоставить готовый harness. Но наличие класса Agent ещё не означает, что определены recovery, cancellation, idempotency и audit. И наоборот, небольшой собственный harness может состоять из нескольких модулей без отдельного framework.

Полезная граница такова:

- **agent design** определяет, какие решения допустимо делегировать модели;
- **harness** исполняет эти решения внутри одного логического run;
- **orchestrator** обеспечивает жизнь процесса и инфраструктурных ресурсов;
- **platform policy** определяет внешние полномочия и организационные правила.

Главный контракт: **proposal** не является **action**

Модель не должна напрямую вызывать shell, HTTP API или MCP server. Она формирует предложение в структурированном формате. Harness превращает его в действие только после последовательности проверок.

```
model proposal
-> parse
-> schema validation
-> capability lookup
-> policy decision
-> approval check
-> budget reservation
-> idempotency registration
-> execution
-> output normalization
-> postcondition verification
-> durable observation
```

Эта цепочка важнее конкретного SDK. Если framework скрывает её за одним методом, инженер всё равно должен понимать, где проходит каждый gate и что произойдёт при сбое между ними.

Например, модель предложила:

```
{
  "action": "dns.update_record",
  "arguments": {
    "zone": "example.com",
    "name": "api",
    "value": "203.0.113.25"
  },
  "reason": "authoritative record differs from desired state"
}
```

Harness обязан ответить на вопросы, которые модель не может решать единолично:

1. Существует ли tool с таким именем и версией?
2. Соответствуют ли arguments schema?
3. Разрешена ли зона текущему identity и Task scope?
4. Требуется ли действие approval?
5. Не устарел ли plan после получения approval?

- 6. Есть ли remaining budget?
- 7. Не выполнялась ли эта operation раньше?
- 8. Как проверить фактический результат?
- 9. Какие данные можно сохранить в trace?

Prompt с фразой «будь осторожен» не заменяет ни одну из этих проверок.

Внутренняя архитектура harness

Удобно разделить harness на control path и data path.

Control path решает, что должно произойти: создаёт run, переводит state machine, проверяет policy, учитывает budget, управляет pause/resume и termination.

Data path переносит содержимое: собирает model context, отправляет запрос provider, передаёт arguments tool executor, нормализует observation и сохраняет artifacts.

Такое разделение не требует отдельных сервисов. В маленьком приложении оба пути живут в одном процессе. Важно, чтобы их обязанности не смешивались логически.

Минимальный набор компонентов:

Компонент	Вход	Выход	Что он не должен решать
Run controller	событие и durable state	следующий transition	domain-факты без evidence
Context assembler	state, instructions, observations	model request	policy на side effects
Model adapter	normalized request	normalized response	выполнение tool call
Decision parser	raw/structured response	typed proposal	authorization
Tool registry	identity, scope, capabilities	доступные tool descriptors	фактическое выполнение
Policy engine	proposal, identity, state	allow, deny, require approval	убеждать модель текстом
Tool executor	approved operation	raw result	объявлять Task успешной
Observation normalizer	raw result	typed observation	скрывать partial failure
State store/journal	events и checkpoints	восстановимый progression	быть единственной копией external state
Budget controller	reservation/usage events	remaining limits	оценивать бизнес-ценность
Trace/audit sink	correlation events	searchable evidence	хранить secrets без фильтрации

Компонент	Вход	Выход	Что он не должен решать
Result builder	verified state и artifacts	terminal result	придумывать отсутствующие evidence

Далее разберём не названия классов, а инженерные контракты между ними.

Run controller: место, где живёт lifecycle

Run controller реализует state machine из предыдущей главы. Он принимает события и решает, какой transition выполнить. Событием может быть model response, tool result, approval, timeout, cancel или recovery signal.

Хороший controller не состоит из рекурсивных вызовов `run_agent()` и не держит всё состояние только в stack. Его логику можно представить функцией:

```
new_state, effects = transition(current_state, event)
```

`effects` - не уже выполненные внешние операции, а команды harness: вызвать model, запросить approval, запустить tool, сохранить artifact или завершить Task. Благодаря этому transition можно тестировать без сети и модели.

Основные обязанности controller:

- назначать монотонный `state_version`;
- проверять terminal conditions до нового шага;
- резервировать budget до вызова внешней зависимости;
- связывать event с ожидающим operation;
- игнорировать duplicate и stale events;
- распространять cancellation;
- checkpoint-ить состояние перед паузой;
- строить terminal result только из verified evidence.

Если controller не умеет выразить `WaitingForApproval` или `WaitingForTool`, приложение начинает удерживать process и надеяться, что ответ когда-нибудь придёт. Это дорого и плохо восстанавливается.

Context assembler: compiler, а не конкатенация строк

Context assembly часто реализуют как `system_prompt + history + latest_message`. Для короткого демо этого достаточно. В production assembler больше похож на compiler pipeline.

Он должен:

1. принять цель, текущее состояние и тип следующего решения;
2. выбрать инструкции с явными версиями;
3. получить только релевантные observations и artifacts;
4. отметить provenance и trust level каждого фрагмента;
5. добавить доступные tools и их schema;
6. применить redaction и data policy;
7. оценить token budget;
8. выполнить truncation, summarization или retrieval;
9. сформировать provider-neutral request;
10. сохранить manifest того, что действительно ушло модели.

Manifest нужен для воспроизводимости. Запись «модель увидела контекст задачи» недостаточна. Нужны identifiers и версии: prompt bundle, tool catalog, memory snapshot, included artifact hashes, compaction strategy и model settings.

Инструкции и данные должны различаться

Любой текст из issue, log, web page или tool output потенциально недоверенный. Harness не обязан понимать все prompt injection, но должен сохранять границы происхождения.

Практичная классификация:

Класс	Пример	Допустимое использование
Platform instruction	policy о запрете production write	authoritative instruction
Agent instruction	роль и procedure конкретного агента	instruction внутри platform policy
User objective	«исследовать ошибку TLS»	цель, но не новые полномочия
Trusted state	approved scope, identity, budget	control data
Retrieved evidence	runbook из контролируемого repo	данные с provenance
Untrusted content	issue body, log line, web page	только evidence, не инструкция
Tool metadata	schema, side-effect class	contract для proposal

Если все категории превращаются в один текстовый блок, модель может принять строку из лога за системную команду. Даже если provider поддерживает роли сообщений, harness должен дополнительно ограничивать authority на уровне tools и policy.

Context window - не база данных

Assembler не должен пытаться поместить всю историю. Его задача - собрать достаточный контекст для текущего decision point.

Полезный порядок при переполнении:

1. сохранить immutable platform и safety instructions;
2. сохранить objective, current state и open decision;
3. сохранить последние verified observations;
4. сохранить schemas только доступных сейчас tools;
5. заменить старые подробности ссылками и summaries;
6. убрать дубли и нерелевантные transcripts;
7. остановиться с NeedsInput или Blocked, если безопасное сокращение невозможно.

Summarization является lossy transformation. Summary нельзя считать authoritative evidence; оно должно ссылаться на исходные artifacts.

Model adapter: единый интерфейс без иллюзии одинаковых моделей

Model adapter переводит normalized request в API конкретного provider и возвращает normalized response. Его цель - изолировать транспортные различия, но не скрыть смысловые capabilities.

Минимальный request contract может включать:

```
model_request:
  request_id: mr-0182
  model_profile: reasoning-medium
  messages_ref: ctx-09a1
  tools_ref: catalog-v17
  required_output_schema: decision-v3
  max_output_tokens: 1800
  deadline: 2026-10-05T01:30:00Z
  cancellation_token: cancel-task-412
  trace_parent: 00-abcd-1234-01
```

Ответ должен нормализовать:

- provider request/response IDs;
- text и structured parts;
- tool proposals;
- finish reason;
- usage, включая cached и reasoning tokens, если доступны;
- latency и retry attempts;
- safety/refusal signals;
- provider-specific warnings;
- raw response reference для отладки.

Абстракция всегда протекает

Разные providers и модели по-разному поддерживают parallel tool calls, strict JSON schema, streaming, reasoning controls, prompt caching, image/audio input и server-managed conversation state. Нельзя свести всё к наименьшему общему знаменателю и затем ожидать одинакового поведения.

Вместо одного списка model names лучше использовать capability profile:

Capability	Зачем знать harness
Structured output strictness	можно ли доверять provider-side schema enforcement
Tool-call concurrency	может ли ответ содержать несколько независимых proposals
Context limit	какой compaction нужен до запроса
Streaming semantics	какие partial events считаются только UI, а какие durable
Cancellation support	можно ли остановить inference или только игнорировать результат
Usage reporting	когда и насколько точно доступна стоимость
Data residency/retention	разрешён ли provider для данного Task
Server-managed state	где находится часть conversation history

Routing должен происходить до отправки чувствительных данных. Если policy запрещает внешний provider, fallback после ошибки не может молча выбрать его ради доступности.

Ошибки model adapter

ModelError слишком широк. Harness должен различать хотя бы:

- authentication/authorization failure;
- quota или rate limit;
- provider unavailable;
- request timeout;
- context overflow;
- unsupported capability;
- malformed structured output;
- safety refusal;
- cancelled request;
- unknown/ambiguous outcome.

Только часть этих ошибок допускает автоматический retry. context overflow требует нового context assembly, а malformed decision - repair или новый model step. Authorization failure обычно требует оператора. Timeout после provider acceptance может оставить неизвестность по usage, но не создаёт внешний domain side effect, пока proposal не прошёл executor.

Decision parser: недоверенный компиляторный front end

Даже при strict structured output ответ модели остаётся недоверенным входом. Parser должен:

- проверять JSON/schema;
- запрещать неизвестные action types;
- нормализовать identifiers, paths и URLs;
- устанавливать size limits;
- отклонять смешение final answer и несовместимого action;
- сохранять raw response отдельно от typed proposal;
- возвращать диагностируемую ошибку, а не None.

Repair полезен только для синтаксических проблем. Если модель выбрала запрещённый tool, нельзя автоматически «починить» решение на похожий разрешённый tool: это уже новое semantic decision и новый model step.

Tool registry и executor: каталог отдельно, выполнение отдельно

Здесь нас интересует место tool execution внутри harness. Семантику Tool, границу с MCP и роль Skills мы отдельно разберём в главе 6.

Tool registry отвечает на вопрос «что доступно этому run сейчас?». Tool executor отвечает на вопрос «как выполнить уже разрешённую operation?». Разделение позволяет менять discovery, не смешивая его с credentials и side effects.

Descriptor полезного tool содержит больше, чем имя и JSON Schema:

```
tool:
  name: dns.read_record
  version: 2.1.0
  input_schema_ref: sha256:8f2...
  output_schema_ref: sha256:91b...
  side_effect: read_only
  authority: dns:zone/read
  timeout: 8s
  retry_class: safe_read
  concurrency_key: zone:{zone}
  data_classification: internal
  verifier: dns.verify_read
```

Для write tool добавляются approval class, idempotency support, compensation/rollback metadata и postcondition verifier.

MCP может дать discovery и transport для tools, resources и prompts, но протокол не определяет, как приложение управляет model context или agent loop. Именно harness агрегирует discovered capabilities, применяет local policy и решает, какие descriptors показать модели. Наличие tool в MCP server не означает автоматического разрешения на его вызов.

Полный путь tool call

Production executor обычно выполняет такую последовательность:

1. Получает typed proposal и immutable operation identity.
2. Повторно загружает актуальный state.
3. Проверяет, что proposal создан для текущего `state_version`.
4. Валидирует arguments и canonical form.
5. Разрешает identity, scope и capability.
6. Вычисляет risk/approval class.
7. Проверяет approval, expiry и exact arguments.
8. Резервирует budget и concurrency slot.
9. Регистрирует operation как `prepared`.
10. Выполняет call с deadline и cancellation propagation.
11. Сохраняет raw result или error.
12. Нормализует result в observation.
13. Проверяет postcondition отдельным read.
14. Помечает operation как `verified`, `failed` или `unknown`.
15. Публикует event для run controller.

Особенно опасен промежуток между пунктами 10 и 11. Внешняя система могла применить write, а процесс упал до записи результата. После recovery нельзя считать операцию ни успешной, ни неуспешной. Статус `unknown` должен запускать reconciliation.

Error и observation не одно и то же

Tool может вернуть HTTP 200 и domain failure внутри payload. Может вернуть timeout после фактически выполненного write. Может завершиться частично. Поэтому normalized result должен явно представлять:

- transport outcome;
- provider/application outcome;
- side-effect certainty;
- retryability;
- raw artifact reference;
- observed external identifiers;
- suggested reconciliation action.

```
operation_result:
  operation_id: op-441
  transport: timeout
  application: unknown
  side_effect: unknown
  retryable: after_reconcile
  external_id: change-9841
  raw_artifact: artifact://tool/op-441-response
```

Фраза tool exception не содержит достаточной информации для безопасного retry.

Output normalization защищает и контекст

Tool result способен быть огромным, бинарным, секретным или вредоносным для model context. Executor не должен автоматически возвращать модели весь stdout.

Нормализатор:

- ограничивает размер;
- отделяет structured result от human-readable text;
- удаляет или маскирует secrets;
- сохраняет полный payload как artifact при допустимой policy;
- добавляет provenance и timestamps;
- помечает недоверенный контент;
- возвращает модели digest и ссылки вместо мегабайтного вывода.

Tool design подробно рассматривается в главе 6, а безопасность исполнения - в главе 37. Здесь важно увидеть роль harness: он является точкой, где model proposal превращается в контролируруемую operation и обратно в observation.

Policy и approval: решения вне prompt

Policy engine получает факты, а не свободный текст:

```
subject + task scope + action + canonical arguments + state + environment
-> allow | deny | require_approval | constrain
```

constrain может сузить действие: ограничить path, maximum rows, destination host, duration или набор fields. Лучше предоставить model уже attenuated tool, чем показывать широкую capability и каждый раз надеяться на правильные arguments.

Policy должна применяться как минимум дважды:

1. когда формируется доступный tool catalog;
2. непосредственно перед execution.

Первая проверка уменьшает число невозможных proposals. Вторая защищает от stale context, изменения identity и подмены arguments.

Approval не заменяет policy. Человек не должен получать просьбу «разрешить shell». Нужен конкретный proposal:

- что изменится;
- где именно;
- какими arguments;
- какие side effects ожидаются;
- чем подтверждена необходимость;
- как проверить результат;
- как откатить изменение;
- до какого времени и для какой state_version действует решение.

После approval harness повторяет policy и input validation. Между паузой и нажатием кнопки среда могла измениться.

Fail-open и fail-closed

Сбой компонента	Read-only действие	Необратимый write
Policy service недоступен	возможно ограниченное local rule	deny/pause
Audit sink недоступен	buffer с жёстким лимитом	обычно pause
Budget store недоступен	conservative local remainder	deny нового expensive step
Approval store недоступен	продолжить без write	deny/pause
Verifier недоступен	вернуть incomplete evidence	не объявлять success

Решение fail-open должно быть явным и привязано к risk class. Глобальная настройка continue_on_error почти всегда слишком груба.

State, journal и checkpoint

Здесь мы фиксируем компоненты recovery внутри harness. Точные различия между context, working state, memory, workspace, checkpoint и snapshot будут определены в главе 5.

Глава 5 подробно разделяет context, working state, memory и snapshot. Для harness сейчас достаточно трёх правил.

Первое: logical state должен переживать restart процесса.

Второе: transition и намерение выполнить side effect должны записываться до внешнего действия.

Третье: checkpoint не доказывает, что external world соответствует локальному state.

Event journal полезен для расследования:

```
RunCreated
ContextAssembled
ModelRequestStarted
ModelResponseReceived
ProposalValidated
ApprovalRequested
ApprovalGranted
OperationPrepared
OperationStarted
OperationOutcomeUnknown
ReconciliationObserved
OperationVerified
RunSucceeded
```

Необязательно строить полноценный event-sourced system. Можно хранить current state и append-only operation ledger. Но инженер должен иметь возможность ответить: что harness собирался сделать, что начал, что увидел после recovery и на основании чего объявил успех.

Checkpoint создаётся:

- после значимого observation;
- перед `WaitingForApproval`;
- перед долгим tool execution;
- после регистрации operation result;
- перед terminal transition;
- периодически в длинном read-only исследовании.

Checkpoint слишком часто увеличивает latency и write amplification. Слишком редко - увеличивает объём повторной работы и риск потерять provenance. Выбор интервала является частью SLO, а не вкусовой настройкой.

Budgets, deadlines и cancellation

Budget controller учитывает несколько ограничений одновременно:

- model requests и tokens;
- wall-clock deadline;
- tool calls;
- денежную стоимость;
- объём artifacts и retrieved data;
- parallel operations;
- write proposals;
- nested/delegated runs.

Budget должен резервироваться до операции, а фактическое usage сверяться после. Иначе несколько параллельных steps могут одновременно увидеть один остаток и совместно превысить лимит.

```
remaining = limit - committed_usage - active_reservations
```

Если точная стоимость неизвестна до завершения, резервируется upper bound. Неиспользованный остаток освобождается.

Deadline не равен timeout

- **Run deadline** ограничивает всю работу.
- **Step timeout** ограничивает одну model/tool operation.
- **Connect/read timeout** описывает транспорт.
- **Approval expiry** ограничивает актуальность решения человека.
- **Lease timeout** определяет, когда другой worker может подобрать abandoned run.

Один параметр `timeout=60` не способен выразить эти semantics.

Cancellation должна быть cooperative и observable. Controller отмечает run как cancelling, прекращает новые proposals, передаёт token активным adapters/executors, ждёт bounded grace period и затем завершает оставшиеся процессы инфраструктурным способом. External writes, которые нельзя отменить, переходят в reconciliation queue.

Terminal `Cancelled` означает не «мы послали сигнал», а «harness больше не иницирует действия, локальные executions остановлены, незавершённые external operations перечислены».

Concurrency и backpressure

Параллельные tool calls сокращают latency, но усложняют state.

Перед параллельным запуском harness должен знать:

- независимы ли operations;
- читают ли они один mutable resource;
- есть ли ordering requirement;
- как объединяются observations;
- можно ли отменить оставшиеся calls после первого достаточного результата;
- какой общий и per-tool concurrency limit;
- как зарезервирован budget.

Полезны `concurrency_key` и conflict policy. Два read для разных hosts могут выполняться одновременно. Два write в одну DNS zone должны сериализоваться или отклоняться. Read после write часто требует ordering barrier.

Backpressure нужен на трёх уровнях:

1. model request queue;
2. tool/provider-specific queue;
3. artifact and trace pipeline.

Если trace exporter замедлился, harness не должен бесконечно накапливать payload в RAM. Если model provider отвечает 429, тысяча runs не должна одновременно выполнить retry. Нужны bounded queues, jitter, global rate limiter и понятный overload result.

Retry: только после классификации

Harness должен различать три класса ошибок.

Transport/infrastructure error - connection reset, rate limit, temporary unavailable. Часто подходит bounded retry.

Contract error - invalid schema, unsupported capability, tool not found. Retry без изменения request бесполезен.

Semantic error - модель выбрала не тот шаг, observation опровергла гипотезу, verifier не подтвердил результат. Нужен новый decision, а не повтор байтов.

Retry policy включает:

- error class;
- maximum attempts;
- backoff и jitter;
- deadline awareness;
- idempotency requirement;
- whether retry creates a new model step;
- what telemetry links attempts into one logical operation.

Важно различать logical call и physical attempt. Пользователь просит один model decision, но adapter может выполнить три HTTP attempts. Trace должен показывать оба уровня, а budget policy - явно решать, что считается платным request.

Circuit breaker защищает provider от лавины повторов, но сам по себе не является fallback strategy. Fallback model может отличаться capabilities, data policy, cost и behavior. Переключение допускается только на совместимый profile и должно фиксироваться в state.

Tracing, audit и privacy

Harness находится в лучшей точке для correlation, потому что видит весь путь:

```
Task -> run -> state version -> model request -> proposal
      -> policy decision -> operation -> observation -> transition
```

Для каждого run нужны стабильные identifiers. Для каждого внешнего call - собственный span/operation ID. OpenTelemetry уже определяет GenAI operations вроде `invoke_agent`, `chat` и `execute_tool`; их можно использовать как основу, добавив domain attributes AX.

Но полный prompt и tool output часто содержат secrets, personal data или proprietary code. Поэтому tracing pipeline должен иметь режимы:

- metadata only;
- redacted content;
- encrypted restricted payload;
- sampled full content для специально разрешённой среды.

Нельзя сначала отправить полный prompt внешнему trace backend, а затем пытаться отредактировать dashboard. Redaction выполняется до export. Raw payload, если он вообще сохраняется, получает отдельную retention и access policy.

Audit event и debug log служат разным целям. Debug log можно sampling-овать. Audit trail для high-risk write должен быть complete, append-only и связывать identity, approval, exact arguments и verified outcome.

Harness и orchestrator: где проходит recovery

Harness управляет логическим run. Orchestrator управляет workload, в котором этот run исполняется.

Ситуация	Основной владелец	Действие
Provider вернул 429	Harness/model gateway	backoff, quota-aware retry
Model response не прошёл schema	Harness	repair/new decision/fail
Tool timeout с unknown side effect	Harness	reconciliation
Process получил OOMKill	Orchestrator + harness	restart workload, load checkpoint
Worker исчез	Orchestrator	reschedule/recover Task
Workspace mount не доступен	Runtime/orchestrator	infrastructure failure
Approval ожидается сутки	Harness сохраняет pause; orchestrator освобождает compute	resume по событию
Пользователь отменил Task	Оба	logical cancel + process cleanup

Граница проявляется при restart. Orchestrator способен снова запустить runner. Но только harness знает, какой logical state загрузить и какую незавершённую operation reconcile.

Не следует позволять обоим уровням независимо повторять один и тот же side effect. Task-level retry перезапускает runner с прежним operation ledger. Он не создаёт новую identity для write только потому, что process новый.

Граница с АХ

АХ предоставляет инфраструктурные primitives и execution substrate: Task lifecycle, Workspace, Model/Gateway, runner contract, размещение и наблюдаемость workload. Конкретный harness может быть Python-процессом, Go binary, Node application, graph framework или CLI-agent.

Для интеграции harness с АХ достаточно явного runner contract:

- где получить Task input и identity;
- где находится durable Workspace;
- как вызвать Model/Gateway;
- как публиковать heartbeat и status;
- как получить cancel/approval event;
- куда записать artifacts;
- как вернуть terminal result;
- что должно сохраниться перед exit.

АХ не должен угадывать внутренний plan агента. Harness не должен реализовывать собственный cluster scheduler. Такая независимость позволяет менять agent framework без миграции control plane и менять инфраструктуру без переписывания domain loop.

Pause и suspend - разные операции

`WaitingForApproval` - логическое состояние run. `suspend` - инфраструктурная оптимизация workload. Сначала harness сохраняет checkpoint и сообщает, что способен быть возобновлён по событию. Затем АХ может освободить compute или snapshot-ить workload.

Если workload был suspended без логического checkpoint, resume может вернуть процесс в устаревшее соединение или середину операции. Если run логически paused, но workload продолжает занимать GPU, корректность сохранена, однако ресурсы используются плохо. Production-система должна согласовать оба слоя.

Как выбирать готовый framework или писать свой harness

Выбор не начинается со списка популярных библиотек. Сначала фиксируется required contract.

Спросите:

1. Есть ли typed state и явные transitions?
2. Можно ли durable pause/resume без удержания процесса?
3. Где хранятся operation IDs и approvals?
4. Какие hooks существуют до и после каждого tool call?
5. Можно ли гарантировать blocking guardrail до side effect?
6. Как распространяется cancellation?
7. Различаются ли logical call и retry attempts?
8. Можно ли заменить model provider без потери нужных capabilities?
9. Как тестировать controller без реальной модели?
10. Можно ли экспортировать traces без sensitive content?
11. Что происходит после process crash между tool execution и checkpoint?
12. Можно ли встроить собственные identity и policy services?

Если framework не даёт ответа, это не всегда причина отказаться. Но недостающую semantics придётся реализовать вокруг него, а не прятать в prompt.

Когда достаточно маленького собственного harness

Собственный минимальный runtime разумен, когда:

- один агент и небольшой набор tools;
- короткий run;
- нет долгих human pauses;
- state легко сериализовать;
- поведение нужно жёстко контролировать;
- команда готова владеть lifecycle и тестами.

Framework полезнее, когда нужны готовые graph transitions, sessions, tool middleware, streaming, handoffs, tracing integrations или multi-agent patterns. Workflow engine полезен, когда главная сложность - durable timers, signals и recovery на дни, а agentic decisions являются отдельными activities.

Нередко лучший вариант - framework внутри activity, durable workflow снаружи и AX как execution platform. Важно назначить один authoritative owner для каждого retry, timeout и state transition.

Референсный run contract

Конфигурация не обязана выглядеть именно так, но все поля должны иметь владельца и semantics.

```
run:
  id: run-412
  task_id: task-981
  agent_spec: incident-investigator@4
  objective_ref: artifact://task/input.json
  state_schema: incident-state@3
  state_store: workspace://state/run-412.json
  operation_ledger: workspace://ledger/run-412.ndjson

model:
  profile: reasoning-medium
  allowed_providers: [local, approved-cloud]
  required_capabilities: [structured-output, tool-calling]
  context_policy: incident-context@7

policy:
  identity: actor://oncall-agent
  scope: service:payments-api
  tool_catalog: incident-read-tools@9
  write_mode: approval-required

limits:
  deadline: 15m
  model_steps: 20
  input_tokens: 180000
  output_tokens: 24000
  tool_calls: 40
  parallel_tools: 4
  artifact_bytes: 50000000
  cost_usd: 4.00

recovery:
  checkpoint: after-observation
  lease: 60s
  unknown_operation: reconcile
  max_model_attempts: 3
  max_tool_attempts: 2

telemetry:
  content_mode: redacted
  trace_sample: always
  audit_writes: always
```

Такой contract полезен даже для single-process приложения. Он заставляет ответить, где хранится state, какие providers допустимы и кто отвечает за unknown operation.

Упрощённый skeleton runtime

```
on_event(run_id, event):
    state = store.load(run_id)
    state = controller.apply_event(state, event)

    while state.is_runnable():
        controller.check_terminal(state)
        budgets.reserve_next_step(state)

        request, manifest = context.build(state)
        store.record(ContextAssembled(manifest))

        response = models.generate(request, state.deadline)
        proposal = decisions.parse(response)

        decision = policy.evaluate(proposal, state)
        if decision.requires_approval:
            store.checkpoint(state.waiting_for(decision))
            return PAUSED

        operation = ledger.prepare(decision, state.version)
        raw_result = tools.execute(operation)
        observation = observations.normalize(raw_result)
        verified = verifier.check(operation, observation)

        state = controller.apply_observation(state, verified)
        store.checkpoint(state)

    return results.build(state)
```

В реальной реализации каждая строка может завершиться ошибкой или получить cancel. Скелет показывает порядок ответственности: context manifest записан до model call; operation создаётся после policy; verification предшествует success; state сохраняется после observation.

Как развивать harness по этапам

Не каждому проекту сразу нужен распределённый runtime. Полезно расти по мере появления требований.

Этап 1. Управляемый single-process loop

Минимум:

- typed proposals;
- фиксированный tool registry;
- schema validation;
- maximum steps и deadline;
- structured logs;
- read-only tools или ручное approval;

- terminal result с evidence.

Этого достаточно для коротких внутренних экспериментов.

Этап 2. Восстанавливаемый run

Добавляются:

- durable state;
- operation ledger;
- idempotency keys;
- pause/resume;
- cancellation;
- error taxonomy;
- simulated tools и replay tests.

Это граница, после которой agent можно безопасно оставлять без живого terminal session.

Этап 3. Production control

Появляются:

- identity-aware policy;
- attenuated capabilities;
- versioned approvals;
- cost and concurrency reservations;
- reconciliation workers;
- redacted distributed tracing;
- provider routing с data policy;
- SLO, overload behavior и runbooks.

Этап 4. Platform capability

Общие части выносятся в reusable services: model gateway, tool registry, policy service, artifact store, trace pipeline и SDK для runner. На этом этапе важно не заставлять все агенты использовать один универсальный prompt или state schema. Платформа стандартизирует contracts, а не domain reasoning.

Как тестировать harness

Тесты model behavior и тесты harness - разные наборы. Harness в значительной части детерминирован и должен проверяться без настоящего provider.

Contract tests компонентов

Model adapter получает scripted responses: text, tool proposal, refusal, malformed JSON, stream interruption, timeout и rate limit. Tool adapter получает success, partial result, timeout-after-write и duplicate request. State store симулирует conflict и lost lease.

Проверяются:

- нормализация provider response;
- schema и size limits;
- policy order;
- budget reservation/release;
- correlation IDs;
- retry classification;
- redaction до trace export;
- terminal result без недоказанных утверждений.

Transition tests

Каждый event проверяется против каждого допустимого state. Особенно важны race conditions:

- cancel одновременно с tool completion;
- approval одновременно с expiry;
- duplicate model response после retry;
- старый worker пишет state после lease transfer;
- два parallel calls завершаются в обратном порядке;
- process падает после external write до local commit.

Ожидаемый результат теста - конкретный state, ledger и набор effects, а не строка ответа модели.

Failure injection

Harness должен переживать искусственные сбои в каждой границе:

1. до model request;
2. после отправки, до response;
3. после response, до parsing;
4. после approval request;
5. после operation registration;
6. после external side effect;
7. во время verification;
8. после checkpoint, до status publish.

Для каждого места задаётся `recovery invariant`. Например: после повторного запуска существует не более одной `domain operation` с данным `idempotency key`; `Succeeded` невозможен без `verifier evidence`.

Replay и golden trajectories

Replay запускает `controller` и `adapters` на сохранённой последовательности `events`. Он помогает проверить `upgrade harness` без повторного вызова внешних `systems`.

Golden trajectory не должна фиксировать каждую формулировку модели. Она фиксирует существенные свойства:

- использованы только разрешённые `tools`;
- `write` не выполнен без `approval`;
- `budget` не превышен;
- найдено `evidence` нужного типа;
- `terminal state` корректен;
- `sensitive payload` не попал в `telemetry`.

Официальные `testing utilities` некоторых SDK позволяют подставлять `scripted model` и записывать `normalized interactions`. Даже если выбран другой `framework`, такой `interface` стоит реализовать самостоятельно.

Практикум: harness для агента проверки change request

Спроектируем `harness` для задачи: «Проанализируй `change request`, проверь `repository` и `CI`, затем подготовь `recommendation`. Ничего не `merge` и не изменяй без отдельного `approval`».

1. Определить границы

Agent может:

- читать `change request` и `diff`;
- искать по `repository`;
- запускать `tests` в `sandbox`;
- читать `CI logs`;
- создавать локальный `report artifact`.

Agent не может:

- `push`-ить `commits`;
- изменять `branch protection`;
- публиковать `review comment`;
- `merge`-ить `change request`;
- читать `secrets` вне `test environment`.

Это не текстовая просьба к модели, а tool catalog и policy.

2. Описать state

```
phase: collecting
change_ref: repo/pr/184
state_version: 1
verified:
  diff_loaded: false
  tests_run: false
findings: []
operations: {}
budgets:
  model_steps_left: 12
  tool_calls_left: 25
terminal:
  status: running
evidence: []
```

3. Собрать контекст для конкретного решения

На первом step не нужно отправлять модели весь repository. Context assembler передаёт objective, diff summary, changed paths, available read-only tools и policy. Когда model просит конкретный файл, tool возвращает содержимое с path, commit SHA и line ranges.

CI log сохраняется artifact, а в context попадает нормализованный fragment с job ID и timestamp. Строка из log не получает instruction authority.

4. Выполнить tools через gates

Proposal `repo.read_file` проходит schema и path scope. Proposal `shell.run_tests` дополнительно проходит command policy и запускается в sandbox с deadline. Proposal `github.merge` отсутствует в catalog, поэтому parser возвращает capability error, а не пытается найти похожую функцию.

5. Построить результат из evidence

Recommendation содержит:

- verified findings со ссылками на diff или log artifacts;
- tests и их exit status;
- непроверенные assumptions;
- residual risks;
- точное предложение следующего действия.

Если tests не запустились из-за отсутствующей dependency, результат `Blocked` честнее, чем модельное «изменение выглядит безопасно».

6. Проверить recovery

В тесте process завершается после запуска tests, но до записи результата. После restart harness находит operation ID, проверяет sandbox job status и присоединяет существующий result. Он не запускает второй дорогостоящий job автоматически.

Это упражнение показывает назначение harness лучше абстрактного списка компонентов: он сохраняет границу между тем, что model предложила, тем, что система разрешила, тем, что действительно произошло, и тем, что удалось доказать.

Типичные антипаттерны

Prompt-only safety. Все правила записаны в system prompt, а executor исполняет любой syntactically valid call.

God Runner. Один класс собирает context, вызывает provider, исполняет shell, пишет state и решает policy. Его невозможно тестировать по частям.

Provider-shaped domain model. Вся система хранит raw messages одного API; смена provider или версии ломает recovery.

Retry everything. Одинаковый decorator повторяет model calls, reads и non-idempotent writes.

Success by narration. Финальный текст модели автоматически становится `Succeeded` без verifier.

Transcript as state. Progression восстанавливается только из conversation history.

Unbounded tool output. Полный log, binary или database dump возвращается в model context и trace.

Approval without version. Оператор подтверждает старый plan, а harness выполняет его после изменения target state.

Double orchestration. Workflow engine и agent framework независимо retry-ят одну operation.

Invisible fallback. При provider error harness переключается на модель с другой data policy или capabilities, не фиксируя переход.

Tracing all content by default. Debug удобство превращается в неконтролируемую копию secrets и пользовательских данных.

Итоги главы

- Harness - runtime одного agent execution, а не синоним модели или orchestration platform.
- Его базовый invariant: model proposal никогда не является action напрямую.

- Run controller владеет state transitions; context assembler строит воспроизводимый request; adapters нормализуют внешние systems.
- Tool execution требует schema, policy, approval, budget, idempotency, normalization и verification.
- Logical state, operation ledger и reconciliation позволяют переживать crash в опасной точке между side effect и checkpoint.
- Budgets резервируются до параллельной работы; deadlines, timeouts, leases и approval expiry имеют разные semantics.
- Retry применяется к классифицированной ошибке, а semantic failure запускает новое решение.
- Tracing связывает Task, model и tool operations, но sensitive content редактируется до export.
- AX управляет workload и инфраструктурным lifecycle; harness управляет внутренним run и восстанавливает его из durable state.
- Framework выбирают по recovery и enforcement contracts, а не по количеству готовых agent abstractions.
- Начинать можно с маленького loop, но production-уровень требует явных identity, policy, audit и failure injection tests.


Дальше. Harness задаёт места хранения и recovery hooks. Следующая глава уточнит семантику данных в этих местах, чтобы restart не превращал transcript, memory и authoritative state в одну неразличимую массу.

Источники и дальнейшее чтение

- [OpenAI Agents SDK: Running agents](#) - run configuration, tool execution, sessions, approvals и tracing.
- [OpenAI Agents SDK: Guardrails](#) - границы input, output и tool guardrails, включая blocking execution.
- [OpenAI Agents SDK: Testing](#) - provider-neutral scripted testing orchestration.
- [Anthropic: Writing effective tools for agents](#) - tools как контракт между детерминированной системой и вероятностным агентом.
- [Model Context Protocol: Architecture overview](#) - границы protocol, host/client/server и discovery tools/resources/prompts.
- [Temporal: Activity Definition](#) - retries, timeouts, heartbeats и требования к idempotent external operations.
- [OpenTelemetry GenAI semantic conventions](#) - общие attributes и operations для agent/model/tool telemetry.

Context, state, memory и snapshot: не смешивать

Состояние агента: семь разных сущностей, которые часто ошибочно называют «памятью»



Глава 4 ввела state, journal, checkpoint и context assembler как компоненты harness. Теперь определим их семантические гарантии: какие данные производны, какие авторитетны, что переживает restart и что можно безопасно восстановить.

Представим, что агент расследует сетевой инцидент. Он прочитал alert, проверил DNS, запросил логи и подготовил изменение. Затем процесс перезапустился.

Что именно должно вернуться после запуска?

- исходная цель;
- подтверждённые факты;
- список уже выполненных tool calls;
- ожидающий approval;
- открытые файлы;
- разговор с пользователем;
- найденные в прошлых задачах рекомендации;
- TCP connection к log server;
- содержимое Python heap;
- фактическое состояние DNS и load balancer.

Это десять разных видов информации с разными владельцами, сроками жизни и гарантиями. Называть их одним словом `memory` удобно только до первого сбоя.

Главный принцип главы:

Context - то, что модель видит сейчас. **State** - то, что приложение считает текущим **progression**. **Memory** - выбранная информация для будущих обращений. **Snapshot** - технический снимок части **runtime**. Ни одна из этих сущностей не заменяет **external source of truth**.

Различие не академическое. От него зависит, повторит ли агент `write` после `restart`, примет ли устаревшее `summary` за факт и сможет ли оператор объяснить, почему было принято решение.

Карта сущностей

Полезно различать как минимум восемь слоёв.

Сущность	Главный вопрос	Типичный срок жизни	Пример
Request context	Что модель увидит в этом inference?	один model call	system instructions, goal, selected evidence
Working state	Где находится Task сейчас?	один run или Task	phase, verified facts, budgets, pending operation
Session history	Что происходило в диалоге?	thread/session	user messages, assistant responses, tool items
Persistent memory	Что стоит использовать в будущих задачах?	несколько runs	preference, reusable lesson, known environment fact
Workspace/artifacts	Какие файлы и evidence созданы?	Task/project	logs, reports, repository checkout, raw tool output
Process RAM	Что нужно живому процессу прямо сейчас?	жизнь процесса	objects, stacks, caches, open descriptors
Checkpoint/snapshot	Как ускорить или обеспечить resume?	до expiry/замены	serialized state, graph checkpoint, VM/process image
External source of truth	Каково реальное состояние мира?	задаёт внешняя система	Git branch, ticket status, DNS record, database row

Одна физическая технология может хранить несколько слоёв. PostgreSQL может содержать `working state`, `session history` и `persistent memory`. Это не превращает их в одну семантическую сущность. И наоборот, одна сущность может быть распределена: `request context` состоит из `instructions`, выбранных `memory items`, `state projection` и `tool schemas`.

Семь вопросов к любому фрагменту данных

Перед тем как решить «сохраним это в memory», ответьте:

1. **Scope:** к чему относится запись - request, run, thread, user, agent, project или organization?
2. **Lifetime:** когда она должна исчезнуть?
3. **Authority:** является ли это фактом, гипотезой, preference или производным summary?
4. **Provenance:** откуда информация получена и когда?
5. **Mutability:** кто может её изменить и как разрешаются конфликты?
6. **Rebuildability:** можно ли восстановить запись из другого источника?
7. **Sensitivity:** содержит ли она secrets, personal data или privileged instructions?

Если хотя бы scope и authority неизвестны, автоматическая retrieval такой записи опасна.

Context: конечный вход одного model call

LLM не читает database, filesystem или предыдущий run напрямую. Она получает конечную последовательность tokens в конкретном request. Это и есть request context.

В него могут входить:

- platform и agent instructions;
- objective пользователя;
- projection текущего state;
- recent conversation items;
- retrieved memory;
- tool descriptions;
- selected files и search results;
- observations текущего шага;
- examples и output schema.

Context существует только для inference. После получения response его содержимое не становится автоматически durable state. Если важный факт присутствовал только в prompt, после compaction или смены provider он может исчезнуть.

Context window - бюджет, а не хранилище

Большое context window создаёт иллюзию, что можно передавать всю историю. Но проблема не только в жёстком token limit. Шумные и противоречивые данные уменьшают полезность внимания, повышают стоимость и затрудняют поиск нужного evidence.

Хороший context assembler отвечает не на вопрос «что у нас есть?», а на вопрос «какой минимальный набор данных нужен для текущего decision point?».

Упрощённо:

```
policy + objective + state projection + selected evidence
+ relevant history + tool catalog + output reserve <= context budget
```

При нехватке бюджета нельзя просто удалять самые старые tokens. Старое approval или исходное constraint может быть важнее свежего многословного tool output.

Context является производным представлением

Request context лучше собирать заново из durable components. Тогда его можно проверить и воспроизвести.

Manifest context assembly может содержать:

```
context_manifest:
  request_id: mr-203
  state_version: 18
  prompt_bundle: incident-agent@7
  objective_ref: artifact://task/input
  included_observations: [obs-41, obs-44, obs-45]
  memory_items: [mem-user-12, mem-runbook-8]
  tool_catalog: tools-readonly@5
  compaction: incident-summary@3
  input_tokens: 32740
```

Manifest не обязан копировать весь prompt, но должен объяснять его состав. Это помогает отличить ошибку reasoning от ошибки retrieval или compaction.

Instruction и evidence нельзя смешивать

Файл, web page, log line и memory item по умолчанию являются данными. Они не получают право менять policy только потому, что попали в context.

Assembler должен сохранять:

- тип источника;
- trust level;
- timestamp и version;
- допустимое использование;
- ссылку на raw artifact.

Строка `ignore previous instructions` из retrieved document остаётся содержимым документа. Техническое enforcement всё равно находится в harness policy.

Working state: восстанавливаемая модель progression

Working state отвечает на вопрос: что уже известно, что ожидается и какой следующий transition допустим?

Он должен быть структурированным и достаточно компактным, чтобы application code мог проверять invariants без участия модели.

```
run_id: run-118
state_version: 23
phase: diagnosing
objective:
  kind: restore_service
  target: payments-api
constraints:
  writes_require_approval: true
verified_facts:
  - id: fact-31
    claim: origin health endpoint returns 200
    source: probe-771
    observed_at: 2026-10-05T02:10:18Z
hypotheses:
  - id: hyp-9
    text: edge certificate bundle is stale
    status: testing
pending:
  kind: tool
  operation_id: op-202
budgets:
  model_steps_left: 8
  tool_calls_left: 17
terminal:
  status: running
```

State хранит raw facts, а prompt форматируется позднее

State не должен состоять из текста «агент думает, что проблема, вероятно, в сертификате». Разделяйте observation, interpretation и decision.

- Observation: probe вернул serial 41:A9 в 02:10 UTC.
- External fact: certificate inventory связывает 41:A9 с expired bundle.
- Hypothesis: edge использует stale bundle.
- Decision: сравнить config revision edge nodes.

Так разные nodes и модели могут использовать данные по-разному, а verifier способен проверить claim.

Производные presentation strings не нужно сохранять, если их легко собрать из raw fields. Это уменьшает расхождение между state и отображением.

State version защищает от старых событий

Каждый mutation получает монотонную версию. Model proposal, approval и tool result ссылаются на версию, для которой были созданы.

Если approval относится к state_version=17, а target config уже изменился на версии 20, harness не должен выполнять старый plan. Он запрашивает новое решение или повторную проверку.

При нескольких workers нужен concurrency control: compare-and-swap, lease, transaction или single-writer discipline. Last-write-wins опасен, потому что поздний, но устаревший worker может стереть свежие evidence.

State и journal дополняют друг друга

Current state удобен для быстрого продолжения. Append-only journal удобен для аудита и восстановления причинной цепочки.

```
ObservationRecorded(obs-41)
HypothesisAdded(hyp-9)
OperationPrepared(op-202)
ApprovalRequested(ap-17)
ApprovalGranted(ap-17, state_version=23)
OperationStarted(op-202)
```

Необязательно восстанавливать state replay всех events, как в полном event sourcing. Практичный вариант - current state, operation ledger и журнал существенных transitions.

Session history: transcript не равен state

Session history хранит последовательность conversation items. Она полезна для continuity: помнить уточнение пользователя, предыдущий ответ и ожидающий tool result.

Но transcript плохо подходит как единственный working state:

- факты смешаны с гипотезами и исправлениями;
- одно утверждение может быть отменено позже;
- model-generated text выглядит так же убедительно, как observation;
- трудно атомарно обновить budget или operation status;
- история растёт без границ;
- compaction теряет детали;
- application code не может надёжно проверить invariant.

Поэтому session может помочь собрать context, но controller восстанавливается из structured state и ledger.

Официальные agent SDK часто называют session «memory», потому что она автоматически подставляет history в следующий run. Это удобный API-термин, но инженер должен помнить: сохранённая история разговора не становится ни verified knowledge, ни checkpoint внешних side effects.

Persistent memory: информация для будущих обращений

Persistent memory существует за пределами одного текущего run. Её цель - сократить повторное исследование или сохранить полезную continuity.

Полезны четыре класса.

Semantic memory

Устойчивые факты и понятия: имя сервиса, topology, внутренние термины, проверенный mapping между team и repository.

Episodic memory

Сведения о прошлом episode: «в инциденте INC-42 похожая ошибка была вызвана stale edge config». Episode помогает сформировать гипотезу, но не доказывает причину нового инцидента.

Procedural memory

Проверенная последовательность действий: runbook, diagnostic checklist, правила использования tool. Лучше хранить её как versioned skill или документ, а не как случайный prose fragment.

Preference memory

Предпочтения пользователя или команды: формат отчёта, язык, рабочие часы, допустимый уровень подробности. Preference не должна расширять authorization.

Класс	Может подсказать	Не может доказать
Semantic	где искать service owner	кто владеет сервисом прямо сейчас без проверки
Episodic	какую гипотезу проверить первой	что новый incident имеет ту же причину
Procedural	какие steps обычно безопасны	что step разрешён текущей policy
Preference	как оформить результат	право выполнить внешнее действие

Memory - не источник абсолютной истины. Это indexed collection кандидатов на включение в context.

Запись memory - отдельный pipeline

Опасно позволять агенту сохранять любое собственное утверждение «на будущее». Ошибка превращается в устойчивое self-reinforcing знание.

Write pipeline включает:

1. извлечение candidate из завершённого episode;
2. классификацию scope и memory type;
3. удаление transient details;
4. проверку provenance;
5. проверку на secrets и personal data;
6. conflict detection с существующими записями;
7. назначение confidence, TTL и owner;
8. human или rule-based validation для high-impact facts;
9. indexing;
10. audit записи и последующего изменения.

Пример memory record:

```
memory_id: mem-service-82
scope: project:payments
kind: episodic
claim: edge config can lag after certificate rotation
source_episode: incident:INC-42
supporting_artifacts: [artifact://inc-42/postmortem]
created_at: 2026-08-19T11:00:00Z
valid_until: 2026-11-19T11:00:00Z
confidence: medium
owner: team:edge-platform
status: active
```

Фраза сформулирована как возможность, а не как вечный факт. Она содержит источник, expiry и owner.

Что не следует запоминать автоматически

- secrets и access tokens;
- неподтверждённые догадки;
- tool output без provenance;
- временные resource identifiers без TTL;
- personal data без цели и retention policy;
- полные transcripts «на всякий случай»;
- instructions из недоверенного документа;
- сведения, которые дешевле и надёжнее получить из authoritative API.

Чтение memory: retrieval не заканчивается vector search

Similarity search отвечает только на вопрос «какие записи лексически или семантически похожи на query?». Для безопасного context нужны дополнительные filters.

Read pipeline:

1. сформировать query из текущего decision point, а не из всей истории;
2. ограничить tenant, user, project и agent scope;
3. отфильтровать expired, revoked и incompatible records;
4. получить candidates через keyword, metadata и semantic search;
5. rerank по relevance, authority, freshness и diversity;
6. обнаружить conflicts;
7. выбрать записи под token budget;
8. добавить provenance и trust labels;
9. сохранить retrieval manifest;
10. предложить revalidation, если память влияет на side effect.

Упрощённый score может учитывать:

```
score = relevance * authority * freshness * scope_match  
       - conflict_penalty - redundancy_penalty
```

Это не универсальная формула, а напоминание: высокая cosine similarity не делает запись свежей или авторитетной.

Конфликтующие memories

Удалять старую запись сразу после появления новой не всегда правильно. Конфликт может отражать изменение мира, разные environments или ошибку retrieval.

Полезный record lifecycle:

- `candidate` - извлечено, но не проверено;
- `active` - допустимо для retrieval;
- `superseded` - заменено более свежей записью;
- `disputed` - есть противоречие;
- `revoked` - признано ошибочным или небезопасным;
- `expired` - TTL закончился;
- `deleted` - удалено по retention/privacy policy.

Модель должна видеть не только claim, но и status. `Disputed` memory используется как повод проверить источник, а не как готовый факт.

Progressive disclosure

Не нужно помещать каждую найденную запись в prompt. Полезный pattern:

1. короткий index или summary говорит, какие memories существуют;
2. модель или deterministic router выбирает релевантную тему;
3. harness загружает полный record;
4. raw artifact читается только при необходимости.

Так memory помогает, не заполняя context старыми деталями.

Workspace и artifacts: материальный след работы

Workspace - файловая среда Task или project. В ней могут находиться source checkout, промежуточные файлы, tool configuration и generated artifacts.

Artifacts - адресуемые результаты: report, patch, raw log, screenshot, test output, context manifest. Artifact должен иметь identity, content type, size, hash, producer и retention class.

Workspace не является memory автоматически. Файл становится полезным для агента только после discovery, чтения и включения релевантной части в context. И наоборот, удаление файла из context не удаляет его из workspace.

Файл, state и artifact играют разные роли

Допустим, агент выполнил diagnostic command.

- Полный stdout сохранён как artifact.
- В state записано: command завершился, exit code 0, artifact ID такой-то.
- В context следующего шага попали только 30 строк вокруг ошибки.
- В persistent memory после завершения может попасть проверенный lesson, но не весь log.

Так сохраняется audit без переполнения prompt.

Workspace требует lifecycle

Нужны правила:

- namespace и ownership;
- quota;
- allowed paths;
- encryption и secret handling;
- cleanup после Task;
- promotion нужных artifacts в долгоживущее хранилище;
- защита от path traversal и symlink surprises;

- version/hash при чтении файлов моделью.

Путь `/workspace/result.txt` без Task identity и hash слаб для аудита: файл мог измениться между решением и выполнением.

Process RAM: удобное, но недолговечное состояние

Heap, stack, in-memory cache, open file descriptors и активные coroutines нужны живому process. Они быстрые, но не должны быть единственной копией критического progression.

В RAM допустимо хранить:

- parsed config;
- connection pools;
- short-lived caches;
- buffered telemetry с лимитом;
- current call objects;
- derived prompt representation.

В RAM опасно хранить как единственную копию:

- approval;
- idempotency ledger;
- external operation ID;
- оставшийся budget;
- verified fact;
- terminal evidence;
- единственный экземпляр user-provided artifact.

Process может исчезнуть из-за OOMKill, node failure, deploy, scale-down или обычного restart. Production recovery начинается с предположения, что RAM потеряна.

Checkpoint и snapshot: логический и технический уровни

Термины используются по-разному в frameworks, поэтому contract важнее названия.

Logical checkpoint сериализует application state в безопасной границе: current node, structured state, pending operations, budgets и identifiers. Обычно он не содержит весь heap.

Runtime snapshot фиксирует техническое состояние execution environment: filesystem, memory pages, process tree и иногда virtual device state. Его цель - быстро продолжить работу, но точный состав зависит от runtime.

Свойство	Logical checkpoint	Runtime snapshot
Уровень	приложение	process/container/VM/runtime
Формат	schema, records, journal	memory/filesystem image, runtime metadata
Переносимость	выше при versioned schema	зависит от kernel, image, template, architecture
Размер	обычно небольшой	может быть большим
Понимает domain state	да	обычно нет
Восстанавливает sockets	явно reconnect	технически возможно не всегда надёжно
Доказывает external outcome	нет	нет
Подходит для audit	да, если есть provenance	ограниченно

Оба механизма полезны. Ошибка - считать runtime snapshot заменой логического checkpoint.

Snapshot фиксирует момент, но не распределённую транзакцию

В момент snapshot:

- external API мог уже применить write;
- response ещё мог не попасть в process;
- database transaction могла быть open;
- filesystem buffers могли не flush-иться;
- remote lease могла продолжать истекать;
- credential могла стать недействительной через секунду;
- DNS и routing могли измениться.

Resume не возвращает весь внешний мир к прошлому моменту. Поэтому snapshot не является undo и не обеспечивает exactly-once side effects.

Consistency boundary должна быть явной

Перед logical checkpoint harness стремится достичь состояния, которое можно интерпретировать после restart:

- все completed observations durably записаны;
- незавершённая operation имеет ID и статус;
- approval связан со state version;
- context можно пересобрать;
- artifacts flush-нуты и адресуемы;
- remaining budgets сохранены;
- active lease или heartbeat известен.

Перед runtime snapshot дополнительно полезно:

- остановить создание новых operations;
- дождаться или классифицировать active calls;
- flush durable files;
- закрыть или пометить connections для reconnect;
- сохранить snapshot metadata и compatibility identity.

Полностью quiescent state получить не всегда возможно. Тогда snapshot metadata должна перечислить unknown operations.

External source of truth нельзя заменить памятью

Для network agent реальный route находится на устройстве или в authoritative controller. Для coding agent реальный commit находится в Git. Для support agent статус case находится в ticket system.

Local state и memory могут содержать projection external world, но projection устаревает.

Каждая запись должна отвечать:

- какой источник authoritative;
- когда projection получена;
- какая freshness нужна для решения;
- как перепроверить;
- что делать при недоступности источника.

Например:

```
projection:
  claim: api.example.com -> 203.0.113.25
  source: authoritative-dns/ns1
  observed_at: 2026-10-05T02:13:22Z
  freshness_slo: 30s
  raw_observation: artifact://dns/probe-91
```

Через пять минут эта запись остаётся полезной историей, но может быть недостаточно свежей для production write.

Cache, projection и memory

Cache оптимизирует повторное получение и может быть отброшен. Projection представляет external state на конкретный момент. Memory выбирает информацию для будущего reasoning. Один record способен играть несколько ролей физически, но invalidation policy различается.

Если service inventory API дешёв и надёжен, лучше перечитать его, чем хранить вечную semantic memory о владельце сервиса. Memory полезна, когда помогает найти правильный authoritative query.

Resume contract: восстановить работу, а не ощущение непрерывности

После restart новый process не обязан «помнить», что чувствовал старый. Он обязан безопасно продолжить contract.

Минимальный resume protocol:

1. Захватить lease run и убедиться, что старый worker больше не authoritative.
2. Загрузить schema/version agent specification.
3. Загрузить latest valid logical checkpoint.
4. Проверить integrity state и artifacts.
5. Восстановить budget и cancellation state.
6. Найти operations со статусом `prepared`, `running` или `unknown`.
7. Выполнить reconciliation с external systems.
8. Проверить approval freshness.
9. Обновить projections authoritative state.
10. Пересобрать context из актуальных данных.
11. Только после этого разрешить новый model step.

```
restart
-> claim lease
-> load checkpoint
-> validate schema
-> reconcile operations
-> refresh external facts
-> rebuild context
-> continue transition
```

Автоматически отправлять в модель последний transcript сразу после restart опасно: там может быть старый plan, а external write уже выполнен.

Schema evolution

Long-running Task может пережить upgrade agent code. State и memory formats должны иметь version.

Варианты:

- backward-compatible reader;
- explicit migration;
- pin Task к старой agent version;

- fail с human-readable migration requirement.

Тихо игнорировать неизвестные fields или заменять их default значениями опасно для approval и operation ledger.

Snapshot compatibility ещё строже: process image может зависеть от runtime image, kernel features, architecture и library versions. При несовместимости правильнее выполнить fresh process start и восстановить logical state.

Compaction и summarization

Когда history растёт, harness создаёт summary или compacted state. Это преобразование с потерями.

Хорошая compaction сохраняет:

- objective и constraints;
- verified facts с provenance;
- rejected hypotheses и почему они отклонены;
- принятые decisions;
- open questions;
- pending approvals/operations;
- external identifiers;
- budgets;
- ссылки на raw artifacts.

Плохая compaction сохраняет только плавный narrative. Narrative легко скрывает uncertainty и превращает предположение в факт.

Summary не переписывает историю

Сохраняйте relation:

```
summary:
  id: sum-19
  covers_events: [evt-100, evt-184]
  generated_by: summarizer@3
  created_at: 2026-10-05T02:30:00Z
  source_hash: sha256:...
  claims:
    - text: edge nodes disagree on certificate serial
      evidence: [obs-41, obs-44]
```

Если summary используется для risky decision, harness может открыть исходные observations.

Privacy, security и retention

Долгоживущая memory увеличивает пользу и одновременно blast radius утечки.

Для каждого слоя нужна отдельная policy:

Слой	Типичный риск	Контроль
Request context	отправка данных provider	redaction, provider/data policy
Session history	накопление sensitive dialog	encryption, TTL, access control
Working state	подмена progression	integrity, versioning, least privilege
Persistent memory	долговременная ошибка или утечка	validation, scope, expiry, deletion
Workspace/artifacts	secrets и большие raw payloads	sandbox, quota, malware scan, retention
Snapshot	plaintext RAM и credentials	encryption, isolation, compatibility policy
Trace	копия prompts/tool results	content controls, sampling, redaction before export

Нужно поддерживать deletion не только основной записи. Memory item может иметь embedding, cache entry, search index, backup и trace reference. Privacy delete должен знать все производные копии или иметь документированный срок их исчезновения.

Memory poisoning

Атакующий пытается сохранить инструкцию или ложный факт так, чтобы будущий run автоматически доверял ему.

Защита:

- недоверенный content не повышает свой trust level;
- write pipeline отделён от текущего model response;
- sensitive scopes требуют validation;
- provenance всегда доступен при retrieval;
- memory не расширяет tool authority;
- есть revoke и conflict workflow;
- evals включают malicious memory records.

Multi-agent boundaries

Не вся память должна быть общей. Shared memory облегчает coordination, но распространяет ошибки и секреты.

Разделяйте:

- private scratch state одного agent;
- Task-shared verified facts;
- team/project memory;
- user preferences;
- organization knowledge;
- public knowledge.

Child agent получает только необходимую projection parent state. Его свободный transcript не должен автоматически становиться parent truth. Parent принимает structured result с evidence и сам решает, что добавить в shared state.

Что сохраняет АХ, а что обязан сохранить агент

Для АХ особенно важно не путать durable Workspace и живой process. Runner может стартовать заново, даже если файлы `/workspace` сохранились. Agent harness должен уметь reconstruct progression из durable state.

Практичный contract:

- АХ Task хранит инфраструктурный lifecycle и execution metadata;
- Workspace хранит files, artifacts и сериализованный agent state;
- harness хранит state schema, operation ledger и resume logic;
- Model/Gateway предоставляет inference, но не является authoritative memory Task;
- Substrate snapshot может ускорять runtime resume, но не заменяет application recovery;
- external systems остаются источниками истины для своих resources.

Если процесс восстановился из snapshot, harness всё равно проверяет leases, credentials, connections и незавершённые operations. Если snapshot несовместим, fresh process должен продолжить работу из logical checkpoint.

Куда положить новую информацию: decision table

Если информация...	Основное место	Дополнительное действие
нужна только для текущего model decision	Request context	не сохранять без причины
определяет допустимый следующий transition	Working state	versioned update

Если информация...	Основное место	Дополнительное действие
является сообщением пользователя	Session history	извлечь structured update при необходимости
полезна будущим Tasks	Persistent memory candidate	validation, scope, TTL, provenance
большая или бинарная	Artifact store/workspace	в state сохранить reference и hash
дешёво получается из authoritative API	Cache/projection	здать freshness, не считать вечной memory
нужна только живому adapter	Process RAM	предусмотреть rebuild/reconnect
ускоряет восстановление runtime	Snapshot	сохранить compatibility и retention metadata
подтверждает внешний side effect	External system + operation ledger	выполнить независимый read-back

Короткое правило: сохраняйте semantic minimum в state, evidence в artifacts, reusable lesson в memory, а current truth перепроверяйте во внешней системе.

Reference data model

Ниже не готовая schema, а пример явного разделения.

```
task:
  id: task-908
  objective_ref: artifact://task-908/input
  agent_spec: network-diagnostician@5

state:
  schema_version: 4
  state_version: 27
  phase: verifying
  verified_fact_refs: [fact-19, fact-22]
  pending_operation: op-741
  approval_ref: null
  budgets_ref: budget-908

session:
  id: thread-311
  latest_item_seq: 84
  compaction_ref: summary-12

memory_query:
  scope: project:edge
  retrieved: [mem-71, mem-90]
  manifest_ref: retrieval-551

workspace:
  root: workspace://task-908
  artifacts:
    - id: tls-probe-203
      sha256: 8c1...
      media_type: application/json

checkpoint:
  id: cp-27
  state_version: 27
  operation_ledger_offset: 119
  created_at: 2026-10-05T02:44:00Z

runtime_snapshot:
  id: snap-18
  checkpoint_id: cp-27
  runtime_identity: runner-image@sha256:91e...
  status: compatible

external_projections:
  - resource: dns://example.com/api
    observation_ref: obs-22
    observed_at: 2026-10-05T02:43:41Z
    freshness_slo: 30s
```

Связь snapshot с logical checkpoint особенно полезна: после resume harness знает, какое application state ожидалось в снимке и с какого journal offset проверять новые события.

Как тестировать state и memory layer

State invariants

Автоматические тесты проверяют:

- state version растёт монотонно;
- terminal state не возвращается в running;
- один active lease имеет одного owner;
- pending operation существует в ledger;
- approval ссылается на текущий proposal и state version;
- budget не увеличивается после restart;
- verified fact содержит provenance;
- context можно пересобрать из referenced data.

Recovery matrix

Проверяйте crash в каждой границе:

Момент сбоя	Что должно произойти после restart
До записи model response	безопасный новый model call в оставшемся budget
После response, до state update	duplicate response игнорируется или применяется один раз
После operation prepare	operation reconciled до execution
После external write	read-back определяет outcome, blind retry запрещён
После artifact upload, до state reference	orphan artifact обнаруживается cleanup/reconciliation
Во время compaction	прежний valid summary остаётся active
После memory index, до metadata commit	incomplete candidate не участвует в retrieval
После snapshot, до suspend status	snapshot lineage проверяется, active process fencing сохраняется

Memory evals

Memory оценивается не количеством сохранённых записей. Полезны метрики:

- retrieval precision и recall на реальных задачах;
- доля retrieved items, фактически использованных;
- stale/expired retrieval rate;
- conflict detection rate;
- число corrections пользователем;

- доля записей без provenance;
- memory poisoning success rate;
- token cost retrieved memory;
- improvement verified task success;
- deletion completion time.

Memory, которая увеличивает token usage и уверенность, но не улучшает verified outcome, не приносит пользы.

Counterfactual tests

Меняйте один слой независимо:

- тот же state, другая memory;
- та же memory, более свежая external projection;
- тот же context, новый state version;
- тот же checkpoint, несовместимый runtime snapshot;
- тот же episode, отозванный memory record.

Правильная система предпочитает свежий authoritative факт старой memory, отклоняет stale approval и умеет продолжить без runtime snapshot.

Практикум: восстановление агента после неизвестного результата

Сценарий: агент должен заменить backend в load balancer после approval. Tool request получил timeout, затем process завершился.

До выполнения

Working state:

```
phase: executing
state_version: 14
proposal:
  id: change-51
  target: lb/payment-api/backend-a
  desired: backend-b
approval:
  id: approval-88
  proposal_id: change-51
  state_version: 14
operation:
  id: op-771
  idempotency_key: payment-api-change-51
  status: prepared
```

В session history есть объяснение пользователю. В workspace лежат diff и rollback plan. Persistent memory содержит старый episode о проблемах этого load balancer. External source of truth - API самого load balancer.

Во время сбоя

Executor отправил operation, но не получил response. В ledger сохраняется `outcome=unknown`. Runtime snapshot отсутствует.

Важно: отсутствие snapshot не является потерей Task, потому что logical checkpoint уже содержит proposal, approval и operation identity.

После restart

Новый process:

- 1. получает lease;
- 2. загружает checkpoint;
- 3. не подставляет старый transcript модели;
- 4. видит `op-771` со статусом `unknown`;
- 5. читает current backend из load balancer API;
- 6. находит `backend-b` и change ID, связанный с operation;
- 7. записывает observation;
- 8. переводит operation в `applied_unverified`;
- 9. запускает health probes;
- 10. только после успешной проверки ставит `verified` и завершает Task.

Если API показывает `backend-a`, harness проверяет operation status по external ID. Только затем policy решает, допустим ли retry с тем же idempotency key.

Что здесь делает каждый слой

Слой	Роль
Context	после reconciliation показать модели актуальные evidence
Working state	сохранить phase, proposal, approval и pending operation
Session history	сохранить человеческий диалог, но не определять outcome
Memory	подсказать прошлый failure mode, не объявлять его причиной
Workspace/artifacts	хранить diff, raw responses и probe results
Process RAM	новый process строит заново
Logical checkpoint	дать точку безопасного application resume
Runtime snapshot	мог бы ускорить start, но не обязателен

Слой	Роль
External source of truth	показать, применилось ли изменение реально

Это и есть правильная mental model: continuity создаётся не иллюзией непрерывной памяти, а согласованными identifiers, evidence и recovery protocol.

Типичные антипаттерны

Everything is memory. Transcript, vector store, state JSON и workspace называют одним термином, поэтому невозможно определить гарантию.

Transcript as database. Controller ищет текущий budget или approval в тексте сообщений.

Context as archive. В каждый request отправляется вся история «чтобы ничего не потерять».

Summary as truth. Model-generated compaction заменяет raw observations и удаляет uncertainty.

Vector similarity as authority. Наиболее похожая запись считается правильной без проверки scope, freshness и source.

Agent writes its own truth. Любой final answer автоматически становится persistent memory.

No expiry. Resource locations, team ownership и procedures живут в memory бесконечно.

Shared memory by default. Все agents и tenants читают один store без namespace и capability checks.

Snapshot equals transaction. Восстановление RAM считается откатом external side effects.

Snapshot equals backup. Единственный runtime image используется как DR strategy.

Process RAM as checkpoint. Важные operation IDs существуют только в objects живого процесса.

Fresh process means new operation. После Task retry создаётся другой idempotency key и повторяется уже выполненный write.

Delete only the row. Основная memory запись удалена, но embedding, cache, snapshot и trace продолжают хранить content.

Итоги главы

- Context - конечный набор tokens одного model call; его нужно собирать, а не путать с хранилищем.

- Working state - структурированная и versioned модель progression, пригодная для programmatic checks и recovery.
- Session history обеспечивает диалоговую continuity, но не является authoritative state.
- Persistent memory хранит кандидаты для будущего reasoning: semantic, episodic, procedural и preference records.
- Memory write требует validation, scope, provenance, TTL и privacy policy; retrieval требует больше, чем similarity search.
- Workspace хранит файлы и evidence; state хранит ссылки и смысл; context получает только нужную projection.
- Process RAM удобна, но критический progression обязан переживать её потерю.
- Logical checkpoint и runtime snapshot решают разные задачи. Snapshot ускоряет resume, но не откатывает внешний мир.
- External system остаётся source of truth; локальные записи являются timestamped projections.
- Resume начинается с lease, checkpoint и reconciliation, а не с повторной отправки transcript модели.
- АХ может сохранять Workspace и управлять lifecycle, но harness отвечает за state schema, ledger и application recovery.
- Качество memory измеряется улучшением verified outcomes, а не количеством записей.

Дальше. State описывает progression, но сам по себе не наблюдает среду и не создаёт side effects. В следующей главе разберём interfaces, через которые agent получает capabilities: Tools, MCP и Skills.

Источники и дальнейшее чтение

- [Anthropic: Effective context engineering for AI agents](#) - context как конечный набор tokens, compaction и structured note-taking.
- [Anthropic: Effective harnesses for long-running agents](#) - continuity между ограниченными context windows через явные artifacts и progress records.
- [OpenAI Agents SDK: Sessions](#) - conversation history, session backends и resume interrupted runs.
- [OpenAI Agents SDK: Agent memory](#) - различие session memory и distilled reusable memory.
- [LangGraph: Persistence](#) - checkpoints для thread state и stores для cross-thread memory.
- [LangGraph: Thinking in LangGraph](#) - raw state, node boundaries, checkpoint frequency и human interrupts.
- [Anthropic: Contextual Retrieval](#) - влияние surrounding context на качество retrieval.
- Главы 14 и 39 этой книги - platform-specific semantics suspend, snapshot ownership и compatibility.

Tools, MCP и Skills

После главы 5 понятно, где хранится progression и как отличать его от context и memory. Теперь разберём interfaces, через которые agent наблюдает среду и действует в ней, не передавая модели неограниченную власть.

Инженер подключает к агенту Git, Kubernetes, базу данных и систему тикетов. Через несколько дней в каталоге уже пятьдесят операций. Модель путает `get_issue` и `search_issues`, отправляет лишние параметры, а при сетевой ошибке повторяет создание комментария. Команда добавляет MCP server и ожидает, что проблема исчезнет. Она не исчезает: появился стандартный способ доставки тех же плохо спроектированных операций.

Затем создают skill с инструкцией «сначала проверь состояние, потом меняй». Это улучшает поведение на демонстрации, но не запрещает вызов опасного tool и не заменяет approval. Получается система, в которой три полезных механизма выполняют не свои роли.

Главный принцип главы:

Tool отвечает на вопрос «что система умеет сделать?», **MCP** - «как capability обнаружить и вызвать через общий протокол?», **Skill** - «как правильно выполнить класс задач?». Полномочия, policy и подтверждение результата находятся ещё одним слоем выше.

Четыре сущности, которые чаще всего смешивают

Сущность	Что это	Что она не гарантирует	Пример
API, CLI, library	интерфейс конкретной системы или код реализации	понятность для модели, безопасный retry, единый discovery	Kubernetes API, <code>git</code> , Python SDK
Tool	формализованная операция, доступная agent loop	транспорт, авторизацию и правильный порядок применения	<code>dns.lookup</code> , <code>issue.create_comment</code>
MCP	протокол обмена context и capabilities между host, client и server	доверие к server, least privilege и безопасность действия	MCP server для GitHub или filesystem
Skill	пакет процедурных инструкций, scripts и references	новые полномочия и технический запрет опасных действий	skill расследования TLS incident

Tool может быть обёрткой над API, локальной функцией, shell command или вызовом другого сервиса. MCP tool является tool, доступным через MCP. Skill может вызывать несколько tools, но сам по себе не обязан быть executable operation.

Есть и пятая сущность - workflow. Это фиксированный или параметризованный граф шагов с явными transitions. Skill советует агенту, как действовать; workflow исполняет заранее определённую структуру. Если порядок обязан быть детерминированным по требованиям compliance, одной инструкции в skill недостаточно.

Tool как интерфейс между вероятностной моделью и детерминированной системой

Для человека UI снижает вероятность ошибки кнопками, подписями и disabled states. Для агента такую роль играет tool contract. Модель выбирает operation и генерирует arguments вероятностно; executor должен интерпретировать их однозначно.

Хороший tool contract содержит больше, чем JSON Schema:

Поле	Зачем оно нужно
Stable name	помогает выбору и сохраняет совместимость traces
Purpose	объясняет, когда применять tool и когда не применять
Input schema	ограничивает форму аргументов, типы, enum и required fields
Preconditions	описывает, что должно быть истинно до вызова
Side-effect class	отличает read, reversible write и irreversible action
Authority scope	показывает требуемые resource, tenant, role и environment
Idempotency	определяет, можно ли повторить request и с каким key
Result schema	отделяет data, status, warnings, references и evidence
Error model	различает invalid input, denied, retryable, partial и unknown outcome
Limits	фиксирует pagination, timeout, payload size и rate limits
Version	позволяет менять contract без скрытой поломки agents

Минимальное описание операции может выглядеть так:

```
name: dns.lookup
description: >
  Читает текущие DNS records для полного domain name.
  Используй для проверки фактического состояния. Не меняет DNS.
input:
  type: object
  required: [fqdn, record_type]
  properties:
    fqdn:
      type: string
      format: hostname
    record_type:
      type: string
      enum: [A, AAAA, CNAME, TXT]
    resolver:
      type: string
      enum: [authoritative, public]
side_effect: none
timeout_ms: 5000
output:
  records: array
  observed_at: date-time
  resolver_identity: string
  ttl_seconds: integer
```

Фраза «работает с DNS» почти бесполезна. Она не сообщает, читает tool или пишет, какой resolver используется и является ли результат authoritative. Description участвует в выборе операции так же, как type system участвует в исполнении.

Не прячьте важную семантику в свободном тексте

Плохой contract:

```
{
  "name": "manage_cluster",
  "arguments": {
    "request": "Сделай всё необходимое, чтобы починить production"
  }
}
```

Executor вынужден повторно интерпретировать естественный язык. Невозможно заранее проверить target, действие, budget и approval scope.

Лучше разделить операции:

```
{
  "name": "deployment.propose_scale",
  "arguments": {
    "cluster": "prod-eu-1",
    "namespace": "payments",
    "deployment": "api",
    "from_replicas": 8,
    "to_replicas": 12,
    "reason": "queue lag above SLO for 10m"
  }
}
```

Proposal ещё не меняет cluster. Отдельный `deployment.apply_scale` принимает proposal ID, state version, approval ID и idempotency key. Это делает границу между reasoning и side effect видимой.

Granularity: не micro-tool и не god-tool

Две крайности одинаково неудобны.

Micro-tools повторяют каждую низкоуровневую API operation. Каталог разрастается, названия пересекаются, а модель расходует шаги на механическую оркестрацию.

God-tool принимает универсальный command или произвольный URL. Он уменьшает каталог, но лишает harness возможности понять intent, проверить arguments и применить точную policy.

Полезная граница tool обычно соответствует осмысленному действию домена:

- имеет одну основную цель;
- возвращает достаточный для следующего решения результат;
- допускает ясную side-effect classification;
- может быть разрешена или запрещена отдельно;
- не требует модели знать внутреннюю пагинацию и служебные API calls.

Например, `logs.search` может сам пройти несколько страниц до заданного `max_events`, но не должен одновременно менять retention policy. `pull_request.prepare` может создать branch, commit и draft PR как одну контролируемую transaction-like operation, если эти шаги всегда образуют единый unit и имеют общий rollback plan.

Названия должны помогать выбору

Namespace и verb снимают неоднозначность:

```
ticket.search
ticket.get
ticket.create
ticket.add_comment
ticket.transition
```


`get_ticket_data`, `fetch_issue`, `find_task` и `manage_ticket` в одном каталоге заставляют модель угадывать различия. Если два tools трудно различить человеку по name и description, модель тоже будет путаться.

Разделяйте read и write. Не делайте параметр `dry_run=true` единственной границей безопасности в одном универсальном tool: модель может пропустить flag, а policy сложнее проверить intent.

Эволюция contract без скрытой поломки

Agent-facing contract меняется опаснее обычного internal API. Кодовый client не начнёт внезапно использовать новый endpoint, а модель способна выбрать новый tool сразу после того, как увидела его в catalog. Даже «уточнение» description меняет routing поведения.

Совместимые изменения обычно добавляют optional result field, расширяют документацию или исправляют implementation без изменения semantics. Несовместимые изменения включают:

- новое значение по умолчанию с другим side effect;
- переименование argument;
- изменение единиц измерения;
- превращение полного результата в paginated;
- изменение error из retryable в unknown;
- расширение resource scope;
- перенос read operation в read-and-write.

Для таких изменений создавайте новую contract version или новое имя operation, поддерживайте период миграции и повторяйте selection evals. Version должна описывать не только server package, но и набор schemas, который видел agent.

```
tool_catalog:
  id: observability@18
  protocol: mcp/2026-07-28
  server_digest: sha256:4c1...
  tools:
    logs.search: 3.1
    metrics.query_range: 2.0
  generated_at: 2026-10-05T08:00:00Z
```

При несовместимости лучше явно вернуть `unsupported_contract`, чем попытаться угадать старый meaning. Silent coercion создаёт правдоподобный, но неверный результат.

Полный жизненный цикл tool call

Model response - только предложение вызвать tool. Production harness проводит его через последовательность проверок:

```
catalog -> model proposal -> parse -> schema validation
-> policy/authority -> approval if required -> executor
-> result normalization -> verification -> observation
```

Стадия	Ответственность
Catalog assembly	показать только релевантные и разрешённые capabilities
Proposal	выбрать operation и arguments
Parsing	получить строго структурированный request
Validation	проверить schema, ranges, target и current state version
Policy	решить, разрешено ли действие этому agent и этому Task
Approval	получить human decision для конкретного proposal
Execution	вызвать real system с scoped credentials
Normalization	привести provider-specific response к стабильной форме
Verification	прочитать source of truth и подтвердить effect
Observation	сохранить факт, provenance и uncertainty в state

Skill может рекомендовать этот порядок. MCP может передать call. Но только harness способен не допустить переход к executor.

Catalog - часть policy и context budget

Не нужно показывать модели все operations организации. Каталог собирается по пересечению:

```
installed capabilities
AND agent role
AND Task scope
AND environment policy
AND current phase
```

Если Task только анализирует incident, write-tools можно вообще не включать. Это уменьшает и риск, и количество похожих descriptions в context.

Изменение каталога должно иметь version. Записав `tool_catalog=ops-readonly@12` в trace, команда сможет воспроизвести, из чего выбирала модель. При динамическом discovery нельзя считать старый список вечным: server может уведомить об изменениях, а client должен invalidated cache получить заново.

Результат важен не меньше запроса

Tool result становится evidence для следующего шага. Свалка stdout или HTML на несколько мегабайт перегружает context и скрывает provenance.

Хороший result разделяет машинные поля и ссылки на raw artifact:

```
{
  "status": "succeeded",
  "data": {
    "fqdn": "api.example.com",
    "records": ["203.0.113.7"],
    "ttl_seconds": 60
  },
  "evidence": {
    "observed_at": "2026-10-05T08:15:02Z",
    "source": "authoritative-ns1",
    "artifact_ref": "artifact://runs/81/dns-response.txt"
  },
  "warnings": []
}
```

Большие logs и query results сохраняются как artifacts. В context возвращаются summary, cursor, counts и ссылка. При этом summary не должен уничтожать raw evidence.

Ошибка - не одна строка

success=false недостаточно. Harness должен понимать следующий допустимый переход.

Outcome	Значение	Типичное действие
invalid	request не соответствует contract	исправить arguments без retry того же request
denied	policy или authority запретили действие	не обходить; запросить другой score или завершить
not_found	resource достоверно отсутствует	проверить target или принять как observation
conflict	state/version изменилась	перечитать source of truth и построить новый proposal
retryable	operation не началась или безопасно повторяема	retry по policy и backoff
partial	выполнена только часть	зафиксировать completed units и reconcile
unknown	side effect мог произойти, response потерян	не повторять вслепую; проверить operation ID и внешний state
succeeded	executor сообщил success	всё равно verify критический effect

Особенно опасно превращать `timeout` в `failed`. После отправки `write timeout` означает неизвестный outcome. Повтор с новым `idempotency key` способен создать второй комментарий, платёж или `deployment`.

MCP: общий протокол, а не магический слой интеграции

Model Context Protocol стандартизует обмен между AI application и поставщиками context/capabilities. В архитектуре есть три роли:

- **MCP host** - приложение, управляющее agents и соединениями;
- **MCP client** - компонент host для связи с конкретным server;
- **MCP server** - программа, предоставляющая capabilities и context.

Один host обычно создаёт отдельный client для каждого server. Server может работать локально или удалённо. Локальность не означает доверие: локальный process всё равно может читать files, использовать credentials и выполнять code.

MCP разделён на data layer и transport layer. Data layer использует JSON-RPC и описывает discovery, calls и core primitives. Transport layer отвечает за framing, соединение и transport-specific authentication.

Три server primitives

Primitive	Назначение	Пример
Tools	исполняемые operations	запрос к API, запись в issue tracker
Resources	читаемый context	schema, file, database record
Prompts	reusable interaction templates	шаблон review или investigation

Это классификация интерфейсов, а не security model. Resource способен содержать malicious instruction. Tool может иметь разрушительный side effect. Prompt может конфликтовать с policy host.

Resources полезны, когда context нужно читать без маскировки под действие. Schema базы, runbook или содержимое файла не обязаны быть tools вида `get_schema()`: resource сохраняет семантику «данные для чтения». Prompts дают reusable starting template, но host решает, показывать ли его пользователю и как объединять с собственными instructions.

Не превращайте каждый primitive в другой ради удобства client. Если resource вызывает дорогое вычисление или раскрывает чувствительные данные, к нему всё равно применяются access control, limits и audit. Если prompt содержит instruction, он всё равно ниже platform policy. Чёткая классификация помогает host правильно отображать intent и применять разные правила.

Что изменилось в MCP 2026-07-28

Актуальное ядро MCP stateless: старый protocol-level session lifecycle и `initialize/initialized` больше не являются основой протокола. Каждый request несёт `protocol version` и относящиеся к нему `capabilities` в `_meta`. Server предоставляет `server/discover`, через который client получает `identity`, поддерживаемые `versions` и `capabilities`. Списки `primitives` могут кешироваться и обновляться при изменениях.

Практический вывод: не проектируйте новый client по ранним примерам 2024-2025 годов без проверки версии `specification`. Но и не путайте `stateless protocol` с `stateless application`: `OAuth flow`, `job execution`, `pagination` и `business operation` могут иметь собственное `durable state`.

STDIO или Streamable HTTP

Вариант	Когда уместен	Риски и обязанности
STDIO	локальный adapter, один host, controlled package	process launch, filesystem access, inherited environment, package supply chain
Streamable HTTP	shared remote service, централизованное обновление, много clients	network identity, TLS, OAuth/token scope, tenancy, rate limits, availability

STDIO убирает сеть между client и server, но не делает `server sandbox`. Remote HTTP упрощает централизованное управление, но добавляет отдельную `trust boundary` и необходимость связывать `user`, `client`, `tenant` и `downstream credentials`.

MCP не выдаёт доверие автоматически



На схеме ниже `protocol` заканчивается раньше реального `side effect`. `Policy gateway` может быть частью `host`, отдельным `проxy` или `server`, но его свойства должны быть явными.

`MCP server` сообщает `metadata` о себе и `tools`, однако `self-reported identity` не является доказательством происхождения. Установленный `package`, `endpoint`, `publisher` и версия должны проходить обычный `supply-chain review`.

`Credentials` следует связывать с минимальным `scope`:

```
binding:
  server: git-prod@2.4.1
  agent_role: reviewer
  task_scope: repo:payments-api
  credentials: github-app-installation:381
  allowed_tools:
    - pull_request.read
    - checks.read
  denied_tools:
    - repository.delete
    - branch.force_push
```

Модель не должна видеть raw token. MCP server тоже не обязан получать широкие user credentials, если gateway может обменивать identity на short-lived scoped token.

Подробные механизмы idempotency, approvals, containment и authority attenuation рассматриваются в главе 37. Здесь важно удержать границу ответственности: transport authentication подтверждает сторону соединения, но business authorization всё ещё проверяет конкретное действие над конкретным resource.

Skills: переносимая процедурная экспертиза

Agent Skill - директория, в которой обязательно есть SKILL.md с metadata и инструкциями. Дополнительно она может содержать scripts, references, assets и другие ресурсы.

```
tls-incident/
|- SKILL.md
|- scripts/
|  `-- compare_cert_chain.py
|- references/
|  |- decision-tree.md
|  `-- provider-notes.md
`- assets/
   `-- incident-report-template.md
```

В SKILL.md обязательны name и description. Description должна объяснять не только действие, но и условия применения: именно эти metadata помогают агенту решить, активировать ли skill.

```
---
name: tls-incident
description: >
  Расследует TLS handshake, certificate chain и routing incidents.
  Используй при certificate errors, hostname mismatch, expiry alerts
  или расхождении сертификатов между edge nodes.
compatibility: Requires openssl and read-only network access
metadata:
  owner: sre-platform
  version: "3.2"
---
```

Progressive disclosure

Skill не должен целиком занимать context с начала Task. Open specification предполагает три уровня:

1. startup metadata - name и description всех доступных skills;
2. полный SKILL.md после активации;
3. scripts, references и assets только по необходимости.

Это позволяет хранить глубокую экспертизу, не оплачивая её tokens в каждом request. Но progressive disclosure работает только при хорошей навигации. SKILL.md должен явно говорить, какой reference читать при каком condition. Цепочка из десяти ссылок превращает skill в лабиринт.

Skill не является permission

Инструкция «никогда не изменяй production без approval» полезна, но остаётся инструкцией для вероятностной модели. Enforcement обязан находиться в tool gateway или executor. Экспериментальное поле allowed-tools в specification не следует считать универсальным security boundary: поддержка зависит от implementation, а реальная authority определяется runtime.

Skill способен:

- объяснить decision process;
- выбрать последовательность tools;
- предоставить domain checklists и examples;
- запускать проверенные deterministic scripts;
- формировать отчёт по template;
- напомнить о verification и rollback.

Skill не способен сам по себе:

- создать credentials, которых нет у runtime;
- запретить executor обойти policy;
- доказать безопасность bundled script;
- превратить model suggestion в transaction;
- подтвердить внешний side effect без чтения source of truth.

Scripts внутри skill

Script полезен, когда операция лучше выражается детерминированным кодом: parse формата, сортировка, проверка certificate chain, преобразование document. Агенту не обязательно загружать весь script в context, чтобы выполнить его.

Но bundled code является executable dependency. До установки проверяйте:

- publisher и provenance;
- hash или signed version;

- network и filesystem access;
- transitive dependencies;
- secret handling;
- reproducibility и tests;
- поведение при malformed input.

Skill из неизвестного repository требует не меньшего review, чем новый CI action или package.

Как Tool, MCP и Skill работают вместе

Вернёмся к TLS-инциденту из главы 3. Там нас интересовали agent loop, hypotheses и transitions; здесь тот же scenario показывает разделение Tool, MCP и Skill. Рассмотрим ошибку `NET::ERR_CERT_DATE_INVALID`.

Tools:

<code>dns.lookup</code>	read DNS records
<code>tls.probe</code>	read chain from selected endpoint
<code>certificate.inventory_get</code>	read expected certificate metadata
<code>load_balancer.read_config</code>	read current listener configuration
<code>change.propose</code>	create non-executing change proposal

MCP server публикует schemas этих tools и resources с inventory documentation. Host через client получает catalog, но показывает agent только read operations. Skill `tls-incident` задаёт процедуру:

1. зафиксировать hostname, user-visible error и время;
2. сравнить public и authoritative DNS;
3. выполнить probe для каждого resolved endpoint;
4. сравнить observed chain с inventory;
5. разделить observation, hypothesis и conclusion;
6. сформировать proposal, но не применять изменение;
7. приложить raw evidence и команды воспроизведения.

Один из результатов:

```
finding:
  status: confirmed
  claim: edge-3 serves an expired certificate
  evidence:
    - probe://edge-3/2026-10-05T08:15:31Z
    - inventory://cert-882/revision-9
  unaffected_endpoints: [edge-1, edge-2]
proposal:
  action: reload_certificate_bundle
  target: edge-3
  expected_revision: 144
  execution: not_requested
```


Здесь skill повышает качество расследования, MCP уменьшает стоимость интеграции, tools дают наблюдения, а harness не допускает write без отдельной фазы и authority.

Что делать, если MCP server недоступен

Failure server не должен превращаться в фантазию модели. Host отмечает capabilities unavailable, сохраняет точную ошибку discovery/call и пересобирает catalog. Skill может предложить approved fallback - например, локальный read-only probe, - но не должен советовать обходить policy произвольным shell command.

Если fallback меняет источник данных, в evidence указывается новый source. Результат public resolver не выдают за authoritative DNS только потому, что основной tool временно недоступен.

Когда выбирать Tool, MCP, Skill или Workflow

Потребность	Предпочтительный механизм
одна стабильная операция внутри приложения	direct tool/function
capability должна работать в нескольких MCP-compatible hosts	MCP server
нужно стандартизовать чтение resources и вызов tools внешней системы	MCP server
агенту не хватает domain procedure и examples	Skill
повторяется анализ с несколькими существующими tools	Skill
последовательность обязана быть детерминированной и audit-ready	Workflow/state machine
требуется жёсткий запрет или approval	Harness policy/gateway
нужен чистый deterministic transform	library или script, возможно внутри Skill

Не каждый REST API нужно немедленно превращать в MCP server. Если tool живёт только внутри одного service и не требует portable discovery, direct adapter проще. И наоборот, копировать десять разных provider adapters в каждый host дороже, чем поддержать один качественный MCP server.

Не каждый runbook нужен как skill. Короткое неизменное правило может жить в policy. Skill оправдан, когда есть distinct trigger, процедура, references, examples и независимый lifecycle.

AX Workspace как декларация среды

AX Workspace может связывать repositories, files, MCP endpoints и skill locations с рабочим окружением agent. Это полезно: Task получает воспроизводимую карту доступных assets вместо ручной настройки.

Но Workspace manifest - декларация, а не свидетельство безопасности. До activation platform должна разрешить:

- откуда получен server или skill;
- какая версия и digest разрешены;
- какие secrets и mounts доступны;
- какие tools войдут в catalog;
- какой network egress допустим;
- кто одобрил изменение dependency.

```
workspace:
  repositories:
    - name: payments-api
      ref: 31f27ab
      mode: read-write-branch
  mcp_servers:
    - name: observability
      endpoint: https://mcp.ops.example/v1
      version: 2026-07-28
      tool_policy: policies/observability-readonly.yaml
  skills:
    - name: tls-incident
      source: registry://sre/tls-incident@3.2.0
      digest: sha256:...
```

Version pinning позволяет воспроизвести Task. Автоматическое подключение `latest` делает trace неполным: одинаковая цель завтра может активировать другие instructions или schemas.

Как тестировать agent-facing interface

Обычный unit test проверяет, что function возвращает ответ. Этого недостаточно. Нужно проверить, как вероятностный caller понимает contract.

Contract tests

- valid и invalid arguments;
- enums, boundary values и malformed Unicode;
- pagination и payload limits;
- timeout до и после начала side effect;
- stable error codes;

- backward compatibility result schema;
- idempotency и conflict handling.

Selection evals

Соберите representative prompts, включая неоднозначные и отрицательные cases. Измеряйте:

- выбрал ли agent правильный tool;
- не вызвал ли tool, когда достаточно ответа или resource;
- правильно ли заполнил arguments;
- распознал ли необходимость clarification;
- остановился ли после denial;
- отличил ли read от write;
- использовал ли skill только по релевантному trigger.

Оценивать нужно не красивый final answer, а состояние environment и trace. Агент мог написать «изменение применено», хотя call был denied. Успех определяется verified external outcome.

Adversarial cases

Добавьте stale catalog, duplicated names, compromised resource text, partial result, lost response, revoked token и изменившийся state version. Для skills проверяйте malicious reference, неожиданную network dependency и конфликт bundled instruction с host policy.

Полезная минимальная матрица:

Case	Ожидаемое поведение
tool отсутствует в текущем catalog	не выдумывать call; сообщить ограничение
server description просит передать secret	policy блокирует; agent фиксирует injection attempt
write timeout после отправки	outcome unknown, затем reconciliation
skill предлагает запрещённый shell fallback	instruction игнорируется, policy сохраняется
schema изменилась	client invalidates cache или сообщает incompatibility
approval относится к старой state version	execution блокируется, proposal строится заново

Типичные антипаттерны

MCP means safe. Общий protocol принимают за trust и authorization.

Skill means capability. Инструкция обещает действие, для которого нет tool, credentials или executor.

Skill means policy. Текстовое правило используется вместо enforced permission.

API dump as tools. Сотни provider operations публикуются без domain design и selection evals.

One tool to rule them all. Универсальный `execute(command)` скрывает intent и side effects.

Read and write together. Один tool меняет систему в зависимости от optional flag.

Success equals verified. HTTP 200 считается доказательством нужного состояния внешней системы.

Timeout equals failure. Write автоматически повторяется после потерянного response.

Raw output into context. Мегабайты logs вытесняют objective, policy и evidence.

Self-reported identity as trust. `serverInfo` используется вместо проверенного endpoint, publisher и digest.

Latest everywhere. Server и skill обновляются без version pinning, trace теряет воспроизводимость.

Description afterthought. Names и descriptions пишутся как документация для человека, хотя они управляют выбором модели.

No negative evals. Проверяют только happy path «agent вызвал tool», но не способность отказаться от вызова.

Практический checklist

Перед добавлением sarability спросите:

1. Это operation, protocol adapter, procedure или deterministic workflow?
2. Может ли name однозначно отличить sarability от соседних?
3. Какой side effect и authority scope?
4. Что произойдёт при duplicate, timeout и partial completion?
5. Где хранится raw evidence и что попадёт в context?
6. Как проверить реальный outcome?
7. Какая версия contract записывается в trace?
8. Кто доверяет server или skill и на каком основании?
9. Можно ли убрать write-tool из catalog до нужной фазы?
10. Есть ли eval, где правильное действие - не вызывать tool?

Если на вопросы 3, 4 и 6 нет ответа, sarability ещё не готова к production, даже если demo работает.

Итоги главы

- Tool - agent-facing contract осмысленной операции, а не просто обёртка над function.
- API и CLI являются реализацией; schema, side effects, errors и verification делают их пригодными для agent loop.
- Granularity должна сохранять domain intent и точную policy: избегайте и micro-tool explosion, и универсального god-tool.
- Model предлагает call; harness проверяет schema, authority, approval, execution и outcome.
- Structured results, provenance и отдельный raw artifact полезнее большого stdout в context.
- Timeout write означает unknown outcome, пока reconciliation не доказал обратное.
- MCP стандартизует discovery и обмен tools, resources и prompts между host, client и server.
- MCP 2026-07-28 использует stateless core и per-request metadata; application state при этом никуда не исчезает.
- Protocol, transport authentication и business authorization решают разные задачи.
- Skill пакет procedural knowledge, scripts и references с progressive disclosure.
- Skill помогает выбрать и связать tools, но не создаёт authority и не заменяет enforced policy.
- MCP servers и Skills входят в software supply chain и требуют provenance, pinning и review.
- AX Workspace описывает рабочую среду, но platform всё равно должна проверять dependencies, scopes и secrets.
- Тестировать нужно tool selection, arguments, отказ, failure semantics и verified environment state.

Дальше. Теперь один agent умеет безопасно получать observations и выполнять actions. Следующая глава покажет, когда одну такую петлю действительно стоит разделить на несколько агентов и как не потерять ownership, evidence и budgets.

Источники и дальнейшее чтение

- [Model Context Protocol: Architecture overview](#) - host/client/server, layers, primitives, statelessness и discovery.
- [MCP: The 2026-07-28 Specification](#) - изменения текущей версии protocol.
- [Agent Skills Specification](#) - структура SKILL.md, optional directories и progressive disclosure.
- [Anthropic: Equipping agents for the real world with Agent Skills](#) - procedural knowledge, code execution, evaluation и security considerations.
- [Anthropic: Writing effective tools for agents](#) - tool design как contract для недетерминированного caller.
- [Anthropic: Building effective agents](#) - agent-computer interfaces, testing и guardrails.
- [Anthropic: Effective context engineering for AI agents](#) - ясные, непересекающиеся и context-efficient tool sets.
- [Anthropic: Demystifying evals for AI agents](#) - multi-turn evals и проверка environment state.
- Главы 36 и 37 этой книги - подробности MCP architecture, idempotency, approvals и safe tool execution.

Multi-agent архитектуры без лишней магии

Главы 3-6 построили один bounded agent: loop, harness, state и capabilities. Теперь решим, когда нескольких таких loops действительно требуют dependency graph, isolation или независимая проверка, а когда multi-agent только увеличивает стоимость.

Команда создаёт четырёх агентов: architect, developer, tester и reviewer. На демонстрации это выглядит как автономная инженерная организация. В реальной задаче architect пишет общий план, developer меняет файлы до завершения плана, tester запускает тесты на старом commit, а reviewer читает summary вместо diff. Все четыре используют один repository, один token и одну модель. Работа стала дороже, но не быстрее и не надёжнее.

Проблема не в количестве агентов. В системе не было настоящих границ: независимых subtasks, разных capabilities, изолированного state и проверяемого protocol передачи результата. Названия ролей создали театральную организацию, но не архитектуру.

Главный принцип главы:

Multi-agent система оправдана, когда разделение создаёт измеримую пользу: параллелизм, изоляцию context, специализацию capabilities или независимую проверку. Если такой пользы нет, один хорошо спроектированный agent почти всегда проще, дешевле и надёжнее.

Что именно считается отдельным агентом

Не каждый LLM call является агентом, и не каждый параллельный worker делает систему multi-agent.

Сущность	Что сохраняется между шагами	Самостоятельно выбирает действия	Пример
Function/ model call	ничего, кроме входа и ответа	нет	классификация issue
Workflow node	state задаёт workflow engine	обычно нет	generate -> validate -> publish
Worker	process и служебный state	не обязательно	executor test jobs
Agent	objective, context, tools, loop и termination	да, в заданных пределах	исследователь repository
Multi-agent system	несколько автономных loops плюс coordination layer	да	coordinator и независимые specialists

Роль - это configuration, а не identity. Два prompts `researcher` и `reviewer`, вызванные последовательно одним controller, могут быть обычным workflow. Это хорошо: не нужно называть multi-agent то, что проще выразить pipeline.

Отдельный agent появляется там, где есть собственный decision loop:

```
objective -> observe -> decide -> act -> update state -> stop/escalate
```

Если несколько таких loops взаимодействуют, архитектура должна определить ownership, protocol и failure semantics. Иначе автономность умножает неопределённость.

Начинайте с single-agent baseline

Перед добавлением второго агента соберите однопоточную версию и измерьте:

- качество результата;
- end-to-end latency;
- model tokens и tool calls;
- долю успешных Tasks;
- число human interventions;
- ошибки verification;
- стоимость одного verified outcome.

Без baseline нельзя понять, принесло ли разделение пользу. Multi-agent система может дать лучший ответ просто потому, что потратила в пятнадцать раз больше tokens. Это допустимо для дорогой research-задачи, но не доказывает эффективность архитектуры.

Четыре причины разделять работу

Независимый параллелизм. Несколько направлений можно исследовать одновременно: регионы, источники, модули repository, hypothesis.

Context isolation. Каждому specialist нужен свой большой корпус данных, а coordinator получает только сжатые findings и evidence refs.

Capability isolation. Researcher читает, implementer пишет только branch, tester исполняет untrusted code в sandbox, approver не имеет execution tool.

Независимая проверка. Другой agent оценивает artifact по rubric или пытается опровергнуть hypothesis.

Пятая возможная причина - модельная специализация: дешёвая модель делает широкую фильтрацию, сильная решает сложные cases. Но смена модели сама по себе не требует multi-agent runtime; это может быть routing в обычном workflow.

Когда разделение не помогает

Оставляйте один agent, если:

- каждый следующий шаг зависит от полного результата предыдущего;
- всем участникам нужен один и тот же большой context;
- несколько writers должны постоянно менять одни файлы;
- задачу быстрее решить одним дополнительным tool call;
- проверяющий не имеет независимого evidence или rubric;
- стоимость coordination сравнима с самой работой;
- outcome нельзя разложить на проверяемые части.

Особенно плохо параллелизуются короткие задачи с высокой связностью. Пять агентов, обсуждающих имя одной function, создают latency, а не производительность.

Сначала нарисуйте граф зависимостей

Multi-agent architecture начинается не со списка персонажей, а с directed acyclic graph работы.

```
      +-> dependency audit -+
issue -> scope --+> code inspection ---+> synthesis -> implementation
      +-> test discovery ----+                |
                                           v
                                           tests -> review
```

Ветки audit, inspection и test discovery независимы и могут идти параллельно. Implementation зависит от synthesis. Tests зависят от конкретного commit. Review зависит от diff и test results.

Если параллельная доля работы равна P , а число workers равно N , идеальное ускорение ограничено:

$$\text{speedup} \leq 1 / ((1 - P) + P / N)$$

В agent system добавляется coordination overhead C :

$$\text{wall_time} \approx \text{serial_path} + \max(\text{parallel_branches}) + C$$

Если decomposing, context packaging, queueing и merging занимают больше, чем сэкономлено на ветках, система стала медленнее. Закон не требует точного математического прогнозирования; он заставляет увидеть critical path.

Независимость бывает трёх видов

Вид	Вопрос	Пример
Data independence	могут ли agents читать разные данные без обмена каждым шагом?	поиск по разным регионам
Write independence	могут ли они менять разные targets без конфликтов?	разные branches или modules
Decision independence	можно ли принять локальное решение без глобального context?	проверить license dependency

Параллелизм чтения обычно проще параллелизма записи. Поэтому production multi-agent workflow часто делает широкий fan-out для исследования, а write оставляет одному owner.

Основные топологии

В этой главе **coordinator** - прикладная роль: она декомпозирует цель, делегирует работу и собирает результат. Это не infrastructure orchestrator из глав 1 и 4, который размещает workloads и обеспечивает их lifecycle.

Topology отвечает на вопросы: кто выбирает следующего участника, кто владеет разговором, где сходятся результаты и кто имеет право завершить Task.

Manager и agents-as-tools

Manager сохраняет objective и user-facing ownership. Specialists вызываются как tools для bounded subtasks и возвращают результат manager.

```
user -> manager -> specialist A
                  -> specialist B
                  -> specialist C
                  <- structured results
user <- final synthesis
```

Подходит, когда нужен единый final answer, общая policy и централизованная агрегация. Specialist получает сформированный input, а не обязательно всю conversation history.

Риск - manager становится bottleneck: плохо decomposes, теряет minority finding или пересказывает evidence с ошибкой. Manager не должен вручную копировать большие результаты; лучше принимать schemas и artifact refs.

Handoff

Текущий agent передаёт ownership specialist, который продолжает interaction.

```
user -> triage -> billing specialist -> user
```

Handoff полезен для routing между distinct domains: support, legal intake, incident type. Он уменьшает manager narration и позволяет specialist работать со своими instructions.

Нужно точно определить:

- какой history получает новый agent;
- какие pending approvals переходят вместе с Task;
- кто отвечает за возврат или следующий handoff;
- сохраняются ли guardrails;
- как предотвращается цикл A -> B -> A.

Handoff не равен вызову function. Меняется owner текущего диалога, поэтому trace и UX должны это отражать.

Fan-out/fan-in

Coordinator создаёт несколько независимых subtasks, затем агрегирует результаты.

```
+--> region A -+
objective ---+--> region B --+--> merge -> verify
+--> region C -+
```

Это сильная topology для research, vulnerability discovery и независимых checks. Она требует overlap policy: ветки должны либо сознательно искать разные области, либо сознательно дублировать поиск для оценки recall.

Fan-in - не простая конкатенация. Aggregator валидирует schema, удаляет duplicates, сохраняет provenance, разрешает contradictions и отмечает gaps.

Pipeline

Каждая стадия преобразует artifact и передаёт его следующей:

```
research -> plan -> implementation -> test -> review
```

Pipeline проще наблюдать, но часто это workflow, а не несколько автономных agents. Он оправдан, когда стадии используют разные tools или authority. Если все стадии детерминированы, реализуйте их code, а не LLM loops.

Generator/evaluator

Generator создаёт artifact, evaluator проверяет по rubric и возвращает defects. Controller решает, повторять ли цикл.

```
generator -> candidate -> evaluator -> pass
      ^               |
      +----- defects -----+
```

Evaluator не должен бесконечно говорить «можно улучшить». Нужны pass criteria, maximum iterations и terminal outcome `needs_human`.

Независимость evaluator не возникает от другого имени. Та же модель, тот же context и те же assumptions дают correlated errors. Усилить проверку можно отдельным evidence, adversarial prompt, deterministic tests, другой model family или human review.

Blackboard и peer swarm

Agents публикуют findings в общее пространство и сами выбирают следующую работу. Такая схема полезна для open-ended exploration, где заранее неизвестна decomposition.

Но coordination становится сложнее: duplicate claims, stale records, race conditions, popularity bias и отсутствие owner. Blackboard должен иметь typed records, versioning, leases и moderator/arbiter. Общий чат без protocol - не blackboard architecture.

Для большинства production systems начинайте с manager или fan-out/fan-in. Peer swarm нужен только после доказательства, что централизованная decomposition действительно ограничивает outcome.

Delegation contract: что получает child

Фраза «изучи security» создаёт дублирование и gaps. Child должен получить ограниченный task envelope.

```
task_id: sec-audit-42/dependency-review
parent_id: sec-audit-42
objective: Identify exploitable dependency risks in the current lockfile
non_goals:
  - do not modify files
  - do not review application authorization logic
inputs:
  repository_ref: 31f27ab
  files:
    - package.json
    - package-lock.json
required_output:
  schema: vulnerability-findings@2
  artifact: artifact://sec-audit-42/dependencies.json
authority:
  tools: [repository.read, advisory.lookup]
  network: advisories-only
budget:
  model_steps: 12
  tool_calls: 30
  wall_time_seconds: 300
termination:
  success: all direct and transitive packages assessed
  escalate: lockfile missing or advisory source unavailable
```

Contract отвечает минимум на девять вопросов:

1. Какую часть общей цели решает child?

2. Что явно не входит в scope?
3. Какая version входных artifacts?
4. Какие tools и authority разрешены?
5. Какой budget?
6. В каком schema вернуть результат?
7. Как доказать claims?
8. Когда остановиться?
9. Когда вернуть вопрос parent, а не импровизировать?

Делегирование уменьшает authority

Child не должен получать больше полномочий, чем parent:

```
child_authority <= parent_authority AND task_scope
```

Coordinator с read/write repository scope может выдать researcher только read. Implementer получает write в отдельный branch, но не merge. Tester запускает code в sandbox без production secrets. Reviewer читает diff и test artifacts.

Если child способен повторно делегировать, attenuation применяется рекурсивно. Глубокая иерархия не должна случайно восстановить привилегии через другого worker.

Делегирование передаёт objective, а не чужой transcript

Полная history parent часто содержит нерелевантные instructions, untrusted text и большой token cost. Child обычно нужны:

- objective и constraints;
- selected evidence;
- versioned artifact refs;
- известные uncertainties;
- expected output schema.

Это projection state, а не копия разговора. Handoff может требовать conversation history для UX, но даже тогда input filter должен удалять secrets и не относящиеся к domain данные.

Coordination state: сообщения не заменяют базу данных

Agents могут обмениваться natural language, но application state должен оставаться structured.

```
parent_task: migration-81
state_version: 17
children:
  - id: inventory
    status: succeeded
    output_ref: artifact://migration-81/inventory.json
  - id: compatibility
    status: running
    lease_expires_at: 2026-10-05T09:10:00Z
  - id: rollback
    status: blocked
    reason_code: MISSING_BACKUP_POLICY
join:
  policy: all_required
  required: [inventory, compatibility, rollback]
```

Natural-language summary полезна модели, но controller не должен извлекать из неё status, budget или operation ID.

Разделяйте control messages и evidence

Тип	Назначение	Пример
Command	назначить bounded work	analyze module payments at commit X
Progress	сообщить состояние без изменения conclusion	12/18 files checked
Finding	передать claim и evidence	vulnerability + file/line + reproduction
Question	запросить missing decision	target environment unknown
Cancellation	прекратить новые действия	parent no longer needs branch
Completion	зафиксировать terminal result	succeeded/failed/partial

Finding не должен скрываться в progress text. Completion не доказывает correctness. Каждый тип имеет schema, correlation ID и timestamp.

Shared workspace требует ownership

Несколько agents в одном filesystem без правил создают lost updates. Выберите один из patterns:

- один writer, остальные read-only;
- отдельный branch/worktree на child;
- file/module ownership;
- append-only artifacts;
- transactional store с optimistic concurrency;
- proposal вместо прямой записи.

Lock на весь repository безопасен, но уничтожает параллелизм. Лучше уменьшать write overlap архитектурой.

Budgets, backpressure и защита от task explosion

Если каждый agent создаёт пять children на глубине четыре, получится до 625 leaf tasks. Даже если каждый дешёвый, система быстро исчерпает concurrency, rate limit и context budget.

Root задаёт envelope для всего дерева:

```
subtree_budget:
  model_tokens: 2_000_000
  tool_calls: 800
  wall_time_seconds: 1800
  max_concurrency: 8
  max_depth: 2
  max_children_total: 24
```

Parent резервирует budget до spawn. Неиспользованный остаток возвращается после terminal state. Формально:

```
sum(reserved_child_budget) <= parent_remaining_budget
```

Дополнительно нужны:

- queue capacity;
- per-tool rate limits;
- admission control;
- priority и fairness между Tasks;
- backoff вместо aggressive polling;
- circuit breaker при повторяющейся системной ошибке.

Agent не должен создавать нового child только потому, что не знает следующий шаг. Spawn является дорогим действием и требует причины: independent scope, expected gain и available budget.

Dynamic effort scaling

Coordinator оценивает complexity до fan-out:

Класс	Типичная стратегия
Simple fact	один agent, без delegation
Bounded comparison	2-3 независимые ветки
Broad research	несколько domain/region specialists
Coupled implementation	один writer плюс параллельные read-only checks

Класс	Типичная стратегия
High-risk change	planner, policy/approval, executor, independent verifier

Числа не универсальны. Их калибруют evals и production telemetry, а не интуиция модели.

Failure semantics дерева Tasks

Multi-agent система добавляет распределённые failure modes поверх ошибок каждого agent.

Дублирование и gaps

Два children выполняют один и тот же поиск, а третий scope остаётся пустым. Причина обычно в расплывчатом contract или отсутствии global coverage map.

Исправление: явные non-goals, partition key и проверка overlap до spawn.

Role drift и reasoning-action mismatch

Reviewer начинает исправлять code, researcher объявляет release, implementer делает вывод без tests. Название роли не ограничивает capability.

Исправление: tool catalog и authority соответствуют роли; output schema не допускает скрытый side effect.

Потеря важного finding

Child нашёл исключение, но aggregator выбрал majority summary. Consensus не является truth. Несколько agents одной model family могут повторять одинаковую ошибку, а один dissenter держать решающее evidence.

Исправление: merge claims по evidence, сохранять contradictions и отдельно поднимать high-severity minority findings.

Premature termination

Coordinator завершает Task после первых успешных branches или evaluator выдаёт pass без проверки required criteria.

Исправление: join policy и completion predicate проверяются code. Только определённый controller переводит root в terminal state.

Livelock и conversation loops

Agents бесконечно передают Task друг другу, критикуют и переписывают один artifact без measurable progress.

Исправление: max handoffs, max iterations, progress metric и outcome `needs_human`.

Stale result

Child работал с commit X, а parent уже перешёл к X+3. Формально успешный result больше не применим.

Исправление: каждый output связывается с input versions. Fan-in отклоняет stale artifacts или запускает targeted revalidation.

Неизвестный side effect

Child применил изменение, но умер до completion message. Parent считает его failed и повторяет операцию.

Исправление: operation ledger, idempotency key и reconciliation с external source of truth. Cancellation не откатывает уже выполненный write.

Коррелированная ошибка

Десять одинаковых agents с одинаковым prompt и sources могут быть уверены в одной неверной hypothesis. Голосование создаёт иллюзию независимости.

Исправление: разнообразить evidence и method, а не только random seed. Один agent ищет подтверждение, другой - counterexample, третий выполняет deterministic test.

Исследование MAST группирует наблюдаемые multi-agent failures в три большие категории: specification/system design, inter-agent misalignment и verification/termination. Практический вывод не в конкретных процентах, а в том, что большинство проблем находятся в orchestration layer и не исчезают от более длинного role prompt.

Fan-in: как собирать результат без потери смысла

Aggregator получает не «мнения агентов», а набор claims.

```
{
  "claim_id": "finding-17",
  "statement": "dependency X is reachable from the public endpoint",
  "confidence": "supported",
  "evidence": [
    "artifact://audit/callgraph.json#path-81",
    "repo://payments@31f27ab/src/api.ts:44"
  ],
  "input_versions": {
    "repository": "31f27ab",
    "advisory_db": "2026-10-05T08:00Z"
  },
  "limitations": ["runtime feature flag not observed"]
}
```

Правильный merge:

1. валидирует output schema;
2. проверяет input versions;
3. группирует claims, но не удаляет provenance;
4. различает duplicate evidence и независимое подтверждение;
5. сохраняет conflicts;
6. проверяет coverage required scopes;
7. вызывает verifier для high-impact claims;
8. создаёт compact synthesis для следующего decision point.

Если два children ссылаются на одну web page, это не два независимых подтверждения. Если conclusions расходятся, aggregator не обязан выбирать среднее: он может вернуть `unresolved` и назначить discriminating test.

Cancellation, retry и recovery

Parent restart не должен повторно создавать всех children. Используйте deterministic child ID:

```
child_id = hash(parent_id, decomposition_version, partition_key)
```

После recovery coordinator читает journal и для каждого child выбирает:

- attach к running Task;
- принять terminal output;
- reclaim после expired lease;
- retry с тем же logical ID;
- cancel, если result больше не нужен;
- reconcile, если outcome write неизвестен.

Cancellation является request, а не мгновенным фактом. Child может находиться внутри external call. Controller ждёт acknowledged stop или помечает Task `cancel_requested` и отслеживает поздний result.

При fan-out fail-fast подходит не всегда. Если одна region query упала, остальные findings всё ещё полезны. Join policy должна различать:

```
join:
  mode: quorum
  minimum_success: 3
  required_partitions: [production]
  allow_partial: true
  partial_label: incomplete_coverage
```

Observability: видеть дерево, а не набор чатов

Trace должен связывать root, children, tool calls и artifacts.

Минимальные identifiers:

- `trace_id` общей цели;
- `task_id` и `parent_task_id`;
- `agent_config_version`;
- `delegation_contract_version`;
- `input_state_version`;
- `tool_catalog_version`;
- `operation_id` для side effects;
- `artifact_ref` результата.

Полезные метрики:

Метрика	Что показывает
Spawn count/depth	task explosion и качество decomposition
Useful parallelism	сколько branches реально перекрылись по времени
Duplicate work rate	стоимость плохого partitioning
Handoff count	routing loops и UX complexity
Join wait time	bottleneck fan-in
Stale output rate	слишком длинные subtasks или слабое versioning
Verified outcome rate	конечное качество, а не число завершённых agents
Cost per verified outcome	экономическую полезность topology
Cancellation lag	способность остановить дерево

Красивый transcript не заменяет distributed trace. Оператор должен быстро ответить: какой child держит critical path, кто расходует budget и какие writes уже произошли.

Как оценивать multi-agent систему

Сравнивайте минимум три variants:

1. сильный single agent;
2. deterministic workflow с теми же tools;
3. multi-agent topology.

Уравняйте или отдельно покажите token/tool budgets. Иначе «архитектура» побеждает просто дополнительным compute.

Outcome metrics

- factual/correctness score;
- completeness и coverage;
- verified environment state;
- defects escaped после review;
- human acceptance;
- latency p50/p95;
- model и tool cost;
- failure recovery rate.

Coordination metrics

- правильность routing и decomposition;
- overlap/gap rate;
- schema-valid child outputs;
- ignored findings;
- incorrect or premature termination;
- количество cycles;
- authority violations;
- reproducibility при одинаковом input version.

Ablation tests

Удаляйте по одному элементу:


- без reviewer;
- без parallelism;
- один model вместо разных;
- text summary вместо structured result;
- общий workspace вместо branches;
- фиксированная decomposition вместо dynamic.

Так становится видно, какой component даёт benefit. Если removal evaluator не меняет качество, evaluator был ритуалом.

End-state evaluation важнее проверки единственного «правильного» пути. Agents могут прийти к одному verified outcome разными trajectories. Но process constraints - authority, budget, запрещённые actions - всё равно оцениваются отдельно.

Практика: software-engineering workflow

Практика: software-engineering multi-agent workflow



Рассмотрим issue: «после обновления cache library периодически теряются session records».

1. Coordinator фиксирует scope

Он создаёт immutable task manifest:

```
goal: identify cause and prepare reviewed fix
repository_ref: 31f27ab
acceptance:
  - regression test reproduces loss before fix
  - test passes after fix
  - no production deployment
budgets:
  children: 4
  wall_time_minutes: 30
```

2. Read-only fan-out

Три children работают параллельно:

- Researcher прослеживает session lifecycle и возвращает call graph.
- Dependency analyst читает changelog и semantics новой cache library.
- Test analyst ищет existing race tests и строит reproduction plan.

У каждого distinct scope и один repository commit. Они пишут только artifacts.

3. Synthesis gate

Coordinator объединяет evidence. Если analysts расходятся, он не выбирает majority, а формирует discriminating experiment: искусственно задержать cache callback и проверить порядок delete/write.

4. Один implementer

Implementer получает:

- confirmed hypothesis;
- reproduction artifact;
- allowed files;
- отдельный branch;
- запрет merge и release.

Он создаёт test и fix в одном bounded change set.

5. Tester проверяет конкретный commit

Tester запускает commands в sandbox, записывает environment digest и возвращает machine-readable report. Он не принимает summary «tests passed» от implementer.

6. Reviewer оценивает artifact

Reviewer получает goal, diff, test results и rubric. Он не имеет write tool. Verdict содержит blocking defects, evidence и coverage gaps.

7. Human/policy gate

Merge остаётся отдельной capability. Approval связан с exact commit SHA, а не с фразой «исправь проблему».

Эта система multi-agent не потому, что роли похожи на людей. Её ценность в parallel read, одном writer, независимом execution environment и отдельном verification evidence.

АХ и дерево Tasks

АХ Task может служить unit isolation для child agent: отдельные resources, Workspace, lifecycle и credentials. Но платформа не обязана угадывать business semantics дерева.

Application layer всё равно определяет:

- parent/child relation;
- deterministic task IDs;
- budget propagation;
- authority attenuation;
- join policy;

- cancellation и recovery;
- output schemas.

Не создавайте AX Task на каждый model call. Новая Task оправдана, когда нужны isolation, отдельный lifecycle, параллельная capacity или другой security scope. Подробная реализация на AX рассматривается в главе 22, а две полные reference architectures - в главе 33.

Где заканчивается orchestration protocol

Внутри одного application agents можно вызывать как tools или handoffs. Между независимыми systems нужен protocol discovery, messaging и long-running task exchange. A2A, например, стандартизует взаимодействие потенциально opaque agents: capability discovery, structured messages, streaming и asynchronous task updates.

Но interoperability protocol не решает:

- правильно ли decomposed objective;
- можно ли доверять remote agent;
- какой budget ему выдать;
- достаточно ли evidence;
- кто авторизует side effect;
- когда root Task считается успешной.

Протокол переносит delegation contract и artifacts. Coordinator и прикладной orchestration layer остаются ответственными за смысл; infrastructure orchestrator лишь исполняет lifecycle выделенных workloads.

Типичные антипаттерны

Role-play organization. Названия CEO, architect и engineer есть, а capabilities и boundaries одинаковы.

Spawn before decompose. Coordinator создаёт children до построения coverage map.

Everyone writes. Несколько agents меняют общий workspace без ownership.

Chat as state. Status и operation IDs извлекаются из сообщений.

Transcript forwarding. Каждый child получает всю history, включая secrets и irrelevant instructions.

Majority means truth. Correlated answers принимаются за независимое подтверждение.

Reviewer can silently fix. Verification и mutation смешаны в одной роли.

Unlimited recursion. Children создают children без subtree budget и depth limit.

Cancel means rollback. Parent считает остановленный child доказательством отсутствия side effect.

Success means done. Completion message принимается без output validation и external verification.

More agents in every eval. Multi-agent variant получает больше tokens, но cost не учитывается.

A2A/MCP as architecture. Наличие protocol заменяет design decomposition, authority и join semantics.

Checklist выбора и проектирования

Перед внедрением ответьте:

1. Какую метрику single-agent baseline нужно улучшить?
2. Какая часть работы действительно параллельна?
3. Где critical path и coordination overhead?
4. Почему нужен agent, а не function или workflow node?
5. Какая topology соответствует ownership?
6. Как выглядит delegation contract?
7. Какие input versions связывают child result?
8. Кто единственный owner каждого write target?
9. Как attenuate authority?
10. Как ограничены subtree cost, concurrency и depth?
11. Как fan-in сохраняет contradictions и provenance?
12. Кто имеет право завершить root Task?
13. Что происходит при parent restart и child timeout?
14. Как измеряется verified outcome и стоимость?
15. Какой ablation докажет, что дополнительный agent действительно нужен?

Если на вопросы 2, 6, 8 и 12 нет ответа, система ещё не готова к нескольким автономным loops.

Итоги главы

- Multi-agent architecture - это несколько decision loops плюс coordination layer, а не несколько role prompts.
- Начинайте с single-agent baseline и измеримой проблемы, которую должно решить разделение.
- Основные источники пользы: независимый параллелизм, context isolation, capability isolation и verification.


- Dependency graph и critical path важнее списка агентов.
- Manager, handoff, fan-out/fan-in, pipeline, evaluator и swarm имеют разные ownership semantics.
- Delegation требует structured contract: objective, non-goals, versions, authority, budget, schema и termination.
- Child authority должна быть уже parent authority и Task scope.
- Coordination state хранится структурированно; сообщения передают commands, findings и progress, но не заменяют state store.
- Shared writes требуют одного owner, отдельных branches или transactional concurrency control.
- Subtree budgets, admission control и depth limits предотвращают task explosion.
- Multi-agent failures включают gaps, duplication, role drift, lost findings, stale outputs, cycles и correlated errors.
- Fan-in агрегирует claims и evidence, а не голосует за самый популярный текст.
- Recovery опирается на deterministic child IDs, journal, leases и reconciliation side effects.
- Evals сравнивают outcome, latency и cost с single-agent и workflow baselines.
- На AX отдельная Task нужна для isolation, lifecycle, capacity или security boundary, а не для каждого шага reasoning.
- Protocol interoperability не заменяет orchestration design, trust и authorization.

Дальше. Логическое разделение ролей требует физических границ выполнения. В следующей главе сравним process, container, gVisor и microVM и свяжем степень изоляции с threat model.

Источники и дальнейшее чтение

- [Anthropic: How we built our multi-agent research system](#) - orchestrator-worker, delegation, parallelism, cost и evals.
- [Anthropic: Patterns and problems in emerging multiagent systems](#) - coordination, systemic resource failures, correlated behavior и epistemic risks.
- [OpenAI Agents SDK: Agent orchestration](#) - manager/agents-as-tools, handoffs и code-driven orchestration.
- [OpenAI Agents SDK: Handoffs](#) - ownership transfer, input filters и handoff configuration.
- [A2A Protocol Specification 0.3.0](#) - interoperability между независимыми agent systems.
- [Cemri et al.: Why Do Multi-Agent LLM Systems Fail?](#) - MAST taxonomy и empirical analysis multi-agent failures.
- [Anthropic: Building effective agents](#) - routing, parallelization, orchestrator-workers и evaluator-optimizer workflows.
- Главы 22, 33 и 37 этой книги - AX Task delegation, reference architectures и safe execution.

От Linux process к gVisor и microVM



В главе 7 мы разделили работу между несколькими agents и зафиксировали ownership. Но логическая граница роли ещё не является физической границей выполнения. Два агента могут иметь разные prompts и разные Task IDs, но фактически работать под одним Linux user, видеть общий filesystem и обращаться к одному Docker socket. Тогда компрометация одного участника автоматически разрушает границы остальных.

Представим reviewer, который получает чужой pull request. Чтобы проверить изменение, он запускает package manager, compiler и test suite. Любой из этих шагов может выполнить код из repository: post-install script, build plugin, test fixture или бинарник из dependency. Если такой workload видит credential, host filesystem или управляющий socket, одной prompt-инструкции «ничего не ломай» недостаточно.

Главный принцип главы:

Isolation tier выбирают по возможностям предполагаемого нарушителя и цене компрометации, а не по слову container в архитектурной схеме. Чем меньше доверия к коду и сильнее tenant boundary, тем меньше host interfaces должен видеть workload.

Изоляция начинается с threat model

Вопрос «что безопаснее: gVisor или microVM?» поставлен слишком рано. Сначала нужно определить, от кого и что именно защищается.

Вопрос	Пример для agent workload	Почему это меняет выбор
Какой код считается недоверенным?	Только входной текст; scripts из repository; произвольный бинарник; целый container image	Чем ближе attacker к native code, тем важнее syscall и kernel boundary
Какие assets находятся рядом?	Model key, Git credential, source code соседнего tenant, host filesystem, control-plane socket	Sandbox с лишним mount или credential остаётся опасным даже без escape
Какой outcome считается компрометацией?	Чтение чужих данных, изменение host, lateral movement, resource exhaustion, скрытая persistence	Разные outcomes требуют разных controls: isolation, egress policy, quotas, audit

Вопрос	Пример для agent workload	Почему это меняет выбор
Кто доверяет host?	Одна внутренняя команда; разные команды; внешние customers	Multi-tenant среда обычно требует более сильной и проверяемой boundary
Какая совместимость обязательна?	Обычный CLI; FUSE; eBPF; custom kernel module; GPU; nested container	Некоторые capabilities несовместимы с более узким System API
Какова цена overhead?	Один долгий job или тысячи коротких sandboxes	Startup, memory и density могут быть важнее средней CPU throughput

Threat model полезно записать одной проверяемой фразой. Например:

Недоверенный build script может получить полный контроль внутри sandbox, но не должен читать host/neighbor data, обращаться к control plane, использовать неразрешённый egress или удерживать ресурсы после deadline.

Такая формулировка сразу показывает, что одного механизма недостаточно. Kernel isolation уменьшает шанс escape. Filesystem mounts определяют доступные данные. Network policy ограничивает exfiltration. IAM и short-lived credentials ограничивают полномочия. cgroups и deadlines защищают availability.

Boundary, policy и resource control решают разные задачи

В разговорах об isolation часто смешивают четыре понятия.

- **Isolation boundary** определяет, какой код и какое состояние отделяют workload от host или соседа.
- **Authorization policy** определяет, какие действия workload имеет право выполнять.
- **Resource control** ограничивает CPU, memory, I/O, процессы и время.
- **Packaging** доставляет executable, libraries и filesystem image.

Container image в первую очередь является форматом упаковки. Namespaces и security settings добавляют изоляцию. cgroups дают учёт и limits. Ни один из этих элементов сам по себе не доказывает, что hostile workload безопасно запускать рядом с чужими данными.

Полезная проверка проста: предположите, что код внутри получил root относительно собственного окружения. Какие host interfaces остаются доступными? Видит ли он devices, privileged syscalls, host network, metadata service, Unix sockets, writable mounts или secrets? Именно этот список, а не название runtime, описывает реальную boundary.

Linux process: дешёвая граница для доверенного кода

Обычный process получает отдельное virtual address space и собственный набор file descriptors, но разделяет host kernel, filesystem namespace, network namespace и многие системные ресурсы с другими процессами. Unix permissions, отдельный UID/GID, ограниченный working directory и service manager уже дают полезную operational boundary.

Process isolation подходит, когда:

- код собран и контролируется одной доверенной командой;
- нет выполнения произвольных repository scripts или пользовательских binaries;
- секреты и файлы разделены обычными OS permissions;
- ошибка процесса опасна для job, но не должна считаться hostile attack;
- важны минимальный startup latency и простая диагностика.

Но process не создаёт самостоятельную security boundary против кода с тем же user. Такой код может читать доступные тому же UID файлы, посылать signals, исследовать /proc, наследовать environment и использовать все разрешённые host syscalls. Отдельный PID не означает отдельный trust domain.

Практический пример: model adapter, написанный вашей командой и не загружающий plugins, можно запускать как service process. Test runner для внешнего pull request - уже другой класс риска.

Container: Linux primitives, собранные в один runtime contract

Обычный OCI container запускает Linux process на host kernel, но меняет его представление системы.

Механизм	Что ограничивает	Чего не гарантирует
PID namespace	Видимость и нумерацию процессов	Защиту от уязвимости shared kernel
Mount namespace	Дерево mounts и root filesystem	Безопасность намеренно проброшенного hostPath
Network namespace	Interfaces, routes, ports и sockets	Запрет egress без отдельной policy
User namespace	Отображение UID/GID container в непривилегированные host IDs	Автоматическую совместимость со всеми volumes и devices
cgroups	Учёт и limits CPU, memory, I/O, PIDs	Confidentiality или syscall isolation

Механизм	Что ограничивает	Чего не гарантирует
Capabilities	Дробление полномочий root	Безопасность при возврате широких capabilities
seccomp	Allow/deny для host syscalls	Полноценный sandbox и business authorization
AppArmor/ SELinux	Mandatory access policy для файлов и других объектов	Корректную policy без сопровождения и тестов

Kernel documentation прямо подчёркивает: seccomp filter уменьшает доступную syscall surface, но сам по себе не является sandbox. `no_new_privs` запрещает `execve()` выдавать новые privileges через `setuid`, `setgid` или file capabilities и позволяет непривилегированному процессу безопаснее устанавливать seccomp filters. Это два слоя defense in depth, а не замена namespaces, LSM и правильным mounts.

Root внутри container и root на host - не одно и то же

Без user namespace UID 0 внутри container часто остаётся UID 0 с точки зрения host kernel, хотя namespaces и capability set ограничивают его действия. User namespace отображает container root в непривилегированный host UID. Rootless runtime идёт дальше: и daemon/runtime, и containers работают без host root, уменьшая последствия compromise управляющего процесса.

Rootless mode не превращает любое сочетание mounts и network в безопасное. Он также имеет ограничения совместимости и требует корректного UID/GID mapping. Но для agent execution это важный вопрос: почему runtime вообще должен иметь host root, если workload не требует devices или privileged setup?

Опасные настройки отменяют boundary

Настройка	Что открывает	Типичный риск
<code>privileged: true</code>	Широкие capabilities и ослабление kernel constraints	Container становится почти host process с дополнительной упаковкой
<code>hostPID</code> / <code>hostNetwork</code>	Host process или network view	Разведка, interference, обход предполагаемой network boundary
Docker/containerd socket	Управление новыми containers и mounts	Практически эквивалент host administration
Writable broad <code>hostPath</code>	Host files вне workspace	Persistence, credential theft, повреждение node
<code>CAP_SYS_ADMIN</code>	Большой набор kernel operations	Резкое расширение attack surface
Unconfined seccomp/LSM	Полная host syscall surface	Больше путей к kernel vulnerabilities
Device passthrough	Driver и device interface	Новая attack surface вне обычного runtime

Настройка	Что открывает	Типичный риск
Long-lived broad secret	External authority	Exfiltration без необходимости sandbox escape

Особенно опасен управляющий socket. Если agent может попросить Docker запустить новый privileged container с mount `/`, то ограничения текущего container не имеют смысла.

Минимальный hardened Pod profile

Конкретная production policy зависит от workload, но разумная исходная точка выглядит так:

```
apiVersion: v1
kind: Pod
metadata:
  name: bounded-agent
spec:
  automountServiceAccountToken: false
  containers:
    - name: agent
      image: registry.example/agent@sha256:...
      securityContext:
        runAsNonRoot: true
        allowPrivilegeEscalation: false
        readOnlyRootFilesystem: true
        capabilities:
          drop: ["ALL"]
        seccompProfile:
          type: RuntimeDefault
      resources:
        requests:
          cpu: "250m"
          memory: "256Mi"
        limits:
          cpu: "2"
          memory: "2Gi"
```

К этому обычно добавляются отдельный writable workspace, tmpfs с limit, default-deny egress, short-lived identity и deadline. Manifest не является универсальным рецептом: test runner может потребовать write в workspace, а browser - дополнительные syscalls. Любое ослабление должно быть связано с конкретной capability и покрыто тестом.

Почему hardened container всё ещё разделяет host kernel

У namespaces и seccomp есть принципиальная граница: разрешённый syscall всё равно обрабатывает host kernel. Container runtime может сократить доступную поверхность, но не заменяет реализацию kernel API.

Для trusted internal service этого часто достаточно. Для hostile native code риск иной: attacker целенаправленно ищет ошибку в разрешённом syscall, filesystem или device path. Чем больше kernels, drivers и privileged helpers доступны на node, тем сложнее доказать containment.

Здесь появляются два разных подхода:

- gVisor ставит перед host kernel отдельный application kernel, который реализует Linux-like System API в userspace;
- microVM помещает workload за guest kernel и virtual hardware boundary, используя hardware virtualization.

Три пути syscall

```
container: app -> allowed syscall -> host kernel

gVisor:    app -> Sentry / application kernel
           -> restricted host calls -> host kernel

microVM:   app -> guest kernel -> virtual device / VMM
           -> KVM -> host kernel
```

Диаграмма упрощает детали, но показывает главное. В обычном container разрешённый syscall приходит в host kernel. В gVisor приложение видит System API, реализованный Sentry; host calls выбирает уже Sentry. В microVM приложение обращается к отдельному guest kernel, а host взаимодействует с VMM и KVM через virtual devices и VM exits.

gVisor: application kernel между workload и host

gVisor предоставляет OCI runtime `runsc`, поэтому снаружи sandbox выглядит как container workflow. Внутри архитектура принципиально отличается от `runc`.

- **Sentry** реализует Linux-like system interface: syscalls, memory management, signals, process model, filesystems и networking.
- **Platform** перехватывает syscalls и page faults. Поддерживаемые варианты имеют разные требования к hardware и performance.
- **Gofer** посредничает при доступе к host-backed filesystem resources.
- **Netstack** реализует network stack в userspace и связывает его с virtual network devices.

Ключевое свойство: syscall sandboxed application не передаётся в host kernel с исходными аргументами. Sentry обрабатывает его по собственной модели и при необходимости делает ограниченные host calls от своего имени. Для escape attacker должен пройти дополнительную независимую реализацию System API, а затем host boundary.

Это не означает абсолютную безопасность. gVisor сам является сложным software и опирается на host kernel. Он не устраняет hardware side channels, ошибки configuration, unsafe

mounts, egress и credential leakage. Его security model прямо говорит: sandbox не заменяет secure architecture.

Systrap и KVM platform внутри gVisor

Термин KVM здесь легко спутать с microVM. gVisor KVM platform использует hardware virtualization для address-space switching и interception, но сохраняет gVisor process model: отдельного conventional guest kernel и virtual machine device model не появляется.

Systrap использует seccomp trap mechanism для перехвата syscalls и не требует hardware virtualization. Официальная документация рекомендует выбирать platform по среде: на bare metal KVM может давать лучший профиль, а внутри VM или без virtualization support практичнее Systrap. Nested virtualization способна сделать KVM platform медленнее.

Не фиксируйте историческое знание вроде «gVisor всегда использует ptrace». Текущая default platform - Systrap, а ptrace больше не является рекомендуемым вариантом. Runtime choice нужно проверять по pinned release и реальной конфигурации node.

Совместимость - часть security decision

gVisor стремится запускать обычные Linux binaries без модификаций, но не реализует каждый syscall, файл в `/proc//sys` и каждый device path. Иногда несовместимость полезна: workload не получает kernel feature, которую platform не собиралась предоставлять. Иногда она блокирует легитимный tool.

Проверять нужно не абстрактный language runtime, а полный execution path:

- package manager и post-install scripts;
- compiler, linker и test runner;
- filesystem watchers, FUSE и special files;
- browser sandbox nesting;
- debugger, profiler и tracing tools;
- network behavior под высокой concurrency;
- GPU или другой device interface;
- checkpoint/restore именно вашего runtime.

Performance тоже зависит от профиля. Syscall-heavy filesystem или network workload может платить больше, чем compute-heavy process, который долго работает в userspace. Поэтому «gVisor медленнее на N процентов» без benchmark share почти бессмысленно.

Когда gVisor является разумным tier

gVisor часто подходит для:

- выполнения test suites и build scripts из недоверенного repository;
- sandboxed code interpreter и browser automation;
- multi-tenant agents, где важна высокая density;
- коротких или suspendable workloads, для которых full VM management слишком тяжёл;
- сред, где OCI integration важнее полной Linux kernel compatibility.

Он менее удобен, когда workload требует custom kernel behavior, broad device access или features, которых нет в реализованном System API. Тогда нужно либо сузить workload, либо выбрать другую boundary, а не отключать protections случайными flags.

microVM: отдельный guest kernel и минимальный virtual hardware

MicroVM использует hardware virtualization и запускает отдельный guest kernel. VMM предоставляет ограниченный набор virtual devices и связывает их с host resources. В сравнении с general-purpose VM уменьшаются device model, boot path и management surface, но фундаментальная VM boundary сохраняется.

Firecracker - пример специализированного VMM для microVM. Он не является Kubernetes runtime сам по себе. Firecracker предоставляет machine model и API для lifecycle, а integration layer должен решить image preparation, network, storage, logging, credentials, snapshot lifecycle и scheduling.

Kata Containers решает другую задачу: даёт OCI/CRI-compatible runtime, который запускает container workload внутри lightweight VM. Kata может использовать разные hypervisors, включая QEMU, Cloud Hypervisor и Firecracker. Поэтому корректное сравнение выглядит так:

Компонент	Главная роль	Что видит platform engineer
gVisor / runsc	Application kernel и OCI runtime	Sandboxed container без отдельного guest Linux
Firecracker	Minimal VMM	API и machine lifecycle, вокруг которых строится runtime
Kata Containers	Container runtime поверх lightweight VMs	OCI/CRI integration и Pod-like UX с VM boundary
KVM	Host kernel virtualization interface	Низкоуровневый механизм, которым пользуются VMM

Что приходится эксплуатировать дополнительно

Отдельный guest kernel приносит более сильную boundary, но добавляет систему:

- guest kernel и root filesystem нужно собирать, обновлять и сканировать;
- virtual network и block devices требуют provisioning;
- memory reserve и Pod overhead должны учитываться scheduler;
- логи и metrics проходят через guest/host boundary;
- debugging требует понимания guest и VMM;
- hardware virtualization должна быть доступна на node;
- nested virtualization в cloud VM или lab может отсутствовать либо иметь высокий overhead.

На Proxmox/KVM lab это означает отдельную проверку: видит ли Kubernetes node virtualization extensions, разрешён ли `/dev/kvm`, совместимы ли CPU flags и не запрещает ли provider nested virtualization. Успешный запуск обычного container ничего об этом не говорит.

Snapshot microVM не равен backup всей задачи

Firecracker snapshot разделяет VM state и guest memory; attached block devices и внешние resources управляются отдельно. Restore также зависит от совместимости CPU features, host kernel, VMM/device model и доступности прежних tap, block и vsock endpoints.

Следовательно, snapshot contract должен включать:

- VMM и snapshot format version;
- CPU architecture и допустимый feature baseline;
- guest kernel/image digest;
- block device identities;
- network reattachment и connection semantics;
- encryption, integrity и access policy для memory image;
- reconciliation внешних side effects после resume.

Memory snapshot может содержать tokens, private keys и пользовательские данные. Его следует считать secret-bearing artifact. CRC защищает от случайной порчи, но не является authenticity или confidentiality control.

И ещё одна граница из главы 5: snapshot возвращает вычислительное состояние, но не отка- тывает Git remote, ticket, payment или DNS. После restore agent обязан сверить внешнюю ре- альность.

Kubernetes RuntimeClass: выбор runtime как platform policy

Kubernetes `RuntimeClass` связывает имя в Pod spec с runtime handler, настроенным в CRI implementation. Это позволяет одному cluster запускать разные workload tiers.

```
apiVersion: node.k8s.io/v1
kind: RuntimeClass
metadata:
  name: gvisor
handler: runsc
---
apiVersion: v1
kind: Pod
metadata:
  name: untrusted-build
spec:
  runtimeClassName: gvisor
  containers:
    - name: runner
      image: registry.example/build-runner@sha256:...
```

Конкретные handler names зависят от containerd/CRI-O configuration. RuntimeClass также может нести scheduling constraints и Pod overhead. Если runtime доступен только на части nodes, class должна направлять Pods на эти nodes и учитывать taints/tolerations.

Создание и изменение RuntimeClass должно оставаться полномочием cluster administrator. Agent не должен выбирать себе менее строгую boundary через tool call. Application передаёт workload classification, а admission/platform policy отображает её на разрешённый runtime.

Полезный contract выглядит так:

```
workload.trust = external-code
workload.devices = none
workload.network = allowlisted-egress
workload.persistence = workspace-only
isolation.required = sandboxed-system-api

platform decision -> RuntimeClass gvisor + policy profile v3
```

Здесь application описывает требования, а не знает имя runtime binary. Это позволяет platform team заменить implementation без изменения agent logic.

Как выбирать isolation tier

Tier	Подходящий workload	Основное преимущество	Главное ограничение
Отдельный process	Доверенный platform code без plugins	Минимальные startup и operational cost	Слабая boundary против hostile code
Hardened container	Доверенный image, внутренние tools, ограниченный blast radius	Зрелая OCI/Kubernetes integration и высокая density	Shared host kernel
gVisor	Недоверенные scripts/ repositories, multi-tenant execution, обычные Linux apps	Дополнительный System API boundary при container UX	Compatibility и workload-dependent overhead

Tier	Подходящий workload	Основное преимущество	Главное ограничение
microVM/Kata	Hostile tenant code, более строгая kernel boundary, нужен guest Linux	Отдельный guest kernel и hardware isolation	Memory, boot, image, device и operations overhead
Отдельный node/cluster	Особо чувствительные assets, privileged devices, сильные regulatory требования	Уменьшение shared failure domain	Стоимость, capacity fragmentation и более сложная operations model

Выбор не обязан быть глобальным. Одна agentic application может использовать несколько tiers:

- coordinator как trusted process;
- read-only repository analysis в hardened container;
- test execution внешнего code в gVisor;
- редкий kernel-level experiment в microVM на специальном node pool.

Это дешевле и яснее, чем помещать каждый model call в microVM или, наоборот, запускать всё на одном privileged runner.

Не выбирайте только по слову stronger

Более сильная boundary может ухудшить итоговую безопасность, если ради совместимости команда начинает выдавать broad mounts, devices и permanent credentials. Неработающий debugger иногда приводит к включению privileged mode, а медленный cold start - к бесконечно живущим sandboxes без cleanup.

Сравнивайте end-to-end profile:

- startup и resume latency;
- idle и peak memory;
- CPU для model-adjacent tools, build и tests;
- filesystem metadata и small-file I/O;
- network throughput и connection churn;
- sandbox density на node;
- compatibility failure rate;
- операционное время на обновления и incident recovery.

Benchmark должен использовать тот же repository size, dependency cache, language toolchain, network policy и concurrency, что production. Microbenchmark одного syscall помогает объяснить механизм, но не выбирает platform за вас.

Isolation не заменяет capability security

Sandbox может идеально удерживать process и всё равно позволить ему легально украсть данные через разрешённые interfaces. Если agent видит production database password и arbitrary Internet egress, escape не нужен.

Для каждого sandbox отдельно проектируются:

- **Filesystem:** какие paths read-only, какие writable, что является disposable, что сохраняется.
- **Network:** default deny, allowlisted destinations, DNS behavior, proxy и metadata endpoint.
- **Identity:** short-lived token, audience, scope, rotation и revocation.
- **Tools:** read/write capabilities, approval и idempotency.
- **Data:** какие artifacts можно вернуть из sandbox и кто их проверяет.
- **Time:** deadline, idle timeout, cancellation и гарантированный cleanup.

Prompt injection действует на уровне решений агента. Sandbox containment действует на уровне исполнения. Они дополняют друг друга: policy должна предполагать, что model уже убеждена выполнить худшее разрешённое действие.

Lifecycle: stop, pause, suspend и destroy

Isolation tier влияет не только на security, но и на lifecycle semantics.

- **Stop** прекращает выполнение, но может оставить filesystem и metadata.
- **Pause** временно не планирует CPU, сохраняя resources занятыми.
- **Suspend** сериализует достаточное состояние и освобождает часть capacity.
- **Destroy** удаляет execution boundary, но не обязательно external artifacts.

Для process/container checkpoint обычно тесно связан с host kernel state. Для gVisor и microVM runtime может контролировать больше state, но portability всё равно зависит от version, architecture, filesystem и network. Любой suspend/resume contract должен явно отвечать:

1. Какие bytes сохраняются?
2. Кто шифрует и авторизует snapshot?
3. На каких hosts его можно восстановить?
4. Что происходит с TCP connections и open files?
5. Как обнаруживается partial restore?
6. Как сверяется внешний мир после resume?

Observability через границу

Сильная isolation усложняет диагностику. Host видит VMM или Sentry, а не всегда каждый guest process привычным способом. Debug interface, который обходит boundary, легко становится новым escape path.

Production design должен заранее определить:

- correlation IDs от Task до sandbox, process и tool call;
- structured stdout/stderr без доверия к содержимому;
- CPU, memory, I/O, process count и network metrics;
- runtime events: create, start, OOM, policy deny, checkpoint, restore, destroy;
- audit mounts, RuntimeClass, image digest и security profile version;
- способ получить crash artifact без broad shell access;
- redaction до вывода logs за tenant boundary.

Фраза «sandbox упал» так же бесполезна, как «агент завис». Нужно знать, завершился ли guest process, сработал ли seccomp/LSM deny, случился ли OOM, потерялся ли VMM, не восстановился ли snapshot или platform отменила Task по deadline.

Как тестировать isolation layer

Compatibility suite

Соберите representative corpus: языковые runtimes, package managers, browsers, compilers, filesystem patterns и network clients. Тестируйте pinned images на каждом runtime tier. Ошибка compatibility должна быть видима до production routing.

Negative security tests

Проверяйте не только успешный job, но и запрещённые действия:

- чтение host paths и соседнего workspace;
- доступ к container runtime socket и Kubernetes API;
- обращение к cloud metadata;
- egress к неразрешённому endpoint;
- создание слишком большого числа процессов;
- mount, namespace escape primitives и forbidden syscalls;
- сохранение процесса после cancellation;
- чтение snapshot другим tenant.

Тест считается успешным, когда действие отклонено ожидаемым control, а событие видно в audit. Просто получить non-zero exit code недостаточно: отказ мог произойти случайно.

Resource abuse

Запускайте fork bomb, memory pressure, disk fill, file descriptor exhaustion и network flood в controlled lab. Проверяйте, что страдает sandbox, а не node control plane или соседние workloads. Отдельно тестируйте cleanup после OOM и hard kill.

Upgrade и restore matrix

Для stateful sandbox нужны тесты N-1/N/N+1: runtime version, host kernel, CPU pool, guest image и snapshot format. Если поддерживается только same-version restore, это допустимый contract, но он должен влиять на rollout strategy.

AX и Agent Substrate

В AX `Task` является минимальной единицей isolated execution. Task описывает image, command, resources и Workspace bindings, но application не должна считать любой Task автоматически достаточной boundary для любого threat model.

Agent Substrate предоставляет runtime layer и в текущей архитектуре поддерживает несколько sandbox backends, включая gVisor и microVM path. Его Actor/Worker model позволяет отделить logical actor от физической capacity, а suspend/resume - освобождать Worker, когда agent простаивает.

Граница ответственности выглядит так:

- application классифицирует workload, данные и требуемые capabilities;
- AX создаёт декларативную Task и управляет её lifecycle;
- platform policy выбирает допустимый sandbox profile;
- Agent Substrate размещает Actor на совместимом Worker и выполняет runtime operations;
- Kubernetes управляет nodes, worker Pods, scheduling prerequisites и cluster-level isolation.

Не следует превращать current implementation в вечную спецификацию. AX и Agent Substrate остаются pre-1.0; Sandbox/SandboxConfig и policy surfaces развиваются. Для production design нужно фиксировать commit/release и проверять реальный backend, а не только design goal.

Особенно важно не путать runtime snapshot с application recovery. Substrate может вернуть process memory и filesystem, но harness всё равно отвечает за state schema, leases, idempotency и reconciliation внешних операций.

Практикум: безопасная проверка недоверенного pull request

Задача: agent получает pull request из внешнего fork, исследует diff, запускает tests и возвращает report. Merge и публикация запрещены.

Шаг 1. Зафиксировать trust и assets

```
trust:
  repository_code: hostile
  base_image: platform-signed
assets:
  readable:
    - source snapshot at exact commit
    - public dependency mirror
  forbidden:
    - host filesystem
    - Kubernetes API
    - production credentials
    - other tenant workspaces
side_effects:
  allowed:
    - write ephemeral workspace
    - upload test report artifact
```

Шаг 2. Разделить setup и execution

Trusted setup component получает repository через platform-controlled fetch и создаёт immutable input artifact. Недоверенный build не получает Git credential. Dependency access идёт через allowlisted mirror. Это уменьшает authority ещё до выбора runtime.

Шаг 3. Выбрать tier

Hardened container может быть baseline для внутреннего trusted repository. Для внешнего fork выбран gVisor: обычный toolchain совместим, нужен container UX и высокая parallel density. MicroVM остаётся отдельным profile для workloads, которым требуется guest kernel или более строгая tenant boundary.

Шаг 4. Ограничить окружение

- read-only source input и отдельный ephemeral writable workspace;
- нет service account token и runtime socket;
- all capabilities dropped, no privilege escalation;
- default-deny egress с dependency mirror и artifact endpoint;
- CPU, memory, PID, disk и wall-clock budgets;
- output size limit и content scanning;
- destroy после report независимо от результата tests.

Шаг 5. Проверить boundary отрицательными тестами

В repository добавляется test fixture, который пытается прочитать host path, metadata endpoint и соседний artifact, затем создаёт process storm. Ожидаемый результат - каждый путь блокируется конкретным control, node остаётся healthy, audit связывает deny с Task ID.

Шаг 6. Измерить цену

Сравните hardened container, gVisor и microVM на одном corpus:

- p50/p95 start-to-first-command;
- полное время install/build/test;
- peak и idle memory;
- node density при целевой concurrency;
- доля несовместимых repositories;
- время cleanup и recovery после kill.

Решение документируется не как «gVisor безопаснее container», а как verified contract: какие attacks проверены, какие interfaces доступны, какой overhead измерен и когда routing повышает tier до microVM.

Типичные антипаттерны

Container means safe. Название packaging format принимается за доказательство containment.

Privileged for compatibility. Любую несовместимость лечат отключением security controls.

Docker socket as a tool. Agent получает host-level authority, чтобы запускать вложенные workloads.

One tier for everything. Model call, trusted controller и hostile build запускаются с одинаковой дорогой boundary.

Sandbox with production secrets. Escape закрыт, но легальный egress позволяет украсть credentials.

Snapshot equals rollback. Restore process state считают откатом внешних side effects.

Benchmark without workload shape. Решение принимают по чужому syscall microbenchmark.

Debug by bypass. Для диагностики навсегда добавляют broad shell, host mount или privileged sidecar.

Runtime selected by agent. Недоверенный workload может сам выбрать менее строгий RuntimeClass.

Node is infinite. Security обсуждают без PID, memory, disk и time limits.

Checklist выбора и эксплуатации

1. Какой exact code считается hostile?
2. Какие host и tenant assets находятся рядом?

3. Можно ли убрать capability вместо усиления sandbox?
4. Какие mounts, devices, sockets и credentials видит workload?
5. Есть ли user namespace/rootless path?
6. Какие syscalls и LSM rules реально применены?
7. Нужен ли отдельный System API boundary или guest kernel?
8. Какие features toolchain несовместимы с выбранным runtime?
9. Кто выбирает RuntimeClass и можно ли обойти policy?
10. Как ограничены egress, metadata и control-plane access?
11. Как измеряются CPU, memory, PIDs, disk и deadline?
12. Что сохраняет snapshot и какие secrets в нём остаются?
13. На каких CPU/kernel/runtime versions разрешён restore?
14. Как sandbox уничтожается после success, failure и cancellation?
15. Какие negative tests доказывают containment?
16. Какой end-to-end overhead измерен на production-like workload?

Итоги главы

- Isolation tier выбирается по threat model, а не по названию runtime.
- Process подходит для доверенного кода, но не является tenant boundary против hostile code.
- Container объединяет namespaces, cgroups и security controls, сохраняя shared host kernel.
- cgroups управляют resources; seccomp уменьшает syscall surface; ни один из них отдельно не является полным sandbox.
- Privileged mode, broad host mounts, devices и runtime sockets способны отменить container boundary.
- gVisor реализует Linux-like System API в Sentry и даёт дополнительную boundary при OCI workflow.
- gVisor Systrap и KVM platform - способы interception, а не две разновидности microVM.
- MicroVM добавляет guest kernel и hardware virtualization, но требует VMM, images, devices и более сложной operations model.
- Firecracker является VMM building block; Kata Containers предоставляет container runtime integration поверх lightweight VMs.
- RuntimeClass позволяет platform policy выбирать runtime и учитывать scheduling/overhead.
- Sandbox не заменяет egress policy, IAM, filesystem scoping, short-lived credentials и tool authorization.
- Snapshot содержит чувствительное runtime state и не откатывает внешний мир.
- Проверять нужно compatibility, containment, resource abuse, restore и end-to-end cost.
- В AX и Agent Substrate application классифицирует workload, а platform обеспечивает выбранную physical boundary и lifecycle.


Дальше. Мы выбрали границу выполнения, но ещё не разобрали substrate, который размещает такие workloads на nodes, связывает их сетью и постоянно приводит actual state к desired. Следующая глава даст необходимый минимум Kubernetes для понимания AX и Agent Substrate.

Источники и дальнейшее чтение

- [Linux kernel: Seccomp BPF](#) - назначение syscall filtering и прямое предупреждение, что seccomp сам по себе не является sandbox.
- [Linux kernel: No New Privileges Flag](#) - semantics no_new_privs и связь с execve.
- [Linux kernel: Control Group v2](#) - resource hierarchy и cgroup namespace.
- [Docker Engine security](#) - namespaces, capabilities, daemon surface и container configuration.
- [Docker Rootless mode](#) - user namespaces и runtime без host root.
- [gVisor: Introduction to security](#) - Sentry, Gofer и dual-kernel security model.
- [gVisor: Platform Guide](#) - Systrap, KVM platform и требования среды.
- [gVisor: Security Model](#) - boundaries, assumptions и ограничения sandbox.
- [gVisor: Performance Guide](#) - structural и implementation costs.
- [Firecracker Design](#) - VMM architecture, device model и threat containment.
- [Firecracker Snapshotting](#) - memory/state files, external resources и security responsibilities.
- [Firecracker Snapshot Versioning](#) - CPU, host kernel и device compatibility.
- [Kata Containers Architecture](#) - OCI/CRI runtime поверх lightweight VMs.
- [Kubernetes RuntimeClass](#) - runtime handlers, scheduling и Pod overhead.
- [Kubernetes: Linux kernel security constraints](#) - seccomp, AppArmor, SELinux и privileged containers.
- [AX Core concepts](#) - Task как smallest unit of isolated execution.
- [Agent Substrate](#) - gVisor/microVM backends, Actor/Worker и suspend/resume.

Kubernetes: необходимый минимум для понимания AX/Substrate

Kubernetes reconciliation loop - mental model, который нужен для AX/Substrate



Kubernetes здесь нужен не как отдельный предмет, а как инфраструктурная среда, в которой живут AX и Substrate. Нам не требуется знать каждую настройку кластера; важно видеть путь workload от намерения до работающего процесса и понимать, где искать сбой.

Эта глава не пытается заменить отдельную книгу о Kubernetes. Её задача практичнее: дать инженеру ровно ту модель, которая нужна, чтобы читать manifests AX/Substrate, понимать placement и lifecycle, отличать проблему Kubernetes от проблемы agent runtime и не принимать cluster abstraction за security boundary.

После главы вы должны уметь

- проследить путь объекта от YAML до процесса на конкретной node;
- объяснить разницу между `spec`, `status`, событием и реальным состоянием процесса;
- выбрать Deployment, StatefulSet, DaemonSet или Job по семантике workload;
- понять, почему Pod остаётся Pending, перезапускается или не получает traffic;
- связать requests, limits, probes, Service, storage и RuntimeClass с поведением agent platform;
- определить, какие данные уместны в Kubernetes API, а какие должны жить в специализированном store;
- провести первый диагностический проход без случайного изменения production state.

Kubernetes не запускает контейнер «по команде»

Самая полезная смена мышления - отказаться от модели удалённого shell. В shell команда означает разовое действие: «запусти процесс». В Kubernetes manifest означает **намерение**: «в cluster должен существовать workload с такими свойствами». Система сохраняет это намерение и продолжает работать с ним после завершения `kubectl`, `disconnect` клиента и перезапуска отдельных компонентов.

Пользователь пишет объект в API. API server проверяет запрос, применяет defaulting и admission policy, затем сохраняет объект. Controllers наблюдают объекты и создают следующие объекты. Scheduler выбирает node для Pod. Kubelet на этой node через CRI просит container runtime подготовить sandbox и containers. CNI настраивает сеть, CSI при необходимости подключает storage. После каждого шага компоненты публикуют status, но ни один успешный API response не обещает, что приложение уже готово.

Поэтому фраза `deployment.apps/controller created` означает только «API принял объект». Она не означает «image скачан», «Pod запущен», «probe прошла» или «Service направляет traffic». Между принятым намерением и полезно работающим процессом находится асинхронная цепочка reconciliation.

Reconciliation как замкнутый контур

Controller читает desired state, наблюдает actual state, вычисляет различие и делает ограниченный шаг. Затем цикл повторяется. Он не обязан завершить всю работу за одну итерацию и должен переживать повторное выполнение. Если Pod исчез, Deployment controller создаст замену. Если node недоступна, другие controllers обновят состояния, а workload controller попытается восстановить нужное число replicas на доступных nodes.

Важно различать **объект** и **реальность**. Запись Pod в API может существовать, пока container ещё не создан. Status может кратко отставать от процесса. Event описывает наблюдавшийся эпизод, но не является долговечным журналом. Именно поэтому оператор читает несколько сигналов, а не делает вывод по одному полю.

Кто за что отвечает

Компонент	Ответственность	Чего он не делает
kube-apiserver	единая API boundary, authentication, authorization, admission, validation и доступ к object state	не запускает containers и не выбирает node
etcd	хранит cluster state, который обслуживает API server	не является application database для произвольных task events
kube-controller-manager	запускает built-in control loops для workloads, nodes, endpoints и других ресурсов	обычно не выполняет workload сам

Компонент	Ответственность	Чего он не делает
kube-scheduler	для unscheduled Pod выбирает подходящую node и записывает binding	не запускает process и не переносит живой Pod между nodes
kubelet	на assigned node приводит Pod к локально требуемому состоянию через runtime и публикует status	не решает глобальное размещение
container runtime / CRI	создаёт Pod sandbox, images и containers	не определяет application policy
CNI implementation	подключает Pod к cluster network и часто реализует NetworkPolicy	наличие API NetworkPolicy не гарантирует enforcement
CSI driver	provision, attach и mount storage по storage contract	не выбирает retention и backup policy за владельца данных

Объект Kubernetes: intent, identity и observation

Почти любой объект имеет четыре слоя. `apiVersion` и `kind` выбирают schema. `metadata` содержит имя, namespace, UID, labels, annotations, owner references и generation. `spec` выражает desired state владельца. `status` сообщает наблюдаемое состояние, записанное системой или controller.

Это не просто формат YAML. Граница между `spec` и `status` определяет ownership. Пользователь не должен вручную «исправлять» status, а controller не должен тихо переписывать intent. Для custom controller полезно публиковать `observedGeneration`: тогда клиент понимает, относится ли status к последней версии spec. Conditions должны отвечать на операционные вопросы вроде `Ready`, `Progressing` и `Degraded`, а не превращаться в неструктурированный log.

Labels предназначены для выбора и группировки объектов; annotations - для дополнительной метаинформации, которую обычно не используют как selector. Namespace создаёт scope имён, RBAC и quotas, но сам по себе не даёт сильной tenant isolation: Pods разных namespaces всё ещё могут оказаться на одной node и использовать общий kernel, если platform не добавила другие boundaries.

Минимальный manifest, который стоит уметь читать

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: ax-controller
  namespace: ax-system
spec:
  replicas: 2
  selector:
    matchLabels:
      app: ax-controller
  template:
    metadata:
      labels:
        app: ax-controller
    spec:
      serviceAccountName: ax-controller
      containers:
        - name: controller
          image: registry.example/ax-controller@sha256:...
          resources:
            requests: {cpu: "500m", memory: "512Mi"}
            limits: {memory: "1Gi"}
          startupProbe:
            httpGet: {path: /health/startup, port: 8080}
          readinessProbe:
            httpGet: {path: /health/ready, port: 8080}
          livenessProbe:
            httpGet: {path: /health/live, port: 8080}
```

Здесь Deployment владеет ReplicaSet, ReplicaSet владеет Pods, а Pod template определяет будущие экземпляры. Selector обязан соответствовать labels template. ServiceAccount задаёт workload identity. Digest фиксирует точный image content. Requests участвуют в scheduling, memory limit ограничивает cgroup, а probes отвечают на три разных вопроса о lifecycle.

Pod: общая судьба, а не маленькая VM

Pod - минимальный deployable compute object Kubernetes. В нём один или несколько containers делят network namespace и обращаются друг к другу через `localhost`. Они могут делить volumes и часть lifecycle. Это делает Pod хорошей границей для процессов, которые должны размещаться и завершаться вместе, но плохой границей для независимых services.

Pod не является VM. Containers обычно используют kernel node. Pod IP может исчезнуть при пересоздании. Pod не «переезжает» на другую node: controller создаёт новый Pod с новым UID, а старый завершается или теряется. Локальный filesystem container не должен считаться durable state.

Init container выполняет подготовительный шаг до application containers: например, проверяет schema или получает configuration. **Sidecar** живёт рядом с приложением ради тесно связанной функции. Каждый sidecar увеличивает resource footprint, startup dependencies и failure surface; telemetry, проху или secret delivery не становятся бесплатными только потому, что вынесены во второй container.

Для agent runtime Pod может содержать trusted supervisor и sandboxed execution component, но совместное размещение не отменяет security analysis. Общие volumes, localhost, process namespace и credentials способны превратить удобный sidecar в путь обхода boundary. Изоляцию следует доказывать конкретной runtime и Pod configuration, а не количеством containers.

Как выбрать workload controller

Ресурс	Когда выбирать	Ключевая семантика	Типичная ошибка
Deployment	stateless или externally stateful service с взаимозаменяемыми replicas	rolling update и поддержание replica count через ReplicaSet	хранить identity или единственную копию state в filesystem Pod
StatefulSet	нужны стабильные ordinal identity, порядок rollout или отдельные persistent claims	предсказуемые имена Pods и управляемая связь с storage	считать StatefulSet автоматической репликацией и backup базы
DaemonSet	по одному Pod на каждой подходящей node или на выбранном классе nodes	node-local agent, supervisor, networking или telemetry	использовать для обычного horizontally scaled API
Job	конечная работа должна завершиться успешно	completion, retries и parallelism для batch	считать повтор Pod гарантией exactly-once side effect
CronJob	периодическое создание Jobs	расписание, concurrency policy и history	полагаться на него как на единственный источник строгой бизнес-периодичности

Для AX/Substrate типичная картина неоднородна. API/controller components естественно выглядят как Deployment. Node-local worker supervisor или runtime integration может использовать DaemonSet. Stateful backing services требуют собственного operator или внешнего managed service. Отдельная agent Task не обязана быть отдельным Kubernetes Job: если platform создаёт тысячи коротких или suspendable actors, прямое отображение «одна Task = один API object» может стать дорогим и семантически неверным.

Scheduling: почему Pod остаётся Pending

Scheduler не спрашивает, сколько ресурсов Pod потребляет прямо сейчас. Он проверяет requests и constraints против allocatable capacity и свойств nodes. Поэтому пустая node по графику CPU всё равно может не принять Pod, если уже размещённые requests исчерпали allocatable. И наоборот, отсутствие requests позволяет overcommit, но ухудшает предсказуемость и eviction behavior.

Request - заявка на capacity и основа scheduling. CPU request также влияет на относительную долю CPU при contention. **Limit** - runtime ceiling: CPU обычно throttled, превы-

шение memory limit может завершить process через OOM. Это разные механизмы; limit не резервирует capacity, а request не является жёстким потолком.

Размещение уточняют несколько инструментов:

- **nodeSelector/node affinity** притягивают workload к nodes с нужными labels, например virtualization support или local SSD;
- **taints/tolerations** отталкивают неподходящие Pods; toleration разрешает рассматривать tainted node, но не гарантирует выбор;
- **pod anti-affinity/topology spread** распределяют replicas по nodes и zones, уменьшая correlated failure;
- **priority/preemption** помогают критичным Pods получить место, но могут вытеснить менее приоритетную работу;
- **RuntimeClass** выбирает runtime handler и может добавлять scheduling constraints и Pod overhead.

Для agent workloads RuntimeClass связывает главу 8 с Kubernetes: classification решает, что hostile build требует gVisor или microVM-backed runtime, а platform policy назначает разрешённый class. Недоверенный Task не должен самостоятельно понижать isolation tier. Nodes с KVM, gVisor или GPU обычно разделяют labels/taints и admission policy, иначе Pod либо не запустится, либо попадёт на неверный runtime pool.

Lifecycle и probes: три разных вопроса

Startup probe отвечает: «успело ли приложение инициализироваться?». Пока она не прошла, liveness и readiness не начинают обычную работу. **Readiness probe** отвечает: «можно ли сейчас отправлять traffic?». Её failure убирает endpoint из готовых backend Service, но не обязана перезапускать container. **Liveness probe** отвечает: «застряло ли приложение так, что требуется restart?». Слишком агрессивная liveness во время нагрузки создаёт restart storm и усиливает incident.

Для controller readiness должна учитывать способность обслуживать новые requests, а не обещать здоровье всех external dependencies сразу. Liveness не должна падать из-за временной недоступности Redis, PostgreSQL или model gateway, если process способен восстановиться без restart. Startup probe особенно важна для больших images, migrations, cache warm-up и local inference servers.

Удаление Pod - протокол, а не мгновенное исчезновение. Kubernetes начинает termination, endpoint перестаёт считаться ready, выполняется lifecycle hook при наличии, process получает termination signal и имеет grace period. Приложение должно прекратить принимать новую работу, завершить или checkpoint активные операции и освободить lease. Если agent runtime игнорирует termination, rollout превращается в потерю задач.

Pod phase `Running` означает, что Pod назначен node и хотя бы один primary container запущен или запускается; это не эквивалент application readiness. `CrashLoopBackOff` - не phase, а сообщение о backoff между повторными запусками. `OOMKilled` обычно указывает на memory boundary, но для причины нужно сопоставить last state, events, node pressure и application metrics.

Service, DNS и реальный путь traffic

Pod IP нестабилен, поэтому клиент обычно обращается к Service. Selector Service выбирает Pods, EndpointSlice хранит актуальные backends, а service proxy или network dataplane направляет traffic. DNS создаёт удобное имя вроде `ax-controller.ax-system.svc`. Service не запускает health check сам: готовность endpoints обычно следует из Pod readiness.

Если DNS name разрешается, это доказывает только discovery. Если TCP connection устанавливается, это ещё не доказывает корректность application protocol, TLS identity или authorization. Диагностика должна идти слоями: DNS - endpoint membership - route - port - TLS - application response.

NetworkPolicy определяет разрешённые ingress/egress flows на уровне Pod selectors, namespaces, IP blocks и ports. Но policy работает только если network implementation её поддерживает и применяет. Policy не является HTTP authorization, не понимает MCP semantics и не заменяет egress proxy. Для agent sandbox особенно опасен «разрешить весь egress ради package install»: тот же путь может использоваться для exfiltration.

Storage: lifetime важнее названия volume

Container filesystem и `emptyDir` удобны для scratch data. `emptyDir` переживает restart отдельного container внутри того же Pod, но удаляется вместе с Pod. PersistentVolume имеет lifecycle, независимый от конкретного Pod; PersistentVolumeClaim выражает запрос workload, а StorageClass описывает provisioning и operational class storage.

Наличие PVC не гарантирует durability. Нужно отдельно знать reclaim policy, replication, failure domain, snapshot support, backup, restore test, encryption и access mode. Local volume способен пережить Pod, но привязывает workload к node. Network volume снимает эту привязку ценой latency и внешней failure domain.

В agent platform полезно разделять:

- ephemeral workspace, которое можно уничтожить вместе с attempt;
- durable artifacts, которые публикуются в object store;
- runtime snapshots с отдельной compatibility и confidentiality policy;
- control-plane database state, которое восстанавливается по собственному backup contract.

Попытка смонтировать один общий PVC во все агенты упрощает demo, но создаёт race conditions, lateral access и неясное ownership. Workspace и artifact должны иметь tenant/task scope, quota и явный cleanup.

Configuration, identity и policy

ConfigMap отделяет non-confidential configuration от image. Secret предназначен для confidential data, но base64 не является encryption. Без encryption at rest Secret может

храниться в etcd незашифрованным; любой субъект с широким `get/list/watch` получает чувствительные значения. Монтирование Secret в Pod передаёт секрет процессу, а значит application обязано не логировать и не пересылать его.

ServiceAccount даёт workload identity для Kubernetes API и связанных identity systems. RBAC отвечает, какие API verbs разрешены над какими resources. Для большинства execution Pods безопасный default - `automountServiceAccountToken: false`; token нужен только workload, который действительно обращается к Kubernetes API. Controller получает отдельный ServiceAccount и минимальные namespaced или cluster permissions.

Admission выполняется до сохранения объекта. Здесь можно запретить privileged containers, host mounts, unsafe capabilities, untrusted registries, произвольный RuntimeClass и отсутствие resource requests. Pod Security Admission применяет профили Pod Security Standards на уровне namespace, но для platform-specific правил часто нужны ValidatingAdmissionPolicy или admission webhook.

Namespace - удобный policy scope, не полноценная hostile multi-tenant boundary. Для недоверенного кода дополнительно нужны runtime isolation, node separation, NetworkPolicy, egress control, scoped identity, quotas и защита control-plane endpoints. Kubernetes оркестрирует эти controls, но не создаёт автоматически правильную threat model.

CRD и operator: когда расширять Kubernetes API

CustomResourceDefinition добавляет новый kind, а custom controller реализует его lifecycle. Это полезно, когда объект действительно является декларативным infrastructure resource: имеет сравнительно небольшую population, долгоживущий desired state, понятные ownership/finalizers и естественно управляется через Kubernetes API.

CRD не стоит использовать как удобную бесплатную database. Официальная документация прямо рекомендует не хранить в Custom Resources обычные application, end-user или monitoring data. Высокочастотные task events, model tokens, logs, traces и миллионы короткоживущих attempts создают нагрузку на API storage/watch и слишком тесно связывают application с cluster control plane.

Хороший вопрос перед созданием CRD: «должен ли cluster operator управлять жизненным циклом этого объекта через декларативный API?». Если ответ звучит как «нам просто нужен JSON store с watch», вероятно, нужен PostgreSQL, Redis, event stream или object storage.

Граница ответственности Kubernetes, AX и Substrate

Слой	Владеет	Не должен подменять
Kubernetes	nodes, Pods, placement, restart, cluster networking/ storage integration, workload identity и cluster policy	agent semantics, tool authorization, conversation state и task event store
Substrate	Actor/Worker lifecycle, runtime backend, sandbox placement, suspend/resume и snapshot contract	общий Kubernetes scheduler или application goal
AX	Task intent, orchestration, agent execution policy, task state/events и связь с tools	container runtime internals и node lifecycle
Harness/ application	agent loop, prompts, context, domain state и решение о следующем действии	physical isolation и cluster-wide capacity management

Пример цепочки: пользователь создаёт AX Task. AX сохраняет intent и просит Substrate предоставить isolated Actor. Substrate выбирает подходящий WorkerPool и physical runtime. Kubernetes обеспечивает, чтобы нужная worker capacity существовала на nodes с требуемым RuntimeClass и ресурсами. Kubelet запускает Pod, runtime создаёт sandbox. При этом task progress не обязан записываться как новый Kubernetes object на каждый model/tool step.

Эта декомпозиция важна при incident. Pod Pending обычно указывает на placement/resource/ runtime integration. Pod Ready, Actor not ready указывает на Substrate lifecycle или ошибочную probe. Actor ready, Task stuck переводит расследование в AX, harness, model или tool layer. Без границ команда лечит каждую проблему перезапуском Pods и теряет исходную причину.

Диагностический маршрут: от intent к процессу

- Найдите владельца.** Определите namespace, kind, name, labels и owner references. Не начинайте с произвольного Pod, если им управляет Deployment или DaemonSet.
- Сравните spec и status.** Проверьте replica counts, conditions, generation, selected node, phase и container states.
- Прочитайте Events.** Они часто сразу показывают FailedScheduling, image pull, mount, admission или probe failure. Помните об их ограниченном retention.
- Если Pod Pending,** проверьте requests, unbound PVC, node selectors, affinity, taints/ tolerations, RuntimeClass, quotas и admission.
- Если container Waiting,** смотрите reason: image, configuration, volume, runtime sandbox или backoff.
- Если container перезапускается,** сопоставьте current/previous logs, exit code, signal, OOMKilled, probe и termination events.

7. **Если Pod Ready, но запрос не проходит**, проверьте Service selector, EndpointSlice, port mapping, DNS, NetworkPolicy, TLS и application authorization.
8. **Если node подозрительна**, изучите Node conditions, allocatable/allocated resources, pressure, kubelet/runtime/CNI/CSI signals и соседние Pods.
9. **Свяжите с platform ID**. Kubernetes metadata должны позволять найти AX Task, Actor, Worker и trace, не раскрывая secret data.
10. **Не исправляйте до гипотезы**. Delete Pod может временно скрыть race, OOM или bad rollout и уничтожить evidence.

Минимальный набор read-only команд

```
kubectl get deploy,ds,sts,pod -n ax-system -o wide
kubectl describe pod <pod> -n ax-system
kubectl get events -n ax-system --sort-by=.metadata.creationTimestamp
kubectl logs <pod> -n ax-system -c <container> --previous
kubectl get pod <pod> -n ax-system -o yaml
kubectl get endpointslice -n ax-system -l kubernetes.io/service-name=<service>
kubectl describe node <node>
```

`logs --previous` особенно полезен после restart. `describe` объединяет status и недавние events, но для точной automation лучше читать structured fields через API. Доступ к debug shell, ephemeral containers и node logs должен быть отдельной привилегией и аудироваться.

Практика: разместить hostile build pool

Представим, что AX исполняет tests из недоверенных pull requests. Из главы 8 известно, что обычный process или default container недостаточен. Теперь нужно выразить platform decision в Kubernetes.

1. Выделите nodes или node pool с поддерживаемым sandbox runtime; добавьте проверяемые labels и taint.
2. Создайте RuntimeClass для gVisor или microVM-backed handler. Укажите scheduling constraints и overhead, если integration это поддерживает.
3. Разрешите этот RuntimeClass только trusted controller через admission policy; пользовательский manifest не должен выбирать более слабый handler.
4. Задайте requests/limits для CPU, memory и ephemeral storage; PID budget обеспечьте настройкой runtime/kubelet, а namespace ограничьте ResourceQuota.
5. Отключите service account token, host namespaces, privileged mode и broad capabilities. Не монтируйте runtime socket.
6. Примените default-deny ingress/egress и точечные разрешения к dependency mirror, artifact store и control endpoint.
7. Workspace сделайте ephemeral и task-scoped; artifacts публикуйте через отдельный scoped identity.
8. Добавьте startup/readiness для worker supervisor и graceful termination, который перестаёт принимать Tasks и завершает или checkpoint активную работу.

9. Проверьте negative cases: host access, metadata, lateral traffic, token absence, resource storm, node drain и forced termination.
10. Измерьте queue time, scheduling latency, sandbox start, image pull, execution и cleanup отдельно.

Результат - не просто «Pod запущен». Готовый contract утверждает, какой runtime применён, на каких nodes, с какими ресурсами и network policy, какой Task размещён, что произойдёт при drain и какие доказательства сохраняются в audit.

Типичные антипаттерны

Running means ready. Phase Pod принимают за готовность application и направляют traffic слишком рано.

Liveness checks every dependency. Краткая проблема внешней системы запускает restart storm.

No requests, generous limits. Scheduler не получает честной модели demand, а node становится непредсказуемой под нагрузкой.

Namespace equals sandbox. Логическое разделение имён ошибочно принимают за boundary против hostile code.

Secret equals vault. Base64, broad RBAC и mounted long-lived token оставляют прямой путь к credential theft.

One Task, one CRD. Высокочастотный application state перекладывают в etcd и watch infrastructure.

Delete until green. Перезапуск уничтожает evidence и маскирует race, leak или неверный capacity model.

Latest image tag. Rollout становится невозпроизводимым, а rollback не гарантирует прежний content.

Service proves connectivity. Создание Service принимают за доказательство endpoints, route, TLS и authorization.

RuntimeClass as user input. Недоверенный workload сам выбирает более дешёвую и слабую isolation boundary.

Checklist перед эксплуатацией AX/Substrate в Kubernetes

1. Какие components являются Deployment, DaemonSet, StatefulSet или внешним managed service и почему?
2. Какие labels и owner references связывают Task, Actor, Worker, Pod и node?

3. Что хранится в Kubernetes API, а что в Redis, PostgreSQL, object store и telemetry backend?
4. Есть ли у status понятные conditions и связь с последней generation?
5. Заданы ли реалистичные requests, limits, quotas и Pod overhead?
6. Как workload попадает на нужный runtime/node pool и кто имеет право выбрать RuntimeClass?
7. Разнесены ли replicas по failure domains?
8. Что именно проверяют startup, readiness и liveness?
9. Как проходит graceful termination при rollout, drain и scale-down?
10. Какие данные исчезают вместе с Pod, а какие восстанавливаются после потери node?
11. Поддерживает ли CNI применяемые NetworkPolicy и проверен ли default-deny?
12. Отключён ли service account token там, где Kubernetes API не нужен?
13. Ограничены ли RBAC, Secret access, privileged settings, host mounts и admission exceptions?
14. Есть ли read-only диагностический маршрут и отдельный audited break-glass path?
15. Проверены ли node pressure, OOM, image pull, CNI/CSI failure, drain и control-plane outage?

Итоги главы

- Kubernetes хранит intent и непрерывно reconciles actual state; успешный API response не равен готовому workload.
- API server, scheduler, controllers, kubelet, runtime, CNI и CSI образуют цепочку с разными обязанностями и failure modes.
- `spec` принадлежит intent, `status` отражает observation; conditions должны быть операционно значимыми.
- Pod - группа совместно размещённых containers с общей судьбой, но не VM и не durable identity.
- Deployment, StatefulSet, DaemonSet и Job выбираются по lifecycle semantics, а не по привычке команды.
- Requests управляют scheduling и долей ресурсов; limits задают runtime ceilings; отсутствие честной модели ломает capacity planning.
- Startup, readiness и liveness отвечают на разные вопросы; ошибочная probe способна создать incident.
- Service стабилизирует discovery над меняющимися Pods, а NetworkPolicy требует реального enforcement со стороны network implementation.
- PVC не равен backup, Secret не равен vault, Namespace не равен hostile tenant boundary.
- RuntimeClass связывает workload classification с physical isolation, но выбор должен контролироваться platform policy.
- CRD подходит для декларативного infrastructure resource, а не для потока task events, logs или model tokens.

- Kubernetes владеет cluster execution substrate; Substrate - Actor/Worker runtime; AX - Task orchestration; harness - agent semantics.
- Диагностика идёт от owner/сpec/status через events и container state к network, storage и node, сохраняя evidence.

Дальше. Kubernetes показал, как desired state превращается в Pods и почему observation всегда немного отстаёт от intent. Следующая глава разберёт общие законы control plane и distributed systems: eventual consistency, idempotency, retries, locks, streams и восстановление после частично выполненных операций.

Источники и дальнейшее чтение

- [Kubernetes Components](#) - роли control plane и node components.
- [Objects in Kubernetes](#) - object model, spec, status и record of intent.
- [Controllers](#) - reconciliation и controller pattern.
- [Workloads](#) - Pods и workload resources.
- [Pod Lifecycle](#) - phases, container states, restart и termination.
- [Liveness, Readiness and Startup Probes](#) - semantics probes и предупреждение о cascading failures.
- [Resource Management for Pods and Containers](#) - requests, limits, scheduling и cgroups.
- [Scheduling, Preemption and Eviction](#) - placement constraints и disruptions.
- [RuntimeClass](#) - runtime handler, scheduling и overhead.
- [Services, Load Balancing and Networking](#) - Pod network, Services, EndpointSlices, CNI и NetworkPolicy.
- [Storage](#) - ephemeral и persistent storage abstractions.
- [Service Accounts](#) - workload identity и least-privilege RBAC.
- [Good Practices for Kubernetes Secrets](#) - encryption, access и ограничения base64.
- [Pod Security Admission](#) - enforcement Pod Security Standards.
- [Custom Resources](#) - назначение CRD и рекомендация не использовать Kubernetes API как application data store.
- [AX Core Concepts](#) - Task и declarative API AX.
- [Agent Substrate](#) - Actor/Worker model и Kubernetes-backed runtime.

Control plane и distributed systems: как проектировать операции, которые переживают сбои

Предыдущая глава показала механику Kubernetes reconciliation: как intent проходит через API, scheduler и kubelet до работающего процесса. Но даже если каждый компонент настроен правильно, между ними остаётся сеть, а сеть не даёт контроллеру простой гарантии: «запрос не выполнен» или «запрос выполнен». Иногда единственный честный ответ - **результат неизвестен**.

Именно с этого начинается инженерия control plane. AX и Substrate - самостоятельные распределённые системы поверх Kubernetes. Они принимают intent, сохраняют состояние, запускают длительные операции и наблюдают за результатом. Процесс может завершиться между side effect и записью status; ответ может потеряться; два экземпляра контроллера могут одновременно увидеть одну работу; старое событие может прийти после нового. Надёжность появляется не из одной удачной библиотеки, а из согласованного протокола восстановления.

Как складываются главы 8-10

Глава	Главный вопрос	Инженерное решение
8. Runtime isolation	от чего и насколько сильно изолировать workload?	process, container, gVisor или microVM по threat model
9. Kubernetes	где и как разместить выбранный runtime?	Pod, controller, scheduling, сеть, storage и RuntimeClass
10. Control plane	что произойдёт при retry, delay, restart и частичном side effect?	status, idempotency, operation ID, versioning, deadline и recovery

Эти вопросы нельзя переставить местами. Kubernetes не усиливает слабую isolation boundary, а microVM не делает control-plane operation идемпотентной. Граница безопасности отвечает на вопрос «что сможет повредить скомпрометированный workload». Control plane отвечает на другой вопрос: «сойдётся ли система к правильному состоянию, если любой шаг задержится, повторится или оборвётся посередине».

Что читатель должен унести из главы

После этой главы инженер должен уметь:

- отделить принятие intent от фактической готовности ресурса;

- описать операцию как конечный автомат и reconciliation loop, а не как длинную цепочку RPC;
- выбрать idempotency key, operation ID и место для durable journal;
- понять, когда нужен optimistic concurrency, lock, lease или fencing token;
- настроить retry с deadline, backoff, jitter и retry budget;
- объяснить роли PostgreSQL, Redis Streams и gRPC без идеи «один инструмент решит всё»;
- провести восстановление после неизвестного результата внешнего side effect.

Control plane - не обычный request handler

Обычный HTTP handler часто мыслится линейно: получил запрос, проверил данные, вызвал зависимость, вернул ответ. Для короткой операции в одном процессе этого иногда достаточно. Control plane управляет ресурсами, которые живут дольше одного запроса: Actor, Worker, snapshot, task, route, volume или sandbox. Поэтому полезнее видеть в нём три части:

- **API** принимает intent и выдаёт стабильную identity ресурса или операции;
- **durable state** хранит spec, текущий status, версии и историю значимых переходов;
- **reconciler** многократно сравнивает desired и observed state и делает один безопасный следующий шаг.

Пользователь просит «создать Actor». API может быстро проверить контракт, записать ресурс и ответить `accepted`. Затем отдельный reconciler выбирает Worker, резервирует capacity, создаёт sandbox, восстанавливает snapshot, ждёт readiness и публикует route. Если controller перезапустится после любого шага, новая replica должна продолжить не из памяти умершего процесса, а из durable state и наблюдаемого мира.

Команда, событие, состояние и status - не одно и то же

Сущность	Смысл	Пример	Главный риск
Command	просьба выполнить действие	<code>ResumeActor(A)</code>	может быть доставлена повторно
Event	утверждение о свершившемся факте	<code>SnapshotRestored</code>	может опоздать или прийти не по порядку
Desired state	устойчивый intent владельца	<code>actor.spec.phase = Running</code>	может измениться во время операции
Observed status	последнее подтверждённое наблюдение	<code>Ready=False, reason=Restoring</code>	всегда немного отстаёт от реальности

Если очередь содержит только команды, а durable state отсутствует, после сбоя трудно ответить, что система уже сделала и чего всё ещё хочет пользователь. Если хранить только события, но не определить правила переходов, журнал превращается в поток фактов без

ясного текущего контракта. Практичный control plane обычно сочетает декларативный спес, вычисляемый status и поток работ, который будит reconciler.

Модель частичного отказа: шесть неприятных вариантов

«Сервис упал» - слишком грубое описание. Для проектирования операции полезно перечислить, что именно наблюдает вызывающая сторона.

1. **Задержка.** Ответ ещё не пришёл. Операция может продолжаться штатно.
2. **Потеря ответа.** Side effect выполнен, но клиент увидел timeout. Это состояние unknown, а не failure.
3. **Повтор.** Клиент, брокер или controller доставил ту же команду снова.
4. **Переупорядочивание.** Событие о старой generation пришло после события о новой.
5. **Crash/restart.** Процесс потерял volatile context между двумя durable записями.
6. **Partition и split view.** Компоненты доступны по отдельности, но не могут согласовать актуальное состояние.

К этому добавляются clock skew и паузы процесса. Поэтому wall-clock timestamp не годится как единственный арбитр владения: часы могут расходиться, а holder lease может «замереть» на долгой паузе и вернуться уже после выдачи нового lease. Версия ресурса, monotonic sequence и fencing token обычно надёжнее предположения «у кого время новее, тот прав».

Accepted, ready и completed

Успешный API response отвечает только на вопрос своего уровня. Например, 202 Accepted означает, что intent принят в обработку, но не что Actor уже доступен. Даже синхронный 200 от внутреннего RPC может означать лишь успешную запись в локальную базу. У ресурса полезно различать как минимум:

- **accepted** - intent проверен и durable сохранён;
- **progressing** - система выполняет шаги и знает, что осталось;
- **ready** - ресурс может обслуживать целевой трафик сейчас;
- **completed** - конечная операция завершена и повторять её не требуется;
- **failed** - достигнуто терминальное состояние с понятной причиной;
- **unknown** - свежего подтверждения нет; это не синоним false.

Клиенту нужен resource ID или operation ID, endpoint чтения status и, при необходимости, watch/stream. Таймаут ожидания клиента не должен отменять сам intent по умолчанию: он только прекращает ожидание. Отмена - отдельная команда с собственным статусом и конфликтами.

Conditions, generation и наблюдаемая версия

Одного поля `phase` быстро становится мало. Actor может одновременно быть `Progressing=True`, `Ready=False` и `Degraded=True`. Condition должна не только нести boolean, но и отвечать «почему»: `type`, `status`, `reason`, `message`, время перехода и `generation`, которую оценивал controller.

`observedGeneration` защищает клиента от ложной уверенности. Если spec уже `generation 12`, а `status` вычислен для `generation 11`, зелёный `Ready=True` относится к старому intent. Аналогично, `version/resourceVersion` позволяет controller обнаружить конкурентное изменение и повторить `read-modify-write` вместо молчаливого перетирания данных.

Watch является оптимизацией доставки изменений, а не единственным источником истины. Соединение обрывается, история может быть сокращена, `cursor` устаревает. Надёжный consumer умеет заново выполнить `list/read`, построить актуальный `snapshot` и продолжить `watch` с новой версии.

Reconciliation loop: один безопасный шаг за раз

Reconciler не обязан завершать весь `lifecycle` за один вызов. Напротив, короткий и повторяемый проход проще тестировать и восстанавливать. Его форма примерно такая:

```
reconcile(resource_id):
    desired = store.read_spec(resource_id)
    observed = inspect_runtime(resource_id)

    if desired.generation is older than observed.intent_generation:
        return # устаревшая работа

    next_step = plan(desired, observed)

    if next_step is none:
        update_conditions(resource_id, Ready=True)
        return

    operation_id = stable_id(resource_id, desired.generation, next_step)
    result = execute_idempotently(next_step, operation_id)
    persist_result_and_status(result)
    enqueue_recheck(resource_id)
```

Ключевые слова здесь - **inspect**, **stable_id** и **persist**. Reconciler сначала выясняет наблюдаемую реальность, затем связывает действие со стабильной `identity` и только после этого обновляет `status`. Если шаг долгий, его лучше представить отдельной `operation record` со своим `lifecycle`, а не держать `lock` и `RPC connection` несколько минут.

Удаление тоже требует reconciliation

Удалить строку из API store легко, но тогда исчезает место, где отмечено, что надо удалить `sandbox`, `route`, `snapshot lease` и `external credential`. Поэтому `deletion` обычно двухфазный: пользователь ставит `deletion intent`, `finalizer` удерживает ресурс, controller освобождает зави-

симые объекты и лишь затем удаляет finalizer. Finalizer не делает cleanup безошибочным; он делает обязанность cleanup видимой и повторяемой.

Для каждого finalizer нужен аварийный runbook. Если внешняя система недоступна навсегда, ресурс может зависнуть в terminating. Ручное снятие finalizer допустимо только после понимания, какие orphaned resources и расходы останутся.

Idempotency: повтор не должен умножать эффект

Идемпотентная операция при повторе имеет тот же *intended effect*, что и один вызов. Это не означает, что ответ, latency или audit log будут одинаковыми. `EnsureActorRunning(A)` естественно ближе к идемпотентности, чем `CreateAnotherActor()`. Хороший API формулирует intent через стабильную identity: «обеспечь Actor A в состоянии Running», а не «ещё раз запусти что-нибудь».

Для команды с side effect клиент генерирует idempotency key или operation ID и повторяет запрос с тем же ключом. Сервер атомарно связывает ключ с fingerprint запроса и результатом:

- тот же ключ и тот же payload возвращают прежний result или текущий status;
- тот же ключ и другой payload дают conflict, а не новую операцию;
- новый ключ означает новый намеренный effect.

Запись deduplication должна жить не меньше максимального окна повторов. Если сервер забывает ключ через час, а очередь может повторить сообщение через сутки, гарантия исчезает. Полезны unique constraint на `(tenant_id, operation_id)` и сохранённый request hash. Проверка «сначала SELECT, потом INSERT» без транзакции оставляет race; уникальность должна обеспечиваться storage.

Миф об exactly-once

В распределённой системе нельзя просто объявить «exactly once» между независимыми хранилищами и внешним миром. Если controller выполнил side effect, но упал до записи `done`, следующий процесс видит незавершённую запись и не знает, повторять ли действие. Практическая стратегия обычно состоит из:

- at-least-once delivery;
- idempotent consumer или deduplication key;
- durable operation journal;
- запроса фактического состояния внешней системы;
- компенсирующего действия, когда истинная атомарность невозможна.

Даже «exactly-once processing» конкретного брокера не распространяется автоматически на email, cloud API, платёжный шлюз или файловую систему. Всегда спрашивайте: exactly once в какой границе и относительно какого durable state?

Retry - управляемая нагрузка, а не рефлекс

Retry полезен только при временной ошибке и безопасной повторяемости. Он опасен при validation error, permanent permission denial и неизвестной семантике side effect. Перед включением автоматического retry операция должна ответить на четыре вопроса:

- 1. Есть ли общий deadline, после которого результат уже не нужен?
- 2. Какие коды действительно transient для этого метода?
- 3. Безопасен ли повтор или есть устойчивый idempotency key?
- 4. Сколько дополнительной нагрузки допустимо создать во время инцидента?

Exponential backoff разводит повторы во времени, jitter не даёт тысячам клиентов проснуться одновременно, attempt limit ограничивает один запрос, а retry budget ограничивает систему целиком. Без budget деградация зависимости вызывает retry storm: каждый timeout создаёт несколько новых вызовов, очередь растёт, latency увеличивается и порождает ещё больше timeout.

Deadline и cancellation

Deadline должен передаваться по цепочке как оставшийся budget, а не обнуляться на каждом hop. Иначе три сервиса с локальным timeout по 30 секунд превращают пользовательский deadline в полторы минуты. Компонент, получивший cancellation, должен прекратить бессмысленную работу, но это не откатывает уже совершённый side effect. Cancellation - сигнал управления вычислением, не распределённая транзакция.

Код UNAVAILABLE может быть retryable, но только если method semantics позволяют. DEADLINE_EXCEEDED также не доказывает, что сервер ничего не сделал. Для non-idempotent метода эти статусы переводят результат в unknown и запускают проверку по operation ID.

Конкуренция: version, lock, lease и fencing

Несколько replicas полезны для availability, но они могут одновременно прочитать один status. Универсального «distributed lock» нет; сначала выбирается тип конфликта.

Механизм	Когда подходит	Что не гарантирует
Optimistic concurrency	короткое read-modify-write, конфликты редки	не удерживает владение во время долгого side effect
Row/advisory lock в БД	координация внутри одной database boundary	не блокирует внешний API после commit или потери сессии
Lease	временное лидерство или assignment с renewal	старый holder может продолжить работу после expiry
Fencing token	защита downstream от устаревшего holder	работает только если downstream сравнивает token

Fencing token - монотонно растущий номер владения. Каждый новый holder получает большее значение; storage или Worker отвергает команды со старым token. Это закрывает опасный сценарий: controller A завис, его lease истёк, controller B получил ресурс, а A «ожил» и попытался записать старый результат.

Lock не заменяет idempotency. Holder может выполнить внешний side effect и умереть до фиксации результата. После expiry новый holder повторит операцию. Поэтому lock уменьшает параллелизм, а operation ID и recovery protocol отвечают за корректность повторов.

Redis Streams: очередь работ с явным подтверждением

Redis Streams полезен, когда control plane нужен упорядоченный log сообщений и распределение работы по consumer group. Consumer читает запись, она попадает в Pending Entries List (PEL), а после успешной обработки consumer отправляет `XACK`. Если consumer умер до `ack`, запись остаётся pending и может быть изучена через `Xpending` и передана другому consumer через `XCLAIM` или `XAUTOCCLAIM`.

Это естественно даёт at-least-once processing: сообщение может быть обработано, но `ack` потерян, после чего оно будет обработано снова. Следовательно, handler всё равно обязан быть идемпотентным. Для production важны не только длина stream, но и:

- возраст самой старой pending записи;
- delivery count и число повторных claims;
- lag consumer group;
- consumers, которые давно не подают признаков жизни;
- политика poison message и dead-letter stream;
- retention/trim, не удаляющий нужную для recovery историю.

Poison message нельзя бесконечно гонять между consumers. После ограниченного числа попыток запись переносится в quarantine/dead-letter path вместе с причиной, payload reference и operation ID. Оператор должен иметь безопасный способ исправить данные и переиграть сообщение, не создавая новую identity операции.

Очередь будит reconciler, но не владеет истиной

Stream хорошо доставляет сигнал «ресурс нужно проверить». Однако durable spec/status обычно остаётся в system of record. Если сообщение потерялось или было trim'нуто, периодический resync всё равно должен найти незавершённый ресурс. Если одно сообщение пришло десять раз, каждый проход читает свежую версию ресурса и быстро понимает, нужен ли следующий шаг.

PostgreSQL: транзакционная граница и source of truth

PostgreSQL подходит для resource records, operation journal, unique constraints и атомарных переходов между связанными строками. Row lock защищает конкурирующее обновление; advisory lock удобен для application-defined identity, но его область и lifetime нужно выбрать осознанно. Session-level advisory lock переживает rollback и требует явного release или завершения session; transaction-level освобождается на commit/rollback.

Транзакция PostgreSQL не охватывает Redis, object store и внешний cloud API. Если в одной функции записать БД, а затем отправить событие, процесс может умереть между шагами. Outbox pattern решает локальную часть задачи: изменение domain state и запись события в outbox совершаются одной транзакцией; отдельный publisher доставляет outbox в stream и помечает публикацию. Доставка всё равно может повториться, поэтому consumer сохраняет deduplication.

Redis и PostgreSQL в одной архитектуре

Задача	Предпочтительный центр	Почему
durable resource state и инварианты	PostgreSQL	transactions, constraints, versioned updates
быстрая доставка работы и fan-out	Redis Streams	consumer groups, pending tracking, низкая latency
snapshot blob	object storage	размер, lifecycle policy, дешёвое долговременное хранение
cluster workload placement	Kubernetes API	scheduler/controllers и node-level execution

Это не строгий закон, а полезная граница ответственности. В текущем контексте AX использует Redis в task control-plane path, а Substrate хранит dynamic Actor/Worker state в PostgreSQL. Их backup, retention и failure domain различаются. Восстановление только Redis не восстанавливает состояние Substrate; восстановление PostgreSQL не доказывает, что AX stream и desired tasks согласованы. Нужен runbook сквозной сверки.

gRPC/protobuf: контракт, время и давление потока

Protobuf задаёт typed schema, а gRPC - transport contract. Совместимость требует дисциплины: не переиспользовать удалённые field numbers, резервировать их, добавлять поля как optional/evolvable и не рассчитывать, что все компоненты обновятся одновременно. Новый сервер должен корректно принимать старого клиента, а rollout должен учитывать mixed versions.

Для каждого метода проектируются:

- deadline и propagation оставшегося budget;
- idempotency и допустимые retryable status codes;
- максимальный размер message и способ передачи больших blobs по reference;
- TLS/mTLS, identity и authorization;
- limits на concurrent streams;
- flow control и backpressure;
- observability по method, code, latency и attempt.

Streaming не отменяет backpressure. Если producer пишет быстрее, чем consumer читает и downstream подтверждает работу, buffers растут до memory pressure или cancellation. Flow control ограничивает объём данных в полёте, но application всё равно должно ограничивать собственную очередь и не держать lock во время медленной отправки.

Внешний side effect: сначала журнал, потом действие

Самая трудная граница - система, которую нельзя включить в локальную транзакцию. Перед вызовом создаётся durable operation record:

```
operation_id: actor-42/gen-7/publish-route
kind: PublishRoute
request_fingerprint: sha256(...)
state: Planned
attempt: 0
external_id: null
last_error: null
```

Затем controller вызывает внешний API с operation ID как idempotency key, если API это поддерживает, и сохраняет внешний ID. После timeout он не создаёт «ещё один route», а сначала ищет существующий объект по idempotency key, tag или external ID. Если внешний API не поддерживает поиск и deduplication, нужно честно выбрать один из плохих вариантов: риск duplicate, ручная сверка или compensating cleanup.

State machine операции может выглядеть так: `Planned -> InFlight -> Confirmed`, а при неопределённости - `Unknown -> Verifying`. Состояние `Failed` допустимо только когда известно, что effect не произошёл или корректно компенсирован. Timeout сам по себе не даёт этого знания.

Практический инцидент: Actor создан, ответ потерян

Рассмотрим последовательность, которая в happy-path тесте почти не видна:

1. AX создаёт operation `op-73` для Actor `A` generation 4.
2. Substrate принимает запрос и durable создаёт Actor.
3. Сеть рвётся до ответа. AX видит `deadline exceeded`.
4. AX повторяет запрос с тем же `op-73`.
5. Substrate находит прежнюю operation record и возвращает identity существующего Actor, а не создаёт второго.
6. Controller AX читает status: Actor существует, но ещё `Ready=False`.
7. Через watch или повторную проверку приходит `Ready=True` для generation 4.
8. AX отмечает свой шаг `confirmed` и продолжает task lifecycle.

Если повтор отправлен с новым operation ID, сервер не может отличить intentional second Actor от retry. Если AX после timeout сразу пишет `Failed`, оператор получит ложный failure при реально созданном ресурсе. Если status не содержит generation, поздний ответ от generation 3 может ошибочно завершить generation 4. Одна короткая авария проявляет необходимость почти всех механизмов главы.

Наблюдаемость: видеть протокол, а не только процессы

CPU и memory важны, но они не объясняют, где застряла операция. Logs, traces и metrics должны связываться полями:

- tenant, resource ID, generation и operation ID;
- controller instance, lease/fencing token и attempt;
- queue/stream, message ID, pending age и delivery count;
- RPC service/method, status code, deadline и remaining budget;
- предыдущий и новый status, reason перехода;
- external system и external object ID;
- duration каждого шага и время с момента принятия intent.

Полезные SLO строятся вокруг пользовательского результата: time-to-accepted, time-to-ready, доля операций в unknown, возраст старейшей незавершённой operation, reconciliation lag. Метрика «controller process up» ничего не говорит о том, сходится ли desired state.

Operation ID должен проходить через AX, Substrate, Kubernetes events и внешние вызовы настолько далеко, насколько это безопасно. Но trace ID не заменяет business identity: sampling может удалить trace, а operation record обязана пережить рестарт и retention observability stack.

Проверка отказоустойчивости

Unit test happy path не доказывает корректность recovery. Нужны тесты на точки разрыва:

- crash после side effect, но до status update;
- crash после записи outbox, но до публикации;
- потеря ack и повторная доставка stream message;
- два reconciler одновременно читают одну version;
- lease истекает во время долгого RPC, старый holder возвращается;
- ответы generation N приходят после N+1;
- watch cursor устарел и требует полного resync;
- внешний API отвечает timeout, хотя объект создан;
- poison message превышает attempt limit;
- object store доступен, а database нет, и наоборот.

Fault injection должен проверять инварианты, а не только отсутствие panic. Например: на один operation ID существует не более одного внешнего объекта; Ready никогда не относится к старой generation; stale fencing token не меняет Worker; удаляемый API resource не исчезает до завершения finalizer cleanup.

Антипаттерны, которые выглядят проще

- **«У нас internal network, timeout не нужен».** Зависший RPC постепенно занимает все workers.
- **«Повторим любой 5xx».** Код ошибки не доказывает безопасность повторного side effect.
- **«Redis Stream гарантирует exactly once».** Потерянный ack закономерно создаёт повторную обработку.
- **«Возьмём lock на всю операцию».** Долгий lock снижает availability и всё равно не откатывает внешний effect.
- **«Status обновим в конце».** После crash не видно, какой шаг выполнялся и что проверять.
- **«Очередь и есть наша база».** Retention, trim и порядок delivery редко выражают все resource invariants.
- **«Timeout означает, что ничего не произошло».** Это одна из самых дорогих ошибок в control plane.
- **«Удалим запись, cleanup сделаем потом».** После удаления теряется durable обязанность освободить зависимые ресурсы.

Практический чек-лист новой control-plane операции

1. Какой durable intent и какая стабильная resource identity?
2. Что означает API success: accepted, ready или completed?
3. Как клиент узнаёт status и к какой generation он относится?
4. Как формируется operation ID и сколько хранится deduplication record?
5. Какие шаги идемпотентны, а какие требуют journal или compensation?
6. Что происходит при crash до и после каждого side effect?
7. Какие ошибки retryable, каковы deadline, backoff, jitter и budget?
8. Как разрешается concurrent update: version, transaction, lease, fencing?
9. Где source of truth, где stream, где blob и где cluster state?
10. Как обрабатываются pending, poison и устаревшие сообщения?
11. Какие IDs связывают logs, traces, metrics и external resources?
12. Как выглядят resync, deletion и ручное аварийное восстановление?

Итог связки

- Глава 8 выбирает physical security boundary по threat model.
- Глава 9 выражает placement, resources, identity, network и lifecycle в Kubernetes.
- Глава 10 превращает операции над этими ресурсами в повторяемый протокол восстановления.
- Надёжный control plane не обещает отсутствие сбоев. Он хранит достаточно identity и state, чтобы после сбоя понять, что произошло, и безопасно продолжить.
- Ни один слой не компенсирует автоматически ошибку другого: сильный sandbox не исправляет duplicate side effect, а идемпотентный reconciler не делает privileged container безопасным.

Дальше. Теперь у нас есть physical boundary, orchestration substrate и правила поведения control plane при отказах. Следующая глава вводит Actor model - способ отделить логически долгоживущую identity агента от конкретного Worker, Pod и периода активного выполнения. На этой базе слова suspend, resume, placement и snapshot перестают быть набором API методов и складываются в lifecycle одной сущности.

Источники и дальнейшее чтение

- [RFC 9110: HTTP Semantics](#) - определение idempotent methods и ограничения автоматического retry.
- [Kubernetes Controllers](#) - reconciliation как управление desired и current state.
- [Kubernetes API Concepts](#) - resourceVersion, list/watch и восстановление после устаревшего cursor.
- [Kubernetes Finalizers](#) - двухфазное удаление и cleanup.
- [Redis Streams](#) - consumer groups, PEL, XACK, XPENDING и claim pending entries.
- [PostgreSQL Explicit Locking](#) - row, table и advisory locks.
- [gRPC Deadlines, Cancellation, Retry](#) и [Flow Control](#) - временной budget, retry policy и backpressure.
- [AX Core Concepts](#) - Task и declarative control-plane model AX.
- [Agent Substrate](#) - Actor/Worker runtime и current project documentation.

Actor model для агентных workload: identity, state и lifecycle

В конце предыдущей главы мы пришли к устойчивой identity, operation ID и reconciliation. Actor model отвечает на следующий вопрос: **вокруг какой сущности собрать состояние и последовательность решений, если физический процесс может исчезать и появляться снова?**

Для агента такой сущностью часто становится разговор, рабочая сессия, пользовательский помощник или автономный исполнитель. Он живёт логически дольше одного HTTP-запроса и дольше одного Pod. Но слово *Actor* перегружено: в классической модели это вычислительная сущность с mailbox; в virtual actor runtime - логическая identity с управляемой activation; в Agent Substrate - stateful workload, который можно suspend и resume на разных Workers. Эти идеи родственны, но не взаимозаменяемы.

Если не провести границу, легко приписать платформе несуществующие гарантии: решить, что Substrate автоматически сериализует сообщения, что snapshot является очередью, а Actor обязательно имеет supervision tree. Эта глава сначала разбирает исходную модель, затем virtual actors и только после этого показывает, что именно переносится в инфраструктуру AX/Substrate.

Что читатель должен унести из главы

После этой главы инженер должен уметь:

- объяснить Actor через identity, private state, behavior и messages, а не через «маленький сервис»;
- отличить logical Actor от activation, process, Worker и Pod;
- выбрать правильную границу Actor для agent session или автономной задачи;
- понять, какие гарантии даёт mailbox и какие приходится строить отдельно;
- спроектировать suspend/resume без потери in-flight work и внешних side effects;
- увидеть hot Actor, unbounded queue, reentrancy и snapshot coupling до production;
- решить, когда Actor model упрощает систему, а когда становится лишним слоем.

Три значения слова Actor

Контекст	Что называется Actor	Что обычно предоставляет runtime
Классическая actor model	identity + private state + behavior + mailbox	message dispatch, turns, references, lifecycle, иногда supervision

Контекст	Что называется Actor	Что обычно предоставляет runtime
Virtual actor	логическая сущность, адресуемая даже без активного процесса	activation/deactivation, placement, directory, persistence hooks
Agent Substrate	экземпляр stateful sandboxed workload	Worker assignment, routing, memory/disk snapshot, suspend/resume

Общий мотив - отделить **кто это** от **где он сейчас выполняется**. Различие - уровень абстракции. Классический Actor определяет программную модель обработки сообщений. Substrate управляет целым окружением процесса. Внутри Substrate Actor может работать приложение на Python, Go или Rust, и оно не становится классическим message actor автоматически.

Классическая модель: маленький владелец состояния

Actor model появилась как способ рассуждать о конкурентных вычислениях без общего изменяемого состояния. Actor получает сообщение и в ответ может:

1. отправить конечное число сообщений известным ему Actors;
2. создать новые Actors;
3. выбрать behavior для обработки следующего сообщения.

Полезная бытовая аналогия - отдельный кабинет с одним ответственным сотрудником. Снаружи нельзя открыть его ящики и поправить документы. Можно только положить запрос во входящую корзину. Сотрудник разбирает запрос, изменяет свои записи и отправляет новые поручения. Адрес кабинета остаётся известным, даже если конкретного сотрудника временно заменили.

Identity и Actor reference

Внешний код обращается не к объекту в памяти, а к reference или logical address. Эта indirection позволяет переместить activation, перезапустить процесс или восстановить state, не раздавая всем новый физический адрес. Ссылка отвечает на вопрос «какому Actor предназначено сообщение», но не обязана раскрывать host, thread или текущий lifecycle state.

Для agent platform identity должна переживать restart. Хороший ключ выводится из domain boundary: `tenant/session`, `workspace/agent` или `job/executor`. IP, Pod name и process ID для этого не подходят: это адреса временного воплощения.

Private state и behavior

Actor владеет своим изменяемым state. Другие Actors не читают его напрямую, а запрашивают операцию сообщением. Благодаря этому инварианты сосредоточены в одном месте. Например, Session Actor может гарантировать, что номер следующего шага монотонно растёт и одновременно существует не более одного active tool call.

Behavior - функция реакции на сообщение в текущем состоянии. Один и тот же `SubmitInput` может приниматься в состоянии `WaitingForUser`, отклоняться в `RunningTool` и превращаться в no-op после `Completed`. Поэтому protocol Actor удобнее описывать как state machine, а не как набор не связанных RPC methods.

Mailbox: очередь не равна гарантии

Mailbox отделяет отправителя от получателя во времени. Отправитель помещает сообщение и не получает право войти во внутренний state Actor. Многие реализации обрабатывают по одному message turn на Actor, что уменьшает потребность в locks.

Но слово mailbox ничего не обещает само по себе. Нужно отдельно выяснить:

- очередь in-memory или durable;
- она bounded или может расти до исчерпания памяти;
- каков порядок для разных senders;
- что происходит при restart, relocation и termination;
- какая delivery semantics: at-most-once или at-least-once;
- есть ли acknowledgement на уровне бизнес-результата.


Например, Akka core по умолчанию формулирует базовую гарантию как at-most-once delivery и ordering для пары sender-receiver. Усиление до retry требует message ID, acknowledgement и deduplication. Это тот же вывод, к которому мы пришли в главе 10: transport не может придумать бизнес-значение «успешно обработано».

Один turn за раз - не магическая защита

Последовательная обработка упрощает state, но не делает систему полностью свободной от concurrency. Пока Actor ждёт внешний API, runtime может запрещать interleaving, тогда длинный вызов блокирует mailbox. Либо runtime разрешает reentrancy, тогда continuation одного запроса может выполняться после части другого, и инварианты снова требуют внимания.

Показательный пример: Actor прочитал `balance=100`, ушёл в `await`, другой turn изменил `balance` до 40, а первый продолжил работу с устаревшим предположением. «Один thread» не спасает, если turns перемежаются. Правило простое: после `await` нужно заново проверить state/version или явно запретить interleaving для критического protocol.

Actor ≠ Worker: logical population can be larger than active capacity



Actor, activation, Worker и Pod

Сущность	Срок жизни	Что в ней устойчиво	Можно заменить без смены Actor identity?
Actor	domain lifecycle	logical ID и lineage state	нет, это сама identity
Activation	период активного выполнения	in-memory embodiment	да
Worker	период доступной capacity	sandbox slot/runtime environment	да
Pod	Kubernetes workload lifecycle	контейнеры и network namespace	да

Главная мысль рисунка: logical population может быть намного больше active capacity. Тысяча зарегистрированных agent sessions не требует тысячу постоянно работающих Pods, если одновременно активны только десятки. Runtime держит warm Workers, а Actors получают физическое воплощение по требованию.

Virtual actor: identity существует дольше activation

Классическая модель обычно заставляет явно создавать и останавливать Actors. Virtual actor runtime делает ещё один шаг: logical Actor считается всегда адресуемым, а runtime сам создаёт activation при обращении и удаляет её после периода бездействия. В Orleans такая сущность называется grain: у неё есть user-defined key, behavior и state, а runtime отвечает за placement, location и activation lifecycle.

Это похоже на виртуальную память. Программа обращается к логическому адресу, не решая, находится ли нужная страница сейчас в RAM. Клиент обращается к logical Actor ID, не решая, на каком host живёт activation и существует ли она в памяти прямо сейчас.

Directory и location transparency

Чтобы reference оставалась стабильной, runtime нужен directory: отображение Actor ID -> current activation location. При activation запись создаётся, при relocation меняется, при failure восстанавливается. Directory находится на критическом пути и определяет, насколько строго система предотвращает две одновременные activations одной identity.

Абсолютная location transparency удобна, но не отменяет физику. Remote call медленнее local call, serialization имеет цену, partition существует, а state может быть расположен далеко. Программный интерфейс может скрывать адрес, но observability и placement policy должны видеть topology.

Activation и deactivation

Activation - временное воплощение Actor на вычислительном узле. При первом обращении runtime загружает state, создаёт instance и направляет туда сообщения. После idle period activation можно убрать из памяти. Следующий вызов снова активирует ту же logical identity, возможно на другом узле.

Deactivation не должна восприниматься как domain deletion. Пользовательская сессия всё ещё существует; исчезает только её горячее представление. И наоборот, удаление Actor требует отдельного решения о retention, audit и dependent resources.

Что именно является Actor в Agent Substrate

Agent Substrate переносит идею virtual identity на более низкий уровень. Его Actor - это не объект класса внутри runtime, а экземпляр sandboxed application environment, связанный с ActorTemplate и snapshot lineage. Когда Actor активен, он назначен Worker и имеет работающие процессы. Когда suspended, durable snapshot остаётся, а Worker освобождается.

Текущая архитектура описывает следующий путь:

1. создаётся Actor record со стабильной identity и ссылкой на ActorTemplate;

2. первоначально Actor может находиться в suspended state и ссылаться на golden snapshot;
3. входящий запрос или явный вызов инициирует resume;
4. control plane атомарно выбирает свободный Worker;
5. node-side компоненты восстанавливают memory и disk state в sandbox;
6. routing layer направляет запрос на текущий Worker;
7. при suspend создаётся новый snapshot, assignment освобождается, Worker возвращается в pool.

Это очень похоже на virtual actor activation, но есть принципиальная оговорка: Substrate управляет **жизнью окружения**, а не обязательно mailbox и turn scheduling приложения внутри. Если HTTP server внутри Actor одновременно принимает 50 requests, Substrate сам по себе не превращает их в 50 последовательных turns.

Что Substrate даёт, а что остаётся приложению

Задача	Substrate/runtime layer	Agent application layer
stable Actor identity	resource ID и control-plane record	domain mapping session/user/job
physical placement	Worker assignment и routing	не должен хранить Worker IP как identity
state capture	memory + writable disk snapshot	quiescence и consistency внешних данных
request concurrency	transport до workload	mailbox, locks, turn model или собственный scheduler
business retry	может восстановить workload	idempotency, operation journal, deduplication
failure policy	crash detection, revert/resume primitives	что повторить, отменить, компенсировать или показать человеку

Эта таблица не обесценивает runtime. Наоборот, она делает контракт честным. Substrate решает тяжёлую инфраструктурную задачу - быстрое физическое воплощение stateful workload. Приложение решает semantic задачу - какой запрос можно выполнять, в каком порядке и что считать завершением.

Как выбрать границу Actor для агента

Actor должен владеть набором state и инвариантов, которые естественно изменяются последовательно. Слишком крупная граница создаёт hot spot; слишком мелкая превращает простое решение в распределённую транзакцию.

Кандидат	Когда хорош	Главный риск
один Actor на user	персональный assistant с единым долгим контекстом	все сессии пользователя конкурируют за один Actor
один Actor на conversation/session	диалоги изолированы и имеют собственную memory	общие user preferences требуют отдельного store
один Actor на task	автономная работа с ясным началом и завершением	много коротких Actors и дорогая activation
один Actor на workspace/project	общий mutable environment и files	hot key, длинный mailbox, большая snapshot
Actor на tool/resource	нужно сериализовать доступ к конкретному устройству или account	cross-actor workflow и возможные циклы ожидания

Практический тест границы:

- можно ли сформулировать один набор инвариантов, которым владеет Actor;
- можно ли обрабатывать большинство операций без синхронного вызова другого Actor;
- помещается ли working set в разумный snapshot и activation budget;
- есть ли естественная стабильная identity;
- допустима ли последовательная пропускная способность одной activation;
- понятно ли, когда Actor idle, suspended и deleted.

Пример: conversation Actor

Пусть Actor представляет одну беседу. Он владеет текущим plan, краткой memory, списком разрешённых tools, последним подтверждённым step и ссылками на artifacts. Команды могут выглядеть так:

```
UserMessage(text, request_id)
ToolResult(call_id, payload_ref)
Approve(step_id, approver)
Cancel(reason, request_id)
IdleTimeout(generation)
```

Behavior зависит от state: `WaitingForUser`, `Planning`, `WaitingForTool`, `WaitingForApproval`, `Completed`. `request_id` делает повтор безопасным, а `step_id` не позволяет позднему approval подтвердить уже заменённый plan. Большие tool outputs хранятся по reference, чтобы не раздувать mailbox и snapshot.

State: что именно должно пережить activation

У агента нет одного монолитного «состояния». Полезно разделить как минимум четыре слоя:

1. **Definition state.** Image, dependencies, sandbox policy и resources из ActorTemplate. Это версия кода и окружения.
2. **Execution state.** RAM, stack, локальные процессы и writable filesystem, которые может захватить snapshot.
3. **Domain state.** Conversation history, approvals, operation journal, artifact metadata. Часто ему лучше жить в явной durable schema.
4. **External state.** Объекты в SaaS, cloud, GitHub, email или payment system. Snapshot ими не владеет.

Snapshot особенно удобен для сложного execution state: прогретая model library, interpreter, process tree, cache, локальный checkout. Но snapshot не заменяет domain model. Через месяц инженер должен уметь узнать, почему задача ждёт approval, не поднимая старую память процесса и не исследуя heap.

Snapshot - не распределённая транзакция

Представим, что agent отправил внешний запрос, получил success, но ещё не записал его в локальный journal. Snapshot в этот момент сохранит неполную картину. После resume agent может повторить side effect. Обратный сценарий тоже возможен: journal говорит *in-flight*, а сетевой ответ уже потерян.

Поэтому перед suspend приложение должно перейти в согласованную точку:

- перестать принимать новую работу или пометить её для следующей activation;
- дождаться безопасных *in-flight turns* либо явно их отменить;
- сбросить buffers и durable записать operation state;
- закрыть или подготовить к пересозданию connections;
- зафиксировать snapshot generation/version;
- только затем разрешить platform checkpoint.

Для операций, которые нельзя спокойно остановить, Actor должен оставаться running или использовать protocol, способный продолжить работу после неизвестного результата. Freeze процесса не превращает внешний мир в часть checkpoint.

Что обычно не переживает resume

После relocation нельзя рассчитывать на прежний IP, TCP connection, PID namespace, kernel timer или mounted credential lifetime. DNS caches, OAuth tokens и database pools могут протухнуть, а remote peer уже закрыл connection. Хороший workload имеет resume hook или lazy reinitialization:

```
on_resume(snapshot_generation):
    refresh_identity_if_needed()
    recreate_network_pools()
    validate_external_leases()
    recheck_inflight_operations()
    publish_ready_only_after_validation()
```

Readiness после restore должна означать не «процесс разморожен», а «application dependencies проверены и новые requests безопасны».

Concurrency: где действительно выполняется сериализация

Actor model часто выбирают, чтобы избежать fine-grained locks. Это работает только при явном месте сериализации. Возможны три варианта:

- **Runtime mailbox.** Framework выдаёт приложению один message turn за раз.
- **Application queue.** HTTP/gRPC handlers складывают команды во внутренний bounded channel, который читает один state owner.
- **Storage serialization.** Несколько handlers работают параллельно, но обновляют state через version/transaction.

Substrate Actor совместим со всеми тремя, но не выбирает вариант за приложение. Если agent server многопоточный, snapshot одного sandbox не означает single-threaded semantics. Архитектурная документация должна прямо назвать owner state и точку сериализации.

Reentrancy, cycles и deadlock

Два Actors могут синхронно вызвать друг друга и оба ждать ответа. При строгой обработке «запрос до конца» получается deadlock. Reentrancy позволяет обработать новый turn во время await, но возвращает риск логической гонки. Часто безопаснее изменить protocol:

- использовать asynchronous reply message вместо вложенного blocking call;
- разбить долгую операцию на state transitions;
- хранить correlation ID и продолжать после отдельного result message;
- не строить циклические цепочки синхронных Actor calls;
- после каждого await валидировать generation и current state.

Delivery semantics и protocol messages

Actor reference создаёт удобную адресацию, но сообщение остаётся распределённой операцией. Оно может потеряться до mailbox, обработаться до потери reply или повториться из-за retry. Поэтому protocol проектируется так же строго, как control-plane API:

- command имеет message ID и expected generation;

- receiver сохраняет deduplication record или делает effect идемпотентным;
- business acknowledgement сообщает не «байты дошли», а «переход state выполнен»;
- deadline ограничивает ожидание sender;
- late reply проверяется по correlation ID и current state;
- dead letters служат диагностике, а не гарантии доставки.

Ordering обычно гарантируется только в узкой границе. Даже если сообщения одного sender приходят по порядку, сообщения от разных senders могут перемежаться. Посредник, retry или relocation также меняют наблюдаемую последовательность. Если порядок важен, protocol несёт sequence/generation и отклоняет stale message.

Supervision: восстановить процесс недостаточно

В Erlang/OTP и Akka Actor hierarchy связывает child lifecycle с supervisor strategy. Supervisor решает, перезапускать ли один child, зависимую группу или останавливать ветку. Это воплощает принцип «let it crash» только при важном условии: state можно безопасно пересоздать или восстановить.

На agent platform существует несколько уровней supervision:

Уровень	Что обнаруживает	Что способен восстановить
application actor runtime	exception/invalid behavior	behavior instance, mailbox strategy, child hierarchy
process supervisor	process exit	process и локальную конфигурацию
Substrate	Actor/Worker lifecycle failure	sandbox из последнего завершённого snapshot
Kubernetes	container/Pod/node failure	Worker infrastructure и platform components
AX control plane	Task не достиг desired state	workflow step через reconciliation

Каждый верхний слой должен понимать семантику нижнего recovery. Если Kubernetes перезапустил Worker, это не доказывает, что Actor side effect можно повторить. Если Substrate восстановил snapshot, это не означает, что потерянные после snapshot messages появятся снова. Infrastructure recovery возвращает вычислительную способность; business recovery возвращает корректность.

Backpressure и hot Actors

Последовательный owner state имеет конечную пропускную способность. Если входящий поток быстрее обработки, mailbox растёт. Unbounded mailbox превращает временную пере-

грузку в memory exhaustion с большой задержкой, когда пользователю уже не нужен результат.

Нужны явные controls:

- bounded queue и понятное поведение при заполнении;
- per-tenant и per-Actor admission limits;
- deadline/TTL сообщения, чтобы не исполнять просроченную работу;
- метрики queue depth, oldest age и service time;
- отдельные limits для user commands и background events;
- приоритет control messages, но без starvation обычной работы.

Hot Actor нельзя бесконечно ускорять добавлением Workers: одна logical identity по определению остаётся одной точкой владения state. Варианты - уменьшить границу Actor, вынести read-only work, разделить state на независимые partitions или использовать несколько aggregator stages. Если инвариант требует глобальной последовательности, предел throughput является ценой этого инварианта.

Security и multi-tenancy

Actor boundary полезна для reasoning, но не является security boundary автоматически. Два Actors в одном process могут иметь логически отдельный state и всё же разделять memory address space. На уровне Substrate изоляцию обеспечивает sandbox class и platform configuration из главы 8.

Особого внимания требуют snapshots. Они могут содержать prompts, credentials, tool outputs, source code и остатки process memory. Поэтому нужны encryption, tenant-scoped authorization, integrity verification, lifecycle retention и audit. Route также является security-sensitive mapping: запрос Actor A не должен попасть в activation Actor B после быстрого reassignment Worker.

Identity внутри восстановленного snapshot требует проверки. Клонирование golden state не должно переносить уникальный actor token, telemetry identity или lease прежнего экземпляра. После resume runtime/application должны привязать окружение к текущим Actor ID, generation и short-lived credentials.

Наблюдаемость Actor lifecycle

Логи только по Pod name теряют связь после relocation. Основная correlation identity - Actor ID, дополненная activation ID, Worker ID и snapshot generation. Минимальный набор telemetry:

- Actor lifecycle state и время последнего перехода;
- activation/resume latency по этапам: lookup, assignment, download, restore, readiness;
- suspend latency, snapshot size и upload throughput;
- Actor ID, activation ID, Worker/Pod и template version;

- request/message ID, mailbox depth, oldest message age и processing time;
- число retries, duplicates, stale messages и dead letters;
- частота crashes, reverts и повторных activations;
- доля warm Workers и ожидание capacity.

Следует различать **actor unavailable** и **actor cold**. Cold Actor может быть здоров, но требовать resume. SLO полезно разложить на warm-request latency, cold-resume latency и долю requests, которые встретили activation.

Когда Actor model подходит

Модель особенно сильна, когда система состоит из большого числа независимо адресуемых stateful entities:

- chat/conversation sessions;
- autonomous tasks с долгим ожиданием;
- user assistants с персональной memory;
- digital twins, game entities, devices;
- workflow coordinators, владеющие небольшой state machine;
- изолированные development workspaces, которые большую часть времени idle.

Общий признак: state естественно partitioned по identity, requests к одной identity удобно сериализовать, а разные identities работают независимо. Тогда Actor boundary уменьшает область locks и failure, а virtual activation экономит capacity.

Когда лучше выбрать другой инструмент

Задача	Почему Actor может мешать	Что рассмотреть
stateless transformation	identity и lifecycle ничего не добавляют	обычный service/worker pool
массовая аналитика по всем entities	fan-out по миллионам Actors дорог	warehouse, stream processor, batch engine
сложные cross-entity transactions	много coordination messages и partial failures	relational transaction boundary
общий большой mutable dataset	неясно, какой Actor владеет state	database/service с явной concurrency model
очень короткие независимые jobs	activation и snapshot overhead больше работы	queue + ephemeral workers
одна глобальная identity с огромным QPS	Actor становится serial bottleneck	partitioning, CRDT, sharded data model

Не следует превращать каждую таблицу БД в Actor. Модель ценна там, где behavior и lifecycle принадлежат entity, а не просто потому, что у строки есть primary key.

Антипаттерны

- **Actor = Pod.** Logical identity оказывается привязана к расходному infrastructure object.
- **Actor = thread.** Теряется multiplexing; тысячи idle entities требуют тысячи threads.
- **Snapshot = database.** Domain state становится непрозрачным и плохо мигрируемым.
- **Mailbox без limit.** Перегрузка маскируется до OOM и многоминутной latency.
- **Синхронные циклы Actor calls.** Последовательная обработка превращается в deadlock.
- **Resume сразу Ready.** Приложение получает трафик до пересоздания connections и проверки leases.
- **Worker IP как identity.** Relocation ломает references и направляет запросы устаревшей activation.
- **«Один Actor на всё».** Глобальная state machine становится hot spot и общей failure domain.
- **Вера в автоматическую exactly-once.** Message delivery, snapshot и внешний side effect остаются разными границами.

Практический чек-лист Actor design

1. Какую domain entity представляет Actor и как выглядит стабильный ID?
2. Какими инвариантами Actor владеет единолично?
3. Где находится точка сериализации: mailbox, application queue или storage?
4. Разрешена ли reentrancy и что происходит после await?
5. Mailbox bounded? Что происходит при overflow и expired message?
6. Каковы delivery, ordering, acknowledgement и deduplication semantics?
7. Какой state живёт в snapshot, database, object store и внешних системах?
8. Как workload достигает quiescent point перед suspend?
9. Что пересоздаётся при resume и когда публикуется readiness?
10. Как предотвращаются stale route и duplicate activation?
11. Как разделены application supervision, Substrate recovery и Kubernetes restart?
12. Как обнаружить hot Actor и когда менять partitioning?
13. Какие данные snapshot содержит и кто имеет право их восстановить?
14. Как Actor version/template обновляется без несовместимого state?
15. Когда Actor удаляется и какой retention остаётся после него?

Итог

- Actor - это прежде всего logical identity и владелец state/behavior, а не process или Pod.
- Классическая actor model добавляет message protocol и mailbox; virtual actor добавляет автоматическую activation и location management.
- Agent Substrate применяет virtual-identity идею к sandboxed workload, но не навязывает приложению классическую mailbox semantics.
- Suspend/resume экономит capacity только при явном quiescence protocol и разделении snapshot, domain state и external state.
- Последовательная обработка упрощает инварианты, но создаёт throughput ceiling, hot-key risk и вопросы reentrancy.
- Infrastructure recovery возвращает Actor к вычислению; бизнес-корректность возвращают idempotency, journal и protocol из главы 10.

Дальше. Теперь Actor, activation и Worker разведены концептуально. Следующая глава рассматривает конкретную operational architecture Agent Substrate: ateapi, atecontroller, atelet, atecom, atenet, PostgreSQL, object storage и путь запроса от gateway до восстановленного sandbox.

Источники и дальнейшее чтение

- [Carl Hewitt: Actor Model of Computation](#) - обзор Actor model автором исходной идеи.
- [Akka: What is an Actor?](#) - state, behavior, reference, mailbox и supervision.
- [Akka: Message Delivery Reliability](#) - at-most-once, ordering, ACK/retry и deduplication.
- [Microsoft Orleans Overview](#) - virtual actors, stable identity и managed activation.
- [Orleans Request Scheduling](#) - single-threaded turns, interleaving и reentrancy.
- [Orleans Grain Directory](#) - mapping logical identity на activation location.
- [Erlang/OTP Supervisor Behaviour](#) - supervision trees и restart strategies.
- [Agent Substrate Architecture](#) - Actor/Worker lifecycle, routing и snapshot state.
- [Agent Substrate Security](#) - cross-Actor isolation, routing, identity и snapshot risks.

Agent Substrate: как устроен runtime для stateful Actors

CURRENT ARCHITECTURE

OPERATIONS FIRST

LIMITS MADE EXPLICIT

В предыдущей главе мы отделили классическую Actor model от конкретной реализации Agent Substrate. Теперь можно пройти по системе изнутри. Представим, что HTTP-запрос адресован Actor, который сейчас не занимает CPU, не привязан к Worker и существует только как запись в control plane плюс snapshot в object storage. Что должно произойти, чтобы запрос получил ответ? Какие компоненты участвуют в этом пути? Где находится истина о состоянии? Что случится, если свободного Worker нет, PostgreSQL недоступен или snapshot повреждён?

Именно на эти вопросы отвечает operational architecture. Названия процессов сами по себе мало полезны. Инженеру важнее понимать ответственность каждого компонента, границы согласованности и цену каждого перехода. Тогда можно решить, подходит ли Substrate workload, выбрать sandbox class, оценить capacity, сформулировать SLO и диагностировать сбой без хаотичных перезапусков.

Что читатель должен унести из главы

После этой главы вы сможете:

- объяснить, зачем Substrate добавляет специализированный control plane поверх Kubernetes;
- разделить infrastructure plane, Actor control plane и request data path;
- проследить холодный и тёплый путь запроса от `atenet-router` до процесса Actor;
- различать `pause`, `suspend`, `resume`, `revert` и `delete` по их эксплуатационным последствиям;
- понимать, какую часть состояния держат PostgreSQL, object storage, Kubernetes и само приложение;
- проектировать capacity, telemetry и runbook вокруг реальных failure modes;
- не принимать показатели из README или architecture roadmap за гарантию для своего кластера.

Какую проблему решает Substrate

Обычный Kubernetes хорошо управляет сравнительно небольшим числом Pod, которые живут минуты, часы или дни. Для agent-like workload профиль часто другой: логических исполнителей много, большинство долго ждёт пользователя, модели или события, а активные перио-

ды короткие и всплесковые. Если каждому логическому исполнителю постоянно держать отдельный Pod, оплачиваются idle memory, Pod IP, записи control plane и лимиты node даже тогда, когда полезной работы нет.

Substrate вводит два разных объекта. **Actor** - долговечная логическая единица с identity и состоянием. **Worker** - заранее поднятая физическая ёмкость, способная временно исполнять Actor. Большое множество Actors отображается на меньшее множество Workers. Когда Actor не нужен, его execution state можно вынести в snapshot и освободить Worker. Когда приходит запрос, Actor восстанавливается на свободном Worker.

Это не бесплатная оптимизация. Мы экономим постоянно зарезервированный compute, но получаем новые задачи: атомарное назначение Worker, перемещение snapshot, маршрутизацию к меняющемуся location, защиту от смешивания состояний разных Actors, наблюдаемость через несколько activation и управление очередью при дефиците capacity. Substrate полезен только там, где эта цена оправдывается плотностью и характером idle/active workload.

Не перепутайте слой. Substrate не строит agent loop, не выбирает модель, не управляет prompt и не вводит классический mailbox. Это execution runtime для sandboxed, stateful workload. Harness и приложение по-прежнему отвечают за reasoning, tool protocol, идемпотентность бизнес-операций и семантику сообщений.

Когда специализированный control plane оправдан

Специализированный Actor control plane нужен не потому, что Kubernetes плох. У него другой рабочий диапазон. Создание Pod включает scheduler, admission, image pull, CNI, kubelet и readiness. Это разумный путь для долгоживущей нагрузки, но слишком тяжёлый для activation, которую хотят укладывать в сотни миллисекунд. Кроме того, миллионы часто обновляемых Actor records и snapshot references не следует превращать в миллионы Kubernetes objects.

Поэтому Substrate оставляет Kubernetes то, что тот делает хорошо: nodes, Deployments, DaemonSets, Worker Pods, инфраструктурную изоляцию и low-frequency reconciliation. Частые операции Actor lifecycle идут через отдельный API и state store. Это фундаментальное архитектурное решение, а не деталь реализации.


Три плоскости системы

Удобно читать архитектуру не как один граф, а как три связанные плоскости.

Плоскость	Что управляет	Основные компоненты	Характер изменений
Infrastructure plane	Nodes, Worker Pods, controller deployments, sandbox capacity	Kubernetes, <code>atecontroller</code> , WorkerPool CRD, <code>atelet</code> DaemonSet	Секунды и минуты; declarative reconciliation

Плоскость	Что управляет	Основные компоненты	Характер изменений
Actor control plane	Actor records, Worker assignments, lifecycle workflows, template metadata	ateapi , PostgreSQL	Высокая частота; транзакции и state transitions
Request data path	Wake-on-request, выбор текущего Worker, туннель до Actor	atenet-router , Envoy ext_proc , atunnel , Actor	На каждый запрос; latency-sensitive

Object storage пересекает плоскости: оно не принимает решение о placement, но хранит durable snapshot, без которого suspended Actor не восстановится. atelet и ateom тоже стоят на границе: control plane инициирует операцию, а фактический checkpoint или restore происходит на node и внутри Worker Pod.



Карта компонентов и ответственности

Компонент	За что отвечает	Чего от него не ждать
ateapi	gRPC API, lifecycle state machine, выбор и атомарное назначение Worker, orchestration resume/suspend, Actor identity issuance	Не исполняет Actor и не хранит blob snapshot внутри себя
PostgreSQL	Динамические Actor и Worker records, state, assignment, version guards, ссылки на snapshot	Не является хранилищем process memory или файловой системы Actor
atecontroller	Reconcile WorkerPool CRD в Kubernetes resources и warm Worker capacity	Не планирует каждую Actor activation через Kubernetes scheduler
atelet	Node supervisor, связь control plane с runtime, перенос snapshot, координация checkpoint/restore	Не является глобальной базой placement и не должен самостоятельно назначать чужой Actor

Компонент	За что отвечает	Чего от него не ждать
ateom	Управление sandbox внутри Worker: запуск, checkpoint, restore; варианты для gVisor и microVM	Не решает, какой Actor и на каком Worker должен работать
atenet-router	Определяет целевой Actor по ate-target-actor, вызывает resume/lookup, выбирает backend, паркует retryable requests	Не хранит authoritative Actor state и не заменяет application gateway с пользовательской authz
atunnel	Принимает аутентифицированный TLS tunnel на Worker и пересылает HTTP к активному Actor через private network	Worker port 80 не становится публичным Actor ingress
Object storage	Durable external snapshots: memory, writable rootfs и durable data в зависимости от scope/backend	Snapshot не равен backup всей системы и не откатывает внешние side effects
Kubernetes	Жизненный цикл control-plane и Worker Pods, node placement, devices, NetworkPolicy, ресурсы	Не является high-frequency Actor registry

Почему Worker уже должен быть тёплым

Главная latency-оптимизация - не создавать Pod при каждом wake-up. Worker Pods заранее запущены и зарегистрированы как свободные. Control plane выбирает подходящий Worker, после чего node-local компоненты восстанавливают sandbox. Kubernetes scheduler находится вне критического пути обычного resume. Он возвращается в путь, когда надо увеличить или восстановить сам пул Workers.

Это означает, что autoscaling WorkerPool не спасает запрос мгновенно. Даже если HPA или cluster autoscaler увидит нагрузку, новые Pod и node появятся позже. Короткий burst должен быть покрыт warm headroom, request parking или admission control верхнего уровня.

Путь одного запроса: Actor уже работает

Начнём с fast path. Клиент или верхнеуровневый gateway отправляет HTTP-запрос в atenet-router и указывает адрес <atespace>/<actor> в заголовке ate-target-actor. Значение Host остаётся authority приложения и не выбирает Actor.

1. Envoy передаёт request headers внешнему процессору router.
2. Router обращается к ateapi через ResumeActor. Операция также играет роль locate: если Actor уже RUNNING, ответ содержит его актуальное Worker assignment.
3. Router открывает mTLS tunnel к atunnel на порту 443 выбранного Worker.
4. atunnel проверяет router identity и соответствие заголовка Actor, реально назначенному этому Worker.
5. Запрос передаётся по private veth к приложению Actor; ответ идёт обратно тем же путём.

Даже fast path не должен полагаться на кэшированный Pod IP без проверки assignment. Actor может suspend/resume на другом Worker. Location transparency удобна приложению, но инфраструктура обязана разрешать identity в актуальное placement.

Путь wake-up: Actor suspended

Для suspended Actor request data path превращается в distributed workflow:

Client

```
-> atenet-router: HTTP + ate-target-actor
-> ateapi: ResumeActor
-> PostgreSQL: проверить state и атомарно claim свободного Worker
-> atelet на выбранной node: Restore
-> object storage: скачать manifest и snapshot objects
-> atecom: восстановить sandbox и network
-> application readiness: Actor способен принять request
-> ateapi: commit RUNNING + worker assignment
-> router: открыть mTLS tunnel к atunnel
-> Actor: исходный HTTP request
```

У этой цепочки есть важное свойство: исходный request удерживается, пока Actor ещё не готов. Нельзя сначала отправить трафик, а затем надеяться, что restore закончится. Граница readiness должна означать готовность приложения обработать запрос, а не только наличие процесса или network namespace.

Golden snapshot и первый запуск

При создании ActorTemplate Substrate может поднять временный golden Actor, дождаться readiness или warm-up interval, suspend его и сохранить опубликованный tag. Новый Actor начинает с ссылки на этот golden snapshot. Первый resume тогда восстанавливает уже прогретое состояние, а не повторяет дорогую инициализацию.

Golden snapshot особенно полезен для загрузки больших зависимостей, инициализации runtime и подготовки read-only caches. Но нельзя бездумно запекать в него короткоживущие credentials, соединения и данные конкретного пользователя. Всё, что попало в memory image или writable layer, размножается вместе с шаблоном. Template следует считать immutable state root; обновление кода обычно означает новый ActorTemplate и новый golden snapshot.

Cold boot и restore - разные режимы

Если snapshot недоступен, несовместим или Actor создан до готовности golden tag, система может идти через cold boot, если это допускает конкретная конфигурация и lifecycle. Cold boot заново запускает OCI workload. Restore возвращает process memory и filesystem state из checkpoint. Эти пути имеют разную latency, разные failure modes и должны различаться в telemetry. Метрика "Actor started" без признака cold/restore скрывает самое важное.

Что происходит при дефиците Worker

Oversubscription означает, что свободный Worker иногда отсутствует. Это не обязательно авария: другой Actor может освободить capacity через несколько сотен миллисекунд. Текущий router поддерживает **request parking**. При `ResourceExhausted`, некоторых transient `FailedPrecondition`, `Aborted` и `Unavailable` он может удерживать request и повторять resume с backoff.

Parking имеет ограниченный budget и ограниченный parking lot. По умолчанию документация описывает budget 5 секунд и максимум 1024 parked requests, но production должен явно закрепить эти параметры и проверить их для выбранной версии. Запросы к одному Actor дедуплицируются на один in-flight resume call, хотя каждый клиентский request занимает отдельный parking slot.

Ситуация	Поведение	Что увидит оператор
Actor уже RUNNING	Fast path, parking slot не нужен	Низкая router latency
Нет свободного Worker, но скоро появился	Request ждёт и обслуживается	<code>parking.wait.duration{outcome="served"}</code>
Capacity не появилась до budget	HTTP 503 после bounded wait	<code>budget_exhausted</code> , pool saturation
Parking lot заполнен	Новый ожидающий request сбрасывается	<code>parking.rejected</code> , HTTP 503
Actor не существует	Fail fast	HTTP 404, ждать бессмысленно
Authentication/permission error	Fail fast	HTTP 401/403

Parking сглаживает короткий burst, но не создаёт capacity. Если `p95 parking wait` растёт, а `budget_exhausted` становится нормой, увеличивать budget бесконечно нельзя: вы только превратите отказ в длинный отказ и займёте больше streams. Нужны warm Workers, admission control, приоритизация или другой коэффициент oversubscription.

Lifecycle: не все виды остановки одинаковы

Состояния Actor - это не декоративные labels. Они задают допустимые операции и объясняют, какие данные уже durable, а какие ещё живут только на node.

Операция	Результат	Worker	Snapshot	Типичный смысл
<code>CreateActor</code>	<code>SUSPENDED</code>	Не назначен	Golden или указанный source tag, если доступен	Создать identity без постоянного compute

Операция	Результат	Worker	Snapshot	Типичный смысл
ResumeActor	RESUMING -> RUNNING	Занят Actor	External snapshot читается или выполняется cold boot	Начать обработку запросов
PauseActor	PAUSING -> PAUSED	Освобождается, но local checkpoint привязан к node	Node-local	Быстрый краткий stop без полной durable выгрузки
SuspendActor	SUSPENDING -> SUSPENDED	Возвращается в pool	Новый external snapshot записан durable	Освободить capacity с переносимым состоянием
RevertActor	... -> SUSPENDED	Активный sandbox прекращается	Возврат к последнему завершённому external snapshot	Восстановиться после crash или отбросить неудачный run
DeleteActor	Record удалён	Assignment освобождён	Actor-owned snapshot собирается	Окончательно убрать logical Actor

Pause не равен suspend

PAUSED экономит execution resources, но local snapshot остаётся привязанным к node. Такой Actor нельзя считать полностью переносимым или защищённым от потери node. Resume должен вернуться туда, где находится local checkpoint. SUSPENDED означает, что завершённый external snapshot сохранён в object storage и Actor может быть восстановлен на другом подходящем Worker.

Из этого следует простое эксплуатационное правило: pause полезен как latency-оптимизация внутри контролируемого окна, suspend - как граница durable hibernation. Перед node maintenance или rolling upgrade paused Actors надо обнаружить и перевести в suspended state, иначе локальное состояние станет препятствием или будет потеряно.

Revert не отменяет внешний мир

RevertActor завершает текущий execution и возвращает Actor к последнему успешно завершённому external snapshot. Это откатывает memory и captured filesystem state, но не отменяет отправленное письмо, списание денег, запись в стороннюю базу или содержимое external volume. Поэтому side effects должны иметь idempotency keys, operation records или compensation. Snapshot rollback - локальный механизм восстановления, а не распределённая транзакция.

Crash и окно потери данных

Если Worker Pod вытесняется, приложению передаётся SIGTERM, а control plane даёт ограниченное окно на suspend. Текущая API guide описывает 30 минут. Если suspend не завершён, Actor переходит в CRASHED, и изменения после последнего external snapshot могут быть потеряны. Долгоживущий Actor, который часами не делает durable checkpoint, имеет большой recovery point objective, даже если процесс кажется здоровым.

Частоту suspend нельзя выбирать только по стоимости snapshot. Это решение между overhead и потенциальным объёмом потерянной работы. Для задач с дорогими side effects приложение должно дополнительно фиксировать logical progress вне memory snapshot.

Где на самом деле живёт состояние

Слой	Примеры	Свойство	Что резервировать
PostgreSQL control-plane state	Actor state, Worker assignment, versions, snapshot URI	Authoritative metadata для lifecycle	Database backup, HA, point-in-time recovery, schema compatibility
Object storage	Memory image, writable rootfs, durable-data objects, manifests	Большие durable blobs, привязанные к owner и template version	Bucket durability, retention, integrity, access policy, inventory
Kubernetes	WorkerPool, Deployments, DaemonSets, node labels, NetworkPolicy	Desired infrastructure state	Git/manifests, CRDs, cluster configuration
Node-local state	Pause checkpoint, caches, runtime assets	Быстро, но связано с node и может исчезнуть	Не считать единственной durable копией
Application/ external state	Бизнес-БД, object store приложения, очереди, SaaS side effects	Не входит автоматически в Actor snapshot	Собственный backup, idempotency и consistency protocol

PostgreSQL и object storage образуют связанную пару. База говорит, какой snapshot является последним завершённым и кому он принадлежит; bucket содержит bytes. Восстановить только базу без соответствующих объектов - получить Actors со сломанными ссылками. Восстановить только bucket - получить orphaned blobs, о которых control plane не знает. Disaster recovery должен определять согласованную точку, порядок восстановления и проверку ссылочной целостности.

Snapshot ownership и commit boundary

External snapshot имеет одного owner: Actor или Tag. Новый snapshot не должен становиться текущим, пока все обязательные объекты не записаны и не проверены. Практически это означает: сначала создать данные под уникальным именем, затем атомарно обновить authoritative reference. Если процесс упал между шагами, останется garbage для сборщика, но не ссылка на незавершённый snapshot.

Actor хранит один текущий external snapshot. Успешный следующий suspend заменяет старый. Если checkpoint нужно сохранить дольше, его фиксируют Tag. Actor, созданный из Tag, может сначала заимствовать tag-owned snapshot. Удаление такого Tag до первого собственного suspend клона оставит его без источника resume; текущая документация прямо предупреждает, что эта опасная операция пока не всегда предотвращается автоматически.

Version compatibility

Memory image тесно связан с runtime, image и ActorTemplate. При смене template нельзя считать старую память переносимой. Текущий API допускает ограниченное обновление suspended Actor при совместимых sandbox, volumes и storage location; если UID template snapshot не совпадает с новым template, система может восстановить durable data и загрузить guest заново вместо memory resume. Production rollout должен тестировать именно такую границу, а не только успешный cold start новой версии.

WorkerPool и capacity engineering

WorkerPool задаёт физическую тёплую ёмкость. ActorTemplate выбирает подходящие pool по labels и sandbox class. Один Worker может одновременно размещать несколько активных Actors, пока хватает CPU, RAM и actor slots. Поэтому capacity считают по каждому ограничивающему ресурсу, а не по равенству «один Worker - один Actor»:

```
for each resource dimension:
  replicas * worker_capacity
    >= concurrent_actor_allocations_at_target_percentile
      + restore_and_maintenance_headroom
      + failure_headroom

and:
  total_actor_slots >= concurrent_running_actors + headroom
```

Но количество Actors в registry в формулу почти не входит. Важны concurrency, средняя длительность active period, burst shape, suspend rate и restore latency. Миллион mostly-idle Actors может требовать меньше Workers, чем несколько тысяч Actors с длинными tool calls.

Что измерять до выбора oversubscription

- распределение active и idle intervals, а не только среднее;
- p50/p95/p99 одновременных running Actors по pool и template;
- скорость wake-up events и длительность всплеска;
- размер full/data snapshot и фактическую пропускную способность object storage;
- CPU, memory и I/O contention во время параллельных restore;
- время освобождения Worker при suspend;
- долю parked, rejected и budget-exhausted requests;
- capacity, которую можно потерять при отказе одной node или zone.

Если pool обслуживает workloads с разными resource profiles, маленький Actor может конкурировать с большим за одинаковый Worker. На практике полезны отдельные pools или классы capacity, чтобы тяжёлые Actors не создавали fragmentation и noisy-neighbor effects.

Версионирование dataplane

Worker capacity привязана к версии Substrate. Nodes несут label `ate.dev/substrate-version`, а `atelet` и `Workers` должны быть совместимы. Новая node, появившаяся после установки без нужного label, не даст ожидаемой capacity. Upgrade нельзя выполнять массовой заменой `serving WorkerPool`: сначала создаётся новый pool и `dataplane`, затем `Actors` последовательно `suspend`, nodes переводятся на новую версию и только после `soak` удаляется старый pool. Глава об `operations` вернётся к полному `runbook`; здесь важен принцип: `Actor portability` не отменяет управление `version skew`.

Sandbox class: gVisor или microVM

Оба backend дают единый `lifecycle API`, но не одинаковую реализацию и стоимость.

Критерий	gVisor	microVM
Изоляция	Отдельное user-space kernel boundary, меньше overhead	Guest kernel и VMM, более тяжёлая граница
Checkpoint/restore	<code>runsc</code> process tree и filesystem state	VM memory snapshot плюс host-backed writable data
Требования к node	Runtime assets, совместимый kernel	<code>/dev/kvm</code> , nested virtualization, Kata/Cloud Hypervisor assets
Latency и density	Обычно выгоднее, но проверяется workload benchmark	Больше overhead, возможна более сильная isolation boundary
Выбор	Подходит большинству sandboxed Linux workload, если <code>syscall compatibility</code> достаточна	Подходит, когда threat model или workload требует VM boundary

Выбор нельзя делать по маркетинговому ярлыку. Сначала определяют threat model, необходимые `syscalls`, `devices`, `network behavior` и предел `latency`. Затем запускают одинаковый benchmark для `cold start`, `resume`, `steady-state` и `suspend`. Sandbox, который быстро восстанавливается на игрушечном counter, может вести себя иначе с сотнями мегабайт `dirty memory` и большим `writable layer`.

Networking и identity-aware routing

Router знает не только IP, но и логический `Actor target`. Это позволяет разбудить `Actor` и выбрать его новое `placement`. Но такой заголовок становится частью `security boundary`: пользователь не должен иметь возможность просто подставить имя чужого `Actor`.

Текущая схема разделяет `routing` и `transport`. Router получает `ate-target-actor`, control plane возвращает `assignment`, затем router подключается к `atunnel` по `mTLS`. `atunnel` проверяет, что `target` соответствует `Actor`, назначенному `Worker`. Это защищает от устаревшего или подменённого маршрута внутри `dataplane`, но не заменяет пользовательскую `authorization policy` на входе.

Arbitrary ports и ограничения протокола

Для порта, отличного от стандартного HTTP, текущая архитектура использует HTTP `CONNECT`. Каждый request внутри долгоживущего tunnel снова проходит actor-aware routing, поэтому может пережить перемещение Actor. Это не означает произвольный raw TCP ingress: документация ограничивает путь HTTP(S)-трафиком. Если agent tool требует SSH, custom binary protocol или inbound UDP, совместимость надо проверять отдельно.

Timeout должен покрывать весь wake-up path

Client timeout, gateway timeout, Envoy `ext_proc` timeout, parking budget и server-side resume deadline образуют цепочку. Если внешний gateway ждёт 2 секунды, а допустимый restore занимает 3 секунды, увеличение Substrate budget не поможет: клиент уже ушёл, хотя control plane может закончить resume. Таймауты проектируют от end-to-end SLO и делают так, чтобы внутренние операции имели осмысленное завершение даже после client disconnect.

Security boundaries без самообмана

Substrate pre-1.0, а его threat model прямо говорит о ранней стадии и недостаточной hardening. Поэтому безопасная эксплуатация начинается не со слова secure-by-default в README, а с проверки конкретных invariant.

- **Control-plane access.** `ateapi`, PostgreSQL и node-local APIs не выставляются во внешнюю сеть; доступ ограничен NetworkPolicy и infrastructure firewall.
- **Authentication не равна authorization.** Текущий `ateapi` принимает mTLS и JWT, но документация указывает, что пользовательские RBAC/authorization ещё не реализованы. Подключённый identity provider фактически даёт широкие права control plane.
- **Worker reuse.** После Actor должны быть удалены process state, filesystem delta, environment, credentials, routes и policy. Остаток от предыдущего tenant - критическая уязвимость.
- **Snapshot integrity и confidentiality.** Actor не должен иметь прямые широкие credentials к bucket. Manifest и blobs нужно проверять до restore; доступ node ограничивают ровно нужными prefixes, насколько позволяет backend.
- **Routing authorization.** Знание имени Actor не должно давать право вызывать его. User-facing gateway обязан сопоставить principal, atespace и разрешённое действие.
- **Actor identity.** Выдача credentials проверяет, что Actor сейчас running и назначен Worker на той же node, откуда обращается atelelet. Короткий срок и отзыв при reschedule уменьшают окно злоупотребления.
- **Egress.** Untrusted agent не получает cluster DNS, metadata service, Kubernetes API и произвольные secrets по умолчанию. Нужны default deny и явные policy.

Практический вывод. До появления полноценной authorization в control plane его сеть и набор доверенных клиентов являются основной границей доступа. Не подключайте к

ateapi identity provider, пользователи которого не должны управлять всеми atespaces и Actors.

Failure matrix: что ломается и как выглядит

Отказ	Симптом	Что остаётся доступным	Первое действие
ateapi недоступен	Новые resume/lookup не проходят; requests могут парковаться и завершаться 503	Уже running Actor физически может быть жив, но router control path затронут	Проверить API replicas, TLS, PostgreSQL и rollout, а не перезапускать Workers
PostgreSQL недоступен	Lifecycle RPC failing, assignment не подтверждается	Running processes могут продолжить работу до следующей операции	Восстановить DB connectivity/HA и проверить consistency до новых writes
Object storage медленное	Пост restore/suspend latency, timeouts	Fast path к already-running Actors	Разложить timing на download/upload, проверить bandwidth, throttling и snapshot size
Snapshot отсутствует или повреждён	Один Actor не resume, integrity/NotFound error	Другие Actors и pools	Не затирать evidence; проверить owner URI, manifest, retention и последний хороший tag
Нет свободного Worker	Parking, затем 503 budget exhausted	Already-running Actors	Проверить pool utilization, stuck RUNNING/PAUSED, suspend throughput и warm headroom
Worker/Node умер	Actor CRASHED или завис в переходном state; assignment устарел	Actors на других nodes	Определить последний external snapshot; затем controlled revert, а не слепой delete
Router недоступен	Ingress падает, хотя Actors и control plane здоровы	Прямые administrative RPC	Проверить Envoy/ext_proc, certificates, service endpoints и parking saturation
Устаревший route/assignment	Tunnel отвергнут, 5xx после перемещения	Control plane state	Проверить assignment version и что router заново разрешает target

Наблюдаемость: Actor живёт дольше Pod

Pod name не является identity Actor. Один Actor за жизнь появится на разных Workers, а один Worker последовательно примет разных Actors. Логи и traces нужно связывать по стабильным полям: `ate.atespace`, `ate.actor.name`, `ate.actor.uid`, `template identity`, `operation` и `activation epoch`.

Текущая observability guide описывает structured container logs и lifecycle records. Для расследования особенно полезны:

- `Actor state changed` - committed transition, а не намерение до транзакции;
- `Actor crashed` - событие с operation и actor identity;
- `Restore timing breakdown` - download, OCI unpack, ateam restore и total;
- `Checkpoint timing breakdown` - где тратится suspend time;
- router access и parking metrics - сколько запросов реально ждало capacity;
- pool utilization, free/busy Workers и assignment churn;
- object-store bytes, errors и throttling;
- PostgreSQL transaction latency, lock conflicts и connection saturation.

SLO нужно разложить на бюджет

```
wake_up_latency =
  router_processing
+ control_plane_lookup_and_claim
+ queue_or_parking_wait
+ snapshot_fetch
+ sandbox_restore
+ application_readiness
+ tunnel_setup
```

Одна итоговая p95 не говорит, что оптимизировать. Если dominant phase - download, добавление CPU в `ateapi` бессмысленно. Если dominant phase - parking, сжатие snapshot не решит shortage capacity. Записывайте phase timing для успеха и ошибки, а также признак snapshot scope, sandbox class и template. Actor UID нельзя бездумно помещать в metric labels с высокой cardinality; для per-Actor расследований подходят logs и traces.

Runbook: Actor не отвечает

1. **Зафиксируйте точный target.** Atespace, Actor name, UID, template, время и request/trace ID. Одинаковое имя после delete/create может означать другую lifetime.
2. **Проверьте HTTP outcome.** 404 указывает на identity/resource, 401/403 - на доступ, 503 - на capacity или unavailable control plane, 504 - на deadline.
3. **Прочитайте Actor state.** `SUSPENDED`, `RESUMING`, `RUNNING`, `PAUSED`, `SUSPENDING` и `CRASHED` требуют разных действий.

4. **Если RESUMING завис.** Найдите operation trace, Worker assignment и restore timing. Проверьте свободные Workers, object storage и ateleet на выбранной node.
5. **Если RUNNING, но request не проходит.** Сверьте assignment с tunnel destination, atunnel TLS, private network и readiness приложения. Не делайте вывод по одному Pod Ready.
6. **Если PAUSED.** Проверьте node-local snapshot и доступность исходной node. Для maintenance переведите Actor в durable suspend.
7. **Если CRASHED.** Определите последний завершённый external snapshot и цену потери данных. После этого используйте revert осознанно.
8. **Проверьте scope проблемы.** Один Actor, один template, один pool, одна node, object-storage region или весь control plane. Это быстрее всего сужает слой.
9. **Сохраните evidence.** State versions, operation logs, manifest URI и timings до restart. Массовый restart может освободить симптомы и уничтожить причинную цепочку.

Project claims, targets и ваш benchmark

README проекта сообщает sub-500ms resume и более 500 activations/sec, architecture document формулирует north-star target 100ms p95 и 1000 wakeups/sec, а также очень большой scale target. Это полезные направления развития, но не взаимозаменяемые гарантии. Документ архитектуры прямо предупреждает, что многое aspirational, а проект остаётся pre-1.0.

Минимальный benchmark должен включать не один counter, а матрицу:

- cold boot, golden restore и последующий Actor-owned restore;
- snapshot sizes: малый, типичный, p95 и предельный;
- gVisor и microVM, если рассматриваются оба;
- одиночный wake-up и burst при 50/80/95/100% pool utilization;
- object storage в той же region и с искусственным throttling;
- node failure, router rollout и временную недоступность `ateapi`;
- parking enabled/disabled и реальные client timeouts;
- correctness после restore: память, writable data, external side effects и credentials.

Результат benchmark - не одно красивое число. Нужны latency distributions по phase, throughput до насыщения, error taxonomy, recovery time и стоимость единицы active Actor-hour при выбранном oversubscription.

Граница между AX и Substrate

В стеке этой книги AX управляет задачей и agent execution на уровне продукта: Task, Workspace, runner, desired state и reconciliation. Substrate предоставляет sandboxed Actor runtime, placement, suspend/resume и actor-aware ingress. Один слой не должен притворяться другим.

Вопрос	AX	Substrate
Какую пользовательскую задачу выполнить?	Да	Нет
Какой harness/process запустить?	Да, через runner/workspace contract	Исполняет заданный OCI workload
Где взять sandbox capacity?	Запрашивает runtime	Выбирает WorkerPool/Worker
Как сохранить RAM и writable filesystem?	Не обязан реализовывать	Checkpoint/snapshot lifecycle
Как возобновить Task после side effect?	Task state и application idempotency	Только возвращает execution environment

Для end-to-end диагностики идентификаторы должны проходить через оба слоя: AX Task ID, Actor UID, Actor operation/activation, request/trace ID и tool operation ID. Иначе успешный ResumeActor нельзя связать с зависшей пользовательской задачей.

Production readiness checklist

- Версия Substrate закреплена; release notes, API guide и manifests соответствуют бинарям.
- Проверено, какие фрагменты architecture являются implemented, а какие roadmap.
- Control plane изолирован от Worker burst; PostgreSQL имеет проверенный backup/restore.
- Object storage policy, lifecycle и snapshot integrity протестированы.
- У `ateapi` есть authentication, а отсутствие полноценной user authorization компенсировано network boundary и доверенным набором клиентов.
- WorkerPools разделены по sandbox class и resource profile; есть failure и maintenance headroom.
- Node labels `ate.dev/substrate-version` автоматически применяются к новым nodes.
- Client/gateway/router/resume timeouts согласованы.
- Parking lot имеет bounded size; alerts различают served wait, budget exhaustion и rejection.
- Restore и checkpoint timings видны по phase; Actor lifecycle связывается по UID.
- Приложение корректно переживает потерю sockets, повтор request и откат к предыдущему snapshot.
- Side effects имеют idempotency keys или compensation; snapshot не считается транзакцией.
- Проверены node loss, partial suspend, corrupt/missing snapshot и rolling upgrade.
- Runbook учит сначала локализовать слой и сохранить evidence, а не restart всего кластера.

Итог

Agent Substrate превращает Actor в логическую сущность, которая живёт дольше конкретного Pod и получает compute по требованию. Для этого система разделяет медленное инфраструктурное reconciliation Kubernetes, быстрый Actor control plane и latency-sensitive request path. Warm Workers убирают Kubernetes scheduler из обычного resume, PostgreSQL фиксирует lifecycle и assignment, object storage хранит durable snapshots, atelelet/ateom восстанавливают sandbox, а atenet-router направляет request к текущему location.

Главный инженерный вывод не в том, чтобы запомнить восемь названий. Нужно видеть границы: metadata отдельно от blob state, pause отдельно от suspend, routing отдельно от authorization, snapshot отдельно от business transaction, request parking отдельно от capacity. Если эти различия отражены в SLO, telemetry и runbook, multiplexing становится управляемой оптимизацией. Если нет, экономия на idle Pods превращается в систему со скрытой очередью, непонятной потерей состояния и трудно воспроизводимыми отказами.

Следующая глава приблизит камеру к ресурсной модели: Atespace, WorkerPool, SandboxConfig, ActorTemplate, Actor и Tag. Мы разберём, какие поля задаёт platform team, какие - разработчик workload, какие значения изменяет только server и как эти объекты связываются без смешивания Kubernetes API с Actor API.

Источники и дальнейшее чтение

- [Agent Substrate README](#)
- [Agent Substrate architecture](#)
- [Substrate API guide](#)
- [ate-api authentication](#)
- [Request parking](#)
- [Actor observability](#)
- [Substrate threat model](#)
- [Rolling upgrade runbook](#)

Ресурсная модель Substrate: от capacity до долговечного Actor

TWO API DOMAINS

VERSIONED RESOURCES

OWNERSHIP MATTERS

В предыдущей главе мы прошли по operational path: запрос приходит в router, control plane находит или возобновляет Actor, а Worker предоставляет sandbox capacity. Теперь нужно понять, какими объектами инженер описывает эту систему. Без этого архитектура остаётся набором процессов, а любое изменение превращается в угадывание: куда положить label, что можно обновить, кто владеет snapshot и почему объект с тем же именем после пересоздания уже не тот же объект.

Ресурсная модель Substrate специально разделена между Kubernetes API и собственным ate API. Это не косметика. Инфраструктурные объекты меняются редко и хорошо согласуются с Kubernetes reconciliation. Actor records и assignments меняются часто, поэтому живут в отдельном control-plane store. Инженеру нужно видеть обе стороны и не переносить правила одной на другую автоматически.

Что читатель должен унести из главы

- какие ресурсы принадлежат Kubernetes, а какие ate API;
- чем Atespace отличается от Kubernetes namespace и почему это ещё не полноценная authorization boundary;
- как WorkerPool, SandboxConfig и ActorTemplate вместе определяют допустимый placement;
- почему ActorTemplate следует версионировать созданием нового объекта, а не редактировать на месте;
- как uid и version защищают update/delete от гонок и повторного использования имени;
- что именно принадлежит Actor, Tag и template golden snapshot;
- как собрать минимальный набор ресурсов без скрытой зависимости от namespace, mutable tags или непроверенного snapshot URI.

Два API-домена и три типа состояния

Домен	Ресурсы	Где хранятся	Кто обычно управляет
Kubernetes API	WorkerPool, SandboxConfig, Deployments, Pods	etcd/Kubernetes control plane	Platform team, GitOps, cluster controllers

Домен	Ресурсы	Где хранятся	Кто обычно управляет
ate API: declarative definitions	Atespace, ActorTemplate, Tag	Substrate control-plane store	Platform или application team через <code>kubectl ate/gRPC</code>
ate API: dynamic records	Actor, Worker, assignments и status	Substrate control-plane store	Clients создают intent; server ведёт lifecycle/status

`WorkerPool` является Kubernetes CRD в конкретном namespace. `SandboxConfig` тоже Kubernetes resource, но cluster-scoped. Напротив, `ActorTemplate`, `Actor`, `Tag` и `Atespace` не являются Kubernetes objects. Их нельзя корректно описывать как обычные namespaced CRD и ожидать, что Kubernetes RBAC автоматически ограничит доступ.

Это разделение определяет диагностику. Если не создаются Worker Pods, смотрят controller, CRD и Kubernetes events. Если Actor застрял в RESUMING или update получил ABORTED, смотрят ate API, resource version и lifecycle workflow. Один `kubectl get all` не показывает всю систему.

Общая грамматика ate API: metadata и references

Atespaced resources имеют общий `ResourceMetadata`:

Поле	Кто задаёт	Смысл
atespace	Клиент при create	Логическая область ресурса; immutable
name	Клиент при create	DNS-compatible имя, уникальное внутри Atespace; immutable
uid	Server	Глобально уникальная identity конкретной lifetime
version	Server увеличивает при mutation	Optimistic concurrency guard
createTime, updateTime	Server	Аудит и диагностика возраста состояния

Имя удобно человеку, но не доказывает identity. Если Actor `team-a/assistant` удалили и создали заново, новый объект может иметь то же имя, но другой `uid`. Логи, snapshot prefixes, idempotency records и долгоживущие ссылки должны учитывать UID, когда важно отличить lifetimes.

ObjectRef не является строкой

Ссылка на ate resource содержит отдельные поля `atespace` и `name`. Даже ссылка на объект в том же Atespace должна явно указывать Atespace. Строка `team-a/assistant` удобна в CLI и routing header, но внутри API её не следует парсить вручную или хранить вместо typed reference.

Почему update начинается с read

Для mutable resource клиент сначала читает объект, меняет разрешённые поля и отправляет полный replacement с теми же uid и version. Если другой процесс уже обновил объект, server возвращает ABORTED. Это лучше last-write-wins: оператор видит конфликт и решает, как объединить intent.

```
read object (uid=u1, version=17)
-> modify allowed field
-> update with uid=u1, version=17
    success: stored version becomes 18
    conflict: ABORTED, re-read before retry
```

Создавать update message с нуля опасно: можно неявно очистить поля, которых клиент не знал. status и server-managed metadata игнорируются на input, но immutable/mutable spec fields всё равно требуют точной модели.

Atespace: logical scope, но не Kubernetes namespace


Atespace - глобально-scoped запись ate API. Его собственное metadata.atespace пусто, а identity задаётся metadata.name. Actor, ActorTemplate и Tag адресуются парой (atespace, name). Одинаковое имя Actor может существовать в разных Atespaces.

Atespace нужен до создания Actor и удаляется только после очистки зависимых ресурсов. Он помогает организовать tenancy, snapshot prefixes и references. Но Atespace не равен Kubernetes namespace:

- WorkerPool живёт в Kubernetes namespace и может обслуживать Actors из разных Atespaces, если selectors это позволяют;
- ActorTemplate живёт в Atespace, но выбирает WorkerPool по labels, а не по совпадению namespace;
- Substrate API authentication не превращает Atespace автоматически в RBAC boundary;
- published Tag может быть использован Actor из другого Atespace и потребовать cross-prefix доступа к object storage.

Проектное правило. Используйте Atespace как logical ownership и адресное пространство, но security boundary подтверждайте отдельной authorization и storage/network policy. Совпадение названий Atespace и Kubernetes namespace может быть полезной convention, но не системной гарантией.

Golden snapshot и жизненный цикл stateful Actor



WorkerPool: тёплая физическая ёмкость

`WorkerPool` описывает fleet заранее запущенных Worker Pods. Это Kubernetes CRD, который `atecontroller` преобразует в Deployment. Ключевые поля:

Поле	Роль	Инженерный риск
<code>spec.replicas</code>	Число Worker Pods	Реплики не равны числу Actors: один Worker может держать несколько Actors
<code>spec.workerImage</code>	Образ <code>ateom</code> для sandbox class	Непроверенный tag создаёт version drift; pin digest
<code>spec.sandboxClass</code>	<code>gvisor</code> или <code>microvm</code>	Должен совпадать с <code>template</code> и <code>SandboxConfig</code>
<code>spec.template.resources.limits</code>	Общий CPU/RAM envelope Worker	Нулевое/отсутствующее измерение может трактоваться как unconstrained placement data
<code>spec.template.nodeSelector</code>	Node placement, включая Substrate version	Непривязанный pool ломает безопасный rolling upgrade
<code>metadata.labels</code>	Их сопоставляют Actor selectors	Не путать с <code>spec.template.labels</code>

Labels пула и labels Pod - разные поверхности

`WorkerPool.metadata.labels` участвуют в Actor placement. `WorkerPool.spec.template.labels` копируются на Deployment/Pods и нужны Kubernetes tooling, policy или observability. Selector `ActorTemplate` не смотрит на Pod labels. Это типичная ошибка: инженер добавляет `workload=secure` в pod template, а Actor продолжает попадать во все eligible pools.

Capacity теперь многомерная

Текущий Worker может одновременно держать несколько Actors. Каждый assignment вычитает declared Actor limits из remaining Worker capacity. Дополнительно действует actor-count limit, по умолчанию связанный с `ateom --max-actors`. Placement прекращается по первому исчерпанному ограничению: CPU, RAM или числу Actors.

```
eligible(worker, actor) =
  sandbox_class_matches
  AND template_selector_matches
  AND actor_selector_matches
  AND remaining_cpu >= actor_cpu_limit
  AND remaining_memory >= actor_memory_limit
  AND assigned_actors < max_actors
```

Поэтому capacity planning нельзя сводить к `replicas == concurrent Actors`. Нужны bin-packing, resource fragmentation и headroom на failure. Два Worker по 8 GiB не гарантируют placement Actor на 12 GiB, хотя суммарно RAM достаточно.

Минимальный WorkerPool

```
apiVersion: ate.dev/v1alpha1
kind: WorkerPool
metadata:
  name: general-gvisor
  namespace: ate-workers
  labels:
    tier: general
    sandbox: gvisor
spec:
  replicas: 6
  workerImage: registry.example/ateom-gvisor@sha256:...
  sandboxClass: gvisor
  template:
    nodeSelector:
      ate.dev/substrate-version: "<installed-version>"
    resources:
      limits:
        cpu: "8"
        memory: 16Gi
```

Pool labels задают eligibility, а nodeSelector фиксирует совместимую версию dataplane. При upgrade создают новый pool и поэтапно переводят nodes/Actors, а не редактируют serving pool с массовым restart.

SandboxConfig: воспроизводимый runtime, а не workload

`SandboxConfig` - cluster-scoped Kubernetes resource. Он отделяет sandbox binaries от ActorTemplate. Для gVisor это `runsc` asset и digest-pinned pause image; для microVM - Cloud Hypervisor, `virtiofsd`, kernel и guest image по архитектурам.

ActorTemplate хранит только runtime family и имя config. При cold boot atelet разрешает assets через этот объект, а snapshot manifest фиксирует версии, необходимые для restore. Такой слой позволяет платформе централизованно поддерживать runtime, не переписывая каждый workload template.

Поле	gVisor	microVM
sandboxClass	gvisor	microvm
pauseImage	Обязателен, pinned digest	Не допускается
assets	gVisor archive per architecture	VMM, virtiofsd, kernel, image
Node requirements	Совместимый Linux runtime	/dev/kvm, nested virtualization

SandboxConfig нельзя обновлять как обычный mutable config без плана совместимости. Новый runtime может не восстановить старую memory image. Безопасная стратегия - новый config/version, новый WorkerPool и новый ActorTemplate с controlled migration.

ActorTemplate: immutable blueprint версии workload

ActorTemplate - ate API resource в конкретном Atespace. Он описывает не отдельный процесс, а версию исполняемой среды: containers, limits, volumes, sandbox, snapshot policy и pool constraints. После создания Substrate строит golden snapshot. Поэтому изменение template задним числом сделало бы непонятным, с каким кодом и runtime связан уже существующий snapshot.

Практический вывод: имя template должно отражать release или configuration version, например coding-agent-v3. Новая image, иной sandbox, другие volume mounts или limits - новый ActorTemplate. Rollout then becomes an explicit migration, а не скрытая мутация основания состояния.

Поле	Что задаёт	На что влияет
metadata	Atespace, name; server добавляет UID/version	Identity template и snapshot provenance
containers	Digest-pinned OCI images, command, args, env, mounts, wakeup probe	Код и готовность workload
resources.limits	Actor CPU и RAM	Sandbox sizing и placement capacity
workerSelector	Equality match по WorkerPool labels	Допустимые pools
sandboxConfig	Runtime family и имя cluster config	Hard gate по sandbox class и restore compatibility
snapshotConfig	Storage prefix, pause/commit scopes	Что сохраняется и сколько стоит lifecycle
volumes	DurableDir, external volume template или systemInfo	State, credentials/trust data и persistence surface

Поле	Что задаёт	На что влияет
<code>status.goldenSnapshotStatus</code>	Server	Готовность golden tag или причина ошибки

Images, command и environment

Container image должен быть pinned digest. Mutable tag вроде `:latest` разрушает воспроизводимость: две node могут cold-boot одинаковый template с разными bytes. Команда и args не полностью повторяют Kubernetes semantics: если явно задан `command`, image ENTRYPOINT и CMD отбрасываются; ссылки `$(VAR)` в command/env не разворачиваются. `envFrom` и `valueFrom` также не являются автоматической частью этого API.

Не копируйте PodSpec механически. ActorTemplate похож на Pod template концептуально, но его schema меньше и ориентирована на checkpointable sandbox. Каждое используемое поле нужно проверять по API выбранной версии.

Wakeup probe - контракт готовности resume

Без `wakeupProbe` `ResumeActor` может завершиться, когда container process уже запущен, но HTTP server ещё не слушает. Probe заставляет lifecycle ждать HTTP 200. Это особенно важно для router wake-on-request: успешный resume должен означать, что исходный request можно передавать приложению.

Probe не должен проверять медленную внешнюю dependency без необходимости. Иначе краткий сбой database превратит каждый Actor resume в timeout и займёт Worker. Разделяйте готовность локального process и полноценную business health.

Actor resources и bin packing

Actor-level limits - часть immutable template и snapshot compatibility. Для gVisor они задают cgroup quota и видимую memory; для microVM - vCPU и guest RAM с runtime reserve. Scheduler использует эти limits при выборе Worker. Отсутствующий limit зависит от runtime defaults и затрудняет capacity planning, поэтому production template лучше задавать CPU/RAM явно.

Заявлять завышенный limit тоже дорого: scheduler резервирует declared envelope, даже если процесс обычно использует меньше. Сначала измерьте p95/p99 steady-state и restore peaks, затем добавьте понятный safety margin.

SnapshotConfig: policy, а не URI одного файла

`snapshotConfig.storageLocation` - базовый object-storage prefix. Конкретные snapshot objects получают owner path автоматически. Policy также задаёт:

- `onPause` - scope node-local checkpoint;
- `onCommit` - scope durable snapshot при suspend;
- `Full` - process memory, writable rootfs delta и поддерживаемые durable volumes;
- `Data` - durable data без memory/rootfs, после resume containers стартуют заново.

`onCommit` должен быть subset `onPause`. Если pause захватил только Data, поздний suspend не может волшебным образом получить уже отброшенную process memory. Подробнее стоимость и failure semantics этих scopes разобраны в следующей главе.

Volumes: не всё является snapshot state

`DurableDir` входит в Data/Full snapshot. External volumes имеют отдельный lifecycle и могут не откатываться вместе с Actor. `systemInfo` передаёт platform metadata или trust bundle. Из названия volume нельзя выводить transactional semantics. Для каждого mount зафиксируйте owner, backup, deletion policy и поведение при revert.

Пример ActorTemplate

```
metadata:
  acespace: team-a
  name: coding-agent-v3
containers:
- name: agent
  image: registry.example/coding-agent@sha256:...
  wakeupProbe:
    httpGet:
      path: /readyz
      port: 80
  volumeMounts:
  - name: workspace
    mountPath: /workspace
resources:
  limits:
  - name: cpu
    quantity: "2"
  - name: memory
    quantity: 4Gi
workerSelector:
  matchLabels:
    tier: general
sandboxConfig:
  sandboxClass: SANDBOX_CLASS_GVISOR
  configName: gvisor-2026-10
snapshotConfig:
  onPause: SNAPSHOT_CONTENT_SCOPE_FULL
  onCommit: SNAPSHOT_CONTENT_SCOPE_FULL
  storageLocation: gs://substrate-state/coding-agent
volumes:
- name: workspace
  durableDir: {}
```

Это protojson-shaped API document, а не Kubernetes manifest: здесь нет `apiVersion` и `kind`. Его создают через `kubectl create actor-template` или gRPC client.

Golden snapshot: status становится частью deployment gate

Create ActorTemplate запускает workflow:

1. создать временный golden Actor в reserved Atespace `ate-golden`;
2. cold-boot workload с выбранным SandboxConfig;
3. дожждаться wakeup/readiness или warmup interval;
4. сделать Full suspend;
5. скопировать snapshot в immutable published Tag, имя которого связано с template UID;
6. удалить временный Actor и записать ссылку в `status.goldenSnapshotStatus.goldenTag`.

Успешный create RPC не всегда означает, что golden snapshot уже готов. Deployment automation должна ждать template readiness и проверять error status. Если Actor создать раньше, чем golden tag готов, он может остаться без snapshot и пойти через cold boot даже после того, как template позже станет Ready.

Worker: observed capacity и runtime epoch

Worker - глобально-scoped dynamic record, представляющий конкретный Worker Pod. Его создаёт dataplane, а не application developer. Record связывает Kubernetes coordinates, pool labels, sandbox class, IP addresses и server-managed status.

Worker status показывает:

- `state` - можно ли принимать новые assignments;
- `capacity` - CPU/RAM и actor slots, которые runtime реально сообщает;
- `allocated` - сумма limits назначенных Actors;
- `observedEpoch` - обработана ли смена runtime epoch.

epoch увеличивается при restart процесса `ateom` внутри того же Pod. Такой restart означает, что sandbox state прежних Actors потерян, даже если Pod UID не изменился. Control plane должен пометить Actors старой epoch как crashed и освободить assignments. Проверка только Pod Ready пропустит этот класс отказа.

Actor: identity, intent и server-managed status

Actor - конкретная логическая instance template. Клиент задаёт минимум:

- `metadata.atespace` и `metadata.name`;
- `actorTemplate` как ObjectRef;
- опциональный per-Actor `workerSelector`;
- опциональный immutable `sourceTag`.

```
metadata:
  atespace: team-a
  name: alice-coding-session
actorTemplate:
  atespace: team-a
  name: coding-agent-v3
workerSelector:
  matchLabels:
    zone-class: standard
sourceTag:
  atespace: team-a
  name: baseline-workspace
```

Placement - пересечение, а не приоритет

Template selector и Actor selector объединяются логическим AND. Actor не может расширить pools, разрешённые template; он только сужает выбор. Затем применяются hard sandbox-class match и remaining capacity. Если labels не пересекаются, результатом будет отсутствие eligible Worker, а не fallback в более широкий pool.

Ограничение	Источник	Можно ли Actor расширить выбор
Sandbox class	ActorTemplate/SandboxConfig	Нет
Template pool labels	ActorTemplate.workerSelector	Нет
Instance labels	Actor.workerSelector	Только добавить ограничения
CPU/RAM/actor slots	Worker observed capacity	Нет
Drain/state/version	Worker/control plane	Нет

Status читают, но не задают

`Actor.status` server-managed и игнорируется на create/update input. Он включает lifecycle state, current Worker assignment, external/local snapshot, in-progress snapshot URI, external volume records и crash details. Клиент не переводит Actor в `RUNNING` записью поля; он вызывает lifecycle RPC, а server выполняет workflow и фиксирует status после реального действия.

Что можно обновить

ActorTemplate reference может измениться только в `SUSPENDED` и при строгой совместимости: тот же SandboxConfig, совместимые volumes/mounts, а после собственного external snapshot - тот же storage location. `sourceTag` immutable. Update требует актуальных UID/version preconditions. Это защищает snapshot от попытки восстановить memory в несовместимом runtime.

Tag: долговечное имя и отдельный owner snapshot

Tag создаётся из suspended Actor. Control plane копирует его external snapshot в новый tag-owned prefix. После завершения Tag неизменно указывает на одну snapshot copy. Это не mutable branch pointer вроде Git tag, который можно передвинуть, а immutable retention pin и источник для клонирования.

Scope	Кто может создать Actor из Tag	Адрес Tag
TAG_SCOPE_ATESPACE	Только Actor в owning Atespace	Всегда <code>owner-atespace/tag-name</code>
TAG_SCOPE_PUBLISHED	Actor в любом Atespace	Не перемещается; остаётся в source Atespace

Published не означает, что snapshot bytes копируются в target Atespace. Restore читает source prefix, поэтому node/storage identity должна иметь доступ к source Atespace. Это важная часть multi-tenant design: публикация control-plane reference и выдача object-storage permissions должны быть согласованы.

Clone сначала заимствует snapshot

Когда Actor создаётся с `sourceTag`, bytes сразу не копируются. `status.externalSnapshot` указывает на tag-owned snapshot. После первого успешного suspend Actor пишет собственную copy под actor prefix и становится её owner.

Опасное окно. Не удаляйте Tag, пока есть Actors, которые ещё заимствуют его snapshot. Сегодня control plane не всегда предотвращает это автоматически. Проверяйте, что clone сделал собственный suspend или что его `snapshotUri` больше не указывает на `/tags/<tag-uid>`.

Snapshot paths и ownership

```
<storageLocation>/atespaces/<atespace>/actors/<actor-uid>/snapshots/<snapshot-id>  
<storageLocation>/atespaces/<atespace>/tags/<tag-uid>
```

UID в path не даёт новому объекту с повторно использованным name унаследовать старые bytes. Server-generated snapshot ID не позволяет двум suspend перезаписать друг друга. Snapshot URI из status следует трактовать как opaque server output; код не должен конструировать его по имени Actor.

Owner	Когда создаётся	Когда удаляется	Кто может ссылаться
Actor	Первый и последующие successful suspend	Следующий suspend заменяет или Actor удалён	Сам Actor
Tag	CreateTag копирует snapshot suspended Actor	При DeleteTag	Actors в пределах scope
Golden Tag	Template preparation workflow	При удалении template	Новые Actors этого template

Database row и object bytes должны удаляться в правильном порядке. Сначала control plane удаляет owned objects, затем ссылку. Retry использует deterministic destination и должен продолжать частично выполненную операцию. Если process упал между шагами, возможен orphaned object, но не ссылка на уже удалённые bytes.

Практический порядок развёртывания

1. **Platform:** установить Substrate и узнать version label dataplane.
2. **Platform:** создать/проверить SandboxConfig с pinned assets.
3. **Platform:** создать WorkerPool с labels, capacity и node version pin.
4. **Owner:** создать Atespace и определить storage prefix/policy.
5. **Developer:** создать immutable ActorTemplate с digest-pinned images и явными limits.
6. **Automation:** дождаться golden snapshot Ready, не только успешного create RPC.
7. **Application:** создать Actor, при необходимости из sourceTag.
8. **Operations:** проверить eligible Workers, resume и wakeup probe.
9. **Protection:** сделать Tag только для snapshot, который действительно нужно удерживать.
10. **Cleanup:** удалять в обратном порядке с проверкой borrowers и external volumes.

Сквозной пример: general и isolated pools

Представим платформу для coding agents. Большинство sessions можно запускать в gVisor на общем node pool. Отдельные customers требуют microVM. Platform team создаёт два SandboxConfig и два WorkerPool с labels `isolation=standard` и `isolation=strong`. Application team публикует два ActorTemplate, потому что sandbox class и snapshot compatibility являются частью версии workload.

Для обычного Actor template selector требует `isolation=standard`. Для regulated Actor - `isolation=strong` и microVM config. Per-Actor selector может дополнительно потребовать `region=eu`, но не может отправить microVM Actor в gVisor pool. Если eu microVM capacity закончилась, правильный результат - bounded waiting или capacity error, а не тихий fallback на более слабую изоляцию.

Когда support engineer готовит воспроизводимый workspace, он suspend'ит Actor и создаёт Atespace-scoped Tag. Для передачи baseline другой команде создаётся отдельный PUBLISHED Tag после проверки, что snapshot не содержит customer secrets. Storage policy выдаёт runtime второй команды read access к source prefix. После того как clone сделал собственный suspend, borrowed dependency можно удалить по retention policy.

Этот пример показывает, что выбор инструмента выражается несколькими ресурсами: Atespace отвечает за logical ownership, WorkerPool - за capacity, SandboxConfig - за runtime bytes, ActorTemplate - за immutable workload contract, Actor - за lifetime, а Tag - за retention и cloning. Попытка поместить всё в один объект сделала бы границы доступа и обновления неявными.

GPU reservation пока не означает GPU внутри Actor

Текущая API guide отдельно предупреждает: device pass-through для Actors временно не поддержан. Extended resource `nvidia.com/gpu` в WorkerPool может поставить Worker Pod на GPU node и зарезервировать устройство, но Substrate не передаст его Actor sandbox. Для GPU workload нужен отдельный подтверждённый integration path; одного pool limit недостаточно.

Кто за что отвечает

Решение	Platform team	Application team	Control plane
Sandbox runtime/assets	SandboxConfig, node capabilities	Выбирает разрешённый class	Проверяет match
Warm capacity	WorkerPool replicas/resources/labels	Объявляет Actor limits	Bin-packing и assignment
Workload version	Registry policy	ActorTemplate, image digest, probes	Golden workflow/status
Tenant scope	Authorization/storage policy	Atespace references	Validation и lifecycle
Snapshot retention	Bucket lifecycle/backup	Tag semantics	Owner references и garbage collection
Instance lifecycle	Capacity/SLO	Create/update/resume/suspend intent	State machine и status

Антипаттерны

- **Считать Atespace Kubernetes namespace.** Это ломает ожидания RBAC и placement.
- **Матчить Pod labels вместо WorkerPool labels.** Actor selector не увидит `spec.template.labels`.

- **Использовать mutable image tag.** Golden/cold boot становятся невозпроизводимыми.
- **Редактировать template как Deployment.** Snapshot остаётся связан со старым code/runtime.
- **Не задавать Actor limits.** Runtime defaults и unconstrained dimensions скрывают capacity risk.
- **Писать status вручную.** Lifecycle изменяется RPC, а не patch поля.
- **Retriable update без re-read.** Повтор с устаревшей version снова конфликтует или стирает intent.
- **Удалять Tag сразу после clone.** Clone может всё ещё заимствовать snapshot.
- **Строить snapshot URI по имени.** Ownership основан на UID и server-generated IDs.
- **Публиковать Tag без storage policy.** Reference доступна, bytes нет.

Production checklist ресурсной модели

- Документировано, какие объекты идут через Kubernetes API, а какие через ate API.
- Atespace naming не выдаётся за authorization без реальной policy.
- WorkerPool labels отделены от Pod template labels.
- Pool pinned к `ate.dev/substrate-version` и sandbox class.
- Worker capacity учитывает CPU, RAM, actor slots, fragmentation и failure headroom.
- SandboxConfig assets и pause image content-addressed.
- ActorTemplate images pinned digest; limits и wakeup probes протестированы.
- Snapshot scopes выбраны осознанно, а storage prefix имеет per-Atespace policy.
- Automation ждёт golden snapshot Ready.
- Actor updates выполняются read-modify-write с UID/version.
- Tag borrowers обнаруживаются до deletion.
- Logs и audit сохраняют UID, version и ссылки на operation, а не только human name.

Итог

Ресурсная модель Substrate связывает два мира. Kubernetes описывает физическую ёмкость и runtime assets через WorkerPool и SandboxConfig. Ate API описывает logical scope, workload version, Actor lifetimes и snapshot retention через Atespace, ActorTemplate, Actor и Tag. Worker records соединяют declarative capacity с фактическим состоянием dataplane.

Главная мысль - ownership и version важнее красивого имени. Template UID определяет происхождение snapshot, Actor UID отделяет одну lifetime от другой, resource version защищает от гонок, Tag владеет отдельной immutable copy, а pool labels задают eligibility независимо от Kubernetes namespace. Если эти связи явны, rollout и cleanup можно автоматизировать. Если скрыты, ошибки проявятся только во время restore или удаления.

Следующая глава разбирает самую дорогую часть этой модели: что именно происходит при pause, suspend и resume, как отличаются Full и Data snapshots, где проходит durable commit boundary и какое состояние невозможно восстановить из process checkpoint.

Источники и дальнейшее чтение

- [Substrate API guide](#)
- [Agent Substrate glossary](#)
- [Agent Substrate architecture](#)
- [ate API resource definitions](#)
- [Substrate API style guide](#)
- [Rolling upgrade runbook](#)

Lifecycle stateful Actor: pause, suspend, resume и восстановление

STATE MACHINE

DURABILITY BOUNDARY

FAILURE SEMANTICS

В главе 13 мы собрали ресурсную модель Substrate: Actor получает identity, ActorTemplate задаёт исполняемую среду, WorkerPool предоставляет capacity, а snapshot всегда имеет конкретного владельца. Теперь разберём главное следствие этой модели: что происходит с Actor между запросами и где проходит граница долговечности.

Фраза «поставить процесс на паузу и потом продолжить» слишком проста для production. Нужно различать checkpoint на локальном диске node, durable snapshot в object storage, cold boot из image, восстановление process memory и откат к последней подтверждённой точке. Эти пути имеют разную стоимость и разные последствия при отказе.

Что читатель должен унести из главы

- чем `PauseActor` отличается от `SuspendActor` и когда выбирать каждый путь;
- как `Full` и `Data` scopes меняют resume semantics;
- как выбирается источник resume: local, external, golden snapshot или cold boot;
- почему checkpoint не делает TCP sessions, leases и external volumes транзакционными;
- как `RevertActor` восстанавливает доступность ценой отката;
- какие метрики и fault-injection tests нужны до aggressive hibernation.

Lifecycle - это state machine, а не набор команд

Control plane фиксирует переходное состояние до дорогой операции. Благодаря этому повторный вызов может продолжить workflow после timeout или restart. Клиенту важно перечитывать `Actor.status`, а не считать сетевой ответ единственной правдой.

Состояние	Смысл	Обычное действие
SUSPENDED	Actor не выполняется; durable snapshot готов или Actor ещё не запускался	Resume, update, delete
RESUMING	Выбирается Worker, подключаются volumes, выполняется restore/boot	Ждать или повторить resume
RUNNING	Sandbox активен и обслуживает трафик	Работа, pause, suspend, revert

Состояние	Смысл	Обычное действие
PAUSING	Создаётся node-local checkpoint	Ждать или повторить pause
PAUSED	Checkpoint хранится на node, worker assignment освобождён	Resume на той же node или suspend
SUSPENDING	Checkpoint создаётся или загружается в object storage	Ждать или повторить suspend
CRASHED	Текущая execution потеряна или wake workflow завершился ошибкой	Revert, затем resume
REVERTING	Уничтожается текущий sandbox и partial state	Ждать или повторить revert
DELETING	Удаляются runtime, volumes и owned snapshots	Повторить delete с guards

Стабильные состояния - SUSPENDED, PAUSED, RUNNING и CRASHED. Остальные описывают workflow. Если Actor долго остаётся в переходе, не редактируйте status вручную: определите незавершённый шаг и повторите публичную операцию либо выполните контролируемый revert.

Как выбрать операцию

Задача	Операция	Состояние хранится	Компромисс
Коротко освободить Worker и быстро вернуться	PauseActor	На node	Быстро, но не durable
Пережить потерю Worker/node	SuspendActor	В object storage	Upload/download и I/O
Запустить из последней точки	ResumeActor	Local, external, golden или none	Путь зависит от scope
Отбросить ошибочную execution	RevertActor	Последний completed external snapshot	Изменения после него теряются
Удержать точку дольше следующего suspend	CreateTag	Отдельная tag-owned копия	Хранение и отдельный owner

Что именно попадает в snapshot

Scope отвечает за состав checkpoint, а операция - за место хранения. Pause оставляет файлы на node, suspend загружает их в object storage.

Scope	Что сохраняется	Resume	Когда выбирать
Full	Process memory, writable rootfs delta и DurableDir	Продолжение memory state	Дорогая инициализация, in-memory progress

Scope	Что сохраняется	Resume	Когда выбирать
Data	Snapshot-capable volumes, прежде всего <code>DurableDir</code>	Fresh containers + восстановленные данные	Restartable process и меньший snapshot

`snapshotConfig.onPause` задаёт scope локального checkpoint, `onCommit` - durable snapshot. `onCommit` обязан быть подмножеством `onPause`:

```
onPause=Full, onCommit=Full -> hot local и hot durable resume
onPause=Full, onCommit=Data -> hot pause, дешёвый durable suspend
onPause=Data, onCommit=Data -> process стартует заново после lifecycle
```

`onPause=Data, onCommit=Full` невозможен: после Data pause память уже не сохранена. Если Actor paused с Data checkpoint, Full commit отклоняется до изменения состояния, чтобы Actor оставался resumable.

Full или Data

Full оправдан, если память содержит дорогое состояние: загруженную модель, compiled graph, interpreter session или agent loop. Но он больше, сильнее связан с runtime и template UID и создаёт I/O burst. Data лучше, когда entrypoint умеет реконструировать execution из файлов и durable records. Такой контракт проще тестировать.

Правило. Начинайте с Data, если есть хороший restart protocol. Выбирайте Full, когда измеренная цена повторной инициализации или потери in-memory progress оправдывает более тяжёлый snapshot.

Golden snapshot: оптимизация первого запуска

Golden snapshot - published Tag, созданный один раз для ActorTemplate. Controller запускает временный Actor в `ate-golden`, ждёт готовности, делает Full suspend, копирует snapshot в tag-owned storage и записывает ссылку в template status.

1. Cold boot digest-pinned image с выбранным `SandboxConfig`.
2. Общая инициализация: libraries, read-only assets, runtime caches.
3. Ожидание `wakeupProbe`; если probe есть не у всех containers, применяется warm-up interval.
4. Full checkpoint независимо от обычного `onCommit`.
5. Создание published Tag, удаление временного Actor, Ready status.

Actor, созданный до готовности golden tag, может получить пустой `externalSnapshot` и впервые пойти через cold boot. Позднее появление golden snapshot не перепривязывает его автоматически. Поэтому Ready должен быть deployment gate.

В golden snapshot безопасно помещать общие libraries и read-only assets. Per-Actor secrets, tenant identity, уникальные leases и живые внешние соединения должны появляться после

clone/resume. Иначе все клоны получают одну замороженную identity или протухший credential.

Resume: четыре источника одного перехода



ResumeActor переводит Actor в `RUNNING`, но внутри это разные пути. Control plane читает status/template, создаёт и подключает external volumes, выбирает Worker, просит atelelet восстановить workload и только после готовности фиксирует assignment.

Источник	Когда	Фактический запуск
Node-local snapshot	<code>PAUSED</code> , local checkpoint имеет приоритет	Restore на node snapshot
Actor external snapshot	Есть собственный suspend	Full restore или Data + fresh boot
Borrowed Tag/golden	Actor создан из Tag или template golden	Restore общей immutable точки
Snapshot отсутствует	Golden не был готов или source не задан	Cold boot из image

Пошаговый resume

- Если Actor уже `RUNNING`, вызов является no-op и возвращает `resumed=false`.
- Lease сериализует lifecycle, чтобы два запроса не назначили два Workers.
- Выбираются source, scope и совместимость template UID.
- Пепесекаются sandbox class, selectors и свободные CPU/RAM/slots.
- Создаются/подключаются external volumes.
- Atelet выполняет restore либо cold boot.
- Все объявленные wakeup probes должны вернуть HTTP 200.
- Status становится `RUNNING` с `workerAssignment`.

Если snapshot создан под другим ActorTemplate UID, memory image нельзя считать совместимой. При разрешённом update Substrate может восстановить durable data, но запустить guest заново. Это migration path, а не hot resume; SLO должен различать эти случаи.

Wakeup probe определяет смысл «готов»

Без probe успешный resume означает, что container process запущен, но application может ещё не слушать порт. С probe RPC ждёт HTTP 200 от каждого container с probe. Default timeout - 30 секунд. Ошибка переводит Actor в `CRASHED`; перед следующим resume нужен revert.

Probe является one-shot gate, а не постоянной readiness check. Он должен проверять локальную готовность, не весь downstream graph. Иначе сбой внешней базы превратит готовые Actors в crashed.

Request parking скрывает wake latency, но не отменяет её

Router может удерживать первый запрос и объединять несколько конкурентных запросов вокруг одного in-flight resume. Но assignment, download, restore, probe и tunnel всё равно входят в latency budget. Подробности routing будут в следующей главе.

Pause: быстрый checkpoint с node affinity

`PauseActor` создаёт checkpoint локально на node. После завершения assignment очищается, volumes отсоединяются, а status хранит `localSnapshot` с node и snapshot name. Следующий resume возвращается к этой node.

Pause экономит object-storage upload и полезен для короткого idle interval. Но это performance tier, не durability tier. Потеря node или очистка локального диска уничтожают точку. Recovery тогда опирается на предыдущий external snapshot через revert, а всё после него теряется.

Свойство	Pause	Suspend
Хранение	Node-local	Object storage
Placement	Snapshot node	Любой совместимый Worker
Потеря node	Не переживает	Переживает
Цена	Локальный checkpoint	Checkpoint + upload/download
Idle horizon	Короткий	Долгий/неопределённый

Pause, затем suspend

Paused Actor можно suspend'ить без повторного запуска. Control plane загружает local snapshot и при необходимости сужает Full до Data:

RUNNING

```
-> short idle: PauseActor (Full, local)
-> idle continues: SuspendActor (Data, external)
-> later ResumeActor: fresh process + restored DurableDir
```

Такой tiered policy даёт быстрый возврат в первые минуты, но не хранит memory image для сессий, которые не вернулись.

Suspend: durable commit и освобождение Worker

`SuspendActor` принимается из `RUNNING` и `PAUSED`. В первом случае Worker создаёт checkpoint и отправляет его в actor-owned URI. Во втором готовый local checkpoint загружается в object storage.

1. Зафиксировать `SUSPENDING` и `inProgressSnapshotUri`.
2. Создать checkpoint или взять local snapshot.
3. Записать manifest и objects в storage.
4. Отсоединить volumes и освободить Worker.
5. Сделать новый snapshot текущим, очистить in-progress fields, перейти в `SUSPENDED`.
6. Освободить предыдущий actor-owned snapshot; borrowed Tag не удалять.

Actor владеет одним текущим external snapshot. Следующий успешный suspend заменяет его. Если точка должна жить дольше, пока Actor suspended создают Tag.

Зачем status показывает in-progress URI

Upload может оборваться после записи части objects. Persisted destination делает retry re-entrant: workflow продолжает тот же URI, а revert удаляет partial snapshot. Предыдущий `externalSnapshot` остаётся последней подтверждённой точкой, пока commit не завершён. После timeout перечитайте Actor: операция могла успешно завершиться или остаться в переходе.

Revert: доступность ценой отката

`RevertActor` принимается из `RUNNING`, `PAUSED` и `CRASHED`. Он уничтожает текущий sandbox, освобождает Worker, отбрасывает local и partial snapshots, сохраняя последний completed external snapshot. Итог - `SUSPENDED`.


```
CRASHED / RUNNING / PAUSED
-> RevertActor
-> discard current execution and partial checkpoint
-> keep last completed external snapshot
-> SUSPENDED -> ResumeActor
```

Revert - controlled rollback. Если durable commit был час назад, час изменений process memory/rootfs потеряется. Automation может делать revert автоматически только при явно принятом RPO.

External volumes не откатываются

External CSI volumes не входят в Actor snapshot. После revert память/rootfs могут вернуться в прошлое, а volume или database остаться в будущем. Нужны idempotency keys, versioned records, transactional outbox или reconciliation. Substrate checkpoint не является распределённой транзакцией.

Что snapshot не обещает сохранить

TCP sessions

Memory image может содержать file descriptor, но remote endpoint не обязан сохранять соединение. NAT, load balancer и server timeout могли истечь. После resume приложение должно переподключиться.

Credentials, DNS и leases

Token может протухнуть, DNS answer измениться, lease перейти другому владельцу. После resume обновляйте credentials и перепроверяйте ownership.

External side effects

Crash между внешним действием и checkpoint создаёт неопределённость. Повтор после revert способен выполнить действие дважды. Нужны idempotency key, deduplication record и reconcile по external operation ID.

Eviction и окно потери данных

При удалении Worker Pod текущий graceful path посылает Actor SIGTERM и оставляет до 30 минут для suspend. Если commit не завершён, Actor становится CRASHED, а всё после предыдущего external snapshot теряется. Это grace period, не гарантия: node может исчезнуть сразу.

RPO определяется максимальным временем между успешными durable snapshots. Actor, running несколько часов, имеет несколько часов потенциальной потери, даже если обычно suspend'ится в конце задачи.

Workload	Подход	Почему
Короткая сессия	Suspend в конце	Повтор работы приемлем
Долгий agent job	Application checkpoints + lifecycle commits	Ограничивает RPO
Финансовое действие	External log + idempotency	Snapshot не доказывает external commit
Warmed model	Golden Full + Data commits	Общий warm state, меньше durable memory

AX nuance: workspace durable, process reconstructable

В AX runner восстановление `/workspace` не гарантирует продолжение того же process tree. Task должен иметь явные checkpoints: plan, tool results, patch state и finalization marker. Хороший agent пишет durable intent до внешнего действия и result после него.

```
step-042.intent.json -> operation_id и ожидаемое действие
step-042.result.json -> подтверждённый результат/reference
checkpoint.json      -> последний завершённый step

resume: read checkpoint -> reconcile dangling intents -> continue
```

Этот protocol полезен и при Full snapshot: memory ускоряет happy path, журнал защищает от eviction, migration и revert.

Сквозной сценарий: coding Actor

1. Golden snapshot содержит language server и общие tool binaries.
2. Первый request делает Full resume из golden.
3. После короткого idle Actor уходит в Full pause на node.
4. Если idle продолжается, paused Actor suspend'ится с Data scope: workspace durable, memory отброшена.
5. Через сутки fresh process восстанавливает workspace и читает journal.
6. После crash revert возвращает последний Data snapshot, journal помогает reconcile tool calls.

Golden решает цену первого boot, pause - короткий idle, suspend - durability, journal - business correctness, revert - recovery.

Observability: измерять путь, а не одну latency

Сигнал	Что показывает
Actors по state и возрасту	Застрявшие transitions и crash rate
Resume latency по source/scope	Local, Full, Data и cold boot
Snapshot bytes/upload duration	I/O cost и storage pressure
Probe timeout	Startup failure или плохой readiness contract
Revert count/rollback age	Recovery frequency и реальный RPO
Cold boot despite golden	Проблемы Ready gate или IAM

```
wake_latency = parking + lease_wait + assignment + volume_attach
               + download_or_boot + restore + probe + tunnel
```

Fault-injection plan

1. Оборвать RPC во время resume и доказать отсутствие второго assignment.
2. Убить control plane после записи in-progress URI и повторить suspend.
3. Прервать upload, затем revert и проверить cleanup.
4. Потерять node с paused Actor и восстановиться из external snapshot.
5. Дать probe timeout, увидеть `CRASHED`, выполнить revert/resume.
6. Сменить совместимый template и проверить Data fallback вместо memory restore.
7. Проверить external volume после revert на temporal mismatch.

Антипаттерны

- **Pause считать durable.** Node-local checkpoint не переживает потерю node.
- **Full считать транзакцией.** External systems остаются снаружи.
- **Retry без чтения status.** Timeout мог скрыть успех.
- **Probe всей системы.** Downstream outage создаёт crashed Actors.
- **Долгий RUNNING без commits.** Eviction grace не задаёт RPO.
- **Обновлять template и ждать hot restore.** Другой UID меняет compatibility path.
- **Хранить per-Actor secret в golden.** Клоны разделят credential.

Production checklist lifecycle

- Для template выбраны `onPause/onCommit` и объяснён выбор.
- Измерены `size`, `upload`, `restore` и `cold boot`.
- Определены idle horizons `RUNNING -> PAUSED -> SUSPENDED`.
- `Template Ready` является gate для `CreateActor`.
- `Probe` проверяет локальную готовность.
- Приложение переподключает `clients` и обновляет `credentials`.
- `External side effects` имеют `idempotency/reconciliation`.
- `RPO` задаётся частотой `durable checkpoints`.
- `Dashboards` разделяют `local`, `Full`, `Data`, `golden` и `cold boot`.
- `Fault injection` покрывает `restart`, потерю `node` и `partial upload`.

Итог

`Pause` быстро освобождает `Worker`, но привязывает `Actor` к `node-local checkpoint`. `Suspend` создаёт переносимую `durable` точку. `Resume` выбирает `local`, `actor-owned`, `borrowed golden snapshot` или `cold boot`. `Revert` возвращает последнюю подтверждённую точку, но не откатывает внешний мир.

Инженер выбирает `consistency model`: что можно потерять, как долго хранить `memory`, где проходит `idempotency boundary` и какой `latency budget` доступен первому запросу. В следующей главе проследим этот запрос через `routing`, `request parking`, `mTLS tunnel` и `egress`.

Источники и дальнейшее чтение

- [Substrate API guide](#)
- [Agent Substrate architecture](#)
- [Agent Substrate glossary](#)
- [Request parking design](#)
- [Rolling upgrade runbook](#)
- [ate API lifecycle definitions](#)

Substrate networking: routing, request parking и безопасный egress

ACTOR-AWARE ROUTING

BOUNDED PARKING

DEFAULT-DENY EGRESS

В главе 14 Actor исчезал с Worker и появлялся снова, сохраняя logical identity. Теперь проследим сетевой путь. Клиент не может обращаться к Pod IP: Actor может быть suspended, перейти на другую node или получить новый Worker. Router должен разрешить logical Actor в текущее назначение, при необходимости дождаться resume и только затем открыть защищённый tunnel.

В обратную сторону действует другой контракт. Код агента считается недоверенным и не должен свободно выходить в интернет. Egress path перехватывает соединение, подтверждает identity Actor и применяет его policy. Ingress решает «куда доставить запрос», egress - «куда этому Actor разрешено обратиться». Смешивать эти задачи опасно.

Что читатель должен унести из главы

- почему `ate-target-actor` является routing key, но не заменяет caller authorization;
- как Envoy, `atenet-router`, `ate API`, Worker и `atunnel` образуют ingress path;
- что request parking сглаживает краткий дефицит capacity, но не создаёт capacity;
- как per-Actor flight registry предотвращает resume storm;
- почему egress policy должна быть default-deny и как различаются HTTP, HTTPS и TLS passthrough;
- как credential injection не допускает secret внутрь Actor и snapshot;
- какие positive/negative probes нужны после каждого изменения policy.

INGRESS

```
Client -> atenet-router -> ate-api Resume/Assign -> mTLS atunnel -> Actor
      | park/retry when transient capacity is unavailable |
```

EGRESS

```
Actor -> atunnel (original destination) -> Egress PEP -> authorized upstream
      identity + policy + effects
```

Стабильная identity вместо Pod address

Ingress request указывает Actor заголовком `ate-target-actor: <atespace>/<actor>`. Host остаётся application authority и не выбирает Actor. Router проверяет формат, обращается к control plane и получает текущий `workerAssignment`. Если Actor suspended, этот же lookup запускает resume.

Actor name удобен для маршрутизации, но lifetime определяется UID. Удалённый и заново созданный Actor с тем же именем - другой объект. Long-lived authorization, audit и certificate validation должны сверять UID, иначе имя можно случайно принять за непрерывную identity.

Security boundary. Заголовок сообщает router, куда направить запрос. Он не доказывает, что caller имеет право обращаться к Actor. Caller authentication и authorization должны выполняться upstream или отдельным policy layer; сам пользовательский заголовок нельзя считать разрешением.

Ingress path: от первого байта до Actor

1. Client отправляет HTTP request в Envoy перед `atenet-router`.
2. Envoy передаёт headers внешнему processor через `ext_proc`.
3. Router извлекает Actor ref и вызывает `ResumeActor`.
4. Control plane возвращает текущий assignment либо назначает Worker и восстанавливает Actor.
5. Router открывает authenticated TLS tunnel к `atunnel` на Worker port 443.
6. `atunnel` пересылает request в private veth Actor.
7. Response проходит назад по тому же tunnel.

Worker Pod port 80 не является прямым ingress Actor. Обход router лишил бы систему resume, assignment lookup и actor-aware authentication. NetworkPolicy должна запрещать такой обход, а observability - различать router traffic и неожиданные прямые connections.

Почему routing нельзя построить на Kubernetes Service

Kubernetes Service хорошо маршрутизирует к набору взаимозаменяемых Pods. Здесь нужен конкретный logical Actor, который может вообще не иметь Pod. Его placement меняется при каждом resume и фиксируется control plane атомарно, без ожидания reconciliation Service/EndpointSlice. Поэтому Substrate использует собственный mapping Actor -> Worker.

Request parking: bounded wait вместо мгновенного 503

Oversubscription означает, что Actors больше, чем свободных Workers. Во время burst scheduler может вернуть `ResourceExhausted`, хотя через сотни миллисекунд другой Actor suspend'ится и освободит capacity. Request parking удерживает входящий request и повторяет resume с backoff вместо немедленного 503.

По умолчанию park budget равен 5 секундам, parking lot допускает 1024 parked requests. Retryable считаются `ResourceExhausted`, transient `FailedPrecondition`, `Unavailable` и concurrent `Aborted`. `NotFound`, authentication/authorization errors и обычный deadline fail fast.

Resume result	Router behavior	HTTP смысл
OK	Route к Worker	Продолжить исходный request
Aborted	Retry	Конкурентный lifecycle
ResourceExhausted	Park + retry	Временный дефицит capacity
FailedPrecondition	Park + retry	Actor в переходном состоянии
Unavailable	Park + retry	Краткий сбой control plane
NotFound	Fail fast	404
PermissionDenied/Unauthenticated	Fail fast	403/401
DeadlineExceeded	Fail fast	504

Budget ограничивает новые retries, а не начатый restore

Если budget закончился, router перестаёт начинать новые попытки. Уже выполняющийся resume не отменяется: control plane мог назначить Worker и загружать snapshot. Router ждёт его реальный результат в пределах server-side RPC deadline и Envoy `ext_proc` timeout. Поэтому request иногда обслуживается позже park budget. Это лучше, чем отменить почти завершённый restore и оставить дорогой workflow без клиента.

Один Actor - один resume flight

Конкурентные requests одного Actor присоединяются к единому in-flight `ResumeActor`. Они занимают отдельные parking slots, но не создают resume storm. Budget принадлежит flight: поздний request получает только оставшееся время, поэтому может увидеть `budget_exhausted` раньше пяти секунд собственного ожидания.

Parking lot - backpressure, а не очередь без границ

Slot берётся только после первой retryable ошибки. Fast-path request к running Actor lot не использует. При заполнении новые parked requests получают 503 `router at capacity`. Envoy

circuit breaker по умолчанию рассчитывается как удвоенный размер lot, минимум 1024: одна часть для parked streams, вторая сохраняет headroom быстрым запросам.

```
parking capacity plan:
  parked_request_max <= ext_proc max_requests
  fast_path_headroom remains available
  client timeout > expected park + restore
  park budget < upstream end-to-end deadline
```

Graceful shutdown

При SIGTERM router и Envoy sidecar продолжают обслуживать in-flight ext_proc streams до drain deadline. Он должен быть не меньше park budget. Иначе rolling update сам создаст сбросы parked requests.

Нестандартные ingress ports

Для Actor port, отличного от default 80, клиент использует HTTP CONNECT с port в authority. Router завершает CONNECT и проводит HTTP(S) traffic через тот же actor-aware path. Каждый request внутри long-lived tunnel снова может разрешить assignment после relocation.

Это не универсальный TCP проху. Сейчас arbitrary-port path поддерживает HTTP(S); raw TCP и другие protocols таким способом недоступны. Protocol requirement нужно проверить до выбора Substrate, а не после переноса workload.

Worker tunnel и mTLS

После assignment router соединяется с atunnel на Worker port 443. Tunnel аутентифицирован TLS, а Actor доступен только через private veth. Certificate и control-plane assignment связывают логическую identity с текущим runtime location.

Нельзя кэшировать Worker IP дольше lifecycle assignment. После suspend/resume Actor может оказаться в другом Pod. Любой sidecar или higher-order gateway, который запомнил старый address, должен повторить actor-aware lookup.

Egress: Actor считается недоверенным

Каждое исходящее TCP connection Actor, кроме DNS на destination port 53, перенаправляется nftables в atunnel. Он получает original destination и открывает mTLS HTTP/1.1 CONNECT к policy enforcement point. PEP проверяет Actor certificate, его UID и состояние через control plane, затем применяет EgressPolicy.

DNS по TCP/UDP 53 может обходить PEP к node-configured resolver. Остальной UDP блокируется, как и прочие IP protocols. Actor networking сейчас IPv4-only. Это конкретный product contract, а не общая «сетевость контейнера».

Почему PEP не доверяет SNI и Host от Actor

Actor контролирует HTTP headers и TLS ClientHello. SNI может быть policy input, но не доказательством, что connection действительно идёт к этому hostname. Если policy разрешает имя, gateway должен сам разрешить и dial'ить разрешённое имя, а не авторизовать произвольный original IP только потому, что Actor прислал подходящий SNI.

EgressPolicy: allow rules, default deny

EgressPolicy является nested resource конкретного Actor. У Actor может быть максимум одна policy с именем default. Rules - unordered allow set; если ни одно правило не совпало, traffic запрещён. Policy имеет UID/version и обновляется read-modify-write, как другие ate resources.

Rule	Что видит gateway	TLS	Effects
http	Каждый cleartext HTTP request, authority и port	Нет	Возможна замена headers
https	SNI, затем decrypted HTTP requests	Gateway MITM и re-origination	Header replacement/credential injection
tlsPassthrough	ClientHello SNI и port один раз	Без расшифровки	Нет

Exact hostname сильнее wildcard; explicit port сильнее all ports. Конфигурации, где два rules одинаково решают один name/port, отклоняются. Wildcard *.example.com покрывает ровно один label: он не включает example.com и a.b.example.com.

Поддерживаемый egress traffic

Traffic	Поддержка	Отказ виден Actor
HTTP/1.1, HTTP/2, gRPC over HTTP/2	Через policy	403
HTTPS с interception или TLS passthrough	Через соответствующий rule	403/TLS failure
WebSocket	Блокируется	403
Forward-proxy CONNECT	Блокируется	403
Другой TCP	Блокируется	Connection закрывается
UDP 53 DNS	Разрешён к node resolver	Обычный DNS
Другой UDP/protocol	Drop	Ожидание до client timeout

Пример policy

```
metadata:
  atespace: team-a
  name: default
rules:
- https:
  hostnames: ["api.example.com"]
  ports:
    numbers: [443]
- tlsPassthrough:
  hostnames: ["models.example.net"]
  ports:
    numbers: [443]
- http:
  hostnames: ["otel-collector.ate-system.svc"]
  ports:
    numbers: [4318]
```

Policy должна перечислять также telemetry endpoints. OpenTelemetry SDK внутри Actor является обычным egress client и не достигает collector без разрешающего rule.

HTTPS interception и trust bundle

`https` rule требует расшифровать HTTP, поэтому gateway выдаёт leaf certificate для SNI и устанавливает новый TLS session к upstream. Actor обязан доверять gateway CA через projected trust bundle. Без него TLS validation внутри Actor должна завершиться ошибкой; отключать verification нельзя.

`tlsPassthrough` сохраняет end-to-end TLS до origin, но gateway видит только ClientHello. Он не может заменить headers или проверять каждый HTTP request. Policy update начинает действовать для нового connection; уже открытый passthrough tunnel может жить до закрытия.

Credential injection: secret не входит в Actor

Для HTTPS API policy может заменить placeholder header реальным credential. Actor отправляет, например, `Authorization: placeholder`. Gateway спрашивает credential provider, provider проверяет actor identity/atespace и читает secret store, затем gateway подставляет значение перед отправкой upstream. Actor никогда не получает secret, поэтому не может прочитать, записать в snapshot или exfiltrate его.

```
- https:
  hostnames: ["api.example.com"]
  effects:
    replaceHeaders:
      - header: Authorization
        prefix: "Bearer "
        credentialUri: ate-secret://k8s.io/default/ns1/api/token
```

Отсутствующий placeholder означает «не запрашивать credential» и request идёт без замены. Если header есть, но provider отключён, secret не найден, Actor не авторизован или provider недоступен, gateway fail closed: обычно 403 для постоянного отказа и retryable 503 для временной недоступности.

Reference Kubernetes provider использует default-deny mapping Atespace -> разрешённые namespaces. Cluster-wide permission читать Secrets у provider не означает, что любой Actor может получить любой Secret; provider обязан применить actor-scoped authorization.

Policy rollout и consistency

Egress gateway может кэшировать policy, поэтому update действует не мгновенно. Long-lived TLS passthrough connection также сохраняет решение до reconnect. Runbook должен учитывать cache TTL и принудительное закрытие connections, когда требуется срочный revoke.

Readiness gateway подтверждает, что компоненты и configuration загрузились. Она не доказывает end-to-end доступность конкретного hostname, корректность DNS, CA chain или credential provider. После deployment нужны probes из реального sandbox.

Как тестировать ingress и egress

Ingress probes

- running Actor: fast path без parking;
- suspended Actor: первый request переживает resume;
- несколько requests одного Actor: один resume flight;
- pool saturation: served within budget и budget-exhausted 503;
- unknown Actor: 404 без parking;
- rolling restart router: parked stream получает нормальный verdict.

Egress probes

- разрешённый DNS и HTTPS hostname;
- запрещённый hostname и тот же IP с поддельным SNI;
- wildcard boundary: один label, apex и nested name;
- TLS validation через projected gateway CA;

- credential placeholder: успешная замена и отрицательный atespace;
- UDP/TCP protocol, который workload реально использует;
- telemetry, model endpoint и MCP endpoint отдельно;
- revoke policy на новом и уже открытом connection.

Observability и capacity signals

Сигнал	Что означает	Действие
<code>parking.active</code>	Текущий demand сверх мгновенной capacity	Смотреть длительность и pool saturation
<code>parking.wait.duration</code> by outcome	Served, budget exhausted, canceled, timeout, error	Разделять capacity и client cancellation
<code>parking.rejected</code>	Parking lot заполнен	Scale router и проверить burst/circuit breaker
Resume latency	Причина задержки первого request	Коррелировать с главой 14
Egress denies by actor/rule	Policy gap или атака	Не разрешать wildcard без расследования
Credential provider 403/503	Authorization или availability	Разные alerts/runbooks
Tunnel TLS failures	Identity/CA/certificate rotation	Проверить обе стороны mTLS

Capacity lesson. Большой parking lot скрывает burst, но удерживает memory и ext_proc streams. Если budget_exhausted растёт постоянно, проблема не в размере очереди: WorkerPool или suspend rate не соответствуют demand.

Антипаттерны

- **Маршрутизировать по Pod IP.** Address устаревает после каждого relocation.
- **Считать target header авторизацией.** Caller может подставить чужое имя.
- **Увеличивать park budget вместо capacity.** Ошибка превращается в долгую latency.
- **Доверять SNI как доказательству destination.** Actor контролирует ClientHello.
- **Разрешать * для удобства.** Default-deny исчезает именно там, где agent способен exfiltrate данные.
- **Отключать TLS verification для interception.** Нужно проецировать gateway CA.
- **Класть API keys в env Actor.** Они попадут в memory/snapshot и доступны недоверенному коду.
- **Проверять policy только с admin Pod.** Реальный path из sandbox другой.

Production checklist networking

- Ingress принимает logical Actor ref и не использует Worker address как identity.
- Caller authorization выполняется до или независимо от routing.
- Park budget, lot size, ext_proc breaker и client deadline согласованы.
- Fast-path headroom остаётся при заполненном parking lot.
- Router drain timeout не меньше park budget.
- Worker ingress доступен только через authenticated tunnel.
- У каждого Actor есть минимальная default-deny EgressPolicy.
- Выбран правильный rule: http, https interception или tls passthrough.
- Gateway CA доступен только workload, которым нужен HTTPS interception.
- Secrets выдаёт credential provider с actor-scoped authorization.
- Positive и negative probes выполняются из обоих sandbox classes.
- Dashboards разделяют parking capacity, lifecycle errors и egress denies.

Итог

Substrate networking связывает стабильную Actor identity с меняющейся execution. Ingress router при необходимости будит Actor, bounded parking сглаживает краткий дефицит Workers, а mTLS tunnel доставляет request только текущему assignment. Egress начинается с противоположного предположения: Actor недоверен, traffic default-deny, destination выбирает gateway, а secrets остаются у credential provider.

Эта глава завершает dataplane path. В следующей главе мы поднимемся уровнем выше и разберём AX control plane: какие решения принадлежат AX, какие делегируются Substrate и где проходит граница ответственности между продуктовым orchestration и runtime.

Источники и дальнейшее чтение

- [Agent Substrate architecture](#)
- [Request parking design](#)
- [Network egress contract](#)
- [Supported egress traffic](#)
- [Egress credential injection](#)
- [EgressPolicy API definitions](#)

AX control plane: от декларации к Actor и граница с Substrate

CURRENT MAIN VERIFIED

DIRECT RECONCILIATION

ROADMAP SEPARATED

В главах 12-15 мы смотрели на Agent Substrate снизу: как Actor получает Worker, как сохраняется его состояние и как трафик находит Actor после suspend/resume. Теперь поднимемся на продуктовый уровень. Инженеру редко хочется вручную создавать ActorTemplate, передавать в него описание workspace, управлять Actor и переводить его runtime states. Ему нужна более понятная декларация: вот задача, вот рабочая среда, вот модель, запусти это безопасно и покажи состояние.


Именно эту роль выполняет AX. Он не заменяет Substrate и не является ещё одним sandbox runtime. AX принимает продуктовый intent в виде Task, Workspace и Model, а затем переводит его в lifecycle operations Substrate. Полезная аналогия: AX отвечает за язык платформы и orchestration конкретной agent workload, Substrate - за надёжное выполнение stateful Actor на кластере.

Но аналогия с Kubernetes легко вводит в заблуждение. AX использует Kubernetes-подобные manifests и команды apply, get, watch, delete, однако его ресурсы не являются Kubernetes CRD. Они обслуживаются собственным gRPC API и хранятся в Redis. Более того, на проверенной версии current main reconciliation выполняется прямо внутри запроса ax-server. Отдельного работающего ax-controller в этой версии нет.

Что читатель должен унести из главы

- какую проблему решает AX поверх Substrate и почему эти слои нельзя смешивать;
- где находятся API contract, desired state, observed status и runtime state;
- как create, resume, suspend, delete и watch проходят через ax-server;
- почему package internal/controller не означает отдельный controller process;
- зачем AX выбрал Redis вместо Task CRD и какую цену платит за этот выбор;
- какие сбои оставляют Redis и Substrate в разных состояниях;
- почему текущая direct-execution схема удобна для ранней версии, но ограничивает масштабирование;
- что уже реализовано, а что пока существует только в roadmap.

AX Task: фактический путь current main



Сначала разделим три контракта

Сложность этой архитектуры возникает не из количества компонентов, а из того, что одно слово «задача» означает разные сущности на разных слоях.

Контракт	Что он описывает	Кто владеет
AX resource contract	Task , ссылки на Workspace , image, command, env, compute requests, debug и status	AX API и Redis
Translation contract	Как Task превращается в Atespace, ActorTemplate, Actor и lifecycle calls	TaskReconciler внутри AX
Runtime contract	Placement, Worker assignment, sandbox, durable volume, snapshot, suspend/resume и network path	Agent Substrate

AX может сказать: «эта Task должна использовать такой image и такие workspaces». Он не выбирает Worker и не восстанавливает snapshot самостоятельно. Substrate умеет запустить Actor, но не знает, что для продукта означают WorkspaceReady , цель workspace или пользовательская команда ax watch . Граница проходит не между двумя наборами процессов, а между двумя моделями ответственности.

Практическое правило. Если решение связано с продуктовым intent агента, его API и статусом - это AX. Если решение связано с безопасным размещением, остановкой, восстановлением и адресацией sandbox - это Substrate.

Компоненты current main

Компонент	Фактическая роль	Чего он не делает
ax	Читает YAML, преобразует документы в typed protobuf calls, выполняет get/watch/lifecycle команды и настраивает доступ к cluster endpoint	Не пишет CRD и не создаёт Actor напрямую

Компонент	Фактическая роль	Чего он не делает
ax-server	Обслуживает gRPC и /healthz, валидирует ресурсы, берёт locks, пишет Redis и синхронно вызывает reconciler	Не выполняет agent command
Redis	Хранит AX resources, индексы, distributed locks и Pub/Sub notifications для watch	Не является источником runtime placement и snapshots
internal/controller	Go package с TaskReconciler, включённый в процесс ax-server	Не отдельный deployment и не непрерывный queue consumer
Substrate Control API	Создаёт Atespace, ActorTemplate и Actor, выполняет resume/suspend/delete и возвращает Worker assignment	Не интерпретирует AX Workspace как продуктивную сущность
ax-task-runner	Работает внутри Actor, материализует workspaces, публикует readiness и запускает workload	Не является control plane

Название package controller здесь описывает паттерн кода, а не topology. Это важная инженерная привычка: архитектуру нельзя выводить из имени каталога. Нужно проследить wiring в cmd/ax-server/main.go. Именно там создаются Redis store, Redis locker, Substrate client и TaskReconciler, после чего reconciler передаётся API server как обычная зависимость.

Что происходит при ax apply

CLI разбирает manifest локально. Raw YAML не отправляется в server: клиент вызывает typed RPC для соответствующего kind. Для Task это CreateTask, потому что Task в текущем API immutable после создания. Workspace и Model используют update semantics.

- Validation.** Server проверяет имя и atespace как RFC 1123 labels, а также корректность workspace bindings и mount paths.
- Serialization per object.** Для ключа task/<atespace>/<name> берётся distributed lock. Параллельные create/resume/delete одной Task не должны менять lifecycle одновременно.
- Existence check.** Если Task уже есть, create завершается FailedPrecondition. Изменить immutable Task повторным apply нельзя.
- Первичная запись.** Task получает timestamp, status и phase Suspended, затем сохраняется в Redis.
- Разрешение ссылок.** Server читает из Redis перечисленные в Task объекты Workspace и передаёт их reconciler.
- Direct reconcile.** В том же RPC context AX вызывает Substrate, создаёт необходимые runtime resources и приводит Actor в suspended state.
- Status update.** Полученный status снова записывается в Redis и публикуется подписчикам watch.

Неожиданный, но принципиальный вывод: успешный `CreateTask` означает не только «спец принят». Request уже прошёл часть runtime provisioning. Поэтому latency и availability Substrate входят в latency и availability AX API. Это проще понимать и отлаживать, но оно связывает два control planes во времени.

Внутри TaskReconciler

Reconciler сначала гарантирует существование Substrate Atespace. Имя Actor всегда равно имени Task; это упрощает маршрутизацию и диагностику. Затем он формирует launch configuration: image, пользовательские env, сериализованный Task в `AX_TASK_YAML` и multi-document Workspace YAML в `AX_WORKSPACES_YAML`.

Для отличающейся конфигурации создаётся per-task ActorTemplate. Его имя включает короткий digest image и environment. Status исключён из digest, иначе каждое изменение phase создавало бы новую template и новый golden snapshot. После этого AX выполняет idempotent `EnsureActor`. Если Actor уже существует, client получает его; crashed Actor пытается revert к snapshot, а Actor в deleting state получает короткое окно на завершение удаления.

Для новой Task desired phase равен `Suspended`, поэтому созданный Actor сразу переводится в suspended state. Команда `ax resume` меняет desired phase на `Running` и снова вызывает тот же reconciler. Substrate назначает Worker и возвращает его address, а AX временно опрашивает `/readyz?check=workspace` внутри Actor. Сначала используется прямой Worker address, при наличии настройки возможен путь через atenet router.

По умолчанию readiness polling ограничен 15 секундами. Если workspace готов, AX устанавливает `WorkspaceReady=True` и `Ready=True`. Если нет, Task остаётся в phase `Running`, но обе conditions объясняют, что initialization продолжается. Это важнее простой строки phase: запущенный Actor ещё не обязательно готов выполнять пользовательскую работу.

Где заканчивается reconciliation

В проверенной версии нет фонового worker, который постоянно сравнивает Redis с Substrate. Polling выполняется только во время конкретного lifecycle RPC. Если workspace стал готов после 15-секундного окна, сам по себе Redis status не обязан обновиться немедленно: нужен следующий вызов, который снова запустит reconciliation, либо будущий механизм постоянного наблюдения.

Поэтому слово reconcile здесь следует понимать узко: это idempotent translation procedure, вызванная API operation, а не бесконечный Kubernetes-style loop. Для пользователя разница проявляется в status freshness, а для оператора - в recovery после частичного сбоя.

Desired, observed и runtime state

Данные	Где живут	Что потеря означает
Task/Workspace/Model spec	Redis	AX теряет продуктовый intent и ссылки, даже если Actor ещё существует

Данные	Где живут	Что потеря означает
Task phase/conditions/actor/ workerIP	Redis	CLI видит устаревшую или отсутствующую картину
Actor/ActorTemplate/ Atespace	Substrate control plane	Нельзя управлять runtime по одному Redis spec
Placement и Worker assignment	Substrate	AX не должен считать cached workerIP авторитетным
Durable filesystem и snapshot	Substrate storage path	Спес сохраняется, но продолжить работу с прежнего состояния нельзя
Workspace setup result	Actor volume плюс AX condition	Filesystem и отображаемый status могут временно расходиться

Redis здесь не является единственным source of truth для всей системы. Он авторитетен для AX resource record. Substrate авторитетен для runtime existence и placement. Durable storage авторитетен для содержимого state. Production runbook обязан проверять все три слоя, иначе «Task Running» легко принять за доказательство, которого оно не даёт.

Почему Redis, а не CRD на каждую Task

DESIGN.md объясняет выбор ожидаемыми миллионами короткоживущих Tasks. Kubernetes API и etcd превосходны как control plane для относительно небольшого количества декларативных infrastructure objects. Высокочастотный application state с быстрым churn создаёт другой профиль: много записей status, большие индексы, watchers, compaction и давление на общий cluster control plane.

Redis позволяет AX выбрать собственный key model, TTL для Tasks, sorted-set indexes и дешёвый Pub/Sub. В текущей реализации Task хранится отдельным JSON value, глобальный и per-atespace indexes - в sorted sets, а status update перезаписывает Task и публикует notification. Workspace и Model хранятся без TTL; Task TTL настраивается опционально и по умолчанию не задан.

Цена решения тоже реальна. CRD бесплатно получили бы Kubernetes authentication, RBAC, admission, resourceVersion, durable watch semantics, audit integration и зрелые backup procedures. Собственный API обязан реализовать или компенсировать это сам. Выбор Redis оправдан не потому, что он «быстрее вообще», а когда churn и требуемая cardinality действительно делают Kubernetes API неподходящим data path.

Watch не равен durable event log

WatchTask подписывается на Redis Pub/Sub channel конкретной Task, затем отправляет клиенту initial snapshot из Redis и последующие MODIFIED messages. Pub/Sub удобен для live UI, но сообщения не сохраняются. При разрыве соединения события между disconnect и

reconnect будут пропущены; новый initial snapshot восстанавливает текущее состояние, но не историю переходов.

Следовательно, watch подходит для «покажи, где Task сейчас», но не заменяет audit log. Если важны доказательство approvals, расход токенов, lifecycle history или расследование инцидента, события нужно отдельно писать в durable journal с idempotency key и retention policy.

Locks, idempotency и граница транзакции

Redis lock сериализует операции одной AX resource. Substrate methods стараются быть idempotent: Atespace и ActorTemplate допускают AlreadyExists, EnsureActor возвращает существующий Actor, delete отсутствующего Actor считается успехом. Эти механизмы уменьшают риск duplicate resources при retry.

Но distributed lock не превращает Redis и Substrate в одну транзакцию. Между сохранением Task и созданием Actor процесс может упасть. Actor может быть создан, а status update в Redis - не выполниться. Delete может удалить Actor, но не успеть удалить Redis record. Это нормальная проблема dual-write, и её нельзя исправить более длинным timeout.

```
possible partial states:
  Redis Task exists, Substrate Actor missing
  Redis says Suspended, Actor is Running
  Actor exists, Redis Task missing
  Actor deleted, Task remains Terminating
  WorkspaceReady=False, workspace already initialized
```

В зрелой схеме recovery выполняет постоянный reconciler: он перечисляет desired resources, сверяет observed runtime, повторяет idempotent steps и обрабатывает orphans по явной policy. Текущий direct path частично восстанавливается при повторной lifecycle operation, но не гарантирует автоматическую convergence без внешнего сигнала.

Failure matrix

Сбой	Что увидит клиент	Что проверить	Безопасное восстановление
ax-server недоступен	Все gRPC operations недоступны; Actors могут продолжать работать	Pod readiness, listener, Redis и Substrate connectivity	Перезапустить server, не удаляя Actors
Redis недоступен	Create/get/watch и locks падают	Persistence, replication, memory pressure, latency	Восстановить Redis, затем inventory diff с Substrate
Substrate API недоступен	Lifecycle RPC завершается error после записи или чтения Redis	TLS, token, service endpoint, Substrate health	Восстановить API и повторить idempotent operation

Сбой	Что увидит клиент	Что проверить	Безопасное восстановление
Server упал после CreateActor	Client видит error, Actor может существовать	Task record и Actor с тем же atespace/name	Не создавать вручную второй Actor; повторить reconcile path
Workspace readiness timeout	Phase Running, Ready False	Runner logs, Worker route, /readyz? check=workspace	Исправить setup и инициировать новый lifecycle check
Delete прерван	Task может остаться Terminating	Actor, templates и Redis record отдельно	Продолжить idempotent cleanup по UID/name policy

Масштабирование direct-execution архитектуры

API replica одновременно является lifecycle worker. Slow Substrate call, workspace readiness polling и delete wait удерживают request и goroutine. Добавление replicas увеличивает concurrency, но каждый replica должен иметь одинаковый доступ к Redis locks, Kubernetes Secrets и Substrate Control API. Балансировщик не решает contention одной Task: lock намеренно оставляет один active lifecycle operation.

Пропускную способность нужно считать не только в requests per second. Для AX важны create latency, concurrent readiness polls, длительность suspend/resume, количество locks в ожидании, Substrate API saturation и Redis write latency. Если средний resume занимает 5 секунд, сотня HTTP workers не превращает один Substrate cluster в бесконечную capacity.

Переход к отдельному asynchronous controller имеет смысл, когда требуется durable work queue, controlled concurrency, retries после падения API process и rate limiting к Substrate. Но он приносит eventual consistency, queue lag, deduplication и отдельную эксплуатацию. Выбирать его нужно по измеренному demand и recovery objectives, а не потому, что «так делает Kubernetes».

Security boundary и текущие ограничения

Substrate client поддерживает TLS, отдельный authority, CA bundle и bearer token file. Это защищает AX -> Substrate path при корректной конфигурации. На стороне пользовательского API current server создаёт обычный gRPC server без видимых authentication/RBAC interceptors и может обслуживать unencrypted HTTP/2. Следовательно, endpoint нельзя публиковать в недоверенную сеть без внешнего authenticated gateway, mTLS или эквивалентного enforcement layer.

Есть и более тонкая граница. Current reconciler помещает Gemini API key из Kubernetes Secret или server environment в ActorTemplate env. Для прототипа это работает, но secret доступен Actor и может попасть в runtime state. Production target главы 15 остаётся прежним: выдавать credential на egress gateway, не помещая его в sandbox. Roadmap AX также обещает least-privilege policies и более строгие security profiles.

Ещё один компромисс: если создание custom ActorTemplate не удалось, reconciler логирует warning и может перейти на default template. В production silent degradation опасна: Task способна стартовать с неожиданным image или environment. Платформе нужен alert на такой fallback, а для security-sensitive workloads лучше fail closed.

Что реализовано, а что пока обещано

Возможность	Статус в проверенном current main
Typed gRPC API, Redis store, Redis locks	Реализовано
Direct Task reconciliation с Substrate	Реализовано внутри ax-server
Task create/suspend/resume/delete/watch	Реализовано
Workspace readiness conditions	Реализован bounded poll во время reconcile
Отдельный ax-controller и durable queue	Не обнаружены в проверенной tree
Постоянный background convergence loop	Не обнаружен
Разделение workspace setup и task runtime на разные Actors	Roadmap
Автоматический suspend по idleness	Roadmap
Task branching, SPIFFE identity, telemetry trajectories	Roadmap
Стабильные specs и production governance	Roadmap; API имеет v1alpha1

Книга фиксирует source snapshot, а не брендовый narrative. AX прямо предупреждает, что проект активно меняется и до stable release возможны breaking changes. Перед внедрением следует повторить проверку wiring, proto и roadmap на выбранном commit.

Как диагностировать Task по слоям

1. **API.** Доступен ли /healthz, проходит ли gRPC, какой exact error code вернулся?
2. **AX record.** Есть ли Task в Redis, каковы phase, conditions, actor и workerIP?
3. **Lock.** Не зависла ли конкурирующая lifecycle operation для того же atespace/name?
4. **Translation.** Какую ActorTemplate выбрал reconciler, не было ли fallback на default?
5. **Substrate.** Существуют ли Atespace, ActorTemplate и Actor, каков Actor state и assignment?
6. **Runner.** Отвечает ли workspace ready probe, что говорят setup logs?
7. **Storage.** Существует ли durable volume/snapshot, если Task должна пережить suspend?
8. **Network.** Работает ли actor-aware route, не используется ли устаревший workerIP?

Такой порядок не даёт перескочить сразу к Worker logs, когда на самом деле Task не прошла validation, и не заставляет чинить Redis, когда проблема в runner readiness.

Антипаттерны

- **Называть package отдельным service.** Deployment topology проверяется по entrypoint и manifests.
- **Считать успешную запись в Redis запущенной Task.** Runtime provisioning может ещё не завершиться.
- **Считать phase Running готовностью.** Для работы нужно `Ready=True`, а не только назначенный Worker.
- **Использовать watch как audit log.** Redis Pub/Sub не хранит пропущенные события.
- **Backup только Redis.** Спец без Actor state и snapshot не восстанавливает работу.
- **Backup только Substrate.** Runtime без AX intent превращается в orphan.
- **Retry create новым именем.** Сначала нужно проверить, не создан ли Actor при partial failure.
- **Публиковать gRPC endpoint напрямую.** Внешний authentication и authorization должны быть явными.
- **Принимать roadmap за текущую гарантию.** План не является implementation contract.

Production checklist control plane

- Версия AX закреплена commit или release, а расхождения с docs задокументированы.
- Проверено, direct или asynchronous reconciliation используется именно в этой версии.
- Redis имеет persistence, backup, restore test, memory limits и alerting.
- Есть inventory reconciliation между Redis Tasks и Substrate Actors.
- Partial create/delete scenarios проверены fault injection.
- gRPC endpoint защищён authentication, authorization и transport security.
- Substrate TLS authority, CA и token rotation протестированы.
- Readiness SLO отделён от API acceptance и Actor phase.
- Watch дополняется durable audit trail, если история является требованием.
- Fallback на default ActorTemplate наблюдаем или запрещён.
- Secrets не передаются в Actor env для недоверенного workload.
- Capacity plan учитывает длительные lifecycle RPC и readiness polling.
- DR exercise восстанавливает Redis, Substrate metadata и snapshots как разные слои.

Итог

AX превращает удобный для инженера agent intent в конкретный runtime lifecycle. Его ценность не в том, что он скрывает Substrate, а в том, что он добавляет продуктовый API и переводит Task, Workspace и Model в Atespace, ActorTemplate и Actor. На проверенной версии этот перевод выполняется синхронно внутри `ax-server`; Redis хранит AX records и live notifications, а Substrate остаётся владельцем placement, sandbox, suspend/resume и snapshot lifecycle.

Эта граница позволяет правильно выбирать инструмент. Если нужна изоляция и stateful runtime - смотрим на Substrate. Если нужен декларативный интерфейс для agent workloads и их product semantics - добавляем AX. Если нужны durable retries, автоматическая convergence и большая независимая controller capacity - проверяем, реализованы ли они в выбранной версии, либо проектируем этот слой отдельно.

В следующей главе мы разберём сами AX primitives: почему Task специально остаётся маленькой, что Workspace материализует внутри sandbox, какую роль играет Model и как не превратить эти ресурсы в неуправляемый универсальный manifest.

Источники и дальнейшее чтение

- [AX README and operational overview](#)
- [AX design and API reference](#)
- [ax-server dependency wiring](#)
- [AX gRPC lifecycle implementation](#)
- [TaskReconciler implementation](#)
- [Redis resource and watch store](#)
- [AX to Substrate client](#)
- [AX roadmap](#)

AX primitives: Task, Workspace и Model без магии

CURRENT MAIN VERIFIED

THREE API KINDS

CONTRACTS VS WIRING

В главе 16 мы проследили путь запроса через `ax-server`, Redis и Substrate. Теперь пора разобрать язык, на котором пользователь объясняет AX, что именно нужно запустить. Этот язык намеренно мал: в проверенном current main есть три API kind - `Task`, `Workspace` и `Model`.

Маленький API полезен только тогда, когда границы объектов понятны. Если положить `image`, `Git repositories`, `credentials`, `model parameters`, `network policy` и весь `lifecycle` в один универсальный `manifest`, его легко создать, но почти невозможно безопасно переиспользовать. AX разделяет описание выполняемой единицы, подготовку рабочей среды и `model configuration`. При этом текущая реализация ещё не соединяет все три объекта так полно, как подсказывают их названия.

Эта глава поэтому отвечает на два вопроса одновременно: какой `mental model` заложен в primitives и что действительно делает source code на зафиксированном commit. Для pre-stable системы такое разделение важнее красивой диаграммы.

Что читатель должен унести из главы

- почему Task не равен Pod, Job или «агенту целиком»;
- почему Workspace является blueprint среды, а не общей сетевой файловой системой;
- что Model настраивает для платформы и почему Task пока не может ссылаться на него;
- почему Gateway больше не является AX kind в current main;
- какие поля уже влияют на runtime, а какие пока существуют только в schema;
- почему порядок документов в multi-document YAML имеет значение;
- что на самом деле доказывает `WorkspaceReady`;
- как выбирать границы ресурсов и versioning strategy для production.

Primitive - это граница ответственности и lifecycle

Primitive полезно выделять не потому, что ему нашёлся знакомый аналог в Kubernetes. Его выделяют, когда часть системы должна иметь собственные владельца, частоту изменений, правила переиспользования и failure semantics.

Primitive	Главный вопрос	Типичный lifecycle
Task	Что изолированно запустить и как управлять этим экземпляром?	Создать один раз, resume/suspend, затем удалить
Workspace	Какой materialized environment должен получить Task?	Переиспользовать и обновлять как blueprint
Model	Как platform component должен вызвать model provider?	Централизованно менять provider configuration и secret reference

Эти lifecycle различаются намеренно. Task immutable после создания: её runtime identity уже связана с Actor и durable state. Workspace и Model обновляемы: это reusable configuration. Но обновляемость объекта не означает автоматическое распространение изменения во все уже созданные Tasks. Между API semantics и rollout semantics всегда нужен отдельный ответ.

Current API surface и documentation drift

Источником истины для поддерживаемых kinds является protobuf и CLI switch, а не отдельная фраза в документации. На проверенном commit `ax.proto` и `ax apply` принимают ровно три kind.

Kind	В protobuf/CLI	Комментарий
Task	Да	Create/get/list/delete/suspend/resume/watch
Workspace	Да	Update/get/list/delete
Model	Да	Update/get/list/delete
Gateway	Нет	Нет kind, message или CLI branch в current main

`docs/manifests.md` всё ещё начинается словами «all four kinds», хотя дальше показывает только Task, Workspace и Model. Это обычный пример documentation drift. Gateway нельзя объявить «на всякий случай»: CLI вернёт unsupported kind. Сетевые ingress/egress contracts принадлежат Agent Substrate и были разобраны в главе 15.

Правило для pre-stable API. README помогает понять intent, docs дают examples, но окончательный contract подтверждают schema, validator и execution path выбранного commit.

Общие правила: metadata, atespace и apply

Каждый AX object имеет `apiVersion: ax.io/v1alpha1`, `kind, metadata.name` и `metadata.atespace`. Пустой `atespace` server заменяет на `default`. `Name` и `atespace` становятся именами ресурсов Substrate, поэтому `validator` требует lowercase RFC 1123 label длиной не более 63 символов.

Atespace - не декоративная папка. Это scope имени, secret lookup и runtime resources. Одинаковые имена в разных atespaces различаются, а Kubernetes Secret для Model client ищется в namespace, равном atespace. Поэтому production manifest лучше задаёт atespace явно, даже если лаборатория использует `default`.

`ax apply` читает multi-document YAML последовательно и отправляет каждый document отдельным typed RPC. Server не получает исходный YAML целиком и не строит dependency graph. Общей транзакции тоже нет: первые документы могут примениться, а следующий завершиться ошибкой.

Resource	Apply operation	Повторное применение
Task	CreateTask	Ошибка, если имя уже существует
Workspace	UpdateWorkspace	created, configured или unchanged
Model	UpdateModel	created, configured или unchanged

Порядок документов является contract

Task reconciliation читает связанные Workspaces из Redis во время создания. Если Task стоит раньше Workspace, отсутствующая ссылка сейчас не вызывает validation error: server просто не передаст Workspace в runner. Runner сопоставит binding с пустым объектом и создаст directory без ожидаемого содержимого.

Поэтому безопасный порядок таков: сначала Workspace, затем Model, если он нужен platform component, и только потом Task. Ещё надёжнее применять reusable resources отдельным deployment step и создавать Tasks после проверки их наличия.

```
safe apply sequence:
1. apply Workspace and Model definitions
2. verify: ax get workspace / ax get model
3. create Task that binds the Workspace
4. resume Task and wait for Ready=True
```

Task: единица isolation и runtime identity

Task отвечает не на вопрос «какую бизнес-задачу решает агент», а на более конкретный: какой sandboxed execution instance должен существовать, с каким filesystem state и lifecycle. Один Task может содержать короткую команду, долгоживущий agent harness или корневой узел, который порождает другие Tasks.

Границу Task стоит проводить там, где нужны отдельные isolation, credentials, suspend/resume, failure recovery или audit identity. Два процесса, которые должны падать, восстанавливаться и получать permissions независимо, не следует помещать в одну Task только ради удобного manifest.

Поля Task и их фактический эффект

Поле	Назначение	Current main
image	Container image для ActorTemplate	Работает; при пустом значении используется default runner image
command	Agent process и arguments	Runner запускает как child; это не container entrypoint
env	Переменные окружения workload	Передаются в ActorTemplate и доступны через API в открытом виде
resources	CPU/memory requests и limits	Есть в schema, но inspected reconciler не маппит их в Substrate ActorTemplate
workspaces	Именованные bindings, paths и goals	Работают, но existence ссылки не валидируется
debug	Включить guest services для ax ssh	Работает; открывает process/file access внутри sandbox

Image и command - разные уровни

AX всегда запускает в container фиксированный путь `/usr/local/bin/ax-task-runner`. Пользовательский `spec.command` приходит runner через `AX_TASK_YAML` и становится дочерним процессом. Поэтому custom image обязан содержать совместимый runner по ожидаемому пути. Просто указать image с привычным ENTRYPOINT недостаточно.

Если `command` пуст, runner продолжает обслуживать metadata до остановки. Если child завершился, runner также остаётся PID 1. Следовательно, phase `Running` и даже container health не доказывают, что agent process продолжает работу. Подробный runner contract будет в главе 18.

Env не является secret store

`EnvVar` содержит только `name` и `literal value`. Значение сохраняется в Task record и возвращается через `ax get task`. В schema нет `valueFrom.secretKeyRef`, а у Task нет `modelRef`. Open issue #348 именно поэтому предупреждает: credentials, помещённые в Task env, становятся API-readable.

Current reconciler отдельно умеет находить hardcoded `gemini-api-secret/GEMINI_API_KEY` и добавлять его в ActorTemplate. Это не универсальная связь Task -> Model и не решает безопасную выдачу произвольных provider credentials. Для production предпочтительны egress credential injection или другой broker, при котором secret не входит в sandbox.

Resources: declaration ещё не enforcement

Manifests показывают `requests.cpu`, `requests.memory`, `limits` и похожи на Kubernetes. Но `TaskReconciler` строит `ActorTemplate` без чтения `task.spec.resources`. Пока mapping не реализован, эти значения нельзя использовать как доказательство `quota` или `isolation`.

При выборе АХ инженер должен проверить не только наличие поля, но и полный путь: `parse` -> `validation` -> `translation` -> `runtime enforcement` -> `observation`. Если цепь заканчивается на `schema`, поле является `intent` или `placeholder`, а не `control`.

Task immutable, но state продолжает жить

Повторный `CreateTask` с тем же именем запрещён. Это защищает связь `Task name`, `Actor` и `durable state` от неявной подмены `image` или `command`. Изменение `executable contract` должно создавать новую `Task identity` либо проходить явную `migration procedure`.

`Suspend/resume` меняют `lifecycle`, а не `spec`. `Delete` сначала удаляет `Actor` и `task-specific ActorTemplates`, затем `Redis record`. Если нужна история завершённых задач, её следует экспортировать до `delete`: `Task store` не является архивом.

Workspace: blueprint materialized environment

`Workspace` часто ошибочно воспринимают как общий `PVC`. На самом деле это `reusable blueprint`: список `Git sources`, `inline files`, `MCP/skills declarations`. Когда `Task` связывает `Workspace`, `runner` материализует его в `durable filesystem` именно этой `Task`. Две `Tasks` ссылаются на один `Workspace definition`, но получают независимые рабочие копии и независимый `runtime state`.

Такое разделение полезно для агентных нагрузок. Агент должен свободно менять `checkout`, создавать `artifacts` и сохранять локальные `caches`, не повреждая среду соседней `Task`. `Shared collaboration` требует отдельного `storage` или `coordination service`; `Workspace reference` сама по себе его не создаёт.

Что хранит Workspace и что делает setup

Часть spec	Intent	Фактическая maiden setup
<code>git</code>	<code>Repositories</code> , <code>branch</code> , <code>dir</code> , <code>depth</code>	<code>Init/fetch/checkout</code> , до 5 попыток, default branch <code>main</code>
<code>files</code>	Создать небольшие <code>configuration files</code>	Записываются с <code>mode 0644</code> ; <code>absolute path</code> также разрешён
<code>mcp.registries/servers</code>	Объявить <code>tool landscape</code>	Хранится в <code>resource</code> и <code>metadata</code> ; <code>inspected SetupWorkspace</code> не <code>materializes MCP config</code>
<code>skills.registries</code>	Источники <code>skill packages</code>	<code>Inspected setup</code> не загружает <code>registries</code>
<code>skills.path</code>	Directory для <code>skills</code>	Directory создаётся, но <code>packages</code> не устанавливаются

Это не повод объявлять Workspace бесполезным. Git и files уже дают воспроизводимый старт, а MCP/skills schema фиксирует желаемый contract для runner или внешнего planner. Но platform owner должен различать declarative data и materialization implementation.

Binding принадлежит Task

Path и goal находятся не в WorkspaceSpec, а в `Task.spec.workspaces[]`. Один blueprint можно смонтировать по разным paths и подготовить под разные цели. Binding без path получает `/workspace/<name>`; первый binding становится working directory command. Paths должны быть absolute и уникальными.

Если bindings нет, runner всё равно создаёт пустой `/workspace`. Если binding ссылается на отсутствующий Workspace, current code также создаёт пустую directory. Поэтому `WorkspaceReady=True` нельзя трактовать как доказательство, что named Workspace был найден.

Goal - просьба bootstrap agent, а не postcondition

Goal передаётся default runner в Antigravity bootstrap script. Script запускается только если он присутствует в image и доступен `GEMINI_API_KEY`; default timeout равен 10 минутам. Goal может установить toolchain или dependencies, но он не является формально проверяемым desired state.

В current setup skipped, timed-out или failed bootstrap логируется, но не делает SetupWorkspace error. После этого marker всё равно может быть записан, а runner выставит readiness. Аналогично Git failure не возвращается runner как error: marker не пишется для retry, однако текущий boot может получить `WorkspaceReady=True`.

Readiness lesson. В текущей реализации `WorkspaceReady` ближе к «runner завершил setup procedure без fatal Go error», чем к «все repositories, tools и goal postconditions проверены». Нужны собственные acceptance probes перед запуском дорогой agent loop.

Idempotency marker и versioning

Runner создаёт marker `/ax/initialized-<path>` отдельно для каждого binding. Если marker найден, maiden setup пропускается. Это защищает изменённый агентом checkout от повторного clone после restart/resume.

Но marker не содержит digest Workspace spec. Update Workspace не запускает fan-out reconciliation существующих Tasks, а already initialized runner не обязан повторять setup. Поэтому изменение branch, files или skill declarations следует считать новой версией environment.

Практичные стратегии: включать version в Workspace name, создавать новую Task на новую версию, либо писать custom migration step с собственным digest marker. Mutable Workspace удобен для future Tasks, но не является fleet-wide rollout mechanism.

Security и ownership

Inline file может иметь absolute path, а goal запускает agent-assisted bootstrap с доступными sandbox privileges. Workspace поэтому должен считаться доверенным platform configuration, а не произвольным input конечного пользователя. Code review, provenance и ограничения egress для maiden setup важны не меньше, чем policy runtime agent.

Credentials для private Git, MCP registries и package managers требуют отдельного design. Простое добавление secret в files или env делает его частью Task record или filesystem snapshot. Лучше выдавать short-lived credentials только setup phase и отделять setup Actor от runtime Actor; именно такое разделение присутствует в AX roadmap, но ещё не реализовано.

Model: configuration для platform model client

Model хранит provider name, model identifier, provider-specific parameters и Kubernetes Secret reference. Его смысл - централизовать model configuration для компонентов AX, например Workspace planner. Это не inference service и не автоматическая настройка каждого agent process.

Поле	Что означает	Current main caveat
provider	Provider selector	Schema принимает string; remote Generate path реализован только для Google
model	Provider model identifier	Используется internal model client
parameters	Свободная JSON map generation settings	Для Google передаётся как generationConfig; systemInstruction обрабатывается отдельно
secretKey	Kubernetes Secret name/key	Secret ищется в namespace, равном atespace

Model не привязан к Task

В TaskSpec нет model reference. Создание Model/default-model не меняет environment пользовательской команды и не заставляет agent использовать указанный model. Internal model.Client умеет загрузить Model из store, но такой client должен быть явно создан platform component.

Workspace planner содержит constructor, который читает default-model из store, однако default runner path в inspected code напрямую запускает Antigravity bootstrap и не вызывает этот planner. Для task workload выбор model остаётся ответственностью harness внутри image или внешнего model gateway.

Provider name не гарантирует adapter

Manifest documentation показывает Google и Anthropic examples. Но current Generate выполняет remote request только для google; другой provider возвращает unsupported provider, если не включён local fallback mode. Схема специально extensible, однако adapter support нужно проверять по коду и end-to-end test.

Secret reference имеет узкую область

`secretKey` не копирует `secret` в `Model record`: `internal client` читает `Kubernetes Secret`. Это лучше `literal env`. Но наличие `Model` не даёт `credential Task`. Более того, `current Task reconciler` использует отдельный `hardcoded Gemini lookup`, а не выбирает `Model resource` по ссылке.

Поэтому перед `production` нужно ответить: кто вызывает `model` - `AX planner` или `agent command`? В первом случае `Model` подходит как `platform configuration`. Во втором нужен `contract harness/gateway` и отдельный способ безопасной выдачи `credentials`.

Куда делся Gateway

Старая версия главы называла `Gateway` четвёртым `primitive` и приписывала ему `listeners`, `allowlist` и `GatewayReady`. В `current protobuf` такого ресурса нет. Сетевой `boundary` существует, но реализуется на уровне `Substrate routing` и `EgressPolicy`, а не `AX Gateway manifest`.

Это хороший пример правильной эволюции `abstraction`: отсутствие `user-facing kind` не означает отсутствие функции. Иногда `platform` становится яснее, когда `policy` остаётся у слоя, который реально применяет её. `AX Task` может пользоваться `runtime networking`, не копируя весь `Substrate network API` в свой `schema`.

Как собрать primitives в рабочую декларацию

```
apiVersion: ax.io/v1alpha1
kind: Workspace
metadata:
  name: checkout-v3
  atespace: team-a
spec:
  git:
    - repo: https://github.com/example/service.git
      branch: main
      depth: 1
  files:
    - path: AGENTS.md
      content: |
        Run tests before changing code.
---
apiVersion: ax.io/v1alpha1
kind: Task
metadata:
  name: investigate-142
  atespace: team-a
spec:
  image: ghcr.io/example/agent@sha256:PINNED_DIGEST
  command: ["agent", "--ticket", "142"]
  workspaces:
    - name: checkout-v3
      path: /workspace/service
      goal: Verify the toolchain and dependencies.
  debug: false
```

Workspace расположен первым намеренно. Image pinned digest отделяет изменение runtime от изменения Task name. Goal короткий и проверяемый внешним probe. Debug выключен по умолчанию. Credentials в manifest отсутствуют. Model не добавлен, потому что этот Task использует model gateway через собственный harness; объявлять неиспользуемый resource только для красоты не нужно.

Как выбирать primitive под задачу

Потребность	Правильная точка	Почему
Другой image, command или isolation boundary	Новая Task	Меняется runtime identity
Одинаковый checkout/setup для многих Tasks	Versioned Workspace	Переиспользуется blueprint, не live filesystem
Несколько repositories с разными paths	Один или несколько Workspace bindings	Первый задаёт CWD, каждый получает свой marker
Model для platform planner	Model resource	Internal client может прочитать config и secret reference

Потребность	Правильная точка	Почему
Model для agent command	Harness/model gateway contract	Task не имеет modelRef
Egress allowlist и credential injection	Substrate EgressPolicy/gateway	Gateway не является AX kind
Общий mutable filesystem нескольких agents	Отдельный storage/collaboration service	Workspace создаёт независимые copies

Антипаттерны

- **Считать field реализованным по наличию в YAML.** Проверяйте translation и enforcement.
- **Ставить Task первым в multi-document file.** Dependencies не сортируются автоматически.
- **Хранить API key в Task env.** Literal возвращается через API.
- **Считать Workspace общим volume.** Каждая Task получает собственную materialization.
- **Обновлять Workspace и ожидать rollout.** Existing Tasks не получают новую среду автоматически.
- **Считать WorkspaceReady semantic test.** Goal, Git или tools могут быть неполными.
- **Создавать Model и ожидать его внутри Task.** Прямой связи в schema нет.
- **Писать Gateway manifest из старой документации.** Current CLI его отвергает.
- **Включать debug постоянно.** Guest services дают process execution и file access.

Production checklist primitives

- API kinds и fields сверены с pinned `ax.proto`.
- Atespace задан явно и соответствует namespace/security boundary.
- Workspace и Model применяются до Task и проверяются отдельно.
- Task image закреплён digest, command и working directory однозначны.
- Task resources подтверждены на уровне Substrate, а не только manifest.
- Workspace references существуют; missing reference даёт deployment failure в вашей pipeline.
- Workspace versioning не зависит от mutable update существующего имени.
- Git checkout, required tools и goal postconditions проверяются отдельным probe.
- Secrets отсутствуют в Task env, inline files и durable snapshot.
- Model используется только компонентом, который действительно читает resource; provider adapter проверен end-to-end, включая rate limits и auth failure.

Итог

Task, Workspace и Model разделяют три разных вида решений: runtime identity, materialized environment и platform model configuration. Их полезно комбинировать, но нельзя вообразить связи, которых нет в current implementation. Task пока не выбирает Model, WorkspaceReady не является полноценным acceptance test, resources ещё не доходят до runtime, а Gateway больше не входит в AX API.

Зрелая работа с primitives начинается с вопроса «кто применяет это поле и когда?». Schema описывает intent, reconciler переводит часть intent в Substrate, runner материализует Workspace, а harness выполняет agent logic. Только пройдя всю цепочку, инженер может считать capability реализованной.

В следующей главе мы углубимся в runner: почему он становится PID 1, как принимает Task и Workspace contracts, что означает maiden setup и какие обязанности нельзя переложить на обычный container entrypoint.

Источники и дальнейшее чтение

- [AX README and three primitives](#)
- [AX v1alpha1 protobuf schema](#)
- [Validation and workspace binding helpers](#)
- [AX CLI apply implementation](#)
- [AX manifest examples](#)
- [AX runner lifecycle](#)
- [Workspace maiden setup implementation](#)
- [AX internal model client](#)
- [Issue #348: Task secret and modelRef gap](#)

Runner: PID 1 как платформенный контракт, а не просто entrypoint

CURRENT MAIN VERIFIED

PROCESS LIFECYCLE

READINESS SEMANTICS

В главе 17 мы разделили Task, Workspace и Model и увидели, что декларация сама по себе ничего не исполняет. Между manifest и пользовательским агентом нужен компонент, который превратит данные control plane в работающий процесс внутри sandbox. В AX эту роль выполняет runner.


Runner легко принять за тонкую shell-обёртку: прочитать команду, запустить её и ждать. Но в AX он одновременно является PID 1 контейнера, подготавливает Workspace, держит metadata surface, сообщает readiness, включает debug services и завершает process tree при suspend. Ошибка в этой точке искажает состояние сразу для трёх наблюдателей: Substrate, AX и самого agent harness.

Поэтому runner полезно рассматривать не как вспомогательный binary, а как платформенный адаптер. Сверху он получает декларативные контракты Task и Workspace, снизу работает с Unix processes и durable filesystem, а наружу выдаёт минимальный протокол здоровья и управления.

Что читатель должен унести из главы

- зачем платформе отдельный runner, если у container image уже есть ENTRYPOINT;
- почему AX всегда запускает `/usr/local/bin/ax-task-runner`, а `spec.command` становится child process;
- какие обязанности возникают у PID 1 и какие из них default runner не решает как полноценная init-system;
- чем различаются container health, workspace readiness и liveness самого agent process;
- почему успешный выход child не завершает Task и не попадает в AX status;
- как runner обрабатывает `SIGTERM`, process group и 10-секундный grace period;
- что именно переживает suspend/resume, а что должно быть восстановлено harness;
- когда достаточно расширить default image, а когда нужен embedded или custom runner;
- как проверить runner до запуска production workload.

Runner contract: граница между AX, sandbox и agent process



Зачем runner существует отдельно от harness

Agent harness отвечает за model loop, tools, memory, budgets и прикладную остановку. Runner решает другой класс задач: получить launch configuration от платформы, подготовить среду, запустить harness как процесс и удерживать management surface sandbox. Смешивать эти роли можно, но тогда обновление agent logic начинает менять платформенный lifecycle, а изменение probes или signal handling требует пересборки всего приложения.

Отдельный runner даёт AX устойчивый внутренний protocol. Control plane не обязан знать, написан агент на Python, Go или TypeScript, является ли он ReAct loop, supervisor или обычным shell script. Для платформы важны фиксированный executable, port 80, readiness и корректное завершение.

Слой	Главная обязанность	Чего он не должен угадывать
AX/ Substrate	Создать sandbox, передать specs, volume и probes	Как работает agent loop и что означает бизнес-успех
Runner	Материализовать Workspace, запустить и остановить process tree, держать management API	Правильность решения задачи агентом
Harness	Выполнять agent logic, сохранять checkpoints и публиковать application state	Как control plane создаёт Actor и восстанавливает filesystem

Launch envelope: что AX передаёт в container

В current main reconciler строит ActorTemplate так, чтобы container всегда стартовал с командой `/usr/local/bin/ax-task-runner`. Пользовательский `spec.command` не становится OCI command. Он сериализуется внутри `AX_TASK_YAML`, а runner позднее запускает его через `os/exec`.

Вход	Значение	Практическое следствие
Image	<code>spec.image</code> или <code>default runner image</code>	Custom image обязан содержать совместимый executable по фиксированному пути
Container command	<code>/usr/local/bin/ax-task-runner</code>	ENTRYPOINT исходного image не определяет lifecycle AX
<code>AX_TASK_YAML</code>	Task без status	Runner получает launch spec, но не authoritative control-plane state
<code>AX_WORKSPACES_YAML</code>	Найденные Workspace resources в binding order	Отсутствующий resource может не попасть в stream
Task env	Literal <code>spec.env</code> плюс platform-provided values	Переменные доступны и runner, и child process
Volume	Durable directory at <code>/workspace</code>	Files переживают suspend/resume; process tree не переживает
Ready probe	GET <code>/readyz</code> on port 80	Custom runner обязан занять этот port и реализовать protocol

Главный compatibility test. Custom image считается AX-compatible не потому, что внутри есть ваш agent binary. Она совместима, если platform entrypoint существует и соблюдает runner contract.

Boot sequence по шагам

Порядок операций важен для диагностики. Одни failures происходят до появления health endpoint, другие оставляют container живым, но неготовым, третьи вообще не отражаются в AX status.

- 1. Parse configuration.** Binary читает Task из `AX_TASK_YAML`, Workspaces из multi-document `AX_WORKSPACES_YAML` и подписывается на `SIGTERM/Interrupt`. Invalid YAML является fatal error: runner завершается до старта server.
- 2. Resolve mounts.** Bindings сопоставляются с Workspace по name. Если resource не передан, binding всё равно превращается в mount с пустым Workspace.
- 3. Start metadata server.** HTTP server начинает слушать до Workspace setup. С этого момента `/healthz` отвечает 200, а `/readyz` ещё 503.
- 4. Prepare Workspaces.** Setup выполняется последовательно в declaration order. При отсутствии bindings создаётся default `/workspace`.
- 5. Mark ready.** Только если каждый вызов `SetupWorkspace` вернул nil, metadata server переключает workspace readiness в true.
- 6. Start command.** Runner выбирает первый Workspace как working directory, собирает environment и запускает `spec.command` в отдельной process group.

7. **Supervise until stop.** Runner ждёт либо завершения direct child, либо отмены context. После выхода child он продолжает обслуживать server до внешнего stop/suspend.

Неочевидный момент: ошибка Workspace setup выставляет внутренний `ready=false`, но current `runner.Run` всё равно переходит к запуску command. Это может быть полезно для debug или self-repair, но application не должна считать наличие процесса доказательством готовой среды.

```
parse specs
-> start metadata server      health=200, ready=503
-> setup workspaces in order
    -> all returned nil      ready=200
    -> any returned error    ready stays 503
-> start child command       happens in both cases
-> child exits               runner stays alive
-> SIGTERM to runner         terminate process group, then exit
```

PID 1: особая роль, но не магия

В Linux PID 1 внутри PID namespace определяет lifetime container: пока этот process жив, container считается работающим. Он получает stop signal от runtime и становится родителем для orphaned descendants. Поэтому обычное приложение, случайно поставленное PID 1, часто неправильно обрабатывает signals или накапливает zombie processes.

Default AX runner решает основную часть lifecycle для одного foreground command. Он подписывается на `SIGTERM`, запускает direct child через `exec.Cmd`, помещает его в отдельную process group и обязательно вызывает `Wait` для этого child. Но в inspected code нет общего `SIGCHLD/wait4` loop или subreaper behavior для произвольно осиротевших grandchildren.

Отсюда инженерное ограничение: agent command должен оставаться foreground supervisor своего дерева. Если библиотека делает double-fork, вызывает `setsid` и отдаёт процессы PID 1, default runner может не вести их как полноценная init-system. Для сложного service tree используйте собственный supervisor внутри command либо custom runner с явным reaping.

Обязанность PID 1	Default runner	Ограничение
Получить stop signal	Да, <code>signal.NotifyContext</code>	Обрабатываются Interrupt и SIGTERM
Остановить process tree	Signal всей исходной process group	Process, ушедший в другую session/group, может избежать сигнала
Дождаться direct child	Да, через <code>cmd.Wait()</code>	Это не универсальный reaper всех orphaned descendants
Держать container после child exit	Да	Container alive больше не означает workload alive
Сообщить exit code control plane	Только log/callback	AX status его сейчас не получает

Три сигнала здоровья, которые нельзя смешивать

Слово ready звучит однозначно, но в этой системе у него несколько уровней. Если dashboard показывает только один зелёный индикатор, оператор не понимает, какой именно факт подтверждён.

Сигнал	Что он доказывает	Чего он не доказывает
/healthz = 200	Metadata server жив и принимает HTTP	Workspace готов, child запущен или agent полезен
/readyz = 200	Все вызовы Workspace setup завершились без возвращённой ошибки	Goal postconditions, toolchain и business dependencies реально работают
Task phase Running	Actor resumed и получил Worker	WorkspaceReady или живой child process
WorkspaceReady=True	AX однажды увидел runner readiness	Текущий child после resume выполняется успешно
Application heartbeat	Harness выполняет ожидаемый loop/checkpoint	Полная готовность внешних tools без отдельных probes

AX опрашивает /readyz примерно каждые 500 ms, но только в ограниченном окне, по умолчанию до 15 секунд. Если setup дольше, Task остаётся Running с WorkspaceReady=False; следующий lifecycle RPC может снова запустить reconciliation. После того как условие стало True, current reconciler сохраняет его через suspend/resume и больше не опрашивает runner для этого condition.

С другой стороны, Agent Substrate использует container readiness probe на том же endpoint. Значит, HTTP readiness остаётся полезной runtime guard, даже если AX status уже содержит старое True. Но ни один из этих механизмов не наблюдает child process напрямую.

Metadata server и debug surface

Runner поднимает один listener. Обычные HTTP/1.1 requests обслуживают health, readiness и metadata. Когда spec.debug=true, незашифрованный HTTP/2 traffic с Content-Type: application/grpc передаётся guest gRPC server через h2c.

Endpoint/service	Назначение	Risk
/metadata/v1alpha1/ax/task	Task launch configuration как YAML	Включает literal env из spec; не считайте endpoint public
/metadata/v1alpha1/ax/workspaces	Найденные Workspace resources в binding order	Это configuration, а не доказательство materialization

Endpoint/service	Назначение	Risk
Guest process service	Запуск, inspection, output и kill процессов	Arbitrary process execution внутри sandbox
Guest filesystem service	Streaming read/write файлов	Доступ к durable Workspace и его artifacts

`AX_METADATA_URL` указывает child на loopback address runner, обычно `http://127.0.0.1:80`. Это удобный self-introspection contract без SDK. Но metadata не должна становиться скрытым secret delivery channel: Task env возвращается почти в исходном виде.

Debug выключен по умолчанию правильно. Его включение меняет не удобство логирования, а attack surface sandbox. Production policy должна ограничивать, кто может создать Task с debug, кто может вызвать `ax ssh` и как такой доступ попадает в audit log.

Child process: что означает exit

Runner запускает command с inherited stdin/stdout/stderr и environment, где есть runner env, `AX_METADATA_URL` и `spec.env`. Working directory берётся из первого Workspace binding. Это делает порядок bindings частью runtime contract, а не косметикой manifest.

После `cmd.Start()` отдельная goroutine вызывает `cmd.Wait()`. Exit code записывается в log и передаётся optional `OnCommandExit` callback, если runner package встроен в custom binary. Default `ax-task-runner` callback не задаёт. Control plane не читает этот результат и не переводит Task в Completed или Failed.

Для long-running agent service такое поведение удобно: после crash можно зайти через debug surface, прочитать files и решить, перезапустить ли workload. Для one-shot automation оно опасно: exit 0 выглядит почти так же, как exit 2, если оператор смотрит только на Task phase.

Workload	Рекомендуемый completion contract
Long-running agent	Heartbeat + last successful loop + restart policy вне одного Task status
One-shot analysis	Atomic result file/status record и explicit completion event до выхода
Code-changing agent	Commit/PR identity, test result и durable operation ledger
Infrastructure action	Approved operation id, before/after evidence и verification result

Task не равен Job. Пока AX не отражает child exit в resource status, терминальный успех должен жить в application protocol, а не выводиться из container health.

SIGTERM, process group и 10 секунд на остановку

Когда sandbox останавливается или suspend инициирует shutdown, runtime доставляет SIGTERM PID 1. Runner отменяет context и отправляет SIGTERM отрицательному PID child, то есть всей process group. Затем ждёт до 10 секунд. Если direct child не завершился, runner посылает group SIGKILL и всё равно ждёт cmd.Wait().

```
Substrate stop/suspend
-> SIGTERM to runner (PID 1)
-> SIGTERM to child process group
-> wait up to 10 seconds
    -> child exits: record result
    -> timeout: SIGKILL process group, then wait
-> stop metadata server
-> runner exits
-> container stops
```

Эти 10 секунд жёстко заданы в current package. Task manifest не содержит termination grace setting. Harness должен либо укладываться в этот budget, либо заранее continuously сохранять state, а не пытаться записать всё при shutdown.

Process group лучше сигнала одному PID: shell, tool process и их обычные descendants получают одинаковый request на завершение. Но это не security boundary. Процесс может создать новую session/group, зависнуть в uninterruptible kernel wait или уже выполнить внешний side effect. SIGKILL останавливает вычисление, но не откатывает Git push, ticket update или network change.

Что переживает suspend/resume

С точки зрения runner resume является новым boot. Substrate восстанавливает durable Workspace files, затем запускает новый container и новый PID 1. Старые goroutines, sockets, in-memory model context и child processes не продолжаются.

State	После resume	Кто отвечает
Files под durable Workspace	Должны быть восстановлены	Substrate snapshot/storage
Workspace initialization marker	Позволяет пропустить повторный setup	Runner/setup logic
Process memory и goroutines	Создаются заново	Harness rehydration
Open sockets и sessions	Потерины	Client reconnect logic
Tool operation in progress	Неизвестен без operation ledger	Application protocol
AX WorkspaceReady condition	Может остаться True	Control-plane stored status

Marker защищает agent-modified checkout от повторной materialization, но не восстанавливает semantic progress. Надёжный harness при boot читает checkpoint, сверяет незавершённые operation IDs с внешними системами и только потом продолжает loop.

Как выбирать уровень customization

Документация AX предлагает три уровня. Правильный выбор определяется не языком agent framework, а тем, насколько вы хотите менять lifecycle contract.

Вариант	Когда выбирать	Что вы поддерживаете
Extend default image	Нужны дополнительные compilers, CLI, SDK или agent binary	Toolchain и supply chain image; runner остаётся upstream
Embed Go runner package	Нужны hooks, например artifact upload через OnCommandExit	Свой binary и version compatibility package
Custom runner	Нужен другой supervisor, workspace layout, init/reaping или protocol extension	Весь platform contract: specs, server, probes, signals, debug и tests

Для большинства команд первый вариант дешевле и безопаснее. Если проблема только в отсутствии Node.js или вашего CLI, не переписывайте PID 1. Embedded package оправдан, когда требуется небольшая интеграция на границе exit/setup. Полный runner нужен лишь тогда, когда стандартный lifecycle принципиально не подходит.

Локальная и end-to-end проверка runner

Default binary умеет читать specs из files, поэтому basic contract проверяется без кластера:

```
ax-task-runner \
  --task-file task.yaml \
  --workspace-file code.yaml \
  --port 8080

curl -i http://127.0.0.1:8080/healthz
curl -i http://127.0.0.1:8080/readyz
curl -s http://127.0.0.1:8080/metadata/v1alpha1/ax/task
```

Но local test не проверяет Substrate signal delivery, restored volume и routing. Минимальная acceptance matrix должна включать:

Сценарий	Ожидаемый результат
Slow Workspace setup	health=200, ready=503, command behavior соответствует вашему policy
Command exit 0/не 0	Runner остаётся жив, exit виден в application telemetry

Сценарий	Ожидаемый результат
Child c descendants	SIGTERM доходит всей foreground process group
Child игнорирует SIGTERM	После 10 секунд применяется SIGKILL
Suspend during tool call	После resume operation ledger предотвращает duplicate effect
Resume from changed Workspace	Проверена marker/version strategy, нет скрытой повторной initialization
Debug off/on	<code>ax ssh</code> запрещён/разрешён ожидаемо и audit-visible

Антипаттерны

- **Считать runner обычным ENTRYPOINT.** Он реализует protocol с control plane и Substrate.
- **Считать Running доказательством живого агента.** Runner может жить после exit child.
- **Перезапускать container из-за каждого exit.** Сначала решите, является workload Job, service или inspectable session.
- **Писать весь state только на SIGTERM.** Hardcoded grace period равен 10 секундам.
- **Daemonize agent process.** Foreground supervisor лучше согласуется с process-group shutdown и observability.
- **Считать readyz application probe.** Он отражает Workspace setup, а не model/tools/ business readiness.
- **Включать debug постоянно.** Guest services дают process и filesystem access.
- **Переписывать runner ради пакета или CLI.** Чаше достаточно расширить default image.

Production checklist runner

- Custom image содержит executable `/usr/local/bin/ax-task-runner`.
- Runner contract и image закреплены digest, а не mutable tag.
- Invalid specs, bind failure port 80 и command start failure наблюдаемы отдельно.
- Health, Workspace readiness и application heartbeat имеют разные metrics.
- Command работает foreground и не теряет descendants за новой process session.
- Exit code и completion result сохраняются вне runner logs.
- Checkpoint interval короче ожидаемого shutdown budget.
- Tool side effects используют idempotency key и durable operation ledger.
- Resume path протестирован как новый process с restored filesystem.

Итог

Runner делает AX Task управляемой sandbox session: принимает specs, подготавливает filesystem, запускает command, отвечает на probes и корректно завершает process group. Его позиция PID 1 нужна не для «агентной магии», а потому, что именно этот process связывает lifetime container с lifecycle workload.


Но default runner сознательно не превращает Task в batch Job или полноценную init-system. Он не публикует child exit в AX status, не доказывает application readiness и не восстанавливает in-memory progress. Эти обязанности остаются у harness и platform design вокруг него.

В следующей главе мы проследим полный lifecycle Task: от `ax apply` и Redis record до Actor resume, runner readiness, suspend и delete. После этой главы уже можно будет чётко отделить control-plane state transition от того, что реально происходит с процессом внутри sandbox.

Источники и дальнейшее чтение

- [AX runner contract](#)
- [Default runner implementation](#)
- [ax-task-runner entrypoint and signal context](#)
- [Metadata, readiness and guest service server](#)
- [Task reconciliation and WorkspaceReady polling](#)
- [Inside the AX sandbox](#)
- [Linux PID namespaces and PID 1 behavior](#)
- [Linux wait and zombie process semantics](#)

Task lifecycle в AX: synchronous reconciliation, состояния и recovery



В предыдущей главе мы разобрали жизнь процесса внутри sandbox. Теперь поднимемся на уровень выше и проследим, что происходит с самим Task: от первого RPC до Actor, suspend, повторного запуска и удаления.

Здесь особенно опасна устаревшая mental model. В старых версиях и ранних материалах AX фигурировали Redis Streams и отдельный ax-controller. В current main на commit `ac23328` эта очередь и отдельный controller удалены. ax-server сам выполняет reconciliation синхронно в обработчиках `CreateTask`, `ResumeTask`, `SuspendTask` и `DeleteTask`, а Redis используется как resource store, канал watch-уведомлений и backend распределённых блокировок.

Это не косметическая перестановка компонентов. Она меняет latency API, failure windows, способ повторять операции и то, что инженер должен считать доказательством успеха.

Сначала разделите три вида правды

У Task нет одной магической записи, которая всегда описывает всё происходящее. В работе участвуют как минимум три источника состояния.

Слой	Что он знает	Чего он не доказывает
Redis AX	Task spec, phase, conditions, actor name, worker IP	Что Actor действительно существует и процесс внутри жив
Agent Substrate	Actor, Worker assignment, suspend/resume и snapshot lifecycle	Что agent command достиг цели или корректно завершился

Слой	Что он знает	Чего он не доказывает
Runner и harness	Workspace bootstrap, child process, checkpoint и application progress	Что AX успел сохранить актуальный status

Reconciliation пытается сблизить эти представления, но не превращает Redis и Substrate в одну транзакционную базу. Между любыми двумя удалёнными вызовами процесс может завершиться, сеть может оборваться, deadline клиента может истечь, а одна система уже успеет принять изменение.

Поэтому lifecycle полезно читать не как красивую последовательность стрелок, а как цепочку отдельно подтверждаемых side effects.

Что значит synchronous reconciliation

Запрос к Task проходит примерно так:

1. CLI вызывает gRPC API `ax-server`.
2. `ax-server` валидирует объект и захватывает lock для конкретного `kind/atespace/name`.
3. Обработчик читает или записывает AX resource в Redis.
4. Тот же обработчик напрямую вызывает Agent Substrate.
5. Для resume он может ждать Workspace readiness до 15 секунд.
6. Итоговый status записывается в Redis, lock освобождается, RPC возвращается клиенту.

Отдельной durable queue между пунктами 3 и 4 нет. Отдельный worker не подберёт незавершённое событие после рестарта `ax-server`. Плюс такого дизайна - простой request path и немедленная обратная связь об ошибке. Цена - более длинные RPC, сильная зависимость от client deadline и необходимость явно проектировать recovery после частично выполненной операции.

Важно: Redis Pub/Sub в current main обслуживает WatchTask и ожидание освобождения lock. Это не прежняя очередь reconciliation и не журнал событий с повторной доставкой.

Create: создать означает подготовить suspended Task

CreateTask не запускает агента. Его нормальный результат - зарегистрированный Task и подготовленный Actor в состоянии Suspended.

1. Admission и immutable identity

Сервер проверяет schema, DNS-подобные имена и коллизии путей Workspace bindings. Пустой atespace становится default. Затем захватывается lock task/<atespace>/<name> и проверяется отсутствие Task с таким именем.

Task в current API immutable: повторный CreateTask для существующего имени возвращает FailedPrecondition, даже если предыдущая попытка provisioning закончилась Failed. Это защищает identity Actor и launch envelope от неявной подмены, но означает, что retry create не является идемпотентным в привычном HTTP-смысле.

Для автоматизации используйте правило: после неоднозначного timeout сначала сделайте GetTask; не отправляйте create вслепую. Если объект уже существует, выбирайте осознанно между ResumeTask после устранения причины и delete/recreate.

2. Первая запись в Redis

Сервер добавляет creation timestamp, создаёт status и устанавливает phase=Suspended. Запись попадает в Redis до обращения к Substrate. Store одновременно обновляет индексы и публикует новое значение в task-specific Pub/Sub channel.

Это важная граница. Если всё последующее сломается, Task уже существует и его имя занято.

3. Формирование launch envelope

Reconciler гарантирует существование Atespace, назначает Actor имя Task и формирует окружение контейнера:

- переменные из Task.spec.env;
- AX_TASK_YAML без status;
- AX_WORKSPACES_YAML с найденными Workspace specs;
- credential для Gemini, если он разрешён через Kubernetes Secret или окружение сервера.

По image и environment вычисляется короткий digest, который входит в имя per-task ActorTemplate. Status намеренно исключён из digest: смена Ready не должна создавать новый template и новый golden state.

fetchWorkspaces добавляет только те references, которые реально нашлись в store. Текущая validation проверяет форму bindings и коллизии paths, но не превращает отсутствие Workspace в отдельную admission error. Поэтому platform policy должна заранее проверять существование всех ссылок, иначе runner может получить неполный AX_WORKSPACES_YAML.

4. Actor создаётся и сразу suspends

Reconciler вызывает EnsureActor. Если Actor уже существует, helper возвращает его; crashed Actor сначала пытается revert к последнему snapshot, а Actor в Deleting коротко ожидается перед повторным create.

Так как `desired phase` равен `Suspended`, reconciler вызывает `SuspendActor`, очищает `workerIp`, выставляет `Ready=False` с reason `TaskSuspended` и возвращает status серверу. После успешной записи status RPC завершается.

Есть тонкость текущей реализации: ошибка `SuspendActor` на `create/suspend` только записывается в log как `warning`, после чего Task всё равно получает `phase=Suspended`. Следовательно, один только AX status не доказывает, что Actor действительно перестал исполняться. Для строгого контроля стоимости или `security boundary` проверяйте состояние Actor в Substrate.

Resume: Running появляется раньше Ready

`ResumeTask` снова захватывает task lock, читает immutable spec, меняет phase в памяти на `Running` и вызывает тот же `Reconcile`.

Reconciler повторно обеспечивает `Atespace`, `template` и `Actor`, после чего вызывает `ResumeActor`. Substrate назначает `Worker`, а AX сохраняет его адрес в `status.workerIp`. На Worker запускается `sandbox`, затем runner как PID 1, `Workspace bootstrap` и `agent command`.

После успешного `ResumeActor` phase уже становится `Running`. Дальше AX проверяет `/readyz?check=workspace` напрямую по Worker IP или через `atenet-router`. Poll interval равен 500 миллисекундам, `default timeout` - 15 секунд.

Результаты принципиально разные:

Наблюдение	Phase	Conditions	Что это означает
Actor resume не удался	Failed	<code>Ready=False</code> , reason <code>ActorResumeFailed</code>	Runtime не подтверждён
Actor работает, Workspace ещё готовится	Running	<code>WorkspaceReady=False</code> , <code>Ready=False</code>	Sandbox запущен, но рабочая среда не готова
Workspace probe вернул 200	Running	<code>WorkspaceReady=True</code> , <code>Ready=True</code>	Workspace bootstrap завершён

`Running` поэтому не следует использовать как сигнал для выдачи новой работы. И даже `Ready=True` не доказывает, что child process жив, model endpoint доступен или агент достиг application goal: эти границы мы разобрали в главе о runner.

Что происходит после 15 секунд

`Timeout readiness` не переводит Task в `Failed`. RPC возвращает Task в `Running` с `WorkspaceReady=False` и reason `Initializing`.

В current architecture нет фонового controller loop, который обязательно проверит probe позднее. Если Workspace станет готов на шестнадцатой секунде, сохранённый status может остаться `Initializing` до следующей lifecycle-операции, вызывающей `reconcile`. Это не значит, что runner не готов; это значит, что control-plane observation устарела.

Для production нужны один из трёх подходов:

- внешний observer периодически сверяет AX status с runner probe и инициирует repair;
- platform extension добавляет background reconciliation;
- вызывающая система считает AX condition snapshot-ом и проверяет фактическую readiness перед назначением работы.

Почему WorkspaceReady остаётся True

После первого успешного bootstrap condition `WorkspaceReady=True` считается sticky и не опрашивается повторно при последующих suspend/resume. Идея разумна: setup выполняется один раз, а durable filesystem возвращается из snapshot.

Но sticky condition - утверждение о прошлом успешном setup, а не криптографическая проверка текущего filesystem. Повреждение snapshot, смена bootstrap contract или ручное изменение volume требуют отдельной version/health policy. Иначе control plane мгновенно выставит `Ready=True`, хотя application-level проверка ещё не выполнена.

Suspend: остановить вычисление, сохранить логическую сущность

`SuspendTask` сериализуется тем же task lock. Сервер читает Task, ставит phase `Suspended` в памяти и вызывает reconciler.

Reconciler снова проходит ensure-шаги, затем просит Substrate suspend Actor. Успешный suspend должен остановить sandbox и запустить предусмотренный Substrate snapshot lifecycle. AX очищает `workerIp`, ставит `Ready=False/TaskSuspended`, но сохраняет прежний `WorkspaceReady=True`, если bootstrap уже когда-то завершался.

Практический смысл suspend:

- AX resource и identity Task остаются;
- Actor и durable workspace остаются частью runtime lifecycle;
- Worker capacity может быть освобождена;
- process memory, sockets и текущий child tree не сохраняются;
- внешний side effect не откатывается;
- после resume harness начинает новый process и восстанавливает semantic progress из durable state.

Не используйте ответ `SuspendTask` как единственное подтверждение остановки расхода ресурсов. Из-за warning-only обработки ошибки `SuspendActor` строгий automation должен после вызова проверить Actor state и отсутствие Worker assignment.

Delete: сначала Terminating, затем Actor, потом Redis

Удаление построено осторожнее, чем suspend:

1. Task lock захвачен.
2. В Redis сохраняется `phase=Terminating`.
3. `ReconcileDelete` удаляет Actor в Substrate.
4. Client опрашивает Actor до ответа `NotFound`.
5. Reconciler пытается удалить все per-task ActorTemplates.
6. Только после этого AX удаляет Task record и индексы из Redis.

Если удаление Actor завершается ошибкой или deadline истекает, Task остаётся в Redis как `Terminating`. Это полезный recovery marker: оператор видит незавершённую очистку и может повторить delete. Если Actor уже исчез, повторная очистка трактует `NotFound` как успех.

Удаление templates является best effort. Ошибки после нескольких попыток записываются как warning, но Task всё равно может исчезнуть из Redis. Поэтому при расследовании утечки image/template artifacts проверяйте Substrate отдельно.

И, конечно, delete Task не равен business rollback. Git commit, ticket, письмо, изменение устройства или cloud resource, созданные агентом, остаются во внешней системе.

Per-resource lock: что он гарантирует и где заканчивается

Production server использует Redis lock с ключом `lock:<kind>:<atespace>:<name>`. Захват выполняется через `SET NX` с уникальным token, освобождение - Lua script, который удаляет только lock с тем же token. Ожидающие клиенты просыпаются через Pub/Sub, а периодический retry страхует пропущенное уведомление.

Это даёт полезное свойство: два обычных `ResumeTask`/`SuspendTask` для одного Task не должны одновременно менять его lifecycle. Операции с разными Task могут идти параллельно.

Но lock не является глобальной транзакцией:

- default TTL равен 30 секундам;
- renewal/heartbeat lease в current implementation отсутствует;
- readiness wait сам может занять 15 секунд, а медленные Substrate calls добавляют время;
- Task lock не блокирует referenced Workspace или Model;
- side effect в Substrate и запись Redis не коммитятся атомарно.

Если обработчик работает дольше TTL, другой запрос способен получить тот же lock, пока первый ещё выполняется. Инженеру нужно либо держать RPC и dependencies заметно бы-

стрее lease, либо добавить renewal/fencing token, либо вынести долгие операции в durable state machine.

Отдельно тестируйте race между resume Task и обновлением Workspace/Model. Reconciler собирает launch envelope из snapshot-а прочитанных объектов, но не захватывает их locks вместе с Task.

Failure windows и осмысленный retry

Где произошёл сбой	Возможное состояние	Безопасное действие
До первой записи Redis	Task отсутствует	Повторить create
После SaveTask, до Actor	Task существует как Suspended/Failed, Actor может отсутствовать	GetTask , устранить причину, resume или delete/recreate
Actor создан, status не записан	Substrate впереди Redis	Сверить Actor по имени Task, затем повторить lifecycle operation
ResumeActor успешен, RPC оборвался	Actor может работать, клиент видит timeout	Не делать create; проверить Task, Actor и runner probe
Readiness timeout	Running , Ready=False ; runner может стать готов позже	Проверить фактический probe, затем repair/reconcile policy
SuspendActor вернул ошибку	AX всё равно может показать Suspended	Проверить Actor state и Worker assignment
Actor удалён, Redis delete не выполнен	Task остаётся Terminating	Повторить delete; NotFound Actor считается успехом
Template cleanup не завершён	Task удалён, templates остались	Периодический orphan audit и garbage collection

Главное правило retry: сначала выясните, какой side effect уже состоялся. Повтор без чтения двух систем безопасен только там, где API явно гарантирует idempotency.

WatchTask - уведомление о status, а не доказательство progress

WatchTask сначала читает текущий Task и отправляет событие INITIAL , затем подписывается на task-specific Redis Pub/Sub channel и пересылает MODIFIED при сохранении status. Канал не является durable event log: отключившийся consumer не воспроизведёт все промежуточные переходы, но после reconnect получит актуальный snapshot через INITIAL .

Server завершает stream автоматически для Failed или Completed . Однако default runner не переводит Task в Completed по exit child process. Следовательно, долгоживущий watch не яв-

ляется ожиданием результата Job. Для application completion нужен отдельный durable protocol harness-a.

Как читать status без самообмана

Поле	Полезная интерпретация	Опасная интерпретация
phase=Suspended	Desired/control-plane lifecycle остановлен	«Actor точно не потребляет Worker»
phase=Running	ResumeActor прошёл и назначение Worker было получено	«Агент жив и выполняет полезную работу»
phase=Failed	Последний synchronous reconcile вернул ошибку	«Никаких runtime side effects не осталось»
phase=Terminating	Delete начат, record сохранён для recovery	«Удаление обязательно завершится само»
WorkspaceReady=True	Workspace setup когда-то успешно завершился	«Текущий restored filesystem полностью исправен»
Ready=True	Actor running и AX считает Workspace готовым	«Model, tools и business outcome готовы»
workerIp	Последний сохранённый routing hint	«Worker assignment гарантированно актуален»

Phase Completed распознаётся watch API, но current Task reconciler и runner не устанавливают его после завершения команды. Не проектируйте batch semantics вокруг поля, которое никто не обновляет.

Минимальные operational playbooks

Create вернул ошибку

1. Выполните GetTask по тому же atespace/name.
2. Если Task отсутствует, retry create допустим.
3. Если Task есть, проверьте phase/conditions и Actor с тем же именем.
4. Не меняйте manifest под тем же именем: Task immutable.
5. После исправления dependency выберите resume или контролируемый delete/recreate.

Task долго остаётся Initializing

1. Сверьте workerIp с реальным Actor assignment.
2. Проверьте runner /healthz и /readyz?check=workspace отдельно.
3. Посмотрите workspace setup logs и доступность Git/files sources.

4. Помните, что status сам может не обновиться после 15-секундного окна.
5. Не объявляйте инцидент model serving, пока не доказана готовность workspace.

Suspend не освобождает Worker

1. Не доверяйте только `phase=Suspended`.
2. Проверьте Actor state и Worker assignment в Substrate.
3. Ищите warning `could not suspend actor on Substrate` в `ax-server`.
4. Убедитесь, что snapshot backend доступен и suspend не завис на runtime-слое.

Delete застрял в Terminating

1. Проверьте, существует ли Actor.
2. Если Actor ещё удаляется, не удаляйте Redis key вручную.
3. После NotFound повторите штатный delete, чтобы завершить очистку record.
4. Отдельно проверьте per-task templates и внешние side effects.

Acceptance matrix для платформенной команды

Сценарий	Что должно быть доказано
Два одновременных resume одного Task	Операции сериализуются до истечения lock lease
Reconcile дольше 30 секунд	Нет overlap или внедрены renewal/fencing
<code>ax-server</code> падает после SaveTask	Recovery находит persisted Task и состояние Actor
Client timeout после ResumeActor	Повтор не создаёт второй Actor и не теряет первый
Workspace готов после 15 секунд	Observer обнаруживает readiness и исправляет stale status
SuspendActor возвращает ошибку	Monitoring не принимает <code>Suspended</code> за доказательство остановки
Delete прерывается после удаления Actor	Повтор завершает Redis cleanup
Redis Pub/Sub сообщение потеряно	Reconnect watch возвращает актуальный <code>INITIAL</code> snapshot
Runner child завершился	Application protocol фиксирует outcome независимо от AX phase

Антипаттерны

- Искать отдельный `ax-controller` в `current main`. Lifecycle выполняет `ax-server`.

- **Называть Redis Pub/Sub очередью reconciliation.** Это transient notification, а не durable work log.
- **Повторять create после timeout без Get.** Task мог уже занять immutable имя.
- **Считать synchronous RPC транзакцией Redis + Substrate.** Между side effects остаются failure windows.
- **Назначать работу по phase=Running.** Сначала проверьте Ready, затем application dependencies.
- **Считать WorkspaceReady=True вечной проверкой данных.** Condition sticky и не валидирует restored state повторно.
- **Считать lock абсолютной защитой.** Lease истекает, а cross-resource transaction отсутствует.
- **Удалять застрявший Redis record вручную.** Так легко потерять ownership Actor и templates.
- **Считать delete откатом действий агента.** Внешние side effects живут отдельно.

Итог

Task lifecycle в current AX - это synchronous orchestration внутри `ax-server`: resource lock, Redis state, прямые Substrate calls и короткое окно проверки runner readiness. Такой дизайн легче проследить, чем прежнюю очередь с отдельным controller, но он требует дисциплины на границах систем.

Инженер должен уметь ответить на четыре вопроса: какой side effect уже произошёл, где хранится последняя observation, истёк ли lock lease и какое действие действительно безопасно повторить. Тогда `Suspended`, `Running`, `Ready` и `Terminating` становятся полезными сигналами, а не успокаивающими ярлыками.


В следующей главе мы перейдём к model endpoint. Теперь связь ясна: даже идеально reconciled и ready Task бесполезен, если inference service не выдерживает контекст, parallelism и latency agent workload.

Источники и дальнейшее чтение

- [AX current-main architecture](#)
- [Task API and synchronous lifecycle handlers](#)
- [Task reconciliation and Workspace readiness](#)
- [Redis resource store and WatchTask Pub/Sub](#)
- [Per-resource Redis locks](#)
- [Substrate Actor operations used by AX](#)
- [Change removing Redis Streams and ax-controller](#)

Local inference как сервис: как выбрать runtime, модель и границу ответственности

Local inference в AX: стабильный model endpoint скрывает runtime, модель и hardware



В предыдущей главе мы довели AX Task до состояния, в котором runner действительно готов принять работу. Следующий внешний dependency — модель. Именно здесь часто возникает опасная иллюзия: если файл с весами загрузился, а `/v1/chat/completions` вернул текст, значит локальный inference уже построен. На самом деле это только удачный smoke test.

Production inference — отдельный сервис со своей очередью, памятью, версиями модели, политикой доступа, SLO и отказами. Harness отправляет ему запросы, но не должен знать, на какой GPU лежат веса, сколько у сервиса replicas и каким engine выполняется decode. Для AX это стабильный **model endpoint**; за endpoint находится самостоятельная эксплуатационная система.

Эта глава отвечает на вопрос **что выбрать и почему**. Мы разберём границу между AX и inference, отличие vLLM от llama.cpp, роль CPU/GPU, состав memory budget, риск quantization и путь от ноутбука до shared production service. Метрики нагрузки подробно появятся в главе 21, а расчёт VRAM и parallelism — в главе 41.

Что означает «локальный»

Local inference не обязательно означает «процесс на том же ноутбуке». Это inference, чьими model artifacts, runtime, hardware и политикой данных управляет ваша команда. Он может работать:

- на workstation инженера;
- на одном GPU-host в лаборатории;
- в отдельном Kubernetes pool;
- в изолированном on-premises кластере;
- в арендованной VM с GPU, если контроль deployment остаётся у вас.

Граница проходит не по длине сетевого кабеля, а по **операционной ответственности**. У внешнего API поставщик обновляет runtime, держит запас capacity и устраняет hardware failures. У local inference всё это становится вашей задачей.

Выбирать его разумно, когда важны data residency, работа без внешнего egress, контроль над model revision, адаптерами и sampling, предсказуемая стоимость при устойчивой нагрузке или очень малая network latency внутри площадки. Но локальный сервис не является автоматически более дешёвым, быстрым или приватным. Простаивающий GPU дорог; перегруженный GPU создаёт очередь; открытый endpoint в локальной сети не защищает данные; неудачная quantization может испортить tool calls незаметнее, чем обычные ответы.

Полезная проверка звучит так: **какую конкретную зависимость мы хотим взять под свой контроль и готовы ли мы эксплуатировать её сами?** Если ответа нет, решение «поставим модель локально» пока архитектурно не закончено.

Где проходит граница АХ

АХ управляет жизненным циклом Task и Actor, workspace и runner. Inference server управляет загрузкой модели, tokenization, scheduling, KV cache и генерацией. Эти циклы не следует смешивать.

Обычно model server живёт дольше отдельного Task и обслуживает несколько Tasks. АХ передаёт runner стабильный URL, identity/credential и логическое имя модели. Reverse proxy или model gateway выбирает backend, проверяет доступ, ограничивает запрос и добавляет correlation ID. За ним runtime распределяет запросы по очереди и hardware.

Такое разделение даёт три свойства:

1. **Task не привязан к физическому GPU.** Host можно заменить, не пересоздавая agent workspace.
2. **Готовность измеряется по слоям.** Task Ready не доказывает, что модель загружена; health model server не доказывает, что она корректно вызывает tools.
3. **Отказы изолированы.** Перезапуск inference replica не обязан останавливать Actor, а удаление Task не выгружает общую модель.

Запускать model server внутри каждого Task допустимо для изолированного эксперимента, но обычно это плохой default: веса загружаются повторно, GPU capacity дробится, cold start растёт, а модель обновляется вместе с пользовательской средой. Per-Task server имеет смысл только при жёсткой tenant isolation, уникальной модели/adapter или исследовании, где воспроизводимость важнее utilization.

Сначала контракт, потом engine

Команда часто начинает с вопроса «vLLM или llama.cpp?», хотя раньше нужно определить контракт workload:

- какие модели и точные revisions нужны;

- какой context реально приходит, а не только объявлен в model card;
- нужны ли tools, parallel tool calls, JSON Schema, vision, embeddings или reranking;
- допустимы ли streaming и cancellation;
- сколько запросов приходит одновременно и насколько они bursty;
- какие TTFT, inter-token latency и availability приемлемы;
- можно ли отправлять prompt во внешний API;
- что происходит при перегрузке: очередь, отказ, fallback или деградация на меньшую модель.

Только после этого сравнивают runtime и hardware. Иначе команда оптимизирует удобный benchmark, а не свой агентный сценарий.

vLLM и llama.cpp — два разных центра тяжести

Оба проекта умеют предоставлять HTTP API, похожий на OpenAI API, выполнять quantized models и обслуживать несколько запросов. Но они оптимизированы под разные исходные ограничения.

Если главный вопрос звучит так...	Первым кандидатом будет	Почему
«Как получить высокий aggregate throughput на GPU и обслуживать общий pool запросов?»	vLLM	Scheduler, continuous batching, PagedAttention, prefix caching и широкий набор distributed/parallel режимов ориентированы на serving.
«Как запустить GGUF на CPU, Apple Silicon, небольшой GPU или гибриде CPU/GPU?»	llama.cpp	Лёгкий C/C++ runtime, большой выбор backends и удобное управление offload делают его сильным для constrained hardware.
«Нужен воспроизводимый lab endpoint без отдельного GPU-server?»	llama.cpp	Один model artifact и компактный server снижают порог первого запуска.
«Модель не помещается на одной GPU или нужен общий production pool?»	vLLM , если модель и hardware поддерживаются	Tensor/pipeline/data/expert parallelism и production metrics дают больше возможностей для масштабирования.
«Нужен один редкий формат модели или backend?»	Проверка support matrix обоих	Название runtime ничего не гарантирует: важна конкретная комбинация architecture, quantization, device и kernel.

vLLM — не просто Python-обёртка над моделью. Его основная ценность — scheduler, который держит множество sequences, переиспользует блоки KV cache и формирует работу для accelerator. В актуальной на октябрь 2026 года линии `v0.31.0` проект предоставляет OpenAI-compatible endpoints, distributed serving, несколько видов parallelism, quantization, structured outputs и Prometheus metrics. Этот список быстро меняется, поэтому production deployment обязан pin'ить image digest и сверяться с документацией именно выбранной версии.

llama.cpp — runtime и набор инструментов вокруг формата GGUF. `llama-server` умеет CPU и GPU inference, partial offload, parallel decoding, continuous batching, embeddings, structured JSON и tool use. Его сильная сторона — не «медленный fallback», а широкий диапазон устройств и очень низкий порог управления. На подходящем GPU он тоже может быть быстрым; на CPU — давать полезный private endpoint там, где отдельный accelerator экономически не оправдан.

Это не единственные варианты. TensorRT-LLM, TGI, SGLang, Ollama и vendor-specific stacks могут оказаться правильнее. Но выбирать следует не по числу звёзд на GitHub, а по шести совпадениям: **model architecture, artifact format, hardware backend, API capabilities, SLO и компетенции команды.**

OpenAI-compatible — это форма разъёма, а не одинаковое поведение

Совместимый endpoint очень полезен: harness может менять `base_url` и переиспользовать client library. Но одинаковые пути `/v1/...` не делают providers семантически идентичными.

Различаться могут:

- поддерживаемые поля запроса и error codes;
- chat template и способ размещения system/tool messages;
- token accounting и предел context;
- формат streaming chunks и cancellation;
- `response_format`, JSON Schema и grammar constraints;
- parallel tool calls, tool choice и сериализация arguments;
- reasoning fields, multimodal parts и usage metadata.

Особенно важен **chat template**. Одна и та же модель с неправильным template может выглядеть «глупее», повторять служебные токены или ломать tool calls. Template — часть deployment artifact наравне с weights и tokenizer, а не косметическая настройка клиента.

Поэтому model adapter в harness должен иметь capability tests. Минимальный набор проверяет обычный chat, streaming, отмену запроса, лимит context, один и несколько tool calls, валидный structured output, обработку tool result и ожидаемые ошибки. Smoke test «модель рассказала анекдот» для agent platform почти ничего не доказывает.

Из чего на самом деле состоит deployment модели

Идентификатора вида `org/model-name` недостаточно для воспроизводимости. Deployment должен фиксировать:

- model repository и immutable revision/commit;

- weights и их format/quantization;
- tokenizer и chat template;
- runtime version и container image digest;
- engine arguments: context limit, dtype, parallelism, cache settings;
- model license и разрешённые способы использования;
- checksum или provenance скачанных artifacts;
- набор capability/evaluation tests;
- hardware, driver и accelerator runtime, на которых выполнена приёмка.

Это можно представить как release модели. Сначала artifacts попадают в контролируемое хранилище, затем проверяются license, hash и совместимость, после чего новая replica прогревает weights и проходит probes. Лишь затем gateway отправляет на неё canary traffic. Старую revision удаляют только после drain активных streams и возможности rollback.

Тег `latest` разрушает эту цепочку: сегодня за тем же именем могут оказаться другие weights, template или runtime. Для агента это особенно опасно — поведение изменится не только в тексте, но и в выборе tools и структуре side effects.

Memory budget: почему «веса помещаются» недостаточно

Грубая оценка размера weights выглядит просто:

параметры × битность / 8

Например, 8 миллиардов параметров в 4-bit representation дают около 4 GB сырых данных. Но это не обещание, что модель запустится в 4 GB: format хранит scales и metadata, часть tensors может иметь другую precision, а runtime нужны дополнительные allocations.

Полный budget включает как минимум:

weights + KV cache + runtime/workspace buffers + временные allocations + fragmentation/reserve

KV cache хранит attention state активных sequences. Он растёт с фактическим context и concurrency, поэтому длинные agent histories могут исчерпать память, даже если weights занимают только половину VRAM. При нехватке cache runtime уменьшает concurrency, вытесняет blocks, recompute'ит данные или отклоняет запрос — конкретное поведение зависит от engine.

Runtime buffers зависят от kernels, graph capture, batch shape и backend. Свободный остаток в 200 MB — не capacity plan. Нужен резерв для пиков, инициализации и version drift.

Глава 41 даст более точный sizing. Здесь важен mental model: сначала измеряем распределение input/output tokens и одновременных sequences, потом выбираем context limit и cache, и лишь затем отвечаем, «помещается ли модель».

Quantization — инженерный компромисс, а не кнопка «сделать меньше»

Quantization хранит weights, а иногда activations или KV cache, с меньшей precision. Это может уменьшить memory footprint и ускорить inference, если hardware имеет подходящие kernels. Но «4-bit» не является единым форматом и не гарантирует ускорения.

Результат зависит от:

- метода quantization и наличия calibration;
- того, какие слои оставлены в большей precision;
- поддержки конкретного format runtime'ом;
- accelerator generation и выбранного kernel;
- стоимости dequantization и размера batch;
- чувствительности модели и задачи к ошибке.

На CPU GGUF quantization часто является естественным способом уместить модель и увеличить скорость за счёт меньшего memory traffic. На GPU неподходящий format может выбрать менее эффективный kernel и проиграть FP16/BF16 или FP8, несмотря на меньшие weights.

Для agent workload evaluation обязана проверять не только «качество ответов». Отдельно измеряйте:

- выбор правильного tool;
- полноту и типы arguments;
- соблюдение JSON Schema;
- устойчивость на длинном context;
- частоту повторов и незавершённых tool loops;
- поведение на отказах tools и adversarial input.

Экономия VRAM не окупается, если модель на несколько процентов чаще создаёт неверный side effect или вынуждает harness повторять шаг.

CPU, GPU и hybrid offload

CPU хорош для небольших моделей, низкой или прерывистой нагрузки, лаборатории и data-local environments без accelerator. Он также удобен как функциональный fallback: endpoint остаётся доступным, пусть SLO и ухудшается. Но нельзя без измерений обещать, что GPU workload «просто переедет на CPU» — timeout'ы и длина очереди могут изменить поведение всего agent loop.

GPU/accelerator нужен, когда важны высокая пропускная способность, короткий prefill на больших prompts или несколько одновременных generations. Здесь производительность часто ограничивается не только FLOPS, но и bandwidth, capacity memory и scheduler'ом.

Hybrid offload переносит часть layers на GPU, а оставшиеся держит на CPU. Это позволяет запустить модель, которая не помещается в VRAM, но создаёт transfer и synchronization cost. Частичный offload — разумный путь для workstation, однако не следует автоматически считать его production scaling strategy. Сначала измеряют реальный TTFT и decode speed на нужном context.

Несколько GPU тоже не являются «одной большой GPU». Tensor parallel делит вычисление слоя и требует communication между devices; pipeline parallel делит layers и добавляет pipeline bubbles; replicas увеличивают throughput независимых запросов, но каждая хранит полный набор weights. Если модель помещается на одном устройстве, несколько replicas часто проще и надёжнее сложного model parallelism. Подробно этот выбор разбирается в главе 41.

Три практических topology

1. Инженерный ноутбук или lab VM

Одна quantized GGUF-модель, llama-server, loopback или закрытая lab network. Цель — проверить model/harness contract, tool schema и воспроизводимость, а не имитировать production throughput. Model revision, template и параметры запуска всё равно фиксируются.

2. Один GPU-host для команды

Одна или несколько vLLM/llama.cpp replicas находятся за reverse proxy. Gateway завершает TLS, проверяет service identity, задаёт request limits и correlation ID. Model server не публикуется напрямую наружу. Deployment имеет readiness probe, startup timeout для загрузки weights и отдельный metrics path.

3. Shared production pool

Gateway маршрутизирует логические имена моделей на versioned pools. Replicas проходят canary и drain; overload policy ограничивает очередь; scheduler и autoscaling опираются на model-specific metrics. Model artifacts берутся из контролируемого registry/cache, а не скачиваются из интернета каждым Pod при старте. Tasks видят стабильный endpoint и не знают topology pool.

Переход между topology должен менять infrastructure, но не contract harness. Если для миграции с ноутбука в кластер приходится переписывать agent loop, граница сервиса была выбрана плохо.

Readiness, overload и отказ

Обычный TCP health check слишком слаб. Нужны как минимум разные сигналы:

- **process alive** — процесс не завершился;
- **model loaded** — weights и tokenizer готовы;

- **inference ready** — короткий контролируемый запрос проходит;
- **capability ready** — canary с tool/JSON contract даёт ожидаемую структуру;
- **service healthy** — очередь и error rate позволяют принимать новый traffic.

При старте large model загрузка weights может занимать минуты. Оркестратор не должен убивать Pod коротким liveness timeout, пока тот легитимно инициализируется. Напротив, readiness нельзя выставлять до завершения загрузки: иначе первые запросы попадут в холодный и ещё не готовый process.

Overload — штатное состояние, которое следует проектировать. Бесконечная очередь превращает локальную экономию в непредсказуемые минуты ожидания. Лучше иметь bounded queue и явный ответ 429/503 с retry policy. Gateway может направить часть traffic на другую replica, меньшую модель или внешний provider — но только если этот fallback прошёл те же capability tests.

Ретрай streaming request требует осторожности. Если клиент уже получил часть текста или agent успел выполнить tool, слепой повтор может дублировать действие. Harness должен отличать безопасный повтор model call от повторения application side effect и связывать попытки единым request/trace ID.

Безопасность: модель тоже часть control boundary

Local endpoint часто считают доверенным просто потому, что он находится «в нашей сети». Для agent platform это опасно: через него проходят system prompts, retrieved documents, tool schemas и иногда секреты из workspace.

Минимальная архитектура включает:

- private network path и deny-by-default policy;
- service identity или gateway authentication, а не общий ключ во всех Tasks;
- отдельный доступ к inference, metrics, profiling и administrative endpoints;
- limits на body size, context, output tokens, concurrency и время запроса;
- проверку provenance model artifacts и pinning image digest;
- редактирование/отключение prompt logging, если там могут быть секреты;
- tenant-aware audit metadata без сохранения лишнего содержимого;
- egress policy для container, который не обязан ходить в интернет после загрузки artifacts.

OpenAI-compatible API key защищает только то, что действительно проверяет выбранный server. Не предполагайте, что тем же механизмом закрыты /metrics, profiling, model load/unload или debug routes. Это проверяют по версии runtime и закрывают на proxy/network layer.

Как принимать решение

Рабочий порядок выглядит так:

1. Зафиксируйте use case и capability contract агента.
2. Выберите model revision по качеству на собственных задачах, а не по общей таблице лидеров.
3. Определите допустимость external API и требования к данным.
4. Соберите workload distribution: context, output, burst concurrency, tools.
5. Проверьте runtime support для модели, format, device и API capabilities.
6. Рассчитайте предварительный memory budget с KV/cache reserve.
7. Соберите минимальный endpoint и прогоните capability tests.
8. Проведите нагрузочный тест на целевом профиле, а не на одном коротком prompt.
9. Добавьте gateway, identity, observability, bounded queue и rollout/rollback.
10. Только после этого называйте endpoint production-ready.

Короткая матрица выбора

Сценарий	Разумный первый вариант	Что доказать до эксплуатации
Personal/lab, CPU или mixed hardware	llama.cpp + pinned GGUF	Template, tool calls, context, реальная скорость, закрытый bind address
Shared single-GPU service	vLLM или llama.cpp за gateway	Memory headroom, burst queue, cancellation, structured output, restart time
Multi-GPU large model	vLLM и поддерживаемый parallel mode	Interconnect cost, failure domain, scaling benefit относительно меньшей модели
Строго изолированный tenant	Dedicated replica/pool	Artifact provenance, identity, network и logging isolation
Нерегулярная малая нагрузка	Сначала сравнить с managed API	Полную стоимость владения, cold start и on-call burden

Антипаттерны

- **Выбирать runtime до workload contract.** Получается быстрый server, который не умеет нужный tool protocol.
- **Считать OpenAI compatibility полной взаимозаменяемостью.** Несовпадение template или streaming ломает harness уже после smoke test.
- **Публиковать model server напрямую в общую сеть.** Gateway и network policy нужны даже «внутри».

- **Использовать `latest`**. Невозможно связать regression с конкретными weights или runtime.
- **Считать размер файла модели размером необходимой памяти**. KV cache и buffers появляются только во время работы.
- **Выбирать максимальный context «на всякий случай»**. Он съедает cache capacity и ухудшает полезную concurrency.
- **Оценивать quantization только по красивому диалогу**. Tool calls и structured output могут деградировать отдельно.
- **Считать CPU fallback прозрачным**. Другой latency profile меняет timeout'ы и queueing всего агента.
- **Лечить overload бесконечной очередью**. Система остаётся формально доступной, но перестаёт выполнять SLO.
- **Смешивать rollout модели с rollout Task**. Эти жизненные циклы должны быть независимы.

Итог

Local inference — это не «модель рядом с агентом», а отдельный сервисный контур. vLLM обычно начинает выигрывать там, где главным становится GPU serving и общий throughput; llama.cpp — там, где важны GGUF, CPU/hybrid execution, constrained hardware и простота первого deployment. Но финальный выбор определяется пересечением model, hardware, API contract, SLO и способности команды сопровождать систему.

Для АХ правильная абстракция проста: Task получает стабильный model endpoint, а runtime, revision и physical placement остаются за этой границей. Внутри границы команда pin'ит artifacts, тестирует tool semantics, планирует memory, защищает endpoint и умеет обновлять его без разрушения agent state.


Теперь можно перейти от архитектуры к числам. В следующей главе мы измерим TTFT, inter-token latency, queue time, aggregate throughput и KV pressure для нагрузки из 10–15+ агентов — и увидим, почему количество агентов почти никогда не равно одновременной inference concurrency.

Источники и дальнейшее чтение

- [vLLM: online serving и поддерживаемые API](#)
- [vLLM: возможности engine и parallelism](#)
- [vLLM: production metrics](#)
- [vLLM releases](#)
- [llama.cpp](#)
- [llama-server: API, batching, structured output и tool use](#)

Производительность inference: как измерять latency, throughput и capacity для 10-15+ агентов

Путь inference-запроса: где возникают queue time, TTFT, ITL и полезный результат



В главе 20 мы выбрали границу model service: AX Task знает стабильный endpoint, а runtime, model revision и hardware скрыты за ним. Теперь возникает практический вопрос: выдержит ли этот endpoint реальную работу десяти, пятнадцати или большего числа агентов?

Ответ нельзя получить одним числом `tokens/s`. Пользователь ощущает не среднюю скорость GPU, а задержку конкретного шага: сколько запрос стоял в очереди, когда появился первый полезный token, не начал ли stream заикаться, успел ли агент сформировать корректный tool call и закончилась ли задача до deadline. Сервер тем временем видит другую картину: batch, prompt tokens, KV cache, preemptions и суммарный throughput.

Цель этой главы - связать эти две картины. Мы разберём timeline запроса, метрики, модель нагрузки, программу benchmark и диагностические признаки bottleneck. Точный расчёт VRAM и выбор parallelism останутся в главе 41; здесь важнее научиться доказывать, что система выполняет свой SLO.

Сначала определите, что значит «быстро»

Фраза «модель отвечает медленно» неоднозначна. Для интерактивного пользователя критично быстро увидеть начало ответа. Для coding agent важнее завершить tool call до timeout. Для фонового researcher допустима большая задержка одного шага, но неприемлемы часовая очередь и массовые retries. Один endpoint может быть хорош для одного класса работы и плох для другого.

До benchmark нужно назвать:

- кто ждёт результат: человек, coordinator или background worker;
- когда ожидание становится заметным или нарушает deadline;
- нужен ли streaming или важен только полный structured result;
- сколько model calls требуется для одной полезной задачи;

- что считается успехом: текст, валидный tool call, завершённый agent step или решённая задача;
- что система делает при перегрузке: ждёт, отклоняет, упрощает модель или уходит на fallback.

Без этого команда легко «улучшает» aggregate throughput, одновременно ухудшая время до первого token и полезную производительность агента.

Timeline одного запроса

Разложим путь запроса на наблюдаемые участки.

1. **Client preparation.** Harness собирает messages, tool schemas и sampling parameters, иногда выполняет retrieval и сокращает context.
2. **Network и gateway.** Запрос проходит TLS, authentication, routing, rate limits и serialization.
3. **Admission и queue.** Server принимает запрос, но sequence ещё не получила compute/cache capacity.
4. **Tokenization и rendering.** Chat template превращает messages в model input; multimodal preprocessing может добавить заметную CPU-нагрузку.
5. **Prefill.** Модель обрабатывает prompt и создаёт KV state. Чем длиннее input, тем больше работы до первого output token.
6. **First token.** Клиент получает первый непустой chunk. На этом заканчивается TTFT.
7. **Decode.** Модель генерирует последующие tokens. Здесь важны ITL, jitter и fairness между sequences.
8. **Completion и postprocessing.** Server завершает stream, client собирает JSON/tool call, валидирует schema и передаёт результат agent loop.
9. **Useful outcome.** Агент использует ответ: вызывает tool, принимает решение или завершает step.

Границы измерения должны быть явными. Server-side TTFT обычно не включает часть client/network времени, а client-side TTFT включает. Метрика gateway может начинаться раньше, чем engine metric. Если сравнивать их без определения точки старта, цифры будут выглядеть противоречивыми, хотя обе корректны.

Для production полезны оба взгляда:

- **client observed** показывает опыт harness и пользователя;
- **server internal** объясняет, где именно потрачено время.

Метрики, которые нельзя смешивать

Метрика	Что измеряет	На какой вопрос отвечает	Чего не доказывает
TTFT - time to first token	От отправки/приёма запроса до первого output token	Насколько быстро система начинает отвечать	Скорость и плавность оставшегося stream
ITL - inter-token latency	Интервал между соседними output tokens	Есть ли паузы и jitter во время decode	Полную длительность запроса
TPOT - time per output token	Средний интервал генерации после первого token	Среднюю decode latency для request	Редкие длинные паузы, которые видны в ITL distribution
E2E latency	Время до последнего token/полного ответа	Когда model call полностью закончится	Где возникла задержка
Prompt throughput	Обработанные input tokens/s	Производительность prefill path	Interactive latency конкретного запроса
Output throughput	Сгенерированные output tokens/s	Производительность decode path	Полезность или корректность output
Aggregate throughput	Tokens/s или requests/s всего deployment	Общую пропускную способность	Fairness и SLO отдельных requests
Queue time	Время ожидания scheduler/admission	Есть ли дефицит capacity	Причину дефицита без остальных метрик
KV occupancy и preemptions	Давление активного context на cache	Хватает ли cache для workload	Качество модели и client latency вне engine
Goodput	Успешные requests/tasks, уложившиеся в SLO, за единицу времени	Сколько полезной работы реально выполнено	Почему отдельные requests не прошли SLO

TTFT удобно мысленно раскладывать так:

`TTFT = network/gateway + queue + tokenize/render + prefill + delivery первого chunk`

А полную model latency - так:

`E2E = TTFT + decode оставшихся tokens + завершение stream`

Это не универсальные формулы telemetry: runtime может считать границы иначе. Их задача - не дать свести все задержки к слову «GPU».

Почему среднее почти всегда врёт

Средняя TTFT 800 ms может скрывать ситуацию, в которой большинство запросов начинает отвечать за 300 ms, а каждый двадцатый ждёт 12 секунд. Для agent coordinator именно этот хвост задержки часто определяет время всей задачи: он ждёт самый медленный child.

Минимально нужны p50, p95 и p99:

- **p50** описывает обычный опыт;
- **p95** показывает частые хвостовые задержки и удобен для рабочего SLO;
- **p99** обнаруживает редкие stalls, queue bursts, cold paths и interference.

Но percentile без sample count и временного окна тоже опасен. P99 по 40 запросам почти ничего не говорит; суточный p95 склеивает утро без нагрузки и вечерний overload. Храните count, rate и histogram по классу запроса, model revision и deployment, а не только одну линию «average latency».

Нельзя бездумно добавлять labels с Task ID или request ID в Prometheus metrics: cardinality взорвётся. Такие идентификаторы принадлежат traces/logs; metrics агрегируются по ограниченному набору измерений вроде model, pool, route и result class.

Количество агентов не равно inference concurrency

Агент не генерирует tokens непрерывно. Он читает tool result, ждёт filesystem/network, выполняет код, запрашивает approval и обновляет state. Поэтому пятнадцать активных агентов не означают пятнадцать постоянных decode sequences.

Для первой оценки можно использовать inference duty cycle:

$\text{средняя concurrency} \approx \text{число активных агентов} \times \text{доля времени в model call}$

Если 15 агентов проводят в inference около 35% wall time, средняя concurrency будет примерно $15 \times 0.35 = 5.25$. Это не capacity guarantee. После общего события - запуска batch, resume Tasks или fan-out coordinator - все 15 могут отправить запрос почти одновременно.

Вторая полезная оценка строится через arrival rate:

$\text{LLM requests/s} = \text{agent tasks/s} \times \text{среднее число model calls на task}$

Если приходит 0.4 задачи в секунду, а агент делает в среднем 6 model calls, endpoint получает около 2.4 requests/s. При средней model latency 2 секунды закон Little даёт примерно $L = \lambda w = 4.8$ одновременно находящихся в системе requests. Если latency под нагрузкой вырастет до 6 секунд, среднее число уже станет 14.4: очередь увеличивает concurrency, а concurrency ещё сильнее увеличивает очередь.

Обе оценки требуют реальных traces. Duty cycle не видит burst, а среднее calls/task не показывает длинный хвост сложных задач. Их используют для начальной гипотезы, затем проверяют replay или synthetic workload.

Что записать из реальной нагрузки

Сервер следует тестировать не «prompts по 1k tokens», а распределением, похожим на production. Для каждого класса model call собирайте:

- input tokens p50/p95/p99;
- output tokens и finish reason;
- tool schema size и число tools;
- долю prefix reuse и повторяющихся system prompts;
- arrival rate, burst size и интервал между requests;
- число параллельных active sequences;
- streaming/cancellation/retry rate;
- model route и sampling parameters;
- долю structured output, vision и embeddings;
- итог agent step: success, validation error, retry или fallback.

Особенно важно не путать объявленный `max_model_len` с фактическим context. Если 99% requests укладываются в 8k, а один диагностический transcript занимает 64k, benchmark из одних 64k prompts покажет стресс-предел, но не ежедневную capacity. Нужны оба режима: representative и worst credible case.

Длины измеряются tokenizer'ом той же model revision и того же chat template. Подсчёт «слов» или characters не воспроизводит реальные input tokens, особенно при JSON, исходном коде и многоязычном тексте.

SLO по классам, а не одно число на весь endpoint

Ниже не готовые нормативы, а пример структуры решения.

Класс запроса	Что важно	Пример измеряемой цели
Interactive chat	Быстрое начало и плавный stream	TTFT p95, ITL p95/p99, error rate
Tool selection / JSON	Полный короткий ответ и schema validity	E2E p95, valid-output rate, retry rate
Long planning	Deadline всего шага	E2E p95, output cap, cancellation rate
Background research	Goodput и стоимость	tasks/hour, tokens/task, success before deadline
Coordinator fan-out	Хвост самого медленного child	group completion p95/p99, rejected children, queue depth

SLO должен включать качество. Например, «95% tool-selection calls заканчиваются за 3 секунды и 99.5% ответов проходят schema validation». Если после quantization latency улучшилась, но valid-output rate упал и появились retries, goodput мог стать хуже.

Полезная capacity-метрика формулируется так:

максимальная нагрузка, при которой одновременно выполняются TTFT, ITL/E2E и error-rate SLO.

Это честнее, чем «сервер выдаёт 900 tok/s», потому что лишние tokens, просроченные requests и повторные попытки не являются полезной работой.

Closed-loop и open-loop benchmark

Два генератора нагрузки отвечают на разные вопросы.

Closed-loop держит фиксированное число clients. Каждый отправляет следующий request только после завершения предыдущего. Такой тест удобен для concurrency sweep и поиска saturation point, но имеет coordinated omission: когда server замедляется, clients тоже реже отправляют requests. Реальный входящий поток мог бы продолжить расти, а benchmark сам себя притормаживает.

Open-loop отправляет requests по заданному arrival schedule независимо от времени ответа. Он лучше показывает queueing и overload. Для agent systems полезны как минимум три arrival profile:

- ровный поток для baseline;
- Poisson-like поток для независимых событий;
- burst/fan-out, где группа requests приходит почти одновременно.

`vllm bench serve` поддерживает request rate, распределение arrivals и burstiness; `llama.cpp` содержит server benchmark сценарии на k6. Но инструмент не заменяет workload design: default `request-rate=inf`, при котором все prompts отправляются сразу, измеряет burst stress, а не обычный production traffic.

Практический benchmark protocol

1. Зафиксируйте deployment

Запишите model revision, quantization, tokenizer/template, runtime version, container digest, hardware, driver, accelerator runtime, parallelism, cache/context settings и gateway configuration. Иначе разницу между двумя запусками невозможно объяснить.

2. Подготовьте dataset

Используйте обезличенный trace replay или синтетический набор, повторяющий распределения input/output. Сохраните отдельные группы short/median/p95/worst-case context и tool schemas. Не отправляйте production secrets в benchmark artifacts.

3. Отделите cold и warm path

Cold start, первая компиляция kernels, graph capture, model load и заполнение prefix cache измеряются отдельно. Для steady-state теста выполните warm-up и убедитесь, что его requests не попали в итоговые percentiles.

4. Найдите single-request baseline

Concurrency 1 показывает нижнюю границу latency и выявляет очевидные ошибки configuration. Это не production capacity, а контрольная точка.

5. Выполните concurrency sweep

Например: 1, 2, 4, 6, 8, 12, 15, 20. На каждом уровне сохраняйте TTFT, ITL/TPOT, E2E, prompt/output throughput, queue, KV occupancy, preemptions, errors и cancellations. Диапазон должен пересечь saturation, а не закончиться на последней зелёной точке.

6. Выполните arrival-rate sweep

Повторите тест open-loop для нескольких requests/s и добавьте burst, похожий на coordinator fan-out. Наблюдайте не только completed requests, но и рост queue, rejected requests и recovery после burst.

7. Дайте системе выйти в steady state

Короткий прогон часто заканчивается раньше, чем заполняется KV cache или проявляется thermal/power throttling. Продолжительность выбирают по workload, но фиксируют warm-up, measurement window и cooldown. Каждый сценарий повторяют, чтобы отличить стабильный эффект от шума.

8. Проверяйте результат

Benchmark не считается успешным только потому, что HTTP status равен 200. Проверяйте truncated completions, пустые streams, invalid JSON/tool calls, wrong finish reasons и несоответствие ожидаемой длине output. Часть нагрузочных генераторов умеет считать только transport success, поэтому semantic validation добавляется отдельно.

Матрица минимального эксперимента

Чтобы тест не превратился в бесконечный перебор, начните с небольшой матрицы.

Ось	Минимальные значения
Context	p50, p95, worst credible
Output	short tool call, median answer, long planning
Load	concurrency 1, expected, burst peak, beyond saturation
Arrival	steady, Poisson-like, coordinator burst
Cache	cold prefix, warm prefix
Result	plain text, structured/tool output

Меняйте одну группу факторов за раз. Сравнивать другой runtime, другую quantization, другой context и новое batching setting в одном прогоне бессмысленно: даже если результат лучше, причина неизвестна.

Как читать симптомы

Наблюдение	Наиболее вероятное направление проверки
TTFT растёт, ITL после старта остаётся нормальной	Queue, длинный prefill, tokenization/gateway, конкуренция prompt-heavy requests
TTFT нормальная, ITL и jitter растут	Decode contention, memory bandwidth, слишком много active sequences, prefill interruptions
Queue растёт вместе с высокой accelerator utilization	Deployment достиг compute/memory capacity; нужен admission, routing или scale-out
Queue растёт, accelerator utilisation низкая	CPU preprocessing, gateway, scheduler stalls, network, locks или неравномерный routing
KV occupancy близка к пределу, растут preemptions	Context/concurrency не помещаются в cache; проверяйте length policy и cache budget
Aggregate tok/s растёт, p95 TTFT нарушен	Throughput получен ценой interactivity; batching/concurrency слишком агрессивны для SLO
Server metrics хорошие, client E2E плохая	Gateway/network, client backpressure, медленное чтение stream или postprocessing
Latency хорошая, tasks/hour падает	Output стал длиннее, tool accuracy ухудшилась, выросли retries или агент делает больше steps
После burst система долго не восстанавливается	Очередь не ограничена, requests слишком длинные или retry storm поддерживает перегрузку

Это направления расследования, не автоматические диагнозы. Подтверждайте гипотезу trace'ом и контролируемым экспериментом.

Свяжите server telemetry с AX

Без correlation «агент завис» и «request 8 секунд стоял в model queue» выглядят одинаково. На границе harness/gateway передавайте и записывайте:

- AX Task ID и Actor ID;
- agent/coordinator ID;
- step и attempt ID;
- inference request ID;
- model route и resolved revision;
- input/output tokens;
- client timestamps: send, first chunk, last chunk;
- outcome: text, tool call, validation failure, cancellation, retry;
- trace ID, связывающий gateway и server span.

Не помещайте уникальные IDs в metric labels. Metrics отвечают «насколько часто и насколько плохо», traces - «что случилось с этим request», logs - «какие события и ошибки зафиксированы».

Для streaming client также измеряйте время между chunks. Server может генерировать tokens равномерно, а проху или client buffer отдавать их пачками. Пользователь увидит рывки, хотя engine ITL останется хорошей.

Admission control лучше бесконечной очереди

Когда arrival rate выше service rate, очередь растёт до тех пор, пока requests не начнут нарушать deadline или не закончится память. Бесконечная очередь не сохраняет availability - она превращает явный отказ в скрытую многоминутную задержку.

Нужны:

- bounded in-flight requests и prompt-token backlog;
- per-tenant или per-priority quotas;
- deadline/cancellation propagation;
- load shedding с понятными 429/503;
- retry budget и jitter, чтобы не создать retry storm;
- fallback только на совместимый и заранее проверенный endpoint.

Актуальный vLLM предоставляет queue и prefill-backlog limits, но названия и semantics flags зависят от версии. В архитектуре важно не конкретное значение CLI, а правило: admission должен отклонить работу раньше, чем гарантированно нарушится SLO.

Оптимизируйте в порядке доказанного bottleneck

Разумная последовательность:

1. **Уберите лишнюю работу.** Сократите повторяющийся context, tool schemas и слишком большие output limits; проверьте prefix reuse.
2. **Ограничьте перегрузку.** Настройте admission, priority и cancellation, чтобы просроченные requests не отнимали capacity.
3. **Настройте scheduler под SLO.** Continuous batching, chunked prefill и concurrency меняют баланс TTFT, ITL и throughput.
4. **Разделите классы traffic.** Interactive и background workload могут требовать разных pools/queues.
5. **Проверьте routing.** Маленькая модель полезна только если с учётом ошибок и retries снижает cost/latency полезной задачи.
6. **Добавьте replicas,** когда модель помещается на одном device и workload состоит из независимых requests.
7. **Меняйте model format, quantization или hardware,** только повторяя quality и capability evaluation.
8. **Переходите к tensor/pipeline/disaggregated serving,** когда измерения показывают, что более простая topology не выполняет SLO.

Флаг, который улучшил чужой benchmark, может ухудшить ваш workload. Например, более крупный batch повышает aggregate tokens/s, но увеличивает latency одной sequence; агрессивный prefill повышает prompt throughput, но создаёт ITL spikes у уже идущих streams.

Agent-aware routing и цена полезного результата

Agent platform часто имеет несколько классов model work: classification, retrieval filtering, tool selection, planning, synthesis и review. Отправлять всё на самую большую модель дорого, но routing на меньшую модель тоже не бесплатен.

Считайте не цену одного token, а:

стоимость успешной задачи = стоимость всех calls + retries + fallback + wasted work

То же относится ко времени:

task latency = сумма последовательных model/tool этапов + критический путь параллельных ветвей

Модель, которая отвечает вдвое быстрее, но увеличивает число agent steps с 4 до 9, может ухудшить и latency, и cost. Поэтому server benchmark дополняют end-to-end evaluation на настоящих задачах.

Когда capacity достаточно

Цель тестирования - не найти абсолютный максимум GPU, а построить **capacity envelope**. Например:

При representative mix endpoint выдерживает 8 concurrent active generations и burst до 15 requests, сохраняя TTFT p95 и valid-tool-call rate в пределах SLO; после этого admission начинает отклонять background traffic.

Такое утверждение проверяемо. В нём есть workload, load, quality и overload behavior. Его можно привязать к alert и повторять после обновления model/runtime.

Для запаса учитывайте отказ replica, rollout и неожиданный burst. Система, которая выполняет SLO только при 100% доступных devices и пустой очереди, не имеет эксплуатационного headroom.

Что сохранять после benchmark

Результат должен быть воспроизводимым artifact, а не скриншотом dashboard. Сохраняйте:

- цель и SLO;
- deployment manifest и версии;
- dataset/profile без секретов;
- команды и configuration генератора;
- raw per-request results;
- server metrics и traces за то же окно;
- summary с percentiles, counts, failures и confidence/variance;
- вывод: capacity envelope, bottleneck и следующее изменение;
- ссылку на предыдущий comparable run.

Так benchmark превращается в regression test. После обновления runtime, driver, quantization или model revision команда сравнивает одинаковый workload, а не полагается на субъективное «кажется быстрее».

Антипаттерны

- **Сравнивать только tokens/s.** Throughput без latency и quality SLO не показывает полезную capacity.
- **Тестировать concurrency 1 и экстраполировать линейно.** Queue, batching и KV pressure нелинейны.
- **Отправлять все prompts в момент zero и называть это production load.** Это один burst-сценарий, не распределение arrivals.

- **Использовать один prompt length.** Agent workload имеет широкий context/output distribution.
- **Смешивать cold start и steady state.** Получается число, которое невозможно интерпретировать.
- **Показывать только average.** Tail latency определяет coordinator и user experience.
- **Не валидировать outputs.** Быстрый invalid tool call не является успешным request.
- **Игнорировать cancellations и retries.** Они потребляют capacity и могут поддерживать overload.
- **Сравнивать разные models/configurations одновременно.** Причина изменения теряется.
- **Оптимизировать GPU, не измеряя gateway и client.** Bottleneck может находиться вне engine.
- **Оставлять очередь без границы.** Просроченная работа мешает requests, которые ещё могли выполнить SLO.
- **Объявлять capacity числом агентов.** Нужны arrival rate, context mix, active generations и duty cycle.

Итог

Производительность inference для multi-agent системы измеряется на трёх уровнях. Engine показывает prefill, decode, KV cache и throughput. Endpoint показывает queue, TTFT, ITL, errors и admission. Agent application показывает число steps, tool-call correctness, retries, task latency и goodput. Ни один уровень сам по себе не объясняет систему.

Для 10-15+ агентов начинайте не с покупки второй GPU, а с traces и workload profile. Переведите activity агентов в arrival rate и active sequences, задайте SLO по классам запросов, проведите closed-loop и open-loop tests, найдите saturation и проверьте recovery после burst. После этого bottleneck становится инженерным фактом, а не предположением.


Следующая глава применит этот подход к multi-agent architecture на AX. Теперь мы знаем цену fan-out: каждый child создаёт не только Task и security scope, но и burst model requests, tail latency и общий budget. Это позволит делегировать работу без task explosion и без перегрузки inference endpoint.

Источники и дальнейшее чтение

- [vLLM: production metrics и определения request phases](#)
- [vLLM benchmark CLI](#)
- [vLLM serving benchmark API](#)
- [vLLM serve: queue limits и performance modes](#)
- [vLLM performance dashboard: TTFT/TPOT SLO и throughput](#)
- [llama-server: Prometheus metrics](#)
- [llama.cpp server benchmark](#)

Multi-agent на AX: как делегировать без task explosion

Практика: software-engineering multi-agent workflow



AX Task удобно использовать как unit isolation для специализированных workers. Но Task не должен создаваться на каждый микрошаг. Граница Task оправдана, когда нужны отдельные resources, security scope, Workspace, lifecycle или parallelism.

Coordinator pattern

Root Task получает goal и создаёт structured subtasks. Каждому child передаются ограниченный input, expected output schema, deadline, maximum steps/tokens и allowed capabilities. Результат сохраняется как artifact/state, а coordinator решает дальнейший переход.

Budget propagation

Если root budget 100 условных единиц, дети не должны суммарно получить 500. Budget распределяется сверху вниз. Это касается не только tokens, но и wall time, GPU quota, external API cost и количества spawned Tasks. Хороший invariant: `sum(child maximum) <= remaining parent budget + explicitly approved burst`.

Authority attenuation

Child Task не должен наследовать все credentials parent. Researcher получает read-only repo; implementer - write branch, но не merge; tester - execution tools без production credentials;

reviewer - read. Для infrastructure workflow collector получает telemetry read-only, action agent - временный scope только после approval.

Idempotent delegation

Coordinator restart не должен создавать дубликаты children. Используйте deterministic subtask IDs/idempotency keys и durable task journal. Если AX API create не имеет нужной high-level semantic, это обеспечивает application layer.

Result aggregation

Не склеивайте все ответы агентов в огромный prompt. Сначала валидируйте structured outputs, извлекайте facts/artifacts и только затем создавайте компактный synthesis context. Это снижает token cost и prompt injection propagation.


Security architecture: threat model agent platform

IMPLEMENTED / VERIFIED

MAIN DELTA where noted

ROADMAP kept separate

Security: безопасный агент - это цепочка ограничений, а не один sandbox



Agent platform объединяет несколько высокорисковых свойств: untrusted natural-language input, executable tools, downloaded code, credentials и network access. Sandbox нужен, но он закрывает только часть угроз.

Основные классы угроз

Prompt injection заставляет модель изменить решение. **Tool injection** подсовывает вредоносные descriptions/results. **Malicious repository/Skill/MCP server** атакует supply chain. **Credential exfiltration** использует shell/network/tool. **Sandbox escape** атакует kernel/runtime boundary. **Lateral movement** использует cluster/service credentials. **Runaway execution** расходует tokens/CPU/API quota. **Confused deputy** заставляет привилегированный tool выполнить действие от имени менее привилегированного task.

Defense in depth

1. Минимальный system/container image.
2. gVisor или microVM в зависимости от threat model.
3. Без privileged/root capabilities без нужды.
4. Read-only base FS там, где возможно; durable mount только в нужное место.
5. Default-deny egress.
6. Short-lived scoped credentials.
7. Tool-level authorization по operation и arguments.
8. Approval для destructive/write actions.
9. Resource/token/time budgets.
10. Audit trail и immutable action journal.

11. Central secret manager/Kubernetes secret integration с минимальным exposure.
12. Continuous vulnerability/supply-chain scanning.

Debug как capability

ax ssh требует `spec.debug: true`, а runner guest services позволяют arbitrary process/file operations внутри sandbox. Следовательно, debug - привилегия, не cosmetic flag. В production его лучше делать временным break-glass mechanism с audit и отдельной identity, а не включать у всех Tasks.


Current maturity

Substrate threat-model document в июне 2026 прямо описывал раннюю стадию hardening; последующие релизы добавили identity/egress/authorization работу, но pre-1.0 status остаётся. AX current issues также поднимают auth/authz control plane. Поэтому production internet/multi-tenant deployment без собственного perimeter и review следует считать высоким риском.

Источники и дальнейшее чтение

- [Substrate threat model](#)
- [Substrate releases](#)
- [AX issues](#)

Identity, authorization и Human-in-the-loop



Authorization для agents должна отвечать не «кто запустил Pod», а «какой logical Task сейчас просит какое действие над каким объектом». Это сложнее обычного service account, потому что один agent способен породить дерево child tasks.

Разделяем identities

- Human/operator identity - кто инициировал или approved.
- Platform/workload identity - какой Task/Actor выполняется.
- Tool identity - каким credential агент обращается к внешней системе.
- Resource authority - над каким subset objects допустимо действие.

Хорошая система связывает их в audit event, но не делает один вечный token универсальным ключом ко всему.

Approval gate

Approval нужен не для каждого tool call, иначе система становится ручным workflow. Его ставят на transition authority: переход из read-only диагностики к write, повышение score, destructive operation, превышение budget или доступ к sensitive data.

Approval object должен содержать конкретный action plan, targets, expected changes, expiry и hash/ID параметров. Подтверждение «разрешить агенту работать дальше» слишком широкое.

Read / write / destructive

Практический policy taxonomy:

Класс	Пример	Default
Read	show route, logs, metrics	allow при scoped identity
Bounded write	создать branch/ticket, изменить один объект	policy + optional approval
High-impact	BGP policy, delete VM, firewall rollout	explicit approval + pre/post checks

Класс	Пример	Default
Destructive/ irreversible	wipe data, revoke root PKI	отдельная процедура / возможно запрет агенту

Verification after action

Успешный tool response не равен успешному outcome. После write всегда отдельный verification step: прочитать новое состояние из authoritative system, проверить invariants и записать result. Желательно, чтобы verifier был логически отделён от executor и не доверял его natural-language summary.

Observability: четыре слоя и единая correlation identity

Четыре слоя observability нельзя смешивать в один «лог агента»

Infrastructure
nodes, CPU/RAM/GPU, network, storage,
Kubernetes

Runtime / sandbox
Worker, Actor, snapshot, resume, process

Agent
steps, tool calls, retries, delegated
Tasks

LLM
TTFT, ITL, tokens, errors, cache, cost

Наблюдаемость agent system должна позволять пройти путь от user goal до конкретного tool side effect и одновременно увидеть infrastructure bottleneck.

Infrastructure layer

Node/Pod CPU, RAM, disk latency, network drops, GPU memory/utilization, Redis/PostgreSQL/object-store metrics, Kubernetes events. Это отвечает на вопрос «платформа физически здорова?».

Runtime layer

Actor state, Worker assignment, resume/suspend duration, snapshot size/transfer, WorkerPool occupancy, scheduling wait. Substrate actor логически переживает разные Workers, поэтому logs должны иметь stable actor metadata, иначе история распадется по Pod names.

Agent layer

Step number, plan/route decision, tool name, sanitized arguments, result class, retry, child Task, approval state. Логи chain-of-thought не являются обязательным или желательным telemetry format; нужен структурированный event trail действий и решений без раскрытия скрытого reasoning.

LLM layer

Provider/model/revision, prompt/output token counts, TTFT, ITL, queue time, error class, cache hit, request ID и cost estimate. Prompt content следует логировать выборочно/редактированно: observability storage сама может стать источником утечки secrets/PII.

Correlation

Минимальные IDs: `trace_id`, user/job id, AX Task id, Substrate Actor UID, tool call id, model request id. Для multi-agent добавляется parent/root task. Один trace должен переживать suspend/resume и Worker relocation.

SLO


Примеры SLO: time-to-Task-ready, resume p95, tool success rate, model TTFT p95, successful agent outcome rate, percentage actions requiring manual recovery. «Tokens/s» сам по себе не является SLO бизнеса.

Источники и дальнейшее чтение

- [Substrate observability](#)

Лабораторный стенд на Proxmox/KVM: Kind, k3s или kubeadm

Базовый учебный стенд: один VM, воспроизводимый путь до работающего AX



Для первой воспроизводимой установки выбираем **Kind внутри одной Debian/Ubuntu VM на Proxmox/KVM**, потому что Substrate current quickstart имеет автоматизированный Kind path и локально поднимает зависимые PostgreSQL/RustFS. Это учебный выбор, не production recommendation.

Kind

Kind запускает Kubernetes nodes как Docker containers и сам использует kubeadm внутри node images. Плюсы: быстро удалить/создать cluster, повторяемость, удобно для CI/lab. Минусы: дополнительный слой container-in-VM, networking/storage отличаются от production, hardware/runtime integration сложнее.

k3s

K3s - лёгкий conformant distribution в одном binary с разумными defaults; удобно для homelab/edge и небольших VM. Он уменьшает операционную стоимость, но скрывает часть деталей, которые полезно увидеть при изучении обычного Kubernetes. Для второго стенда это хороший вариант, особенно если ресурсы ограничены.

kubeadm

Kubeadm даёт более «обычный» Kubernetes bootstrap и заставляет явно выбрать CNI, control-plane topology, storage и upgrades. Это лучше для обучения production mechanics и multi-node lab, но требует больше работы.

Практический выбор

Lab-1: Proxmox → VM → Docker → Kind → Substrate → AX.

Lab-2 optional: 3+ VM → kubeadm или k3s → Substrate → AX → separate inference node.

Если планируется microVM, Proxmox должен пробросить nested virtualization/KVM внутрь VM (`/dev/kvm` доступен guest). Для gVisor это требование мягче, хотя конкретный `runsc platform` тоже надо проверить.

Минимальный размер VM


Не задаём универсальные числа, потому что версии и demo images меняются. Практический старт для control-plane lab без большой LLM: несколько vCPU, 12-16 GiB RAM и десятки GiB SSD. Локальный LLM лучше вынести на отдельную GPU VM/host и подключить API, иначе resource pressure смешивает две задачи: изучение orchestration и benchmark inference.

Источники и дальнейшее чтение

- [Substrate README quickstart](#)
- [Kind](#)
- [K3s](#)
- [kubeadm](#)

Production engineering: HA, persistence, upgrades и DR

Production-like topology: failure domains должны быть явными



Production-like AX/Substrate нужно рассматривать как несколько независимых stateful planes, а не как один application Deployment.

Что сохранять

AX state: manifests/status/events в Redis - определить persistence/replication/backup strategy и RPO.

Substrate dynamic state: PostgreSQL - HA, PITR/backup, consistency с snapshot metadata.

Snapshot blobs: object storage - durability, lifecycle, versioning/retention, throughput.

Container images: registry - immutable digests и availability.

Secrets/identity: Kubernetes/external secret store, CA/JWT/SPIFFE material.

Observability: separate backend с retention.

HA не равно «реплик больше»

API replicas требуют load balancing и shared state. Controllers требуют правильных consumer groups/locks/idempotency. PostgreSQL/Redis HA добавляет собственные failure modes. Object store должен выдерживать одновременно restore burst и checkpoints. WorkerPool availability зависит от Kubernetes nodes и image locality.

Upgrade discipline

Для pre-1.0 компонентов:

1. Pin exact versions/images.
2. Read breaking release notes.
3. Test snapshot compatibility.
4. Upgrade lab/staging.
5. Create recovery point.

6. Upgrade control plane before/after workers согласно конкретной compatibility matrix.
7. Run create/suspend/resume/delete and egress tests.
8. Roll gradually.

DR questions

Восстановление должно отвечать: можно ли поднять AX desired resources из backup, сопоставятся ли они с Substrate Actors, доступны ли snapshot URIs, совместимы ли sandbox assets, какие external side effects уже произошли. Документированный DR drill важнее наличия файлов backup.

Capacity reserve

Нельзя держать WorkerPool и inference GPU на 100% average utilization. Resume burst, compaction, node drain и model load требуют headroom. Резерв задаётся через SLO/benchmark, а не фиксированными 20% для всех систем.

Performance и scaling: что реально ограничивает систему

Производительность AX/Substrate определяется цепочкой bottlenecks. Headline density бесполезна без понимания active ratio и snapshot profile.

Основные коэффициенты

logical actors / physical workers - oversubscription. Он полезен только если большая доля actors suspended/idle. Для постоянно активных agents oversubscription не создаёт бесплатный compute.

resume latency складывается из assignment, snapshot location/transfer, restore, readiness и routing. Большой workspace/snapshot или удалённый object store легко доминирует над собственно sandbox startup.

controller throughput определяет скорость массового create/update. Current AX issue про serial reconcile напоминает: bottleneck может быть в control-plane loop, даже когда Workers свободны.

state-store QPS и tail latency влияют на scheduling/status. Redis/PostgreSQL должны benchmark'иться с реальным object count и payload size.

object-store bandwidth/IOPS особенно критичны при suspend storm, node drain или массовом resume после события.

Benchmark matrix

Измеряйте отдельно:

- cold create → ready;
- golden start → ready;
- suspend latency vs snapshot size;
- resume latency warm/cold object cache;
- concurrent resumes 1/10/100/...;
- controller create/reconcile throughput;
- WorkerPool saturation behavior;
- egress proxy overhead;
- inference latency independently от AX.

Project claims

Substrate README публикует ориентиры высокой density и sub-second resume. В книге они отмечаются как **PROJECT CLAIM**, а не гарантия. Ваша target workload может иметь большие files, dirty memory, network dependencies и другую storage topology.

Practical performance budget

Полезно заранее разложить SLO: например, interactive agent wake $p95 \leq 2$ s, LLM TTFT $p95 \leq 1.5$ s, tool call $p95 \leq 2$ s. Тогда видно, где оптимизация действительно заметна пользователю, а где выигрыш 50 ms растворяется в model inference.

Failure modes и troubleshooting handbook

Диагностика идёт снизу вверх: infrastructure → runtime → AX control plane → runner/workspace → tools/model → agent logic. Ниже - рабочая матрица, которую стоит адаптировать под конкретный deployment.

Симптом	Слой	Что проверить первым	Типичные причины
Task не создаётся	AX API	ax apply , server logs, schema	invalid name/spec, missing ref
Task долго Pending	AX/Substrate	controller events, Actor status	no eligible Worker, reconcile backlog
Actor не resume	Substrate	WorkerPool, snapshot, atele	no capacity, incompatible/ broken snapshot
WorkspaceReady=False	Runner	runner logs, /readyz	Git/MCP/goal bootstrap failed
WorkspaceReady=True, файлов нет	Runner	filesystem + Git exit	silent bootstrap error/version bug
Task Running, агент умер	Runner/app	ps , custom app metric	child exited, PID1 runner жив
ax ssh не работает	debug/ network	spec.debug , routing	debug off, CLI bug, guest service unreachable
TLS egress ломается	Gateway/ atenet	DNS/TCP/TLS probes	policy translation/SNI/hostname issue
Model timeout	inference/ network	server queue, TTFT, GPU	saturation, oversized context, egress
GPU OOM	inference	KV/weights/batch	context/concurrency too high
Suspend медленный	Substrate/ storage	snapshot size/ bandwidth	dirty memory/files, object store
Resume cold	Substrate/ storage	cache/locality	remote snapshot/image pull
Child Tasks множатся	harness	spawn events/budget	retry without idempotency, no depth limit
Write action повторён	tool layer	action journal/ idempotency	timeout after side effect

Командный порядок

1. Зафиксировать exact versions и timestamps.
2. `kubectl get pods -A / events / node pressure`.
3. Проверить AX server/controller health/logs и Redis reachability.
4. Проверить Actor/WorkerPool status и Substrate components.
5. Проверить runner health/readiness и actual child process.
6. Positive/negative egress probes из sandbox.
7. Model endpoint latency independently.
8. MCP endpoint independently с той же identity/policy.
9. Только после этого анализировать agent prompt/loop.

Не доверять одному status


Current AX issues показывают полезный принцип: control-plane condition может отражать «шаг reconciliation завершён», а не end-to-end truth. `Ready=True` не доказывает живой child command; `GatewayReady=True` не доказывает успешный TLS к allowlisted host. Верификация должна соответствовать пользовательскому outcome.

Источники и дальнейшее чтение

- [AX issue #346](#)
- [AX issue #345](#)
- [AX issue #347](#)
- [AX issues](#)

Когда АХ нужен, а когда проще другой инструмент

Когда АХ является разумным кандидатом, а когда это избыточный слой



АХ разумно оценивать по workload properties, а не по моде на agents.

Сильные сигналы в пользу АХ/Substrate

- Много логических agents, значительная часть времени idle.
- Нужна изоляция untrusted/generated code.
- Workspace/state должны переживать паузы.
- Желательны suspend/resume и reclaim physical capacity.
- Нужен единый declarative lifecycle для heterogeneous agent images.
- Task population и churn выходят за удобную модель «один Pod/Job на всё».

Когда обычный Kubernetes Job лучше

Если workload stateless, запускается, делает deterministic batch и завершает работу, Job проще. Он интегрирован с Kubernetes auth/observability и не требует дополнительного control plane.

Когда worker queue лучше

Если code trusted, tasks короткие, state хранится в DB, а изоляция не нужна, Celery/RQ/custom workers или message queue могут быть намного дешевле операционно.

Когда Temporal/workflow engine лучше

Если главная сложность - durable business workflow, timers, retries и exactly-tracked transitions, а execution code trusted, workflow engine часто естественнее. АХ можно комбинировать с ним: workflow engine решает business orchestration, АХ - sandboxed agent execution.

Когда LangGraph/AutoGen/CrewAI уместны

Они находятся ближе к agent logic/harness. Их можно запускать **внутри** АХ Task. Сравнивать «АХ vs LangGraph» как взаимоисключающие продукты некорректно.

Ray

Ray решает distributed compute/scheduling и actors в другом смысле. Он может быть хорош для parallel Python/ML workloads, но security/sandbox/suspend semantics и agent-specific primitives отличаются. Выбор зависит от dominant problem.

Главный принцип: сначала используйте самый простой runtime, который удовлетворяет threat model, state и scaling requirements. Дополнительный control plane должен окупать собственную сложность.

Антипаттерны

Один гигантский агент

Один process с доступом ко всем tools и credentials удобен для demo, но создаёт огромный blast radius, context pollution и плохую диагностику. Разделяйте роли там, где различаются authority или context.

Agent вместо deterministic logic

Не просите LLM считать CIDR, проверять обязательный формат или решать, выполнен ли health check, если это можно сделать кодом. LLM полезна для неоднозначного reasoning; deterministic constraints должны исполняться deterministically.

State только в prompt

После context compaction/restart состояние исчезнет или исказится. Critical progression фиксируется в durable structured state.

Unlimited retries

Retry без классификации error создаёт loops и дублирует side effects. Нужны limits, exponential backoff и idempotency.

Shared root credentials

Один token на всех agents уничтожает возможность least privilege/audit. Используйте scoped/short-lived identity.

`egress: *` навсегда

Wildcard удобен на первом smoke test и опасен как постоянная production policy. Сначала измерьте реальные destinations, затем сузьте allowlist и добавьте отрицательные probes.

Debug всегда включён

`spec.debug` расширяет control surface внутри sandbox. Включайте только там, где есть операционная необходимость.

Task per thought

Создание Task на каждый reasoning step превращает control plane в дорогую шину сообщений. Task boundary должна соответствовать isolation/resource/lifecycle boundary.

Snapshot как backup


Snapshot оптимизирует resume; он не заменяет backup authoritative state. Особенно это верно для внешних systems и Tag lifetime.

Benchmark на одном пустом actor

Результат не переносится на real workspace, dirty memory, large snapshots и concurrent bursts. Benchmark должен репрезентировать production distribution.

Практикум: 14 последовательных лабораторных работ

Базовый учебный стенд: один VM, воспроизводимый путь до работающего AX



Ниже - маршрут от чистой VM до двух multi-agent systems. Команды намеренно ориентированы на понимание процесса; exact flags текущего релиза необходимо сверить с pinned README/release notes перед запуском.

Lab 1. Подготовка VM

Создайте Debian 13 или Ubuntu LTS VM в Proxmox. Включите достаточные CPU/RAM/disk, NTP и nested virtualization, если хотите microVM. Проверьте `virt-host-validate //dev/kvm` по необходимости. Установите Docker, Git, Go версии, требуемой pinned AX/Substrate, `kubectl`, `ko`.

Результат: чистый snapshot VM `ax-lab-base`.

Lab 2. Kind и Kubernetes minimum

Создайте Kind cluster. Отработайте `kubectl get nodes`, `get pods -A`, `describe`, `logs`, `exec`, Service/DNS, Secret, readiness probe. Намеренно сломайте image и readiness, чтобы увидеть events.

Lab 3. Agent Substrate quickstart

Используйте pinned release scripts `hack/create-kind-cluster.sh` и `hack/install-ate-kind.sh --deploy-ate-system ...`. Убедитесь, что поднялись control components, PostgreSQL и RustFS. Установите `kubectl-ate` подходящей версии.

Lab 4. Actor lifecycle

Создайте WorkerPool, ActorTemplate, Actor. Наблюдайте transition `suspended/running`, `assignment` и `component logs`. Цель - руками увидеть, что Actor identity не равна Pod identity.

Lab 5. Snapshot/resume

Запишите state в durable directory и RAM/app state согласно demo; suspend; убедитесь, что Worker освобождён; resume на возможном другом Worker. Измерьте latency и размер snapshot. Повторите 10 раз.

Lab 6. gVisor и microVM

Сравните RuntimeClass/SandboxConfig path. Для microVM проверьте KVM/nested virtualization. Выполните одинаковую filesystem/network/process workload и зафиксируйте compatibility/performance differences. Если microVM невозможно поднять в nested lab, архитектурный эксперимент считается завершённым после проверки constraints - не маскируйте отсутствие KVM обходом security.

Lab 7. Установка AX

Checkout tag `v0.3.1`, настройте image registry, выполните deployment в `ax-system`. Проверьте Redis, server/controller components. Установите CLI той же версии, а не `@latest`.

Lab 8. Первый Task + Workspace

Создайте Workspace с небольшим Git repo и file; Task с `sleep`/простым agent command. Наблюдайте `ax watch`, `WorkspaceReady`, filesystem. Suspend/resume и убедитесь, что workspace changes сохранены, а process PID изменился.

Lab 9. Gateway

Начните с deny/явного allow. Проверьте DNS, HTTP, TLS для разрешённого и запрещённого destination из `ax ssh`. Сохраните egress проху logs. Не используйте успешный status как единственную проверку.

Lab 10. Cloud LLM

Подключите provider через безопасный secret path, доступный вашей pinned версии. Сделайте минимальный model adapter с timeout/retry и метриками tokens/TTFT. Не кладите API key literal в Task manifest.

Lab 11. CPU local inference

На отдельной VM или host поднимите pinned llama.cpp server с небольшой GGUF model. Проверьте OpenAI-compatible endpoint, concurrency 1/2/4, context 1k/4k/8k. Снимите CPU utilization, RAM и latency. Это fallback lab, который воспроизводится без GPU.

Lab 12. NVIDIA + vLLM + Qwen

На GPU host установите совместимые NVIDIA driver/CUDA/container toolkit. Запустите pinned `vLLM v0.30.0` image/server с выбранной Qwen model, начав с conservative context/concurrency. Измерьте TTFT/ITL/aggregate throughput и KV pressure. Затем увеличивайте concurrency до нарушения целевого SLO. Зафиксируйте точку saturation.

Примерный шаблон, не copy-paste для любой модели:

```
vllm serve <model-id> \
  --tensor-parallel-size 1 \
  --max-model-len <tested-context> \
  --gpu-memory-utilization <tested-value> \
  --api-key <service-key>
```

Lab 13. Software-engineering multi-agent


Coordinator создаёт Researcher/Implementer/Tester/Reviewer Tasks. Каждая роль получает отдельный policy/Workspace view. Implementer пишет только branch, Reviewer не имеет write, merge остаётся human-approved. Измерьте число Tasks, tokens и wall time против single-agent baseline.

Lab 14. Infrastructure multi-agent


Постройте pipeline Coordinator → Telemetry → Network Diagnostics → Logs/Config → Validator → Action Planner → Approval → Restricted MCP → Verification. Read-only agents работают без approval. Action tool выдаёт краткоживущую capability только на заранее согласованный объект/операцию. Verification повторно читает устройство/систему и подтверждает intended outcome.

Критерий успеха: agent не может расширить scope собственным prompt'ом и не может выполнить write до approval.

Практика: software-engineering multi-agent workflow




Практика: инфраструктурная диагностика с контролируемым изменением



Две референсные multi-agent архитектуры

Практика: инфраструктурная диагностика с контролируемым изменением



Software engineering

Coordinator отвечает за decomposition, budgets и final synthesis. Researcher анализирует issue/repository, но не пишет. Implementer получает отдельный branch. Tester выполняет tests в sandbox и возвращает machine-readable результаты. Reviewer сверяет diff с goal и security rules. Human или отдельный policy gate выполняет merge/release.

Смысл разделения - не имитация команды людей, а разные capabilities. Если всем четырём ролям дать один token с admin-доступом к GitHub, архитектура теряет большую часть security value.

Infrastructure / network operations

Этот сценарий лучше показывает production constraints. Telemetry collector собирает metrics/flows/logs. Network diagnostic agent анализирует MTR/BGP/routing state. Config analyst читает running config и change history. Validator сопоставляет независимые evidence. Planner формирует **структурированный** change request: device, commands/API, expected effect, rollback/preconditions. Approval service подтверждает exact request. Restricted MCP server выполняет только разрешённую операцию. Verification agent читает пост-состояние.

Write tool должен проверять target и arguments сам. Если approval разрешил `set local-pref 150 for policy X`, agent не должен суметь подменить target на policy Y в последнем tool call. Capability должна быть cryptographically or server-side bound to approved parameters либо пересверяться policy engine.

Rollback

Rollback - отдельный plan, а не фраза «если плохо, верни назад». Нужны pre-change snapshot/config, measurable success condition, timeout observation и deterministic reverse action. Для BGP/network change это может быть staged route-map attach/detach и проверка traffic/route table, а не LLM improvisation.

Mental models, glossary и cheatsheets

Если запомнить только десять вещей

- 1. **LLM ≠ Agent.** Модель предлагает следующий output; agent появляется из loop + state + tools.
- 2. **Agent ≠ Harness.** Harness - управляющая система вокруг reasoning.
- 3. **Harness ≠ Orchestrator.** Первый управляет шагами одного execution, второй - population/lifecycle.
- 4. **AX ≠ Substrate.** AX даёт agent-oriented declarative control plane; Substrate - actor/sandbox runtime.
- 5. **Actor ≠ Worker.** Actor - logical identity/state; Worker - physical capacity.
- 6. **Task ≠ Pod.** Task - AX abstraction, которая через Substrate в итоге использует Kubernetes resources.
- 7. **Context ≠ Memory.** Context - текущие tokens; memory/state должны иметь durable representation.
- 8. **Snapshot ≠ Backup.** Snapshot оптимизирует resume и имеет lifecycle/compatibility ограничения.
- 9. **MCP ≠ Authorization.** MCP стандартизует capability exchange; policy всё равно надо enforce.
- 10. **Ready ≠ outcome.** Control-plane readiness не доказывает, что бизнес/agent action успешен.

Мини-гlossарий

Термин	Практическое значение
Agent	цикл принятия действий вокруг модели и среды
Harness	context/tool/state/policy/retry infrastructure агента
Tool	формализованная операция с schema и side effect semantics
MCP	протокол взаимодействия agent clients с tools/resources/prompts
Skill	переиспользуемая инструкция/процедура, а не transport
Task	AX unit isolated execution
Workspace	declarative Git/files/MCP/skills environment
Gateway	AX network ingress/egress policy abstraction
Model	AX model provider/config/credential reference

Термин	Практическое значение
Actor	Substrate logical stateful instance
ActorTemplate	immutable runtime blueprint + golden snapshot root
WorkerPool	physical warm execution capacity
Worker	physical assignment target for running Actor
Snapshot	checkpoint RAM/durable data according to runtime semantics
Golden snapshot	prepared baseline used to start new Actors
Reconciliation	повторное сведение actual state к desired state
TTFT	time to first generated token
ITL	inter-token latency during decode
KV cache	attention state для active sequence

AX operational cheatsheet

```
# Используйте CLI той же версии, что control plane
ax apply -f stack.yaml
ax get tasks
ax describe task <name>
ax watch task <name>
ax suspend task <name>
ax resume task <name>
ax delete task <name>
# только при debug=true
ax ssh <name> -- ps aux
```

Kubernetes first-response cheatsheet

```
kubectl get nodes -o wide
kubectl get pods -A -o wide
kubectl get events -A --sort-by=.lastTimestamp
kubectl describe pod -n <ns> <pod>
kubectl logs -n <ns> <pod> --all-containers --tail=200
kubectl top nodes
kubectl top pods -A
```

Incident questions

- Какая exact версия AX/Substrate?
- Какой Task/Actor UID?
- Desired state принят API?
- Controller обработал событие?


- Есть подходящий Worker?
- Snapshot доступен и совместим?
- Runner `/healthz` и `/readyz`?
- Child agent process реально жив?
- Gateway пропускает DNS/TCP/TLS до нужного endpoint?
- Model server не в queue/OOM?
- MCP tool доступен с той же identity?
- Есть ли записанный side effect до retry?

Что изучать глубже отдельно

Для Kubernetes - официальные Concepts, RBAC, NetworkPolicy и kubeadm docs. Для Linux isolation - namespaces/cgroups/seccomp и gVisor architecture. Для distributed systems - idempotency, leases, consensus и transactional outbox. Для inference - vLLM/llama.cpp performance docs и GPU architecture. Для MCP - всегда сверяйте **versioned** specification, потому что протокол в 2026 существенно изменился относительно ранних материалов.

Context engineering: управление контекстом и durable state

Context engineering: finite budget is assembled, not magically remembered



Context engineering - это управление ограниченным вычислительным ресурсом

У агента нет бесконечной «памяти». В каждый запрос модели попадает конечный context window, а значит harness должен выбирать, **какие факты в него попадут сейчас**, а какие останутся во внешнем state. Практическая модель бюджета:

- P - policy/system instructions;
- S - текущий structured state задачи;
- R - retrieved evidence;
- H - недавняя история;
- T - tool results;
- O - резерв на output.

Рабочее правило: $P + S + R + H + T + O \leq C$, где C - доступное context window. Это не математическая оптимизация ради оптимизации: при переполнении harness начинает либо терять важные ограничения, либо «забывать» модель второстепенными логам и трассировками.

Что должно быть durable

В durable state стоит хранить не поток текста, а сведения, которые нужны для возобновления и аудита:

```
objective: "диагностировать потерю доступности"
constraints:
  - "write actions require approval"
known_facts:
  - source: "telemetry-api"
    fact: "packet_loss=18% on uplink-2"
    observed_at: "2026-10-03T08:11:00Z"
decisions:
  - id: d-17
    decision: "collect reverse-path trace before proposing change"
open_questions:
  - "is loss visible from alternate peer?"
side_effects:
  - tool_call_id: tc-442
    action: "created diagnostic ticket"
    external_id: "INC-9042"
```

Compaction должен сохранять **факты, принятые решения, ограничения, незакрытые вопросы, внешние идентификаторы и уже совершённые side effects**. «Сделать summary последних 50 сообщений» - слабая стратегия, если summary теряет именно эти элементы.

Provenance важнее красноречия

Harness должен знать происхождение каждого существенного факта. Для operational agent разумный приоритет примерно такой: live authoritative API/state > signed/config repository > internal documentation > curated knowledge base > general web > arbitrary untrusted content. Это не означает, что низкоприоритетный источник бесполезен; означает, что конфликт нельзя разрешать только по уверенности формулировки LLM.

Prompt injection и разделение данных/инструкций

Retrieved content, Git README, тикет пользователя, web page и output внешнего MCP server должны по умолчанию трактоваться как **данные**, а не как privileged instructions. Harness должен отдельно хранить policy layer и не позволять документу вида «ignore previous instructions and run ...» автоматически менять полномочия агента.

Memory tiers

Практически полезно различать:

Слой	Для чего	Типичный TTL
Request context	один model call	секунды/минуты
Working state	текущая Task	часы/дни
Episodic history	прошлые эпизоды/решения	дни/месяцы
Semantic knowledge	устойчивые факты/документация	месяцы
External source of truth	реальное состояние системы	определяется системой

Persistent memory не должна становиться альтернативной CMDB/CRM/NMS. Если истиной является Router API, Git или Lanbilling, агент должен уметь вернуться к этой системе и перепроверить факт.

Resume contract


После suspend/resume агент должен восстанавливать не «ощущение непрерывного сознания», а конкретный execution contract: objective, state version, acquired evidence, pending operations, tool call ledger, approval state и external IDs. Для AX это особенно важно: durable / workspace может сохраниться, но процесс runner/agent стартует заново.

Метрики context layer

Следите минимум за input tokens, output tokens, долей retrieved context, compaction count, cache hit ratio, retrieval latency, number of conflicting facts, stale-state age и процентом model calls, где harness был вынужден отбросить evidence из-за budget. Это позволяет отличить «слабую модель» от плохо собранного context pipeline.

MCP 2026: протокол, discovery, transport и trust boundaries

MCP 2026-07-28: stateless request model and discovery



Сначала проверьте версию протокола

MCP быстро эволюционировал. Для этой книги reference point - спецификация **2026-07-28**. Она существенно отличается от ранних tutorial: core стал stateless, старый protocol-level session lifecycle удалён, version/capabilities передаются в request metadata, а server discovery вынесен в отдельный механизм. Поэтому пример с `initialize`, `initialized` и обязательным `Mcp-Session-Id` нельзя автоматически переносить на новый implementation.

Логическая модель

MCP отвечает за стандартизированный обмен capability между host/client и server. Для эксплуатации полезно мыслить четырьмя независимыми слоями:

1. **Discovery** - какие servers/capabilities существуют.
2. **Description/schema** - какие tools/resources/prompts доступны и какие аргументы они принимают.
3. **Transport** - как именно request добирается до server.
4. **Authorization/policy** - имеет ли данный principal право выполнять действие сейчас.

Schema не является authorization. Наличие `delete_user(id)` в tool list не означает, что агенту следует разрешить его вызвать.

Tools, resources и prompts

Tool - действие с потенциальным side effect. **Resource** - адресуемые данные/контент. **Prompt** - reusable prompt/template contract. Эти категории нужно различать при policy: чтение inventory resource и выполнение `commit_config` требуют принципиально разной authority.

Discovery

В новой модели discovery должен позволять client определить server metadata/capabilities без старой stateful handshake. При этом self-reported metadata не следует использовать как

доказательство доверия: имя server, description или advertised capability не удостоверяют identity.

Transport и routing

При HTTP transport эксплуатационная цепочка выглядит не как «LLM вызывает MCP», а как `agent harness -> MCP client -> resolver/proxy -> authenticated HTTP/TLS -> MCP server -> target system`. На каждом переходе возможны собственные таймауты, DNS ошибки, проху policy и credential scope.

Authorization

Хороший policy layer проверяет одновременно principal, Task/tenant, tool, resource scope, arguments, time window, approval token и expected target state. Для write operation полезно связывать approval не с именем tool, а с **конкретным normalized action hash**: `tool + arguments + target + revision + expiry`.

Multi-round interactions

Протокол поддерживает сценарии, где server во время выполнения запрашивает дополнительный ввод/подтверждение. Harness обязан ограничивать такие цепочки: max rounds, timeout, cumulative budget и допустимые request types. Иначе «один tool call» становится скрытым бесконечным workflow.

Long-running work

Длительная операция должна иметь external operation/task identifier и наблюдаемый status. Не держите единственный HTTP request открытым часами, если target system предоставляет job model. Retry по timeout без idempotency key может создать дублирующий side effect.


MCP server как часть threat model

MCP server может быть ошибочным, скомпрометированным или просто возвращать untrusted content. Он не должен получать больше network/credential authority, чем требуется его назначению. Особенно опасен «универсальный admin MCP», внутри которого десятки несвязанных полномочий выдаются одному process identity.

MCP в AX Workspace

Workspace удобен как декларативная точка подключения MCP и skills, но это не отменяет network policy, secret scoping и runtime authorization. Нормальный acceptance test должен проверить: discovery, один read call, denied write without approval, allowed write with bounded approval, timeout, unavailable server, malformed output и audit correlation ID.

Безопасное выполнение tools: idempotency, approvals и attenuation полномочий



Tool call - это маленькая транзакция, а не функция модели

Для production agent полезно разделять каждый потенциально изменяющий вызов на последовательность:

proposal -> schema validation -> semantic validation -> authorization -> approval -> execution -> verification -> audit.

LLM может сформировать proposal, но не должна сама определять, что proposal авторизован.

Классы side effects

Класс	Пример	Retry policy
Pure/read	show interface	обычно безопасный retry
Idempotent write	set desired_state=X	retry с key/version
Create	создать ticket/VM	только с idempotency key
Destructive	delete/reset/reboot	explicit approval + precondition
Irreversible/external	отправка платежа/письма	strongest confirmation + ledger

Самая неприятная ситуация - **timeout after commit**: client не получил ответ и не знает, произошло действие или нет. Решение - idempotency key, external operation ID и read-after-timeout reconciliation, а не слепой повтор.

Preconditions

Write action следует привязывать к ожидаемому состоянию:

```
{
  "device": "edge-1",
  "operation": "replace_route_map",
  "expected_revision": "sha256:...",
  "desired_revision": "sha256:...",
  "approval_id": "apr-771",
  "idempotency_key": "task-91-step-8"
}
```

Если `expected_revision` уже не совпадает, агент должен вернуться в `plan/approval`, а не применять устаревшее решение.

Authority attenuation

Coordinator не должен передавать child agent полный собственный credential. При delegation выдаётся более узкий capability: меньший set tools, меньший target scope, меньший TTL, меньший budget. Каждый следующий слой может **сужать**, но не расширять authority без нового внешнего решения policy engine.

Approval должен быть связан с объектом действия

Плохой approval: «разрешаю агенту менять BGP в течение часа». Хороший: «разрешаю operation X на device Y с diff Z при current revision R, до 17:05, после чего обязательна verification V». Это превращает human-in-the-loop из психологической кнопки «ОК» в технический control.

Verification и compensation

После write читаем состояние из authoritative source и сравниваем с success condition. Rollback/compensating action готовятся **до** destructive step. У некоторых систем rollback не является inverse function, поэтому playbook должен учитывать реальные semantics target API.


Circuit breakers

Harness должен иметь per-tool rate limit, max consecutive failures, global task budget, concurrency cap и emergency deny switch. Это защищает и от hallucination loop, и от реального degraded dependency.

Audit record

Записывайте principal, Task/agent identity, normalized request, policy result, approval, idempotency key, start/end timestamps, external operation ID, result hash и verification result. Полный raw secret/token в audit попадать не должен.

Authority attenuation: child may narrow scope, never silently widen it



AX control plane: state, event flow и operational truth

Current AX control path: API and reconciliation are separable scaling domains



Почему одного API status недостаточно

В declarative control plane существует несколько разных истин: request принят API, desired state записан, event увиден controller, reconciliation выполнен, Substrate создал/возобновил Actor, runner жив, child process жив, Workspace готов, а конечная бизнес-задача действительно выполняется. Эти состояния нельзя сворачивать в один boolean Ready.

Current-main controller split

В current main AX присутствует отдельный ax-controller, использующий Redis stream consumer group и TaskReconciler с Substrate client. Это отличается от старого DESIGN.md, где reconciliation описан как обязанность ax-server. В книге release baseline и current-main delta поэтому разведены явно.

Redis как control state/event substrate

Если Redis используется для desired/status/event coordination, его persistence, eviction policy и memory pressure становятся control-plane safety issue. allkeys-lru для такого store - плохая идея: eviction control object может выглядеть как «случайная потеря Task». Production deployment должен знать, какие keys/streams durable, как устроены consumer groups и как выполняется recovery после restart.

Conditions как timeline

Pending, Running, Ready, WorkspaceReady, Suspended, Failed полезны только вместе с reason/message/transition time/generation. Operator должен видеть, **какое поколение specs** породило status, иначе старый Ready=True может быть принят за подтверждение нового изменения.

Liveness != progress

Runner может оставаться живым после выхода child command. Поэтому нужны две независимые группы сигналов:

- platform health: API/controller/Substrate/runner доступны;
- workload progress: child PID/state, heartbeat, last meaningful event, output/checkpoint age, task-specific success condition.

Progress watchdog особенно нужен автономным agent loops: process может не падать, но часами повторять одну ошибку.

Controller backlog

Наблюдайте stream lag, oldest unprocessed event age, reconcile latency p50/p95/p99, retries per object, dead-letter/error count и Substrate API latency. При росте population сначала может ломаться не sandbox capacity, а serialized reconciliation path.


Dependency updates

Workspace, Model, Gateway и Task должны иметь понятную propagation semantics. Если Task уже запущен, изменение shared object не обязательно мгновенно и безопасно менять его runtime. В production лучше использовать versioned/immutable references и deliberate rollout, чем «магическое live mutation».


Operational truth hierarchy

При инциденте идём сверху вниз: client request -> API persisted desired state -> controller event/reconcile -> Substrate Actor/Worker -> runner -> child process -> MCP/model dependency -> final external effect. Это снижает риск диагностировать LLM, когда на самом деле controller не обработал spec.

State ownership: четыре хранилища отвечают за разные истины




Readiness hierarchy: each green light proves only its own layer



Substrate snapshots: ownership, storage и совместимость

Snapshot ownership: URI lifetime matters for clones and garbage collection



Snapshot - объект с владельцем и contract, а не просто файл

Substrate связывает snapshot с Actor/Tag и ActorTemplate identity. Для external storage полезно понимать логическую структуру пути: отдельные namespaces/spaces, actor UID и snapshots, а также tag-owned copies. Storage layout - часть runtime contract, но приложение не должно напрямую модифицировать эти объекты.

Кто владеет snapshot

У Actor есть текущий snapshot, который заменяется после следующего успешного suspend. Tag может удерживать собственную копию дольше lifecycle исходного Actor. Clone, созданный из Tag, способен временно использовать borrowed snapshot до своего первого успешного suspend, после чего получает собственный state lineage.

Template compatibility

Snapshot содержит связь с ActorTemplate UID. При несовместимом template runtime может восстановить durable data, но выполнить fresh boot guest/process environment вместо полного memory resume. Это правильное поведение: восстановление RAM поверх другого runtime image может быть физически некорректным.

Dirty state и consistency

Прежде чем считать snapshot консистентным, нужно понимать, что происходило с filesystem buffers, database clients, sockets и внешними транзакциями. Memory checkpoint может зафиксировать process в момент, когда удалённая транзакция уже committed, а локальный response ещё не обработан. Поэтому external side effects всё равно требуют idempotency ledger.

Storage performance

Resume latency складывается не только из orchestration. Важны metadata lookup, object-store RTT, snapshot size, available bandwidth, decompression/page-fault strategy, worker locality и

concurrent restores. Headline «sub-second resume» нельзя превращать в universal SLO без собственного benchmark.

Integrity и encryption

Snapshot потенциально содержит secrets, plaintext tokens, retrieved data и process memory. Object storage должен обеспечивать encryption at rest, tenant isolation, integrity checking, scoped credentials и lifecycle deletion. Backup retention и snapshot retention - разные policies.

Golden snapshot


Golden snapshot должен быть максимально детерминированным: runtime packages, runner, base workspace preparation. Long-lived user secrets лучше inject после restore/start, а не bake в golden image/snapshot. Иначе rotation становится дорогой, а compromise snapshot затрагивает весь population.

Snapshot != backup

Snapshot оптимизирует runtime resume. Backup обеспечивает восстановление после потери control state/storage/cluster. Production DR должен отдельно сохранять declarative manifests, control-plane DB/Redis/PostgreSQL, object storage и внешние source-of-truth данные.

Gateway и egress: DNS, TLS и проверка реальной доступности

Gateway validation: test DNS, transport, TLS and application outcome separately



GatewayReady не означает, что приложение дошло до API

Network policy может быть syntactically valid и reconciled, но реальный connection ломается на DNS, route, TCP, TLS, SNI, proxy или application authorization. Поэтому readiness policy object - только один слой evidence.

Hostname allowlist сложнее CIDR

Hostname policy требует решить, кто резолвит имя, как долго кешируются IP, что делать с несколькими A/AAAA, CDN rotation и DNS rebinding. Если enforcement происходит на IP layer, результат DNS должен корректно и безопасно обновлять allowed destinations. Если на L7/TLS layer - нужен корректный SNI/hostname matching.

TLS chain

Минимальная диагностика из sandbox:

```
getent ahosts api.example.com
nc -vz api.example.com 443
openssl s_client -connect api.example.com:443 -servername api.example.com </dev/null
curl -sv https://api.example.com/health
```

Первые команды последовательно проверяют resolver, TCP reachability, TLS/SNI/certificate chain и HTTP/application. Это быстрее, чем сразу менять Gateway manifest.

Negative tests обязательны

После разрешения `model.internal:443` проверьте не только успешный call туда, но и отсутствие доступа к запрещённому control endpoint, metadata service, RFC1918 ranges и произвольному Internet host. Security acceptance test должен доказывать и allow, и deny.

Dependencies надо инвентаризировать

Agent image может обращаться не только к model API: Git, package mirrors, OAuth/OIDC, MCP servers, DNS, NTP, artifact registry, telemetry collector. Runtime package installation в production Task часто превращает tight egress policy в allow-all. Лучше собирать immutable images заранее.

MCP gateway


Для большого числа external MCP/API endpoints полезен controlled egress proxy/gateway: central auth, destination allowlist, rate limits, audit, DLP и credential brokering. Тогда sandbox знает только один restricted endpoint, а не получает десятки raw secrets.

Incident flow

Проверяйте: Gateway desired/status -> DNS result -> policy target -> route -> TCP -> TLS/SNI -> HTTP -> application auth -> MCP/model protocol. AX issue с hostname Gateway/TLS на ранней версии - хороший пример того, почему каждый слой нужно тестировать отдельно.

Local inference sizing: память GPU, parallelism и эксплуатационные SLO

Tensor parallelism: extra GPUs add communication, not just VRAM



VRAM - это не только веса модели

Приближённый бюджет GPU memory состоит из: weights + KV cache + activations/workspaces + CUDA/runtime allocations + fragmentation/reserve. Поэтому модель, чьи quantized weights «влезает в 24 GB», ещё не гарантирует нормальный serving при длинном context и concurrency.

KV cache зависит от workload

KV pressure растёт с количеством одновременно активных sequences и их фактической длиной context. Для sizing собирайте распределение input/output tokens, а не один `max_model_len`. Если 99% запросов имеют 4k tokens, резервировать поведение как при 128k для каждого slot может быть слишком дорого.

Tensor parallelism

Tensor parallel делит вычисления слоя между GPU и требует collective communication практически на каждом decode step. На NVLink/NVSwitch это одна экономика, на PCIe - другая. Добавление второй GPU может быть необходимо для capacity, но не обязано удваивать tokens/s и иногда ухудшает latency для небольшой модели.

Pipeline и data parallel

Pipeline parallel полезен, когда модель не помещается на одном устройстве/TP domain, но вводит bubbles и complexity. Data parallel/replicas часто проще для независимых запросов, если модель целиком помещается на одной GPU. Выбор определяется model fit, topology и SLO.

CPU fallback

llama.cpp/GGUF позволяет построить воспроизводимый CPU-only lab и аварийный low-throughput path. Но CPU fallback не следует считать равнозначным GPU production endpoint: TTFT и decode latency могут изменить поведение timeouts всего agent harness.

vLLM knobs

Memory utilization, max model length, max concurrent sequences, batching/scheduling и parallelism flags должны документироваться **по конкретной версии vLLM**. Не копируйте tuning command из старой статьи без сверки `--help` и release docs.

OpenAI-compatible != identical

Совместимость endpoint означает похожий API surface, но не гарантирует одинаковые параметры, tool-call semantics, structured output, token accounting или error codes. Model adapter должен иметь provider-specific capability tests.


SLO сначала, GPU потом

Для agent platform определите: допустимый TTFT, p95 end-to-end model latency, target concurrent active generations, peak prompt tokens/s, output tokens/s, max queue delay и availability. Только после этого выбираются model size, quantization и GPU topology.

Интеграция с АХ

Model endpoint лучше предоставлять через стабильный internal service URL. Agent Task не должен знать физический GPU host. Observability связывает Task/Actor ID с inference request ID, чтобы можно было отличить «агент завис» от «10 секунд стоял в model queue».

Production security, secrets и disaster recovery



Классифицируйте secrets по назначению

Разделяйте control-plane credentials, model API keys, MCP/service credentials, registry pull secrets, user delegated tokens и infrastructure admin secrets. Один универсальный secret для всех Tasks уничтожает tenant isolation.

Injection time имеет значение

Статический secret в image - худший вариант. Лучше short-lived credential при start/resume или on-demand exchange через broker/проxy. Тогда suspend длительностью сутки не означает, что проснувшийся agent продолжит использовать credential, срок/полномочия которого уже изменились.

Rotation после resume

Harness должен предполагать, что credential после длительного сна истёк. Resume path включает refresh/re-auth, а не только повтор старого request. Ошибка 401 после resume должна маршрутизироваться в credential recovery, а не в бесконечный LLM retry.

Tenant boundary

Namespace сам по себе не является полной multi-tenant security boundary. Нужны RBAC, service accounts/workload identity, NetworkPolicy/egress, sandbox isolation, secret scope, storage isolation и audit. Для hostile code выбирается более сильный sandbox class.

Что резервировать

Минимальный backup set: pinned manifests/Helm values, AX control state, Substrate dynamic state database, snapshot/object storage, PKI/identity configuration, registry references и external system mappings. Git repositories и CRM/CMDB могут быть отдельными authoritative systems и не дублироваться без необходимости.

RPO/RTO по слоям

Не задавайте одно RPO «для AX». Desired manifests могут иметь RPO почти ноль в Git, Redis/PostgreSQL - минуты, snapshots - часы, transient logs - вообще не восстанавливаться. RTO control plane и RTO каждого dormant Actor также разные.

Recovery order

Типовой порядок: identity/PKI -> Kubernetes core -> durable DB/object storage -> Substrate control plane -> WorkerPools -> AX state/control plane -> model/MCP dependencies -> workload resume. Если начать поднимать Actors до восстановления policy/identity, можно получить функционально работающую, но небезопасную систему.

External side effects не откатываются из backup


Восстановление Task к старому checkpoint не отменит уже созданный тикет, отправленное письмо или применённую сетевую конфигурацию. Поэтому ledger external actions и idempotency keys должны переживать disaster recovery.

DR drills

Проверяйте как минимум: loss одного worker, loss Kubernetes node, restart Redis/PostgreSQL, temporary object-store outage, restore control plane в новый cluster, недоступный model endpoint и восстановление task state при уже совершённом external action.

Operations runbook: диагностика по слоям и release acceptance

Troubleshooting ladder: идите от физического слоя к agent logic



Не начинайте инцидент с restart всего кластера

Сначала сохраните evidence: Task manifest/status, generation/conditions, controller lag/logs, Actor/Worker assignment, runner health, child process state, Gateway/DNS test, model request ID, MCP call ID и последние внешние side effects. Restart может удалить самую полезную информацию.

Слой 1 - Kubernetes/infrastructure

```
kubectl get nodes -o wide
kubectl get pods -A -o wide
kubectl get events -A --sort-by=.lastTimestamp
kubectl top nodes
kubectl top pods -A
```

Проверяем pressure, scheduling, image pulls, storage/network и crash loops.

Слой 2 - Substrate

Проверяем WorkerPool capacity, Actor phase/assignment, snapshot URI/compatibility, resume errors, object-store reachability и atele/atecontroller logs. Если Actor не получил Worker, AX runner ещё вообще не участвует в проблеме.

Слой 3 - AX

Сверяем desired Task generation, controller reconcile/error/backlog, referenced Workspace/Model/Gateway, conditions и suspend/resume transition. Current-main split `ax-server/ax-controller` означает, что API может быть доступен при сломанном reconciliation.

Слой 4 - runner/workload

`/healthz` отвечает на вопрос о runner, `/readyz` - о readiness contract, но отдельно проверяется child process и task-specific progress heartbeat. Из debug Task полезны `ps`, environment metadata, `/workspace` contents и DNS/network probes.

Слой 5 - MCP/network/model

Проверяем DNS -> TCP -> TLS -> HTTP/protocol; затем auth, rate limit и server-side operation status. Для inference сравниваем queue time, TTFT, decode throughput, KV/VRAM pressure и OOM/eviction events.

Слой 6 - agent logic

Только после инфраструктурных проверок анализируем prompt/context, tool schema, retry loop, planning и memory. Это предотвращает типичную ошибку: «тюнинг prompt», когда MCP endpoint просто не резолвится.

Failure taxonomy

Используйте категории: desired-state admission, reconciliation, placement/capacity, restore/snapshot, runner/bootstrap, dependency/network, inference, tool authorization, external side effect, agent reasoning. Incident tag по слою облегчает статистику повторяемости.

Release acceptance suite

Перед обновлением AX/Substrate прогоните pinned набор: create simple Task; Workspace Git bootstrap; MCP read; denied write; approved idempotent write + verification; suspend/resume with durable file; worker loss; forbidden egress; model call; child-process exit; snapshot restore; backup/restore control state. Результаты сохраняйте вместе с exact versions/commits.

Post-incident

Фиксируйте timeline, root layer, detection gap, unsafe retry/approval opportunities, lost observability и конкретный regression test. Для быстро меняющегося pre-1.0 stack regression suite важнее предположения «minor update ничего не ломает».

Приложение А. Аудит проектов и выявленные расхождения

A.1 AX

Release baseline: v0.3.1, commit e70162a, release 25.09.2026.

Current API family: ax.io/v1alpha1.

Stability: project explicitly warns about breaking changes before stable.

Ключевые факты current documentation/source audit:

- README описывает четыре user primitives: Task, Workspace, Gateway, Model.
- docs/manifests.md в current crawl говорит «all four kinds», но видимая часть документа подробно показывает Task/Workspace/Model; Gateway лучше проверять по README/examples/API, а не по одной странице.
- cmd/ax-controller существует и читает Redis stream consumer group, создавая TaskReconciler с Substrate client.
- DESIGN.md всё ещё описывает reconciliation внутри ax-server. Это documentation drift.
- Runner всегда PID 1 и restart после resume видит durable /workspace, но новое process tree.
- Current known issues показывают полезные ограничения: readiness может не отражать exit child command; workspace clone мог завершаться «успешно» при пустом repo; hostname Gateway/TLS имел bug; ssh/control-plane auth вопросы меняются.

Вывод: production runbook должен ссылаться на pinned release и regression tests, а не только на main docs.

A.2 Agent Substrate

Release baseline: v0.3.0, commit ccecc78, release 30.09.2026.

Status: pre-1.0; API compatibility не гарантирована.

Ключевые факты:

- Quickstart использует Kind и может разворачивать PostgreSQL/RustFS локально.
- WorkerPool - Kubernetes-side physical capacity; ActorTemplate/Actor/Worker dynamic state относится к Substrate API/state store.
- Current architecture использует PostgreSQL для dynamic control state и object storage для snapshots.
- gVisor и microVM - разные sandbox classes.
- Golden snapshot и Tag ownership - важная часть clone/resume semantics.
- Architecture document содержит прямое предупреждение, что часть design aspirational.

- v0.2.0/v0.3.0 быстро усиливали multi-actor networking, egress, identity, authorization/observability, поэтому старые статьи быстро устаревают.

A.3 MCP

Для книги принята specification 2026-07-28, потому что она меняет базовый mental model: stateless core, server/discover, request metadata versioning, новый subscription mechanism и изменения authorization/deprecations. Материалы 2024-2025 про обязательный initialize/session flow нужно читать как legacy compatibility, а не current normative behavior.

Приложение B. Production readiness checklist

Platform

- ☐ AX/Substrate/container images pinned по digest/tag.
- ☐ Compatibility matrix проверена в staging.
- ☐ Redis/PostgreSQL persistence и backup протестированы restore drill'ом.
- ☐ Object storage durability/throughput/retention проверены.
- ☐ WorkerPool headroom измерен burst benchmark'ом.
- ☐ Registry и DNS имеют понятные failure modes.

Security

- ☐ Default-deny egress; wildcard отсутствует вне исключений.
- ☐ Debug/SSH disabled by default.
- ☐ Scoped short-lived tool credentials.
- ☐ MCP servers/skills/repositories проходят allowlist/review.
- ☐ Write/destructive tools требуют policy/approval.
- ☐ Sandbox backend выбран по threat model.
- ☐ Control-plane API закрыт perimeter/authn/authz.
- ☐ Audit logs нельзя изменить workload'у.

Agent

- ☐ Max steps/tokens/wall time заданы.
- ☐ Retry limits и idempotency strategy заданы.
- ☐ Durable state не существует только в prompt/RAM.
- ☐ Child task depth/count budget задан.
- ☐ Tool calls имеют schema validation.
- ☐ Post-action verification есть для writes.

Observability

- ☐ Trace связывает user/job → Task → Actor → tool/model request.
- ☐ TTFT/ITL/queue/KV metrics собираются.
- ☐ Suspend/resume/snapshot metrics собираются.
- ☐ Central logs переживают Worker relocation.
- ☐ Alerts основаны на SLO, а не только CPU.

Приложение С. Карта источников

Основные первичные источники, использованные для аудита:

1. Google AX repository: <https://github.com/google/ax>
2. AX README: <https://github.com/google/ax/blob/main/README.md>
3. AX DESIGN: <https://github.com/google/ax/blob/main/DESIGN.md>
4. AX concepts: <https://github.com/google/ax/blob/main/docs/concepts.md>
5. AX manifests: <https://github.com/google/ax/blob/main/docs/manifests.md>
6. AX runner: <https://github.com/google/ax/blob/main/docs/runner.md>
7. AX roadmap: <https://github.com/google/ax/blob/main/docs/roadmap.md>
8. AX current controller source: <https://github.com/google/ax/blob/main/cmd/ax-controller/main.go>
9. AX issues: <https://github.com/google/ax/issues>
10. Agent Substrate repository: <https://github.com/agent-substrate/substrate>
11. Substrate architecture: <https://github.com/agent-substrate/substrate/blob/main/docs/architecture.md>
12. Substrate API guide: <https://github.com/agent-substrate/substrate/blob/main/docs/api-guide.md>

13. Substrate observability: <https://github.com/agent-substrate/substrate/blob/main/docs/observability.md>
14. Substrate threat model: <https://github.com/agent-substrate/substrate/blob/main/docs/threat-model.md>
15. Kubernetes Concepts: <https://kubernetes.io/docs/concepts/>
16. Kubernetes Custom Resources: <https://kubernetes.io/docs/concepts/extend-kubernetes/api-extension/custom-resources/>
17. gVisor: <https://gvisor.dev/docs/>
18. MCP specification 2026-07-28: <https://modelcontextprotocol.io/specification/2026-07-28>
19. MCP release notes: <https://blog.modelcontextprotocol.io/posts/2026-07-28/>
20. vLLM docs: <https://docs.vllm.ai/>
21. vLLM releases: <https://github.com/vllm-project/vllm/releases>
22. llama.cpp: <https://github.com/ggml-org/llama.cpp>
23. Kind: <https://kind.sigs.k8s.io/>
24. K3s: <https://docs.k3s.io/>
25. kubeadm: <https://kubernetes.io/docs/setup/production-environment/tools/kubeadm/>

Веб-документация была проверена 03.10.2026. Для быстро меняющихся `main` страниц это дата среза, а не гарантия неизменности.